FREUDENBERG
INNOVATING TOGETHER

DHBW
Duale Hochschule
Baden-Württemberg
Mannheim

Duale Hochschule Baden-Württemberg Mannheim

Projektarbeit 2

Einsatz von LLMs zur Unterstützung von Stichprobenanalysen im Audit-Bereich. Ein Vergleich verschiedener KI-Modelle hinsichtlich ihrer Eignung für interne Prüfungsprozesse bei der Freudenberg Group

Studiengang Wirtschaftsinformatik

Studienrichtung Data Science und Künstliche Intelligenz

Verfasser(in):	Leonard Verclas
Matrikelnummer:	3317974
Firma:	Freudenberg & Co. Kommanditgesellschaft
Kurs:	WDSKI24B
Studiengangsleiter:	Prof. Dr. Bernhard Drabant
Wissenschaftliche(r) Betreuer(in):	Stefanie Bell
Firmenbetreuer(in):	Andreas Hass
Bearbeitungszeitraum:	03.08.2026 - 09.11.2026

Todo list

Text Kapitel 4 . . . 2

Text Grundlagen und Kapitel 3 . . . 2

vllt. zu hypotethisch -> wie ght er über reine Compliance-Aspekte hinaus? . . . 3

Hier zum Einstieg noch mehr Kontext. Das internal Audit hat verschiedene Methoden. ua Stichproben -> rechnungen aber auch user benutzeranlegen etc. . . . 4

auch wieder sehr mystisch: mitteleinsatz prüfungseffizienz etwas menschlicher einfacherer ausführen . . . 4

noch durchgehe, quellen etc .-> siehe copilot chat . . . 5

noch besser erklären . . . 9

so rihcitg zitiert oder zusammenfassen? . . . 9

Freudenberg einheitlich benennen: Freudenberg Gruppe vs. Freudenberg & Co. (FCo), Internal Audit vs. Corporate Audit . . . 14

Quelle? ansonsten auch David . . . 16

genaue Zahlen begründen: 100 Rechnungen, 24 %, 24 Fehler, Verteilung 6, 5, 4, 4, 3, 2 . . . 16

wissenschaftlich begründen, warum diese Kriterien . . . 20

festgelegte Regel für richtige Markierung mit falschem Grund nennen, z. B. Wertung als FN . . . 25

ggf. zusätzlich Fleiss' Kappa über die Durchläufe . . . 26

Anzahl betroffener Rechnungen und Umgang damit in der Auswertung, z. B. Ausschluss oder Wertung als Fehler . . . 26

auffällige Unterschiede zwischen Precision und Recall beschreiben, z. B. ob ein Modell eher zu viele oder zu wenige Exceptions meldet . . . 26

Datengrundlage für Benutzerberechtigungen kurz nennen: Anzahl Fälle, Anzahl Exceptions laut Ground Truth, was als Exception gilt . . . 27

Ergebnisse beschreiben, Unterschiede zum Anwendungsfall Rechnungen benennen . . . 27

festlegen, ob über alle Fälle gemeinsam gerechnet wird (Micro) oder der Mittelwert beider Anwendungsfälle gebildet wird (Macro), und kurz begründen . . . 27

Umrechnungsregel nennen . . . 27

Ergebnis, bleibt die Rangfolge stabil? 27

Stärken und Schwächen je Modell in wenigen Sätzen gegenüberstellen, z. B. hohe Precision bei geringerer Konsistenz 28

z. B. Abweichung zwischen messbaren Kennzahlen und Einschätzung der Senior Auditoren 28

Ergebnisse interpretieren und mit dem Stand der Forschung aus Kapitel [XX] abgleichen. Mögliche Leitfragen: Decken sich die Ergebnisse mit bisherigen Studien? Welche Fehlerarten treten bei allen Modellen auf? 28

wichtigste Unterscheidungsmerkmale, z. B. Erkennungsrate, Konsistenz 28

Einschränken, in welcher Rolle, z. B. als Unterstützung bei der Vorprüfung, wobei die abschließende Bewertung weiterhin durch Auditoren erfolgt. 28

1. Erstellen von fehlerhaften Rechnungen und Tickets (Orientierung an historischen Auditfällen)
2. Modelle analysieren Dokumente
3. Anwendung der Bewertungsmatrix
4. Punktesystem auf Bewertungsmatrix anwenden
5. Auswertung der Ergebnisse
6. Zusätzlich: Modelle auf historische Ereignisse prüfen, bzw. historische Ereignisse nochmals auf Fehler überprüfen

Stichprobenrisiko erklärt: (vgl. Baumeister 2019, S.12) und detailliert S. 40 ff.

herausforderungen und möglichkeiten künstlicher Intelligenz im Auditbereich:

Möglichkeiten:

Große datenmengen anstelle von stichproben durch schnellere Bearbeitung. Herausfiltern von wichitgen Kennzahlen, wie kosten, vertragspartner etc. -> Pflichtproben herausfiltern, die menschliche oder maschinelle Prüfung benötigen. (vgl. (Kokina et al. 2025, S.3))

Anomalieerkennung -> z.b. finanzielle Informationen (vgl. (Kokina et al. 2025, S.2))

Herausforderungen:

Transparenz und Erklärbeitkeit - Auditoren und Regulatoren müssen verstehen können, warum wurde eine Entscheidung getroffen, wie ist ein Ergebnis zustande gekommen? (Kokina et al. 2025, S.16)

Robustheit und Zuverlässigkeit - Es muss nachweisbar sein, dass die Ergebnisse reproduzierbar sind, das Modlele stabil arbeiten und kein Model drift stattfindet (Kokina et al. 2025, S. 13 f.)

Übermäßiges Vertrauen an die KI - Auditoren müssen Ergebnisse immernoch professional skeptisch auditieren. Die Ki darf nur als Unterstützer gelten. Die finale Entscheidung bleibt beim Auditor. Durch den Einsatz von KI kann es hier zu AutomationBias führen. Hierbei kann es dazu kommen, dass Auditoren Fehler übersehen, weil das System keine gemeldet hat. (Lyell und Coiera 2017, S.425 f.)

Inhaltsverzeichnis

Abbildungsverzeichnis vi

Tabellenverzeichnis vii

Quelltextverzeichnis viii

Abkürzungsverzeichnis ix

Kurzfassung (Abstract) x

1 Einleitung 1
- 1.1 Problemstellung & Motivation der Arbeit . . . 1
- 1.2 Zielsetzung der Arbeit . . . 1
- 1.3 Aufbau der Arbeit . . . 2

2 Grundlagen 3
- 2.1 Internal Audit . . . 3
- 2.2 Stichprobenanalyse im Internal Audit . . . 4
- 2.3 Künstliche Intelligenz . . . 4
  - 2.3.1 Large Language Models . . . 4
  - 2.3.2 Prompt Engineering . . . 4
- 2.4 Einsatz von Künstlicher Intelligenz im Audit . . . 4
  - 2.4.1 Potenziale in der Stichprobenanalyse . . . 5
  - 2.4.2 Risiken in der Stichprobenanalyse . . . 5

3 State of the Art 6
- 3.1 Aktuelle Durchführung von Stichprobenanalysen bei Freudenberg . . . 6
- 3.2 Einsatz von KI im Auditbereich . . . 7
- 3.3 Verfügbare KI-Lösungen für den Auditbereich . . . 8
  - 3.3.1 Kommerzielle Lösungen . . . 8
  - 3.3.2 Open-Source-Lösungen . . . 9
  - 3.3.3 Spezialisierte KI-gestützte Audit-Lösungen . . . 10
- 3.4 Chatnutzung und KI-Agenten . . . 10
- 3.5 Einordnung des KI-Einsatzes bei Freudenberg . . . 11

4 Evaluationsdesign 13
- 4.1 Forschungsdesign . . . 13

4.2 Wahl der Untersuchungsumgebung . . . 13
4.3 Auswahl der zu untersuchenden Modelle . . . 14
4.4 Entwicklung der Testdatensätze . . . 15
4.5 Entwicklung eines geeigneten Prompts . . . 17
4.6 Nutzwertanalyse . . . 19
4.7 Entwicklung einer Bewertungsmatrix . . . 20
4.8 Gewichtung der Bewertungsmatrix . . . 23

5 Evaluationsdurchführung 25
5.1 Durchführung der Tests . . . 25
5.2 Ergebnisse der Stichprobenanalysen . . . 26
5.2.1 Rechnungen . . . 26
5.2.2 Benutzerberechtigungen . . . 27
5.2.3 Gesamtvergleich . . . 27
5.3 Auswertung der Bewertungsmatrix . . . 27
5.4 Vergleich der Modelle . . . 28
5.5 Analyse der Ergebnisse . . . 28
5.6 Beantwortung der Forschungsfrage . . . 28

6 Fazit und Ausblick 29
6.1 Zusammenfassung der wichtigsten Erkenntnisse . . . 29
6.2 Fazit zur Eignung von LLMs im Audit . . . 29
6.3 Handlungsempfehlungen für Freudenberg . . . 29
6.4 Zukünfige Entwicklungspotenziale . . . 29

Anhang

A Prompts 30

Literatur 31

Abbildungsverzeichnis

Tabellenverzeichnis

4.1 Verteilung der eingebauten Fehler auf die Fehlergruppen 16
4.2 Gewichtung der Bewertungsmatrix 23

5.1 Konfusionswerte je Modell für den Anwendungsfall Rechnungen 26
5.2 Kennzahlen je Modell für den Anwendungsfall Rechnungen 27
5.3 Kennzahlen je Modell für den Anwendungsfall Benutzerberechtigungen . . 27
5.4 Gesamtvergleich der Modelle über beide Anwendungsfälle 27
5.5 Bewertungsmatrix der Nutzwertanalyse 28

Quelltextverzeichnis

Abkürzungsverzeichnis

DHBW	Duale Hochschule Baden-Württemberg
LLM	Large Language Model
KI	Künstliche Intelligenz
FCo	Freudenberg & Co.

Kurzfassung (Abstract)

1 Einleitung

1.1 Problemstellung & Motivation der Arbeit

Mit der fortschreitenden Entwicklung Künstliche Intelligenz (KI) stehen Unternehmen vor der Herausforderung, ihre Geschäftsprozesse kontinuierlich zu optimieren und durch den gezielten Einsatz neuer Technologien effizienter zu gestalten. Insbesondere im Audit-Umfeld bietet der Einsatz von KI ein erhebliches Potenzial zur Steigerung von Effizienz, Prüfungsqualität und Transparenz. KI unterstützt interne Auditoren, indem der manuelle Analyseaufwand reduziert wird und umfassendere sowie schnellere Prüfungen ermöglicht werden. (vgl. Wassie und Lakatos 2024, S. 11–12).

Ein besonders vielversprechendes Anwendungsfeld stellt die Analyse von Audit-Stichproben dar. Im Rahmen dieser Prüfungen werden zum Beispiel Rechnungen untersucht, um Auffälligkeiten, Regelverstöße oder potenzielle Risiken zu identifizieren. Die manuelle Analyse dieser Unterlagen ist jedoch zeitaufwendig und bindet erhebliche personelle Ressourcen. Gleichzeitig steigt aufgrund wachsender Datenmengen und zunehmend komplexer Geschäftsprozesse die Schwierigkeit, relevante Auffälligkeiten zuverlässig zu erkennen.

Vor diesem Hintergrund gewinnt die Unterstützung von Stichprobenanalysen durch KI-basierte Verfahren zunehmend an Bedeutung. Für die Freudenberg-Gruppe stellt sich dabei die Frage, wie KI-Technologien gewinnbringend in die Stichprobenanalyse im Internal-Audit-Prozess integriert werden können. Neben der Verbesserung der Effizienz und Prüfungsqualität durch den Einsatz von KI spielt insbesondere die Einhaltung strenger Datenschutz- und Compliance-Anforderungen sowie die Auswahl eines geeigneten KI-Modells für die Analyse von Audit-Dokumenten eine zentrale Rolle. Daraus ergibt sich die Notwendigkeit, die Eignung verschiedener KI-Lösungen für die Unterstützung von Stichprobenanalysen im Internal Audit systematisch zu untersuchen.

1.2 Zielsetzung der Arbeit

Ziel dieser Projektarbeit ist die systematische Untersuchung und Bewertung verschiedener KI-gestützter Werkzeuge zur Unterstützung von Stichprobenanalysen im Internal Audit

der Freudenberg-Gruppe. Der Fokus liegt dabei auf Large Language Models (LLMs), die Auditoren bei der Analyse von Prüfungsdokumenten unterstützen können. Hierzu werden ausgewählte LLMs auf identische Audit-Stichproben angewendet. Die Modelle sollen potenzielle Auffälligkeiten, Risiken oder Regelverstöße in Rechnungen identifizieren sowie ihre Bewertungen nachvollziehbar begründen. Anschließend werden die Ergebnisse anhand einer Bewertungsmatrix miteinander verglichen. Dabei stehen insbesondere die Erkennungsqualität, die Nachvollziehbarkeit der Ergebnisse, die Konsistenz der Analysen sowie die praktische Einsetzbarkeit im Audit-Umfeld im Vordergrund. Auf Basis dieser Untersuchung soll ermittelt werden, welches KI-Modell die Anforderungen der Freudenberg-Gruppe im Kontext von Stichprobenanalysen im Internal Audit am besten erfüllt. Die gewonnenen Erkenntnisse sollen eine fundierte Grundlage für die Bewertung des Potenzials von LLMs im Audit-Bereich sowie für deren zukünftigen Einsatz innerhalb der Organisation schaffen. Daraus ergibt sich folgende Forschungsfrage: Wie unterscheiden sich verschiedene Large Language Models hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit-Bereich?

1.3 Aufbau der Arbeit

Text Kapitel 4

Text Grund-lagen und Kapitel 3

2 Grundlagen

2.1 Internal Audit

Das Internal Audit stellt eine unabhängige und objektive Prüfungs- und Beratungsfunktion innerhalb einer Organisation dar. Die zentrale Aufgabe besteht darin, die Angemessenheit und Wirksamkeit von Governance-, Risikomanagement- und internen Kontrollsystemen zu bewerten sowie durch unabhängige Prüfungs- und Beratungsleistungen zur Verbesserung dieser Systeme beizutragen. Im Gegensatz zu externen Audits ist das Internal Audit organisatorisch in das Unternehmen eingebunden, wobei seine Unabhängigkeit durch geeignete Governance-Strukturen sichergestellt wird (vgl. The Institute of Internal Auditors 2024, S.15-16). Als Bestandteil des Internen Kontrollsystems unterstüzt das Internal Audit die Organisation dabei, ihre strategischen und operativen Ziele wirksam und regelkonform zu erreichen. Dabei überprüft es bestehende Prozesse, identifiziert Risiken und bewertet die Wirksamkeit implementierter Kontrollmaßnahmen (vgl. Cantù, Langella und Vannini 2025, S. 263–264). Die Existenz von Audit-Funktionen begründet sich insbesondere durch die Notwendigkeit, Transparenz, Rechenschaftspflicht und Vertrauen innerhalb komplexer Organisationen sicherzustellen.

Moderne Audit-Ansätze beschränken sich jedoch nicht ausschließlich auf die Überprüfung der Regelkonformität. Vielmehr soll Internal Audit organisatorisches Lernen fördern, das Risikobewusstsein der beteiligten Akteure stärken und Verbesserungsmöglichkeiten in Geschäftsprozessen aufzeigen. Dadurch leistet die Funktion einen Beitrag zur kontinuierlichen Weiterentwicklung der Organisation und schafft einen Mehrwert, der über reine Compliance-Aspekte hinausgeht (vgl. Cantù, Langella und Vannini 2025, S. 18–21). Für die Durchführung der Prüfungen werden unter anderem Dokumente gesichtet, interpretiert und analysiert sowie deren Übereinstimmung mit gegebenen Anforderungen bewertet (vgl. Roussy 2013, S. 556–557). Ein Prozess,der ein erhebliches Potenzial für die Nutzung von KI mit sich bringt (vgl. Schumann und Marx Gómez 2021, S.1). Im Rahmen dieser Arbeit liegt der Fokus auf dem Internal Audit bei FCo, welches für die Prüfung von Dokumenten und Abläufen aus verschiedenen Konzernfunktionen der Freudenberg Gruppe zuständig ist.

vllt. zu hypothetisch -> wie ght er über reine Compliance Aspekte hinaus?

2.2 Stichprobenanalyse im Internal Audit

Für das Internal Audit ist es in der Regel nicht möglich, alle Dokumente einer Grundgesamtheit zu prüfen. Daher wird unter anderem auf die Stichprobenanalyse zurückgegriffen. Bei der Stichprobenanalyse wird aus einer Grundgesamtheit eine Pflichtprobe und eine zufällige Stichprobe entnommen. Die Grundgesamtheit bildet eine abgegrenzte Menge gleichartiger Elemente, beispielsweise alle Rechnungen, die einem Konto zugeordnet sind. Die Pflichtprobe der Grundgesamtheit umfasst alle Elemente, die zuvor definierte Kriterien erfüllen, beispielsweise Rechnungen, die über einem bestimmten Betrag liegen. Diese Elemente müssen als Teil der Stichprobe geprüft werden. Weitergehend wird aus den restlichen Elementen der Grundgesamtheit eine zufällige Stichprobe entnommen, die zusätzlich zur Pflichtprobe geprüft wird (vgl. Freudenberg 2026). Die verbleibenden Elemente der Grundgesamtheit werden vorerst nicht geprüft und bedingen damit eine gewisse Unschärfe der Prüfungsaussagen, was als Stichprobenrisiko bezeichnet wird. Ziel ist es, eine möglichst hohe Prüfungseffizienz zu erreichen. Demnach wird versucht mit dem geringsten Mitteleinsatz ein hinreichend sicheres Prüfungsurteil zu erreichen (vgl. Baumeister 2019, S. 11–12).

Hier zum Einstieg noch mehr Kontext. Das internal Audit hat verschiedene Methoden. ua Stichproben -> rechnungen aber auch user benutzeranlegen etc.

2.3 Künstliche Intelligenz

2.3.1 Large Language Models

2.3.2 Prompt Engineering

Das Prompt Engineering beschreibt den wichitgsten Part der Nutzung eines KI-Systems. Erst durch den Prompt weiß die Maschine was der User erreichen möchte. Ein Prompt kann in verschiedenen klar definierte Teile unterteilt sein.

2.4 Einsatz von Künstlicher Intelligenz im Audit

Der Einsatz von KI im Audit ist kein rein konzeptionelles Zukunftsszenario, sondern bereits in der Prüfungspraxis etabliert (vgl. Kokina et al. 2025, S. 7 f.). KI unterstützt Auditoren bei der Analyse großer strukturierter und unstrukturierter Datenmengen, indem sie

auch wieder sehr mystisch: mitteleinsatz prüfungseffizienz etwas menschlicher einfa

Muster erkennt, Anomalien identifiziert und Vorhersagen trifft (vgl. Ivakhnenkov 2023, S. 56). KI unterscheidet sich zu klassischen Datenanalysemethoden dadurch, dass sie auch nichtlinerare Zusammenhänge verarbeiten kann und somit flexibel auf unterschiedliche Auffälligkeiten aufmerksam machen kann (vgl. Kyriazos und Poga 2024, S. 1790 f.). Es zeigt sich, dass Auditfirmen mit höheren KI-Investitionen eine bessere Prüfungsqualität erreichen und gleichzeitig die Prüfungszeit verkürzen können (vgl. Fedyk et al. 2022, S. 940 ff.). Somit zeigen sich auch für das internal Audit bei FCo Potenziale, die Effizienz und Qualität der Prüfungen durch den gezielten Einsatz von KI zu steigern.

2.4.1 Potenziale in der Stichprobenanalyse

Besonders in der Stichprobenanalyse kann der Einsatz von KI zu einer signifikanten Effizienzsteigerung führen. Durch die Automatisierung der Dokumentenprüfung können Auditoren schneller und umfassender potenzielle Auffälligkeiten, Risiken oder Regelverstöße identifizieren. KI-gestützte Systeme können große Mengen an Rechnungen analysieren, Muster erkennen und Anomalien hervorheben, die menschlichen Prüfern möglicherweise entgehen würden. Dies ermöglicht eine gezieltere Auswahl von Stichproben und reduziert den manuellen Aufwand erheblich. Zudem kann KI dazu beitragen, die Konsistenz und Nachvollziehbarkeit der Prüfungsprozesse zu verbessern, indem sie standardisierte Bewertungsmaßstäbe anwendet und Ergebnisse transparent dokumentiert. Durch die Automatisierung durch KI kann eine deutliche größerer Menge an Stichproben analysiert werden, wodurch die Aussagekraft der Prüfungsergebnisse steigt und das Stichprobenrisiko minimiert wird.

2.4.2 Risiken in der Stichprobenanalyse

Trotz der zahlreichen Vorteile birgt der Einsatz von KI in der Stichprobenanalyse auch Risiken. Ein zentrales Risiko besteht in der Abhängigkeit von den verwendeten KI-Modellen und deren Trainingsdaten. Wenn die Modelle auf unzureichenden oder verzerrten Daten trainiert wurden, können sie fehlerhafte oder voreingenommene Ergebnisse liefern oder Halluzinieren, was zu falschen Prüfungsurteilen führen kann. Zudem besteht die Gefahr des Automation-Bias. Auditoren können die Ergebnisse der KI-Systeme unkritisch übernehmen, ohne diese ausreichend zu hinterfragen und so Auffälligkeiten oder Risiken übersehen.

noch durchgehe, quellen etc .-> siehe copilot chat

3 State of the Art

3.1 Aktuelle Durchführung von Stichprobenanalysen bei Freudenberg

Die Stichprobenanalyse im Internal Audit von Freudenberg folgt einer strukturierten Vorgehensweise, die in den internen Vorgaben des Corporate Audit festgelegt ist (vgl. Freudenberg 2026). Sie lässt sich in vier aufeinander aufbauende Schritte gliedern: die Definition und Klassifizierung der Grundgesamtheit, die Auswahl der Stichprobe, die Prüfung der ausgewählten Elemente sowie die abschließende Bewertung der Ergebnisse. Im Folgenden werden diese Schritte am Beispiel der Prüfung von Lieferantenrechnungen ohne Bestellnummer beschrieben. Das Vorgehen ist grundsätzlich auf weitere Prüffelder übertragbar.

Im ersten Schritt wird die Grundgesamtheit der relevanten Prüfobjekte festgelegt (vgl. Baumeister 2019, S. 12). Im Beispiel umfasst sie alle Rechnungen ohne Bestellnummer, die im Prüfungszeitraum erfasst wurden. Diese Rechnungen werden anschließend anhand definierter Kriterien klassifiziert, etwa nach Rechnungswert, Lieferant, manueller Buchung oder weiteren risikorelevanten Merkmalen (vgl. Freudenberg 2026).

Auf Grundlage dieser Klassifizierung erfolgt im zweiten Schritt die Auswahl der Stichprobe. Dazu wird ein Schwellenwert festgelegt. Alle Rechnungen, die diesen Schwellenwert überschreiten, werden verpflichtend in die Stichprobe aufgenommen und bilden die sogenannten Pflichtproben (vgl. Baumeister 2019, S. 19–20). Aus der verbleibenden Grundgesamtheit werden ergänzend weitere Rechnungen zufällig ausgewählt. Durch die Kombination aus risikobasierter Auswahl und zufälliger Stichprobenziehung werden sowohl potenziell kritische Transaktionen als auch Elemente aus der übrigen Grundgesamtheit in die Prüfung einbezogen (vgl. Freudenberg 2026).

Im dritten Schritt prüft der Auditor jedes ausgewählte Stichprobenelement im Detail. Hierfür sammelt er die relevanten Informationen und Nachweisdokumente, gleicht diese miteinander ab und dokumentiert die Ergebnisse (vgl. Baumeister 2019, S. 17; Freudenberg 2026).

Im vierten Schritt bewertet der Auditor die Ergebnisse hinsichtlich möglicher Auffälligkeiten, Abweichungen oder Regelverstöße. Festgestellte Unregelmäßigkeiten werden dokumentiert und als Audit Exceptions erfasst (vgl. Baumeister 2019, S. 48–49; Freudenberg 2026).

Die Beschreibung zeigt, dass insbesondere die Sammlung, der Abgleich und die Dokumentation der Nachweise überwiegend manuell erfolgen. Diese Tätigkeiten wiederholen sich für jedes Stichprobenelement und sind entsprechend zeitaufwendig (vgl. Baumeister 2019, S. 66–67).

3.2 Einsatz von KI im Auditbereich

Genau an den manuellen Punkten der Stichprobenanalyse setzt der Einsatz von KI an. In großen Prüfungsgesellschaften sind einfache KI-Anwendungen, etwa zur Extraktion von Informationen aus Dokumenten, bereits weit verbreitet, während komplexere Ansätze wie generative KI bislang überwiegend experimentell eingesetzt werden (vgl. Kokina et al. 2025, S. 2). Der Nutzen von KI im Audit lässt sich bereits belegen. Prüfungsgesellschaften, die stärker in KI investieren, erreichen eine höhere Prüfungsqualität. Zugleich sinken die Prüfungsgebühren und die Prüfungen können über die Zeit mit weniger Personal durchgeführt werden, was auf eine effizientere Durchführung hindeutet (vgl. Fedyk et al. 2022, S. 940 f.). Auch für das Internal Audit wird erwartet, dass KI die Arbeitsweise der Prüfungsfunktion grundlegend verändert und Prüfungen effizienter macht (vgl. Wassie und Lakatos 2024, S. 12). Bisher lag der Schwerpunkt vor allem auf der Analyse strukturierter Daten, beispielsweise der Erkennung von Anomalien in Finanzinformationen (vgl. Kokina et al. 2025, S. 2). Mit generativen LLMs lassen sich nun auch unstrukturierte Dokumente wie Rechnungen, Verträge oder E-Mails auswerten. Verfahren zur Verarbeitung natürlicher Sprache werden im Internal Audit bereits für die Analyse solcher Textdaten untersucht (vgl. Schumann und Marx Gómez 2021, S. 1). Damit rückt auch die dokumentenbasierte Prüfung einzelner Stichprobenelemente in den Fokus.

Wie der Einsatz generativer KI im Internal Audit eines Großkonzerns umgesetzt werden kann, zeigt das Beispiel Uniper. Die dortige Auditabteilung setzt ChatGPT in der Prüfungsvorbereitung, der Prüfungsdurchführung und der Berichterstattung ein. Erste Tests ergaben je nach Prozess geschätzte Effizienzgewinne von 50 % bis 80 %. Um die aufkommenden Risiken zu minimieren, die mit dem Einsatz von KI im Audit aufkommen, müssen

strikte Regeln festgelegt werden (vgl. Emett et al. 2025, S. 125 ff.). Solche Risiken betreffen beim Einsatz von KI im Audit unter anderem die Verantwortlichkeit für Ergebnisse, die Transparenz der Verfahren und den Datenschutz (vgl. Munoko, Brown-Liburd und Vasarhelyi 2020, S. 1). Der Nutzen generativer KI hängt somit von klaren Vorgaben und einer kontrollierten Nutzung ab.

Die fachliche Verantwortung für die Beurteilung der Ergebnisse verbleibt dabei weiterhin beim Auditor. Hierbei besteht jedoch das Risiko des Automation Bias. Nutzer vertrauen den Ergebnissen automatisierter Systeme zu stark und können dadurch Fehler leichter übersehen (vgl. Lyell und Coiera 2017, S. 425 f.). Die von KI-Systemen erzeugten Ergebnisse sind daher als Entscheidungshilfe zu verstehen und müssen durch den Auditor eigenständig überprüft werden.

3.3 Verfügbare KI-Lösungen für den Auditbereich

Für den Einsatz von KI im Auditbereich stehen verschiedene Arten von Lösungen zur Verfügung. Diese lassen sich in drei Gruppen einteilen: kommerzielle LLMs, die von Anbietern wie Anthropic, OpenAI oder Google bereitgestellt werden, Open-Source-Modelle, die auf eigener Infrastruktur betrieben werden können, sowie spezialisierte Softwarelösungen, die gezielt für Prüfungsprozesse entwickelt wurden. Im Folgenden werden diese drei Gruppen vorgestellt und hinsichtlich Leistungsfähigkeit, Datenschutz, Kosten und Implementierungsaufwand eingeordnet.

3.3.1 Kommerzielle Lösungen

Generative KI und speziell LLMs werden in der Forschung zunehmend als neue Allzwecktechnologie eingeordnet, die in zahlreichen Branchen und Tätigkeitsfeldern eingesetzt werden kann (vgl. Calvino, Haerle und S. Liu 2025, S. 44). Damit kommen LLMs grundsätzlich auch für den Einsatz im Auditbereich in Frage. Generative KI-Modelle lernen Muster und Zusammenhänge aus großen, teilweise unstrukturierten Datenmengen und können auf dieser Grundlage Informationen verarbeiten, aufbereiten und nutzbar machen (vgl. Feuerriegel et al. 2024, S. 112). Diese Fähigkeiten sind insbesondere für die Analyse und Bewertung von Stichproben im Auditbereich relevant. Jedoch ist zu berücksichtigen, dass die Modelle auch halluzinieren können, also falsche oder nicht belegbare Informationen generieren (vgl.

Ji et al. 2023, S. 2; Huang et al. 2025, S. 2). Daher ist eine abschließende Bewertung der Ergebnisse durch den Auditor weiterhin erforderlich.

Die einzelnen Modelle werden kontinuierlich weiterentwickelt, wobei ihre Leistungsfähigkeit und Genauigkeit stetig zunimmt (vgl. Artificial Analysis 2026). Zum Stand der Arbeit (Oktober 2026) führen Modelle von Anthropic, OpenAI und Google die Benchmark-Rankings wie den Artificial Analysis Intelligence Index an (vgl. Artificial Analysis 2026). Der Artificial Analysis Intelligence Index kann jedoch nur als erster Referenzwert herangezogen werden (vgl. DeepLearning.AI o. D.). Für den konkreten Anwendungsfall der Stichprobenanalyse im Audit sind weitere, spezifische Faktoren zu berücksichtigen, die im Rahmen der Evaluation untersucht werden.

Kommerzielle Modelle werden in der Regel als Cloud-Dienst bereitgestellt. Dadurch lassen sie sich mit geringem Implementierungsaufwand nutzen, da weder eigene Hardware noch der Betrieb der Modelle im Unternehmen erforderlich ist. Die Verarbeitung der Daten erfolgt jedoch auf der Infrastruktur des Anbieters. Für den Einsatz mit vertraulichen Prüfungsdaten ist daher ein vertraglich abgesicherter Zugang notwendig, der die Einhaltung von Datenschutz- und Compliance-Anforderungen gewährleistet. Bei Freudenberg besteht ein solcher Zugang über den Microsoft Copilot, bei dem die Daten innerhalb der Microsoft-365-Umgebung verarbeitet und nicht für das Training der zugrunde liegenden Modelle verwendet werden (vgl. Microsoft 2026a). Die Kosten kommerzieller Lösungen entstehen über Lizenzen oder eine nutzungsabhängige Abrechnung. Bei Freudenberg sind diese im Rahmen der bestehenden Copilot-Lizenz bereits abgedeckt, sodass für den betrachteten Anwendungsfall keine zusätzlichen Kosten anfallen (vgl. Freudenberg & Co. KG 2026).

3.3.2 Open-Source-Lösungen

Neben kommerziellen Modellen existieren Open-Source-Modelle. Als Open-Source-Modelle werden LLMs verstanden, deren Modellgewichte frei verfügbar sind (vgl. Kapoor et al. 2024, S. 2). Bekannte Beispiele sind Llama von Meta, Qwen von Alibaba, Kimi von Moonshot AI oder DeepSeek von DeepSeek-AI(vgl. Artificial Analysis 2026). Open-Source-Modelle stellen grundsätzlich eine Alternative zu kommerziellen Lösungen dar. Durch den Betrieb auf unternehmensinterner Infrastruktur verlassen die Daten das Unternehmen nicht, wodurch Datenschutz- und Compliance-Anforderungen gezielt berücksichtigt werden können. Zudem fallen keine nutzungsabhängigen Lizenzkosten an (vgl. Kapoor et al. 2024, S. 3, 9).

noch besser erklären

so richtig zitiert oder zusammenfassen?

Dem steht ein erheblicher Infrastruktur- und Implementierungsaufwand gegenüber. Für den Betrieb leistungsfähiger Modelle wird eigene Hardware mit ausreichender Rechenleistung benötigt. Hinzu kommen die Wartung, die Aktualisierung der Modelle und das notwendige Fachwissen im Unternehmen (vgl. Kapoor et al. 2024, S. 3). Außerdem liegen in den aktuellen Benchmark-Rankings die kommerziellen Modelle vor Open-Source-Lösungen (vgl. Artificial Analysis 2026).

3.3.3 Spezialisierte KI-gestützte Audit-Lösungen

Abseits von generativen LLMs existieren spezialisierte Softwarelösungen, die KI gezielt für Prüfungsprozesse einsetzen. Ein bekanntes Beispiel dafür ist DataSnipper. Die Software erzielt auf Bewertungsplattformen gute Bewertungen (vgl. Gartner Peer Insights 2026; G2 2026) und wird laut Hersteller unter anderem von den Big 4 eingesetzt, wodurch sie eine hohe Marktrelevanz im Prüfungsumfeld besitzt (vgl. DataSnipper 2026b). DataSnipper ist als Erweiterung für Microsoft Excel umgesetzt und wurde speziell für die Anforderungen von Prüfungs- und Finanzprozessen entwickelt (vgl. YourAIFinder 2026). Zu den zentralen Funktionen gehören die automatisierte Extraktion von Daten aus Dokumenten, der Abgleich dieser Daten mit Arbeitspapieren sowie die Erstellung nachvollziehbarer Audit Trails (vgl. G2 2026). DataSnipper verfolgt einen Human-in-the-Loop-Ansatz. Die KI unterstützt die Auditoren, die finale Bewertung verbleibt dabei weiterhin beim Auditor (vgl. DataSnipper 2026a).

Spezialisierte Lösungen sind auf typische Prüfungsschritte zugeschnitten und stellen vorkonfigurierte Funktionen für Auditprozesse bereit, wodurch sie ohne eigene Prompt-Entwicklung eingesetzt werden können (vgl. DataSnipper 2026a). Im Gegensatz zu generischen LLMs beschränkt sich ihre Nutzung jedoch auf die vom Hersteller bereitgestellten Funktionen. Darüber hinaus ist der Einsatz in der Regel an eine separate Softwarelizenz gebunden.

3.4 Chatnutzung und KI-Agenten

Wie in Abschnitt 3.1 beschrieben, besteht die Prüfung eines Stichprobenelements aus mehreren aufeinander aufbauenden Schritten, die für jedes Stichprobenelement erneut durchgeführt werden. Für die Unterstützung dieser Schritte durch ein LLM kommen grundsätzlich

zwei Nutzungsformen in Frage: die Nutzung über ein Chatfenster und der Einsatz von KI-Agenten.

Grundsätzlich lassen sich die Arbeitsschritte mithilfe eines einzelnen, ausführlichen Prompts in einem Chat mit einem LLM beschreiben. Die Nutzung eines Chatfensters ist jedoch primär auf die Bearbeitung einzelner Benutzereingaben ausgelegt. Sprachmodelle reagieren dabei teilweise empfindlich auf Unterschiede in der Formulierung und Struktur von Prompts (vgl. Sclar et al. 2024, S. 16). Werden viele Dokumente nacheinander im selben Chat verarbeitet, entsteht zudem ein langer Kontext. Informationen in der Mitte solcher Kontexte werden von Sprachmodellen schlechter berücksichtigt (vgl. N. F. Liu et al. 2024, S. 157), während irrelevante Informationen die Ergebnisqualität zusätzlich beeinträchtigen können (vgl. Shi et al. 2023, S. 8). Für Auditprüfungen, deren Ergebnisse nachvollziehbar und zwischen verschiedenen Stichprobenelementen vergleichbar sein müssen, stellt dies eine Herausforderung dar.

KI-Agenten gehen über die reine Chatnutzung eines LLM hinaus. Sie sind für die automatisierte Ausführung konkreter Aufgaben konzipiert und erweitern generative KI durch die Integration von Werkzeugen, definierten Anweisungen und strukturierten Prozessabläufen (vgl. Sapkota, Roumeliotis und Karkee 2026, S. 1). Ein Agent wird dabei, beispielsweise im Microsoft Copilot Studio, einmalig mit festen Instruktionen, Wissensquellen und Aktionen konfiguriert (vgl. Microsoft 2026b). Dadurch wird jede Eingabe nach demselben Schema verarbeitet, wodurch der Ablauf standardisiert, dokumentierbar und wiederverwendbar wird. Identische Ergebnisse bei wiederholter Verarbeitung sind damit jedoch nicht garantiert. Sprachmodelle erzeugen ihre Ausgaben auf Basis von Wahrscheinlichkeiten und können deshalb auch bei gleicher Eingabe unterschiedliche Antworten liefern (vgl. Huang et al. 2025, S. 5, 12). Die Konsistenz der Ergebnisse muss daher gesondert überprüft werden.

3.5 Einordnung des KI-Einsatzes bei Freudenberg

Die Freudenberg Gruppe nutzt aktuell gruppenweit die KI-Lösung von Microsoft, den Microsoft Copilot. Hierbei werden für alle Nutzer die Modelle GPT-5.6, GPT-6.1 sowie Claude Sonnet 5, Claude Sonnet 5.5 und Claude Opus 5.5 zur Verfügung gestellt (vgl. Freudenberg & Co. KG 2026). Der Copilot kann dabei unter Berücksichtigung der Datenschutz- und Compliance-Richtlinien auf alle internen Dokumente zugreifen, für die der jeweilige

Nutzer berechtigt ist. Zusätzlich bietet Microsoft die Möglichkeit, über das Copilot Studio eigene Agenten zu bauen. Hierbei können die Agenten auf interne Dokumente zugreifen und Aufgaben automatisiert ausführen. Für die Agenten sind aktuell die Modelle GPT-4.1, GPT-5, GPT-5.3, GPT-5.5 sowie Claude Sonnet 4.6, Claude Opus 4.6, Claude Opus 4.7 und Claude Opus 4.8 hinterlegt (vgl. Freudenberg & Co. KG 2026).

Bei Freudenberg stehen damit beide in Abschnitt 3.4 beschriebenen Nutzungsformen zur Verfügung. Die verfügbaren Modelle unterscheiden sich jedoch zwischen den beiden Varianten. Im Chatfenster des Microsoft Copilot sind teilweise neuere Modelle verfügbar als im Copilot Studio. Offen bleibt, welches der verfügbaren Modelle für die Stichprobenanalyse von Rechnungen im Auditkontext die besten Ergebnisse liefert. Zur Beantwortung dieser Frage wird im weiteren Verlauf der Arbeit eine Evaluation durchgeführt, deren Aufbau in Kapitel 4 beschrieben wird.

4 Evaluationsdesign

4.1 Forschungsdesign

Zur Beantwortung der Forschungsfrage, wie sich verschiedene LLMs hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit unterscheiden, wird in dieser Arbeit eine vergleichende Evaluation der Modelle durchgeführt. Dazu werden die ausgewählten Modelle auf verschiedene Prüfungsdokumente angewendet. Die Modelle analysieren sowohl die Rechnungen als auch die Bestätigungen zur Freigabe der Rechnungen, markieren mögliche Auffälligkeiten und begründen ihre Befunde. Die Ergebnisse werden mithilfe einer Nutzwertanalyse ausgewertet. Damit Unterschiede in den Ergebnissen tatsächlich auf die Modelle zurückzuführen sind, werden alle übrigen Einflussfaktoren konstant gehalten. Für jedes Modell wird im Copilot Studio ein eigener Agent mit identischen Instruktionen angelegt. Alle Modelle erhalten dieselben Rechnungen und dieselben Freigaben sowie denselben Prompt, um identische Bedingungen zu gewährleisten.

Das vorliegende Kapitel beschreibt den Aufbau der Evaluation. Dazu gehören die Wahl der Untersuchungsumgebung, die Auswahl der Modelle, die Testdaten, der Prompt sowie die Kriterien und Regeln, nach denen die Ergebnisse bewertet werden. Die konkrete Durchführung der Evaluation wird in Kapitel 5 beschrieben.

4.2 Wahl der Untersuchungsumgebung

Wie in Abschnitt 3.5 beschrieben, können die Modelle bei Freudenberg sowohl über das Chatfenster des Microsoft Copilot als auch über eigene Agenten im Copilot Studio genutzt werden. Für die Stichprobenanalyse von Rechnungen im Auditkontext wird in dieser Arbeit der Einsatz eigener Agenten im Copilot Studio anstelle der reinen Chatnutzung gewählt.

Die Entscheidung ergibt sich aus den in Abschnitt 3.4 beschriebenen Eigenschaften der beiden Nutzungsformen. Im Chat müssten die Anweisungen für jeden Prüffall neu eingegeben werden, wodurch Abweichungen in Formulierung und Struktur entstehen können. Im Agenten sind Instruktionen und Wissensquellen dagegen fest hinterlegt, sodass jedes Stichprobenelement nach demselben Prüfschema verarbeitet wird. Der Agent kann auf die für

die Prüfung relevanten Dokumente zugreifen, Informationen extrahieren und die definierten Prüfschritte automatisiert durchführen. Dieses Vorgehen entspricht dem von Schreyer et al. (2024, S. 1) beschriebenen auto-piloted Auditing.

Für den vorliegenden Anwendungsfall ist daher entscheidend, wie leistungsfähig ein Modell hinter einem Agenten im Copilot Studio ist. Die Modellleistung bleibt somit der zentrale Untersuchungsgegenstand, wird jedoch unter den Bedingungen betrachtet, unter denen ein Einsatz im Internal Audit realistisch ist. Da sich im Agenten ausschließlich das zugrunde liegende Modell austauschen lässt, erfüllt der Agentenansatz zudem die in Abschnitt 4.1 geforderte Konstanz der übrigen Einflussfaktoren. Als Einschränkung ist zu berücksichtigen, dass neuere Modelle, die bislang nur im Chatfenster verfügbar sind (siehe Abschnitt 3.5), unter diesen Bedingungen nicht untersucht werden können.

4.3 Auswahl der zu untersuchenden Modelle

Freudenberg einheitlich benennen: Freudenberg Gruppe vs. FCo, Internal Audit vs. Corporate Audit

Die Auswahl der zu untersuchenden Modelle basiert auf der aktuellen Nutzung von KI-Lösungen in der Freudenberg Gruppe. Wie in Abschnitt 3.5 beschrieben, nutzt die Freudenberg Gruppe gruppenweit die Premium Version des Microsoft Copilot und die dort ausgerollten Modelle von OpenAI und Anthropic. Hierbei werden sowohl die internen Datenschutz- und Compliance-Richtlinien als auch EU-Richtlinien eingehalten. Ein weiterer Vorteil ist, dass durch die Nutzung der Modelle über den Microsoft Copilot keine weiteren Kosten anfallen (siehe Abschnitt 3.3.1). Zudem ist der Copilot bereits im Internal Audit ausgerollt, weshalb es keiner weiteren Schulungen und Gewöhnungszeiten für Mitarbeiter bedarf.

Von den in Abschnitt 3.3 vorgestellten Lösungen werden Open-Source-Modelle und spezialisierte Softwarelösungen im Rahmen dieser Arbeit nicht untersucht. Der Betrieb von Open-Source-Modellen wäre mit erheblichem Infrastruktur- und Implementierungsaufwand verbunden (siehe Abschnitt 3.3.2). Für den Einsatz von spezialisierten Softwarelösungen wie DataSnipper müsste eine zusätzliche Lizenz erworben werden, die weitere Kosten verursachen würde (siehe Abschnitt 3.3.3).

Der Microsoft Copilot ermöglicht es den Auditoren, auf verschiedene Modelle von Anthropic und OpenAI zuzugreifen. Da die Evaluation, wie in Abschnitt 4.2 begründet, über eigene Agenten im Copilot Studio durchgeführt wird, werden im Rahmen dieser Arbeit alle Modelle berücksichtigt, die im Copilot Studio für die Erstellung von Agenten zur Verfügung stehen.

Dies sind GPT-4.1, GPT-5, GPT-5.3 und GPT-5.5 sowie Claude Sonnet 4.6, Claude Opus 4.6, Claude Opus 4.7 und Claude Opus 4.8.

4.4 Entwicklung der Testdatensätze

Für die Evaluation der betrachteten KI-Modelle ist eine Datenbasis erforderlich, die den realen Prüfungskontext möglichst genau abbildet. Die Verwendung originaler Rechnungsbelege aus dem Internal Audit der Freudenberg Gruppe ist ausgeschlossen, da diese personenbezogene sowie geschäftskritische Informationen enthalten und daher im Rahmen dieser Evaluierung nicht herangezogen werden dürfen. Um dennoch eine hinreichend umfangreiche und belastbare Testbasis zu schaffen, werden die Testdatensätze mithilfe generativer KI erzeugt.

Die künstlich erstellten Rechnungen orientieren sich in Struktur, Umfang und Informationsgehalt an realen Rechnungen und enthalten dieselben prüfungsrelevanten Kriterien wie die im Audit untersuchten Dokumente. Nach der Generierung der Rechnungen werden gezielt Fehler in die Dokumente eingebracht. Dieser Ansatz orientiert sich an Benchmark-Studien zur Evaluation von LLMs im Finanzkontext, bei denen vorhandene Finanzdokumente systematisch durch künstlich eingefügte Fehler verändert werden, um die Fähigkeit der Modelle zur Identifikation von Inkonsistenzen zu untersuchen (vgl. Panda 2026, S. 1).

Neben den Rechnungen werden auch Screenshots von Mails zur Freigabe der einzelnen Rechnungen erstellt. Auch hier werden gezielt einzelne Fehler in die Datensätze eingebaut. Der Testdatensatz umfasst somit sowohl fehlerhafte als auch vollständig korrekte Rechnungen sowie die zugehörigen Freigaben.

Als fehlerhaft gilt in dieser Arbeit jede Rechnung, bei der mindestens eine Abweichung von den in Abschnitt 3.1 beschriebenen Prüfkriterien vorliegt. Eine solche Abweichung wird im Audit als Exception bezeichnet. Sie kann die Rechnung selbst betreffen, etwa eine falsche Bankverbindung, oder den zugehörigen Freigabeprozess, etwa eine Genehmigung durch eine nicht berechtigte Person. Jede fehlerhafte Rechnung im Testdatensatz enthält genau eine eingebaute Exception. Dadurch ist für jede Rechnung eindeutig festgelegt, ob und welcher Fehler vorliegt. Diese Zuordnung bildet die Grundlage, mit der die Ergebnisse der Modelle verglichen werden.

Für die vorliegende Arbeit wird eine Fehlerquote von 24 % festgelegt, was bei einem Datensatz von 100 Rechnungen insgesamt 24 fehlerhaften Belegen entspricht. Nach internen

Angaben liegt die Quote für fehlerhafte oder unvollständige Rechnungen bei 18 % (vgl. internes Meeting David Goth). Durch eine Fehlerquote von 24 % ist die Anzahl fehlerhafter Rechnungen ausreichend groß, um die Erkennungsleistung der Modelle repräsentativ zu untersuchen . Gleichzeitig bildet die Mehrheit an korrekten Rechnungen den realen Prüfungskontext realitätsnah ab.

Quelle? ansonsten auch David

Bei der Fehlererzeugung wird bewusst auf eine breite Streuung unterschiedlicher Fehlertypen geachtet. Die Fehler werden in sechs Gruppen unterschieden. Die größte Gruppe bilden typische Betrugsmuster mit 6 Fehlern. Sie zeigen den Nutzen eines solchen Systems im Audit bei kreativen Betrugsmaschen auf. Bei 5 Fehlern liegt das Problem im Freigabeprozess, wenn eine Rechnung ohne die erforderliche Freigabe oder durch eine nicht berechtigte Person genehmigt wird. Weitere 4 Fehler betreffen den Abgleich mit den Stammdaten, bei denen die Angaben auf der Rechnung von den hinterlegten Lieferantendaten abweichen, zum Beispiel bei Anschrift oder Bankverbindung. Bei 4 Fehlern handelt es sich um einfache Rechen- bzw. Zahlenfehler, die als Basisfälle gelten. Weitere 3 Fehler betreffen ein falsches Rechnungsdatum oder die Zuordnung zur falschen Periode, sodass der Aufwand im falschen Zeitraum gebucht wird. Die letzten 2 Fehler betreffen eine fehlende Rechnungsnummer. Tabelle 4.1 fasst die Fehlergruppen zusammen.

genaue Zahlen begründen: 100 Rechnungen, 24 %, 24 Fehler, Verteilung 6, 5, 4, 4, 3, 2

Anzahl	Fehlergruppe
6	Betrugsmuster
5	Fehler in der Rechnungsfreigabe
4	Abgleich mit Stammdaten
4	Rechnerische Fehler und Basisfälle
3	Datum und Periode
2	Fehlende Rechnungsnummer
24	**Gesamt**

Tabelle 4.1: Verteilung der eingebauten Fehler auf die Fehlergruppen

Da jede Fehlergruppe nur zwischen 2 und 6 Fehler umfasst, sind Aussagen zur Erkennungsleistung einzelner Fehlergruppen nur eingeschränkt belastbar. Die Auswertung nach Fehlergruppen dient daher als ergänzende Betrachtung. Der Vergleich der Modelle erfolgt über die Gesamtheit aller Rechnungen.

4.5 Entwicklung eines geeigneten Prompts

Die Qualität der von einem LLM erzeugten Ausgabe hängt maßgeblich von der Gestaltung des Prompts ab (vgl. Sclar et al. 2024). Prompt Engineering bezeichnet die systematische Gestaltung, Strukturierung und Optimierung von Eingabeanweisungen (Prompts) für LLMs. Ziel ist es, durch die gezielte Auswahl von Aufgabenbeschreibungen, Kontextinformationen, Beispielen und Formatierungen das gewünschte Modellverhalten zu erzeugen und die Qualität der Ergebnisse zu verbessern (vgl. Schulhoff et al. 2025, S. 1). Der Prompt für diese Arbeit wird deshalb auf Basis etablierter Techniken des Prompt Engineering entwickelt. Um die Vergleichbarkeit der untersuchten Modelle sicherzustellen, wird auf eine modellspezifische Optimierung verzichtet. Alle Modelle erhalten denselben Prompt. Dieser enthält klare Anweisungen zur Analyse der Rechnungen, zur Identifikation möglicher Auffälligkeiten und zur nachvollziehbaren Begründung der Ergebnisse.

Die inhaltlichen Anforderungen an den Prompt ergeben sich aus dem bestehenden Vorgehen der Stichprobenanalyse bei Freudenberg (vgl. Abschnitt 3.1). Der Prompt bildet die Prüfschritte ab, die ein Prüfer bei einer Eingangsrechnung durchführt. Dazu gehören die Extraktion der Rechnungsdaten, der Abgleich mit der Referenztabelle, die rechnerische und formale Prüfung sowie die Suche nach Betrugsindikatoren. Abschließend werden der Freigabeprozess und die Berechtigung des Genehmigers geprüft. Das Ergebnis dient als Grundlage für die anschließende menschliche Prüfung. Das Modell unterstützt den Prüfer also, übernimmt aber nicht den vollständigen Prüfungsprozess und gibt lediglich eine Empfehlung für das weitere Vorgehen ab.

Der Prompt besteht aus zwei Teilen. Die Instruktionen sind in jedem Agenten identisch und dauerhaft hinterlegt und legen Rolle, Ziel, Quellen, Regeln, Prüfschritte und Ausgabeformat fest. Der Kurzprompt wird für jeden Prüffall mit identischem Wortlaut in den Chat des jeweiligen Agenten eingegeben. Er startet die Prüfung und benennt die vorliegenden Unterlagen. Der vollständige Prompt, unterteilt in Instruktionen und Kurzprompt, befindet sich in Anhang **??**.

Bei der Gestaltung des Prompts werden mehrere etablierte Techniken angewendet. Zu Beginn erhält das Modell ein klar definiertes Ziel und eine eindeutige Rolle als Prüfagent des internen Audits. Die Rolle gibt dem Modell den fachlichen Rahmen der Aufgabe vor (vgl. Microsoft 2026b).

Für jede Eingabe ist festgelegt, welche Funktion sie erfüllt. Die Rechnung liefert die Ist-

werte, die Referenztabelle die Sollwerte und die Freigabematrix die Berechtigungen. Die Freigabeunterlagen gelten ausschließlich als Evidenz und werden nicht automatisch als gültig angenommen. Durch diese Quellenhierarchie muss das Modell bei widersprüchlichen Angaben nicht selbst entscheiden, welcher Quelle es folgt. Die einzelnen Wissensquellen werden in den Instruktionen ausdrücklich benannt und erklärt (vgl. Microsoft 2026b).

Die Aufgabe ist in elf Prüfschritte mit fester Reihenfolge zerlegt. Die Aufteilung in klar getrennte Einheiten verringert Mehrdeutigkeiten und verhindert, dass das Modell Aufgaben zusammenführt oder neu interpretiert (vgl. Microsoft 2026b). Zusätzlich wird die Prüfung dadurch nachvollziehbar, da jeder Schritt im Ergebnis sichtbar ist.

LLMs neigen dazu, fehlende Informationen durch plausibel klingende, aber falsche Inhalte zu ersetzen (vgl. Huang et al. 2025, S. 1). Der Prompt verbietet deshalb Annahmen und Ergänzungen. Fehlt eine Information oder kann sie nicht geprüft werden, muss das Modell feste Statuswerte wie „nicht vorhanden“, „nicht lesbar“ oder „nicht prüfbar“ verwenden. Verdachtsmomente dürfen nur als „Hinweis auf“ formuliert werden, da die Feststellung eines Betrugs dem Prüfer vorbehalten bleibt (vgl. Anthropic 2026).

Die Ausgabe folgt einer festen Struktur mit vorgegebenen Feldern und Statuswerten. Ohne vorgegebenes Ausgabeformat kann es zu inkonsistentem Verhalten zwischen verschiedenen Modellen kommen (vgl. Microsoft 2026b). Das feste Format erleichtert die menschliche Prüfung und macht die Ergebnisse der Modelle direkt vergleichbar. Die Gesamtbewertung der Freigabe, die Auffälligkeiten mit Risikostufe sowie die Angabe zur menschlichen Nachprüfung bilden die Grundlage für die Auswertung (siehe Abschnitt 5.3).

Neben den inhaltlichen Anforderungen unterliegt der Prompt technischen und methodischen Rahmenbedingungen. Die Instruktionen eines Agenten in Copilot Studio sind auf 8000 Zeichen begrenzt (vgl. Microsoft 2026b). Eine ausführliche Fassung mit Definitionen, Beispielen und Beschreibungen aller Statuswerte umfasste rund 30.000 Zeichen und lag damit deutlich über diesem Limit. Zudem berücksichtigen LLMs Informationen in langen Kontexten weniger zuverlässig (vgl. N. F. Liu et al. 2024, S. 157). Irrelevante Informationen im Kontext können die Leistung der Modelle zusätzlich verschlechtern (vgl. Shi et al. 2023, S. 9). Der Prompt soll dem Modell deshalb nur die für die Aufgabe notwendigen Informationen bereitstellen.

Daraus ergeben sich folgende Anforderungen an den Prompt. Die Regeln werden stichpunktartig formuliert und auf ausführliche Erklärungen wird verzichtet. Alle elf Prüfschritte müssen dabei vollständig enthalten bleiben, damit der Prüfprozess unverändert abgebildet

wird. Instruktionen und Kurzprompt dürfen sich nicht widersprechen, da das Modell sonst selbst entscheiden müsste, welcher Anweisung es folgt.

Der Prompt wird vor der Evaluation in mehreren Durchgängen erprobt und angepasst. Dazu werden fünf zusätzliche Validierungsrechnungen mit den zugehörigen Freigaben erstellt. Drei dieser Rechnungen werden bewusst mit Fehlern versehen: einer fehlerhaften Freigabe, einer fehlenden Rechnungsnummer und einem Rechenfehler. Die beiden übrigen Rechnungen sind vollständig korrekt. Die Validierung erfolgt mit Claude Opus 4.8 und GPT-5.5. Da je ein Modell von Anthropic und OpenAI verwendet wird, ist der Prompt nicht auf einen einzelnen Anbieter zugeschnitten. Nach jedem Durchgang wird geprüft, ob die Agenten die eingebauten Fehler erkennen und die korrekten Rechnungen nicht beanstanden. Weicht das Ergebnis davon ab, wird der Prompt entsprechend angepasst. Der Prompt gilt als geeignet, sobald er bei allen fünf Validierungsrechnungen in drei aufeinanderfolgenden Durchläufen zu einem korrekten Ergebnis führt.

Die Validierungsrechnungen sind nicht Teil des Testdatensatzes aus Abschnitt 4.4. Dadurch wird verhindert, dass der Prompt gezielt auf die Rechnungen der Evaluation zugeschnitten wird und die Ergebnisse zu positiv ausfallen. Der finale Prompt wird vor Beginn der Evaluation festgelegt und für alle Modelle unverändert eingesetzt.

4.6 Nutzwertanalyse

Die Eignung der untersuchten LLMs für den definierten Anwendungsfall im Audit lässt sich nicht anhand eines einzelnen Kriteriums bestimmen. Um ein ganzheitliches Ergebnis zu erhalten, müssen sowohl quantitative als auch qualitative Kriterien berücksichtigt werden. Die Bewertung erfordert somit die gleichzeitige Betrachtung mehrerer, teilweise konkurrierender Kriterien und stellt ein mehrdimensionales Entscheidungsproblem dar (vgl. Kozłowska 2022, S. 116 f.).

Zur strukturierten Berücksichtigung dieser Kriterien wird in dieser Arbeit eine Nutzwertanalyse durchgeführt. Sie ist eine bewährte Methode zur Lösung mehrdimensionaler Entscheidungsprobleme und ermöglicht es, verschiedene Bewertungskriterien zu gewichten und zu einem Gesamtnutzwert zusammenzufassen (vgl. Kühnapfel 2021, S. 79 f.). Dadurch lassen sich die untersuchten Modelle systematisch und nachvollziehbar hinsichtlich ihrer Eignung vergleichen. Da die Gewichtung der Kriterien auf einer subjektiven Einschätzung beruht, wird sie in Abschnitt 4.8 offen dargelegt und begründet.

4.7 Entwicklung einer Bewertungsmatrix

Um die Evaluation basierend auf einer Nutzwertanalyse durchzuführen, muss eine Bewertungsmatrix mit mehreren quantitativen und qualitativen Kriterien entwickelt werden (vgl. Liang et al. 2023, S. 3). Bei der Entwicklung der Bewertungsmatrix werden die Anforderungen für den Anwendungsfall der Corporate Audit Abteilung der FCo berücksichtigt. Die Bewertungsmatrix umfasst drei Hauptkriterien, die für die Eignung der Modelle für den definierten Use Case von zentraler Bedeutung sind. Diese Kriterien sind die Erkennungsleistung der Modelle, die Qualität der Begründungen und die Konsistenz der Ergebnisse. Aus der gewichteten Zusammenführung dieser Kriterien ergibt sich eine Rangfolge der untersuchten Modelle.

wissenschaf begrün- den, warum diese Kriteri- en

Als zentrales quantitatives Kriterium wird die Erkennungsleistung der Modelle herangezogen. Die Bewertung erfolgt auf Ebene der einzelnen Rechnung. Eine Rechnung gilt als vom Modell beanstandet, wenn das Modell eine Audit Exception erkennt. Maßgeblich ist dabei ausschließlich das Feld „Audit Exception“ am Ende der Ausgabe (siehe Anhang **??**). Das Modell meldet eine Audit Exception, sobald mindestens eine Feststellung in den Unterlagen nachgewiesen ist. Dazu zählen Abweichungen von der Referenztabelle bei Betrag, Empfänger, Lieferant, USt-IdNr. oder Zahlungsdaten, rechnerische Fehler sowie fehlende Pflichtangaben wie die Rechnungsnummer. Ebenso führen eine unberechtigte, widersprüchliche oder erst nach der Zahlung erteilte Freigabe und sonstige Auffälligkeiten ab einem mittleren Risiko zu einer Audit Exception. Unsicherheit, ein bloßer Verdacht oder fehlende Unterlagen reichen dagegen allein nicht aus.

Unabhängig davon bewertet das Modell, ob eine menschliche Nachprüfung erforderlich ist. Diese Empfehlung spricht das Modell auch in unklaren Fällen aus, etwa bei fehlenden oder unleserlichen Unterlagen oder bei Hinweisen auf Betrug. Für die Einordnung als beanstandet wird sie nicht herangezogen, da sie keine nachgewiesene Abweichung voraussetzt. Die Erkennungsleistung wird somit ausschließlich an den Feststellungen gemessen, die das Modell anhand der Unterlagen belegen kann.

Eine Ausnahme bilden Rechnungen, deren eingebauter Fehler eine fehlende Freigabe ist. Kann das Modell in den Unterlagen keine Freigabe finden, meldet es laut Prompt keine Audit Exception. Der Grund ist technischer Natur: Kann ein Modell den Freigabescreenshot nicht lesen, findet es ebenfalls keine Freigabe, obwohl diese vorhanden ist. Keine Freigabe für das Modell bedeutet daher nicht automatisch, dass die Rechnung nicht freigegeben wurde. Diese Rechnungen werden deshalb gesondert bewertet. Sie gelten als vom Modell

beanstandet, wenn die Gesamtbewertung der Freigabe „Keine Freigabe in den bereitgestellten Unterlagen nachweisbar“ lautet, das Modell eine menschliche Nachprüfung empfiehlt und den Freigabenachweis als lesbar eingestuft hat. Stuft das Modell den Nachweis als nicht lesbar ein, wird die Rechnung als False Negative gewertet, da der Befund nicht auf einer inhaltlichen Prüfung beruht.

Zusätzlich wird für jedes Modell erfasst, bei wie vielen Rechnungen es den Freigabenachweis nicht lesen konnte. Diese Lesefehlerquote fließt nicht in die Nutzwertanalyse ein, wird aber ergänzend ausgewiesen, da sie die Aussagekraft der übrigen Ergebnisse eines Modells einschränkt.

Durch den Vergleich mit den im Testdatensatz festgelegten Fehlern lässt sich jede Rechnung einer von vier Kategorien zuordnen. Ein True Positive liegt vor, wenn das Modell eine fehlerhafte Rechnung beanstandet und mindestens ein Befund den eingebauten Fehler zutreffend benennt. Wird eine fehlerhafte Rechnung nicht beanstandet oder lediglich aus einem anderen Grund beanstandet, handelt es sich um einen False Negative, da der eigentliche Fehler im Audit unentdeckt bliebe. Ein False Positive liegt vor, wenn eine korrekte Rechnung beanstandet wird. Wird eine korrekte Rechnung nicht beanstandet, handelt es sich um einen True Negative.

Auf dieser Grundlage werden die Kennzahlen Precision und Recall berechnet. Der Precision-Wert gibt an, wie viele der vom Modell als fehlerhaft identifizierten Rechnungen tatsächlich fehlerhaft sind. Er berechnet sich aus dem Quotienten der richtig als fehlerhaft klassifizierten Rechnungen, den sogenannten True Positives, und der Summe aus True Positives und False Positives. Der Recall-Wert gibt an, wie viele der tatsächlich fehlerhaften Rechnungen vom Modell korrekt identifiziert wurden. Er berechnet sich aus dem Quotienten der True Positives und der Summe aller tatsächlich fehlerhaften Rechnungen, also der Summe aus True Positives und False Negatives.

$$\text{Precision} = \frac{TP}{TP + FP} \qquad \text{Recall} = \frac{TP}{TP + FN} \tag{4.1}$$

Da jede Rechnung fünfmal von jedem Modell analysiert wird (siehe Konsistenz), werden Precision und Recall zunächst für jeden Durchlauf einzeln berechnet. Für die Nutzwertanalyse wird anschließend der Mittelwert über die fünf Durchläufe verwendet. Dadurch fließt kein einzelner, zufällig besonders guter oder schlechter Durchlauf allein in die Bewertung ein.

Als weiteres Kriterium wird die Qualität der Begründungen der Modelle bewertet. Die qualitative Bewertung der Begründung erfolgt durch zwei Senior Auditoren der FCo. Bewertet werden die Begründungen zu allen beanstandeten Rechnungen aus dem ersten Durchlauf eines Modells. Die Auditoren bewerten die Begründungen anhand der drei Kriterien Korrektheit, Nachvollziehbarkeit und Faktentreue. Die Korrektheit beschreibt, ob die fachliche Argumentation zutreffend ist. Die Nachvollziehbarkeit beschreibt, ob ein Prüfer anhand der Begründung verstehen kann, wie das Modell zu seinem Befund gekommen ist. Die Faktentreue beschreibt, ob alle genannten Angaben tatsächlich in den Unterlagen enthalten sind.

Jedes Kriterium wird auf einer Skala von 1 bis 5 bewertet, wobei 1 für „sehr schlecht“ und 5 für „sehr gut“ steht. Die Auditoren bewerten unabhängig voneinander. Weichen ihre Bewertungen für eine Begründung um mehr als einen Punkt voneinander ab, wird die Bewertung gemeinsam besprochen und abgestimmt. Anschließend wird der Mittelwert der Bewertungen der Auditoren gebildet und als Teilwert der Qualität der Begründung herangezogen.

Als letztes Kriterium wird die Konsistenz der Modelle bewertet. Wie in Abschnitt 3.4 beschrieben, garantiert auch ein standardisierter Agent keine identischen Ergebnisse bei wiederholter Verarbeitung. Dazu wird jede Rechnung mit identischem Prompt fünfmal von jedem Modell analysiert. Anschließend werden alle unterschiedlichen Befunde erfasst, die über die fünf Durchläufe hinweg gemeldet wurden. Zwei Befunde gelten dabei als identisch, wenn sie denselben Prüfschritt und dieselbe Auffälligkeit betreffen, unabhängig von ihrer Formulierung.

Für jeden dieser Befunde wird ermittelt, in wie vielen Durchläufen er auftaucht. Ein Befund, der in allen fünf Durchläufen gemeldet wird, erhält somit den Wert 1, ein Befund, der nur in einem Durchlauf auftaucht, den Wert 0,2. Die Konsistenz ergibt sich aus dem Mittelwert dieser Anteile über alle Befunde und wird in Prozent angegeben. Liefert ein Modell in allen Durchläufen exakt dieselben Befunde, erreicht es eine Konsistenz von 100 %. Je häufiger sich die gemeldeten Befunde zwischen den Durchläufen unterscheiden, desto geringer fällt der Wert aus.

4.8 Gewichtung der Bewertungsmatrix

Um die drei Hauptkriterien zu einem Gesamtergebnis zusammenzuführen, werden diese entsprechend ihrer Bedeutung für den Audit-Use-Case gewichtet. Die Gewichtung erfolgt auf Basis der Anforderungen der Corporate Audit Abteilung der FCo.

Die Erkennungsleistung erhält mit 50 % das höchste Gewicht, da die zuverlässige Identifikation fehlerhafter Rechnungen die Kernaufgabe der Stichprobenanalyse darstellt. Innerhalb dieses Kriteriums wird der Recall mit 30 % höher gewichtet als die Precision mit 20 %. Ein False Positive, also ein Fehlalarm, wird vom Auditor im Rahmen der weiteren Prüfung erkannt und verursacht lediglich zusätzlichen Prüfaufwand. Wird ein Fehler hingegen vom Modell nicht gemeldet (False Negative), besteht die Gefahr, dass auch der Auditor diesen übersieht, da er sich auf das Ergebnis des Systems verlässt (vgl. Abschnitt 3.2).

Die Qualität der Begründungen wird mit 30 % gewichtet. Auditoren müssen nachvollziehen können, wie ein Ergebnis zustande gekommen ist, um die Befunde prüfen und dokumentieren zu können. Die Korrektheit erhält hierbei mit 12 % das höchste Gewicht, da eine fachlich falsche Argumentation auch bei richtig erkanntem Fehler zu einer fehlerhaften Dokumentation führen kann. Die Nachvollziehbarkeit wird mit 10 % und die Faktentreue mit 8 % gewichtet. Erfundene Angaben sind im Audit zwar besonders kritisch, werden aber teilweise bereits über die Korrektheit erfasst.

Die Konsistenz erhält mit 20 % das geringste Gewicht. Reproduzierbare Ergebnisse sind zwar eine Voraussetzung dafür, dass Auditoren einem Modell vertrauen können. Eine hohe Konsistenz sagt allein jedoch nichts über die Richtigkeit der Ergebnisse aus, da auch ein Modell, das dauerhaft dieselben Fehler übersieht, konsistent arbeitet. Tabelle 4.2 fasst die Gewichtung zusammen.

Hauptkriterium	**Gewicht**	**Teilkriterium**	**Gewicht**
Erkennungsleistung	50 %	Recall	30 %
		Precision	20 %
Qualität der Begründungen	30 %	Korrektheit	12 %
		Nachvollziehbarkeit	10 %
		Faktentreue	8 %
Konsistenz	20 %	Konsistenz	20 %

Tabelle 4.2: Gewichtung der Bewertungsmatrix

Da die Kriterien auf unterschiedlichen Skalen erfasst werden, müssen sie vor der Verrechnung vereinheitlicht werden. Precision, Recall und Konsistenz liegen bereits als Prozent-

werte vor. Für die Teilkriterien der Begründungsqualität wird zunächst der Mittelwert über alle Auditoren gebildet. Dieser wird anschließend über $e = \frac{x-1}{4} \cdot 100$ in einen Wert zwischen 0 und 100 umgerechnet, sodass die schlechteste Bewertung den Wert 0 und die beste Bewertung den Wert 100 erhält. Somit sind alle Kriterien auf einer gemeinsamen Skala. Der Nutzwert eines Modells ergibt sich dann als Summe der gewichteten Einzelwerte:

$$N_j = \sum_{i=1}^{6} w_i \cdot e_{ij} \tag{4.2}$$

Dabei steht N_j für den Nutzwert des Modells j, w_i für das Gewicht des Teilkriteriums i und e_{ij} für den normierten Wert des Modells j im Teilkriterium i. Der Nutzwert liegt damit ebenfalls zwischen 0 und 100.

Die gewählte Gewichtung stellt eine begründete, aber nicht die einzig mögliche Festlegung dar. Je nach Schwerpunkt einer Prüfung könnte etwa die Precision höher gewichtet werden, wenn der zusätzliche Prüfaufwand durch Fehlalarme stärker ins Gewicht fällt. Um den Einfluss der Gewichtung auf das Ergebnis zu prüfen, wird im Rahmen der Auswertung zusätzlich eine Sensitivitätsanalyse durchgeführt. Dazu wird das Gewicht jedes Hauptkriteriums nacheinander um 10 Prozentpunkte erhöht und verringert. Die Gewichte der übrigen Hauptkriterien werden dabei im bisherigen Verhältnis angepasst, sodass die Summe weiterhin 100 % beträgt. Bleibt die Rangfolge der Modelle dabei stabil, kann das Ergebnis als robust betrachtet werden.

5 Evaluationsdurchführung

In diesem Kapitel wird beschrieben, wie die in Kapitel 4 festgelegte Evaluation praktisch umgesetzt wurde. Anschließend werden die Ergebnisse der Stichprobenanalysen dargestellt, in der Bewertungsmatrix zusammengeführt und analysiert. Am Ende des Kapitels wird die Forschungsfrage beantwortet.

5.1 Durchführung der Tests

Für jedes untersuchte Modell wurde in Microsoft Copilot Studio ein eigener Agent angelegt. Alle Agenten erhielten denselben Prompt und dieselbe Konfiguration, sodass sich die Agenten ausschließlich im zugrunde liegenden Sprachmodell unterscheiden. Der Prompt wurde zuvor anhand von fünf separaten Rechnungen mit Freigaben entwickelt und vor Beginn der Tests eingefroren. Am eigentlichen Testdatensatz wurden danach keine Anpassungen mehr vorgenommen. Damit wird vermieden, dass der Prompt auf die Testdaten optimiert wird und die Ergebnisse dadurch zu positiv ausfallen. Der finale Prompt befindet sich in Anhang [XX].

Untersucht wurden die Modelle [Modell A], [Modell B] und [Modell C] (Stand der Modellversionen: [Datum]). Die Tests wurden im Zeitraum vom [XX] bis [XX] durchgeführt.

Die Durchführung erfolgte automatisiert über einen Flow in Power Automate. Der Flow übergibt jede Rechnung des Testdatensatzes an den jeweiligen Agenten und trägt dessen Antwort zusammen mit Zeitstempel, Modell und Laufnummer in eine Excel Tabelle ein. Diese Antworten werden anschließend automatisch mit der Abgleichstabelle (Ground Truth) verglichen. Aus dem Abgleich ergibt sich für jede Rechnung, ob es sich um ein True Positive (TP), False Positive (FP), True Negative (TN) oder False Negative (FN) handelt.

Für die Einordnung als TP reicht es nicht aus, dass eine Rechnung als Exception markiert wurde. Zusätzlich wird der vom Modell genannte Grund für die Exception mit dem in der Ground Truth hinterlegten Grund verglichen. Nur wenn beide übereinstimmen, wird die Antwort als TP gewertet. Weicht der Grund ab, wird der Fall einzeln betrachtet und entschieden. Alle Einzelfallentscheidungen wurden ohne Kenntnis des jeweiligen Modells getroffen und sind mit Begründung in Anhang [XX] dokumentiert.

festgelegte Regel für richtige Markierung mit falschem Grund nennen

Zur Messung der Konsistenz wurde jede Rechnung pro Modell [n] Mal ausgewertet. Die Konsistenz ergibt sich aus dem Anteil der Rechnungen, bei denen das Modell in allen Durchläufen zum gleichen Ergebnis kam.

Ergänzend wurden die Antworten von [XX] Senior Auditoren anhand eines einheitlichen Bewertungsbogens beurteilt (siehe Anhang [XX]). Damit die Bewertung nicht durch die Erwartung an ein bestimmtes Modell beeinflusst wird, wurden die Modellnamen vorher entfernt. Die Übereinstimmung zwischen den Bewertenden wurde mit [Krippendorffs Alpha] geprüft.

Während der Durchführung zeigten sich zwei technische Auffälligkeiten. Erstens wurden die Freigabescreenshots in den Rechnungsunterlagen häufig nicht erkannt und konnten deshalb nicht ausgelesen werden. Zweitens werden PNG Dateien im Chatfenster von Copilot Studio gar nicht verarbeitet. Diese Einschränkungen betreffen alle Modelle gleichermaßen und werden in Abschnitt 5.5 bei der Interpretation berücksichtigt.

5.2 Ergebnisse der Stichprobenanalysen

Im Folgenden werden die Ergebnisse getrennt nach Anwendungsfall dargestellt. Dieser Abschnitt beschreibt die Ergebnisse zunächst ohne Bewertung. Die Interpretation folgt in Abschnitt 5.5.

5.2.1 Rechnungen

Der Testdatensatz umfasst 100 Rechnungen, von denen laut Ground Truth [XX] eine Exception enthalten. Tabelle 5.1 zeigt die Verteilung der Ergebnisse je Modell, Tabelle 5.2 die daraus berechneten Kennzahlen.

Tabelle 5.1: Konfusionswerte je Modell für den Anwendungsfall Rechnungen

Modell	TP	FP	TN	FN
[Modell A]	[XX]	[XX]	[XX]	[XX]
[Modell B]	[XX]	[XX]	[XX]	[XX]
[Modell C]	[XX]	[XX]	[XX]	[XX]

Den höchsten F1 Score erreicht [Modell], den niedrigsten [Modell].

ggf. zusätzlich Fleiss' Kappa über die Durchläufe

Anzahl betroffener Rechnungen und Umgang damit in der Auswertung, z. B. Ausschluss oder Wertung als Fehler

auffällige Unterschiede zwischen Precision und Recall be-

Tabelle 5.2: Kennzahlen je Modell für den Anwendungsfall Rechnungen

Modell	Precision	Recall	Accuracy	F1 Score	Konsistenz

5.2.2 Benutzerberechtigungen

Datengrund für Benutzerberechtigungen kurz nennen: Anzahl Fälle, Anzahl Exceptions laut Ground Truth, was als Exception gilt

Tabelle 5.3: Kennzahlen je Modell für den Anwendungsfall Benutzerberechtigungen

Modell	Precision	Recall	Accuracy	F1 Score	Konsistenz

5.2.3 Gesamtvergleich

Tabelle 5.4 fasst die Kennzahlen beider Anwendungsfälle zusammen.

Tabelle 5.4: Gesamtvergleich der Modelle über beide Anwendungsfälle

Modell	Precision	Recall	Accuracy	F1 Score	Konsistenz

Die Ergebnisse der Senior Auditoren sind in Tabelle [XX] dargestellt. Die Übereinstimmung zwischen den Bewertenden liegt bei [XX], was nach [Quelle] als [gering/mittel/hoch] einzustufen ist.

5.3 Auswertung der Bewertungsmatrix

Ergebnisse beschreiben, Unterschiede zum Anwendungsfall Rechnungen benennen

Die Ergebnisse aus Abschnitt 5.2 fließen nun in die Nutzwertanalyse ein. Die Kriterien und ihre Gewichtung wurden bereits in Kapitel 4 vor der Durchführung der Tests festgelegt und wurden danach nicht verändert. Für jedes Kriterium wurden die gemessenen Werte in Punkte auf einer Skala von [1 bis 5] überführt. Multipliziert mit der jeweiligen Gewichtung ergibt sich der Nutzwert je Modell.

Um zu prüfen, wie stark das Ergebnis von der gewählten Gewichtung abhängt, wurde eine Sensitivitätsanalyse durchgeführt. Dabei wurden die Gewichte der Kriterien jeweils um [XX] Prozentpunkte verändert.

festlegen, ob über alle Fälle gemein-

Tabelle 5.5: Bewertungsmatrix der Nutzwertanalyse

Kriterium	Gewicht	[Modell A]	[Modell B]	[Modell C]
Nutzwert	100 %	[XX]	[XX]	[XX]

5.4 Vergleich der Modelle

[Modell] erreicht mit [XX] Punkten den höchsten Nutzwert, gefolgt von [Modell] und [Modell].

Auffällig ist .

5.5 Analyse der Ergebnisse

Bei der Interpretation sind mehrere Einschränkungen zu beachten. Der Testdatensatz ist mit 100 Rechnungen eher klein, sodass bereits wenige abweichende Fälle die Kennzahlen deutlich verändern. Die Untersuchung fand ausschließlich innerhalb von Copilot Studio statt. Die beschriebenen Probleme beim Auslesen der Freigabescreenshots und bei PNG Dateien sind daher eher eine Grenze der Plattform als der Modelle selbst, beeinflussen aber die gemessenen Ergebnisse. Zudem beruht die Bewertung der Senior Auditoren auf subjektiven Einschätzungen, deren Aussagekraft von der Übereinstimmung der Bewertenden abhängt. Schließlich bilden die Ergebnisse den Stand der Modellversionen zum Zeitpunkt der Tests ab und können sich mit neuen Versionen ändern.

5.6 Beantwortung der Forschungsfrage

Die Forschungsfrage dieser Arbeit lautet: *Wie unterscheiden sich verschiedene LLMs hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit-Bereich?*

Die Ergebnisse zeigen, dass sich die untersuchten Modelle vor allem in unterscheiden. xyz eignet sich nach der Nutzwertanalyse am besten für den Einsatz im Internal Audit bei Freudenberg.

Stärken und Schwächen je Modell in wenigen Sätzen gegenüberstellen, z. B. hohe Precision bei geringerer Konsistenz

z. B. Abweichung zwischen messbaren Kennzahlen und Einschätzung der Senior Audito-

6 Fazit und Ausblick

6.1 Zusammenfassung der wichtigsten Erkenntnisse

6.2 Fazit zur Eignung von LLMs im Audit

6.3 Handlungsempfehlungen für Freudenberg

6.4 Zukünfige Entwicklungspotenziale

A Prompts

Literatur

Anthropic (2026). *Reduce hallucinations*. URL: https://platform.claude.com/docs/en/test-and-evaluate/strengthen-guardrails/reduce-hallucinations (besucht am 02. 10. 2026).

Artificial Analysis (2026). *Comparison of AI Models across Intelligence, Performance, and Price*. Artificial Analysis. URL: https://artificialanalysis.ai/models (besucht am 11. 08. 2026).

Baumeister, Daniel (2019). „Sample size and error containment judgments in non-statistical audit sampling-the sensivity of auditors to a revision of professional standards". Diss. Dissertation, Dortmund, Technische Universität, 2019.

Calvino, Flavio, Daniel Haerle und Sarah Liu (Juni 2025). *Is generative AI a General Purpose Technology? Implications for productivity and policy*. OECD Artificial Intelligence Papers 40. Paris: OECD Publishing. DOI: 10.1787/704e2d12-en. URL: https://www.oecd.org/content/dam/oecd/en/publications/reports/2025/06/is-generative-ai-a-general-purpose-technology_6c76e7b2/704e2d12-en.pdf.

Cantù, Elena, Cecilia Langella und Ilaria Elisa Vannini (2025). „Making sense of the internal audit function: toward internal controls integration and organizational learning". In: *Financial Accountability & Management* 41.2, S. 262–273.

DataSnipper (2026a). *DataSnipper AI*. Abgerufen am 12. Oktober 2026. DataSnipper. URL: https://www.datasnipper.com/product/ai (besucht am 12. 10. 2026).

– (2026b). *About DataSnipper*. URL: https://datasnipper.com/about-us (besucht am 09. 10. 2026).

DeepLearning.AI (o. D.). *Artificial Analysis Revamps Intelligence Index: Independent AI Testing Authority Turns from Saturated Knowledge Benchmarks to Harder Business Tests*. https://www.deeplearning.ai/the-batch/independent-ai-testing-authority-turns-from-saturated-knowledge-benchmarks-to-harder-business-tests. Abgerufen am 08.10.2026.

Emett, Scott et al. (2025). „Leveraging ChatGPT for enhancing the internal audit process—a real-world example from Uniper, a large multinational company". In: *Accounting Horizons* 39.2, S. 125–135.

Fedyk, Anastassia et al. (2022). „Is artificial intelligence improving the audit process?" In: *Review of Accounting Studies* 27.3, S. 938–985. DOI: 10.1007/s11142-022-09697-x.

Feuerriegel, Stefan et al. (2024). „Generative AI". In: *Business & Information Systems Engineering* 66.1, S. 111–126. DOI: 10.1007/s12599-023-00834-7.

Freudenberg, Corporate Audit (2026). „Internal Audit Sample Testing Guidance Examples". Interne Excel-Datei, Freudenberg & Co. KG.

Freudenberg & Co. KG (2026). „Verfügbare Modelle im Microsoft Copilot und im Copilot Studio". Interne Systemkonfiguration, Stand: Oktober 2026.

G2 (2026). *DataSnipper Reviews 2026: Details, Pricing & Features*. URL: https://www.g2.com/products/datasnipper/reviews (besucht am 06. 08. 2026).

Gartner Peer Insights (2026). *DataSnipper Reviews, Ratings & Features 2026*. Gartner, Inc. URL: https://www.gartner.com/reviews/market/artificial-intelligence/vendor/datasnipper (besucht am 06. 08. 2026).

Huang, Lei et al. (2025). „A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions". In: *ACM transactions on information systems* 43.2, S. 1–55.

Ivakhnenkov, Serhii (2023). „Artificial intelligence application in auditing". In.

Ji, Ziwei et al. (2023). „Survey of Hallucination in Natural Language Generation". In: *ACM Computing Surveys* 55.12, S. 1–38. DOI: 10.1145/3571730.

Kapoor, Sayash et al. (2024). „Position: On the Societal Impact of Open Foundation Models". In: *Proceedings of the 41st International Conference on Machine Learning*. Bd. 235. Proceedings of Machine Learning Research. PMLR, S. 23082–23104. URL: https://proceedings.mlr.press/v235/kapoor24a.html.

Kokina, Julia et al. (2025). „Challenges and opportunities for artificial intelligence in auditing: Evidence from the field". In: *International Journal of Accounting Information Systems* 56, S. 100734. ISSN: 1467-0895. DOI: https://doi.org/10.1016/j.accinf.2025.100734. URL: https://www.sciencedirect.com/science/article/pii/S1467089525000107.

Kozłowska, Justyna (2022). „Methods of Multi-Criteria Analysis in Technology Selection and Technology Assessment: A Systematic Literature Review". In: *Engineering Management in Production and Services* 14.2, S. 116–137. DOI: 10.2478/emj-2022-0021.

Kühnapfel, Jörg B. (2021). *Scoring und Nutzwertanalysen: Ein Leitfaden für die Praxis*. 2. Wiesbaden: Springer Gabler. DOI: 10.1007/978-3-658-34810-6.

Kyriazos, Theodoros und Mary Poga (2024). „Application of Machine Learning Models in Social Sciences: Managing Nonlinear Relationships". In: *Encyclopedia* 4.4, S. 1790–1805. DOI: 10.3390/encyclopedia4040118.

Liang, Percy et al. (2023). *Holistic Evaluation of Language Models*. arXiv: 2211.09110 [cs.CL]. URL: https://arxiv.org/abs/2211.09110.

Liu, Nelson F. et al. (2024). „Lost in the Middle: How Language Models Use Long Contexts". In: *Transactions of the Association for Computational Linguistics* 12, S. 157–173. DOI: 10.1162/tacl_a_00638.

Lyell, David und Enrico Coiera (2017). „Automation bias and verification complexity: a systematic review". In: *Journal of the American Medical Informatics Association* 24.2, S. 423–431.

Microsoft (2026a). *Daten, Datenschutz und Sicherheit für Microsoft Copilot*. Microsoft Learn. URL: https://learn.microsoft.com/de-de/microsoft-365/copilot/microsoft-365-copilot-privacy (besucht am 08. 10. 2026).

– (11. Mai 2026b). *Schreiben effektiver Anweisungen für deklarative Agents*. URL: https://learn.microsoft.com/en-us/microsoft-365/copilot/extensibility/declarative-agent-instructions (besucht am 02. 10. 2026).

Munoko, Ivy, Helen L. Brown-Liburd und Miklos Vasarhelyi (2020). „The Ethical Implications of Using Artificial Intelligence in Auditing". In: *Journal of Business Ethics* 167.2, S. 209–234. DOI: 10.1007/s10551-019-04407-1.

Panda, Silu (2026). *FinVerBench: Evaluating Large Language Models on Numerical Consistency Verification of Financial Statements*. Preprint, eingereicht am 28.05.2026. DOI: 10.48550/arXiv.2605.29586. arXiv: 2605.29586 [cs.CL]. URL: https://arxiv.org/abs/2605.29586 (besucht am 07. 09. 2026).

Roussy, Mélanie (2013). „Internal auditors' roles: From watchdogs to helpers and protectors of the top manager". In: *Critical Perspectives on Accounting* 24.7, S. 550–571. ISSN: 1045-2354. DOI: https://doi.org/10.1016/j.cpa.2013.08.004. URL: https://www.sciencedirect.com/science/article/pii/S1045235413000932.

Sapkota, Ranjan, Konstantinos I. Roumeliotis und Manoj Karkee (2026). „AI Agents vs. Agentic AI: A Conceptual Taxonomy, Applications and Challenges". In: *Information Fusion* 126, S. 103599. DOI: 10.1016/j.inffus.2025.103599.

Schreyer, Marco et al. (2024). *Artificial Intelligence Agentic Auditing*. SSRN Working Paper. DOI: 10.2139/ssrn.4909147. URL: https://ssrn.com/abstract=4909147.

Schulhoff, Sander et al. (2025). *The Prompt Report: A Systematic Survey of Prompt Engineering Techniques*. arXiv: 2406.06608 [cs.CL]. URL: https://arxiv.org/abs/2406.06608.

Schumann, Gerrit und Jorge Marx Gómez (2021). „Natural language processing in internal auditing–A structured literature review". In.

Sclar, Melanie et al. (2024). „Quantifying Language Models'Sensitivity to Spurious Features in Prompt Design or: How I learned to start worrying about prompt formatting". In: *International Conference on Learning Representations*. Hrsg. von B. Kim et al. Bd. 2024, S. 25055–25083. URL: https://proceedings.iclr.cc/paper_files/paper/2024/file/6c0e99d736da621403018ca7b32b1a4d-Paper-Conference.pdf.

Shi, Freda et al. (2023). „Large Language Models Can Be Easily Distracted by Irrelevant Context". In: *Proceedings of the 40th International Conference on Machine Learning*. Bd. 202. Proceedings of Machine Learning Research. URL: https://arxiv.org/abs/2302.00093.

The Institute of Internal Auditors (2024). *Global Internal Audit Standards*. Accessed: 2026-09-02. Lake Mary, FL: The Institute of Internal Auditors. URL: https://www.theiia.org/globalassets/site/standards/globalinternalauditstandards_2024january9.pdf.

Wassie, Fekadu Agmas und László Péter Lakatos (2024). „Artificial intelligence and the future of the internal audit function". In: *Humanities and Social Sciences Communications* 11.1, S. 386.

YourAIFinder (2026). *DataSnipper – AI Audit Automation Platform Inside Excel*. URL: https://youraifinder.com/tool/datasnipper (besucht am 06. 08. 2026).

Hilfsmittelangabe zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten

DHBW
Duale Hochschule
Baden-Württemberg

Persönliche Angaben

Verclas, Leonard	3317974
Nachname, Vorname	Matrikelnummer
Gaußstrasse 5, 68775 Ketsch	WDSKI24B
Anschrift	Kurs
S242792@student.dhbw-mannheim.de	0176 45895734
E-Mail	Telefon- / Handynummer

Für das Modul

Praxismodul 2

Modulbezeichnung / Semester

muss ich am

09.11.2026

Datum der Frist

folgende Prüfungsleistung erbringen:

☐ Projektarbeit I ☒ Projektarbeit II

☐ Seminararbeit ☐ Bachelorarbeit

☐ Sonstige

genaue Bezeichnung der sonstigen Prüfungsleistung

Zur Verwendung KI-gestützter Werkzeuge erkläre ich in Kenntnis des Hinweisblatts "Hinweise zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung wissenschaftlicher Arbeiten und die prüfungsrechtlichen Folgen ihres Einsatzes" Folgendes:

- **Ich habe mich aktiv über die Leistungsfähigkeit und Beschränkungen der in meiner Arbeit eingesetzten KI-Werkzeuge informiert.**
- **Bei der Anfertigung der Prüfungsleistung habe ich durchgehend eigenständig und beim Einsatz KI-gestützter Werkzeuge maßgeblich steuernd gearbeitet.**
- **Insbesondere habe ich die Inhalte entweder aus wissenschaftlichen oder anderen zugelassenen Quellen entnommen und diese gekennzeichnet oder diese unter Anwendung wissenschaftlicher Methoden selbst entwickelt.**
- **Mir ist bewusst, dass ich als Autor/in der Arbeit die Verantwortung für die in ihr gemachten Angaben und Aussagen trage.**
- **Ich habe keine weiteren als die nachstehend von mir benannten KI-gestützten Werkzeuge zur Erstellung der Arbeit eingesetzt und diese nur in der angegebenen Art und Weise.**

- **Soweit ich KI-gestützte Werkzeuge zur Erstellung der Arbeit eingesetzt habe, gebe ich diese in der nachstehenden "Übersicht verwendeter Hilfsmittel" mit ihrem Produktnamen und ihres genutzten Funktionsumfangs vollständig an; wörtliche oder sinngemäße Übernahmen KI-generierter Inhalte habe ich in ein separates Verzeichnis aufgenommen und im Text belegt (z. B. als Fußnote). Diese Inhalte sind als pdf-Datei in den elektronischen Beigaben hinterlegt.**

Produktname(n) eingesetzter Hilfsmittel:

Genutzter Funktionsumfang im Hinblick auf

- **Themenerfassung und Strukturierung** (Aufgabenstellung oder Präzisierung, Forschungsansatz, Gliederung)

- **Themenbearbeitung** (Darstellung/Beschreibung des Problems, Darlegung von wissenschaftlichen Grundlagen, Schlussfolgerungen allgemein und für das konkrete Thema / Erkenntnisgewinn, Evaluierung des Textes / Feedback der KI)

- **Quellenrecherche, -auswahl und -auswertung** (welche Quellen wurden durch das KI-Werkzeug gefunden, wie erfolgte die weitere Recherche)

- **Formale Gestaltung, insbesondere Sprache** (Welche Eingabe wurde an die KI getätigt? Textgenerierung, Textkorrektur, Paraphrasieren und Umschreiben, Übersetzen, kreatives Schreiben)

Hinweis:

Geben Sie in der jeweiligen Rubrik die Seitenzahl in ihrer wissenschaftlichen Arbeit an und erläutern Sie die Art und Weise sowie den Umfang der von Ihnen genutzten KI-basierten Werkzeuge.

Ort, Datum **Unterschrift der/des Studierenden**