

Duale Hochschule Baden-Württemberg Mannheim

Projektarbeit 2

Einsatz von LLMs zur Unterstützung von Stichprobenanalysen im Audit-Bereich. Ein Vergleich verschiedener KI-Modelle hinsichtlich ihrer Eignung für interne Prüfungsprozesse bei der Freudenberg Group

Studiengang Wirtschaftsinformatik

Studienrichtung Data Science und Künstliche Intelligenz

Verfasser(in):	Leonard Verclas
Matrikelnummer:	3317974
Firma:	Freudenberg & Co. Kommanditgesellschaft
Kurs:	WDSKI24B
Studiengangsleiter:	Prof. Dr. Bernhard Drabant
Wissenschaftliche(r) Betreuer(in):	Stefanie Bell
Firmenbetreuer(in):	Andreas Hass
Bearbeitungszeitraum:	03.08.2026 - 09.11.2026

1. Erstellen von fehlerhaften Rechnungen und Tickets (Orientierung an historischen Auditfällen)
2. Modelle analysieren Dokumente
3. Anwendung der Bewertungsmatrix
4. Punktesystem auf Bewertungsmatrix anwenden
5. Auswertung der Ergebnisse
6. Zusätzlich: Modelle auf historische Ereignisse prüfen, bzw. historische Ereignisse nochmals auf Fehler überprüfen

Erreichung von Prüfungseffizienz im Audit Stichproben -> Die Handlungsalternative, mit der ein hinreichend sicheres Prüfungsurteil mit dem vermutlich geringsten Mitteleinsatz erreicht werden kann. Prüfungseffizienz durch Integration statistischer Gesetzmäßigkeiten in den Prüfungsansatz.

Grundgesamtheit: abgegrenzte Menge von gleichartiger Elemente (gleiches Konto zu verschiedenen Rechnungen) (vgl. Baumeister 2019, S.11)

Stichprobenrisiko erklärt: (vgl. Baumeister 2019, S.12) und detailliert S. 40 ff.

herausforderungen und möglichkeiten künstlicher Intelligenz im Auditbereich:

Möglichkeiten:

Große datenmengen anstelle von stichproben durch schnellere Bearbeitung. Herausfiltern von wichtigen Kennzahlen, wie kosten, vertragspartner etc. -> Pflichtproben herausfiltern, die menschliche oder maschinelle Prüfung benötigen. (vgl. (Kokina et al. 2025, S.3))

Anomalieerkennung -> z.b. finanzielle Informationen (vgl. (Kokina et al. 2025, S.2))

Herausforderungen:

Transparenz und Erklärbarkeit - Auditoren und Regulatoren müssen verstehen können, warum wurde eine Entscheidung getroffen, wie ist ein Ergebnis zustande gekommen? (Kokina et al. 2025, S.16)

Robustheit und Zuverlässigkeit - Es muss nachweisbar sein, dass die Ergebnisse reproduzierbar sind, das Modelle stabil arbeiten und kein Model drift stattfindet (Kokina et al. 2025, S. 13 f.)

Übermäßiges Vertrauen an die KI - Auditoren müssen Ergebnisse immernoch professional skeptisch auditieren. Die KI darf nur als Unterstützer gelten. Die finale Entscheidung bleibt beim Auditor. Durch den Einsatz von KI kann es hier zu AutomationBias führen. Hierbei kann es dazu kommen, dass Auditoren Fehler übersehen, weil das System keine gemeldet hat. (Lyell und Coiera 2017, S.425 f.)

Inhaltsverzeichnis

Abbildungsverzeichnis	iv
Tabellenverzeichnis	v
Quelltextverzeichnis	vi
Abkürzungsverzeichnis	vii
Kurzfassung (Abstract)	viii
1 Einleitung	1
1.1 Problemstellung & Motivation	1
1.2 Zielsetzung der Arbeit	2
1.3 Aufbau der Arbeit	2
2 Grundlagen	3
2.1 Audit	3
2.2 Stichprobenanalyse im Audit	3
2.3 Künstliche Intelligenz	4
2.3.1 Large Language Models	4
2.3.2 Prompt Engineering	4
2.4 Einsatz von Künstlicher Intelligenz im Audit	4
2.4.1 Potenziale in der Stichprobenanalyse	4
2.4.2 Chancen und Risiken	4
2.4.3 KI-gestützte Audit-Lösungen	4
3 State of the Art	5
3.1 Aktuelle Durchführung von Stichprobenanalyse bei Freudenberg	5
3.2 Einsatz von KI im Auditbereich	6
3.3 Verfügbare KI-Lösungen für Audits	6
3.3.1 Kommerzielle Lösungen	7
3.3.2 Open-Source-Lösungen	7
3.3.3 Spezialisierte KI-gestützte Audit-Lösung	7
3.4 Einordnung des KI-Einsatzes bei Freudenberg	8
4 Evaluationsdesign	9
4.1 Forschungsdesign	9

4.2	Auswahl der zu untersuchende Modelle	9
4.3	Entwicklung der Testdatensätze	10
4.4	Entwicklung eines geeigneten Prompts	10
4.5	Nutzwertanalyse	10
4.6	Entwicklung einer Bewertungsmatrix	11
4.7	Gewichtung der Bewertungsmatrix	13
5	Evaluationsdurchführung	14
5.1	Durchführung der Tests	14
5.2	Ergebnisse der Stichprobenanalysen	14
5.2.1	Rechnungen	14
5.2.2	Benutzerberechtigungen	14
5.2.3	Gesamtvergleich	14
5.3	Auswertung der Bewertungsmatrix	14
5.4	Vergleich der Modelle	14
5.5	Analyse der Ergebnisse	14
5.6	Beantwortung der Forschungsfrage	14
6	Fazit und Ausblick	15
6.1	Zusammenfassung der wichtigsten Erkenntnisse	15
6.2	Fazit zur Eignung von LLMs im Audit	15
6.3	Handlungsempfehlungen für Freudenberg	15
6.4	Zukünftige Entwicklungspotenziale	15
Anhang		
A	Prompts	16
A.1	Prompt GPT	16
A.2	Prompt Claude	17
Literatur		20

Abbildungsverzeichnis

Tabellenverzeichnis

Quelltextverzeichnis

Abkürzungsverzeichnis

DHBW	Duale Hochschule Baden-Württemberg
LLM	Large Language Model
KI	Künstliche Intelligenz

Kurzfassung (Abstract)

1 Einleitung

1.1 Problemstellung & Motivation

Mit der fortschreitenden Entwicklung Künstliche Intelligenz (KI) stehen Unternehmen vor der Herausforderung, ihre Geschäftsprozesse kontinuierlich zu optimieren und durch den gezielten Einsatz neuer Technologien effizienter zu gestalten. Insbesondere im Audit-Umfeld bietet der Einsatz von KI ein erhebliches Potenzial zur Steigerung von Effizienz, Prüfungsqualität und Transparenz. KI unterstützt interne Auditoren, indem der manuelle Analyseaufwand reduziert wird und umfassendere sowie schnellere Prüfungen ermöglicht werden. (vgl. Wassie und Lakatos 2024, S. 11–12).

Ein besonders vielversprechendes Anwendungsfeld stellt die Analyse von Audit-Stichproben dar. Im Rahmen dieser Prüfungen werden Rechnungen und Benutzerberechtigungen untersucht, um Auffälligkeiten, Regelverstöße oder potenzielle Risiken zu identifizieren. Die manuelle Analyse dieser Unterlagen ist jedoch zeitaufwendig und bindet erhebliche personelle Ressourcen. Gleichzeitig steigt aufgrund wachsender Datenmengen und zunehmend komplexer Geschäftsprozesse die Schwierigkeit, relevante Auffälligkeiten zuverlässig zu erkennen.

Vor diesem Hintergrund gewinnt die Unterstützung von Stichprobenanalysen durch KI-basierte Verfahren zunehmend an Bedeutung. Für die Freudenberg-Gruppe stellt sich dabei die Frage, wie KI-Technologien gewinnbringend in die Stichprobenanalyse im Internal-Audit-Prozess integriert werden können. Neben der Verbesserung der Effizienz und Prüfungsqualität durch den Einsatz Künstlicher Intelligenz spielt insbesondere die Einhaltung strenger Datenschutz- und Compliance-Anforderungen sowie die Auswahl eines geeigneten KI-Modells für die Analyse von Audit-Dokumenten eine zentrale Rolle. Daraus ergibt sich die Notwendigkeit, die Eignung verschiedener KI-Lösungen für die Unterstützung von Stichprobenanalysen im Internal Audit systematisch zu untersuchen.

1.2 Zielsetzung der Arbeit

Ziel dieser Projektarbeit ist die systematische Untersuchung und Bewertung verschiedener KI-gestützter Werkzeuge zur Unterstützung von Stichprobenanalysen im Internal Audit der Freudenberg-Gruppe. Der Fokus liegt dabei auf Large Language Model (LLM), die Auditoren bei der Analyse von Prüfungsdokumenten unterstützen können. Hierzu werden ausgewählte LLMs auf identische Audit-Stichproben angewendet. Die Modelle sollen potenzielle Auffälligkeiten, Risiken oder Regelverstöße in Dokumenten wie Rechnungen, User-Provisioning-Vorgängen und Verträgen identifizieren sowie ihre Bewertungen nachvollziehbar begründen. Anschließend werden die Ergebnisse anhand definierter Bewertungskriterien miteinander verglichen. Dabei stehen insbesondere die Erkennungsqualität, die Nachvollziehbarkeit der Ergebnisse, die Konsistenz der Analysen sowie die praktische Einsetzbarkeit im Audit-Umfeld im Vordergrund. Auf Basis dieser Untersuchung soll ermittelt werden, welches KI-Modell die Anforderungen der Freudenberg-Gruppe im Kontext von Stichprobenanalysen im Internal Audit am besten erfüllt. Die gewonnenen Erkenntnisse sollen eine fundierte Grundlage für die Bewertung des Potenzials von LLMs im Audit-Bereich sowie für deren zukünftigen Einsatz innerhalb der Organisation schaffen. Daraus ergibt sich folgende Forschungsfrage: Wie unterscheiden sich verschiedene Large Language Models hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit-Bereich?

1.3 Aufbau der Arbeit

2 Grundlagen

2.1 Audit

Das Audit stellt eine unabhängige Prüfungsfunktion innerhalb einer Organisation dar. Die zentrale Aufgabe besteht darin die angemessene Wirksamkeit von Governance- und internen Kontrollsystemen zu bewerten und hierzu objektive Prüfungs und Beratungsleistungen bereitzustellen. (vgl. Cantù, Langella und Vannini 2025, S. 263 - 264)

Aufgaben, Ziele, Bedeutung von Stichprobenanalyse, aktuelle Herausforderungen

2.2 Stichprobenanalyse im Audit

Die Stichprobenanalyse ist eine Prüfungsmethode im Audit-Bereich. Hierbei wird versucht eine Möglichst hohe Prüfungseffizienz zu erreichen. Daher soll die Handlungsalternative gewählt werden, die mit dem geringsten Mitteleinsatz ein hinreichend sicheres Prüfungsurteil erreicht. Aus einer Grundgesamtheit wird hierbei eine Pflichtprobe als auch eine zufällige Menge an Stichproben herausgezogen. Die Grundgesamtheit beschreibt hierbei eine abgegrenzte Menge gleichartiger Elemente. Zum Beispiel alle Rechnungen, die zu einem Konto gehören. Die Pflichtprobe sind Elemente, die bestimmte Kriterien erfüllen, beispielsweise unbekannte Konten oder Rechnungen, die über einem bestimmten Betrag liegen (vgl. Freudenberg 2026). Diese Elemente müssen als Teil der Stichprobe geprüft werden. Weitergehend wird aus den restlichen Elementen der Grundgesamtheit eine zufällige Stichprobe entnommen, welche zusätzlich der Pflichtprobe geprüft wird. Die restlichen Elemente der Grundgesamtheit, die vorerst nicht geprüft werden und damit bei Prüfungsaussagen eine gewisse Toleranz bieten gelten als Stichprobenrisiko (vgl. Baumeister 2019, S.11 - 12).

2.3 Künstliche Intelligenz

2.3.1 Large Language Models

2.3.2 Prompt Engineering

Das Prompt Engineering beschreibt den wichtigsten Part der Nutzung eines KI-Systems. Erst durch den Prompt weiß die Maschine was der User erreichen möchte. Ein Prompt kann in verschiedenen klar definierte Teile unterteilt sein.

2.4 Einsatz von Künstlicher Intelligenz im Audit

2.4.1 Potenziale in der Stichprobenanalyse

2.4.2 Chancen und Risiken

2.4.3 KI-gestützte Audit-Lösungen

DataSnipper

3 State of the Art

3.1 Aktuelle Durchführung von Stichprobenanalyse bei Freudenberg

Aktuell folgen die Stichprobenanalysen im Internal Audit bei Freudenberg einer strukturierten und risikoorientierten Vorgehensweise. Der Prozess lässt sich exemplarisch anhand der Prüfung von Lieferantenrechnungen ohne Bestellbezug beschreiben und ist grundsätzlich auf weitere Anwendungsfälle übertragbar. Zunächst wird eine Grundgesamtheit relevanter Objekte definiert, beispielsweise aller im Prüfungszeitraum erfassten Rechnungen ohne Bestellnummer. Anschließend wird diese Grundgesamtheit anhand definierter Kriterien, wie Rechnungswert, Lieferant, manueller Buchung oder weiterer risikorelevanter Merkmale, kategorisiert und analysiert.

Auf Basis dieser Klassifizierung wird ein Threshold festgelegt. Alle Rechnungen, die diesen Schwellenwert überschreiten, werden verpflichtend in die Stichprobe aufgenommen. Ergänzend dazu wird eine zufällige Auswahl weiterer Rechnungen aus der verbleibenden Grundgesamtheit getroffen, um eine angemessene Abdeckung des Prüffeldes sicherzustellen.

Die ausgewählten Stichprobenelemente werden anschließend durch den Auditor einer detaillierten Prüfung unterzogen. Hierbei werden sämtliche für die Bewertung relevanten Informationen und Nachweisdokumente gesammelt, geprüft und dokumentiert. Nach Abschluss der Analyse bewertet der Auditor die Ergebnisse hinsichtlich möglicher Auffälligkeiten, Abweichungen oder Regelverstöße. Werden Unregelmäßigkeiten festgestellt, werden diese dokumentiert und als Audit Exceptions erfasst.

Durch die Kombination aus risikobasierter Auswahl und zufälliger Stichprobenziehung wird sichergestellt, dass sowohl potenziell kritische Transaktionen als auch repräsentative Elemente der Grundgesamtheit in die Prüfung einbezogen werden. Dadurch kann mit vertretbarem Prüfungsaufwand ein hohes Maß an Prüfungssicherheit erreicht werden. (vgl. (Freudenberg 2026))

3.2 Einsatz von KI im Auditbereich

Forschungsstand, vergleichbare studien, andere Unternehmen

3.3 Verfügbare KI-Lösungen für Audits

Auswahlverfahren basierend auf AI Benchmarks:

Modell muss Dokumente interpretieren, Belege verknüpfen, Inkonsistenzen finden, Schlussfolgerungen begründen

Intelligence Index: aggregiert mehrere Test, GPQA (5 Sterne) , Humanity's Last Exam (5 Sterne), Browse Comp (4 Sterne), SimpleQA (4 Sterne), MRCR (4 Sterne), SciCode (2 Sterne) etc. -> allgemeiner Index

Agentic Index: nutzen wir agenten?

Context Window -> Audit prüfung viele dateien und Daten -> je größer, desto mehr Dokumente können gleichzeitig verarbeitet werden

Coding Index -> Excel-Datei analysieren? Stichproben automatisch ziehen?

Cost per Task -> in vergleich zu den oben stehenden benchmarks

wenig relevant : speed, latency, output tokens

Intelligence Index: Opus 5 , Fable 5, GPT 5.6, Kimi K3, Grok 4.5, Sonnet 5, GLM 5.2

Intelligence Index vs. Cost per Intelligence Index Task:

DeepSeek V4 Flash, GPT-5.6(Luna), Grok 4.5, Kimi K3

Context Window: Kimi K3, GPT 5.6 (Luna, Terra, Sol) GLM 5.2, Sonnet 5, Haiku 4.5, Opus 5, Fable 5

(Artificial Analysis 2026)

3.3.1 Kommerzielle Lösungen

- Microsoft Copilot (Audit hat Zugriff): GPT 5.6 (nicht klar, ob sol, terra, luna), GPT 5.5 - Claude (Zuhause - keine sensiblen Daten (Daten selber erstellen)): Fable 5. Opus 5, Sonnet 5, Haiku 4.5 - Grok 4 - nur standard

3.3.2 Open-Source-Lösungen

Kimi K3 -> aber das kann man nirgendwo laufen lassen

Laptop (16 GB RAM) -> Qwen 3.5 PB, Phi-4 -> deutlich schlechter, wo kann ich das laufen lassen? LM studio zum manuellen testen OLLama zur python evaluierung

3.3.3 Spezialisierte KI-gestützte Audit-Lösung

Abseites von generativen LLMs gibt es spezialisierte KI-gestützte Audit-Lösungen. In dieser Arbeit wird DataSnipper als die Vergleichssoftware zu den herkömmlichen LLMs genutzt. DataSnipper erzielt an mehreren Rankings sehr gute Rankings unter KI-gestützten Audit-Lösungen und wird auch von den Big 4 als Audit-Tool verwendet, was das Tool zu einer der weit verbreitetsten spezialisierten KI-Lösungen im Audit-Bereich macht und eine hohe Marktrelevanz besitzt (vgl. G2 2026, Gartner Peer Insights 2026, YourAIFinder 2026). DataSnipper fungiert als Excel-Add-In und stellt verschiedene KI-Funktionen zur Unterstützung von Auditprozessen bereit. Im Gegensatz zu herkömmlichen LLMs wurde DataSnipper speziell für die Anforderungen von Audit- und Finance-Prozessen entwickelt. Zu den zentralen Funktionalitäten gehören die automatisierte Datenextraktion, der Abgleich von Dokumenten mit Arbeitspapieren, die Erstellung nachvollziehbarer Audit Trails sowie die KI-gestützte Analyse von Dokumenten. Darauf aufbauend gibt es erweiterte Funktionen durch sogenannte Excel Agent, die Audit Aufgaben innerhalb bestehender Workflows unterstützen. Ein wesentliches Merkmal ist der Human-in-the-Loop-Ansatz. Dbai übernimmt die Software repetitive Prüfungs- und Dokumentationsschritte, während fachliche Entscheidungen und die finale Bewertung weiterhin durch den Auditor erfolgt. Zudem bleibt jede Analyse mit den zugrunde liegenden Dokumenten verknüpft, wodurch eine hohe Nachvollziehbarkeit der Ergebnisse gewährleistet wird.

3.4 Einordnung des KI-Einsatzes bei Freudenberg

Die Freudenberg Gruppe nutzt aktuell gruppenweit die KI-Lösung von Microsoft Microsoft Copilot. Hierbei werden für alle Nutzer die Modelle GPT 4.5 und GPT 4.6 zur Verfügung gestellt. Der Copilot darf hierbei Zugriff auf alle internen Dokumente haben und bietet volle Datensicherheit- und integrität. Zusätzlich zum Microsoft Copilot gibt es für eine geringe Anzahl an Nutzern über GitHub Copilot die Möglichkeit auf begrenzte Ressourcen von Claude Sonnet und Claude Opus zuzugreifen. Hierbei lagte der Fokus jedoch auf der Software-Entwicklung. Die Anwendung auf den Auditbereich ist hierbei auf Grund von begrenzter Ressourcen nicht empfehlenswert.

4 Evaluationsdesign

Ziel, Anwendungsfall, Auswahlkriterien LLMs, Vorstellung ausgewählter LLMs, Evaluationsmetriken

4.1 Forschungsdesign

Um die Evaluation der für den Use Case am besten geeigneten Lösung durchzuführen wird eine Bewertungsmatrix aufgesetzt. Auf diese Matrix werden die Modelle GPT 5.3, GPT 5.5, Claude Sonnet 4.6, Claude Opus 4.6, Claude Opus 4.7 und Claude Opus 4.8 angewandt und anhand von definierten Kriterien anhand einer Bewertungsmatrix bewertet.

4.2 Auswahl der zu untersuchenden Modelle

Die Auswahl der zu untersuchenden Modelle basiert auf der aktuellen Nutzung von KI-Lösungen für die Freudenberg Gruppe. Wie in 3.4 beschrieben nutzt die Freudenberg Gruppe gruppenweit den Microsoft Copilot Premium Version und die dort ausgerollten Modelle von OpenAI und Anthropic.. Hierbei werden sowohl die internen Datenschutz- und Compliance Richtlinien als auch EU-Richtlinien eingehalten.

Die Nutzung der Modelle über den Microsoft Copilot zur Stichprobenanalyse bringt keine weiteren Kosten auf. Zudem ist der Microsoft Copilot schon im internal Audit ausgerollt und es bedarf keiner Gewöhnung und Schulung neuer KI-Lösungen.

Auch die Nutzung von Open-Source-Modellen stellt grundsätzlich eine Alternative zu kommerziellen Lösungen dar. Durch den Betrieb auf unternehmensinterner Infrastruktur können Datenschutz- und Compliance-Anforderungen gezielt berücksichtigt werden. Da die Bereitstellung und der Betrieb solcher Modelle jedoch mit erheblichem Infrastruktur- und Implementierungsaufwand verbunden sind, werden Open-Source-Modelle im Rahmen dieser Arbeit nicht betrachtet.

Der Microsoft Copilot ermöglicht es den Auditieren auf die Modelle GPT 5.3, GPT 5.5, Claude Sonnet 4.6, Claude Opus 4.6, Claude Opus 4.7 und Claude Opus 4.8 zuzugreifen.

Genauere Details, bei welcher Anfrage der Copilot zum Beispiel auf GPT 5.6 Sol, GPT 5.6 Terra oder GPT 5.6 Luna zugreift sind nicht bekannt. Die vier Modelle gehören laut dem Artificial Analysis Intelligence Index zu den aktuell am besten gewerteten kommerziellen KI-Modellen nach Claude Opus 5, Claude Fable oder Grok 4.5. Da die Modelle mit höherem Artificial Analysis Intelligence Index nur durch höhere zusätzliche Kosten nutzbar sind, sind die aktuell unter dem Copilot Studio nutzbaren Modelle für die Evaluierung vollkommen geeignet (vgl. Artificial Analysis 2026).

Quelle -
> Maurice (interens Meeting AI Specialist)

4.3 Entwicklung der Testdatensätze

Um keine Auditrichtlinien zu verletzen werden für die Evaluation Testdatensätze erstellt. Diese werden durch generative KI auf Basis bestehender Rechnungen erstellt.

4.4 Entwicklung eines geeigneten Prompts

Das Prompt Engineering beschreibt einen der wichtigsten Bestandteile eines KI-Prozesses. Für ein bestmöglichstes Ergebnis der Evaluation wird der Prompt auf maximale Leistung erstellt. Hierfür wird für den Prompt eine eindeutige Rolle definiert. Anthropic empfiehlt explizit dem Modell eine Rolle zu geben. Die Rolle reduziert Interpretationsspielraum und fokussiert das Modell auf seine auditrelevante Aufgabe. Zudem bekommt das Modelle eine klar definierte Aufgabe. Dies hilft dem Modell die genauen Angaben zu befolgen und nicht am Thema vorbei oder nicht detailliert genug zu antworten. Durch die Angaben des Kontext wird für das Modell klarer, auf was genau geachtet werden muss.

cite
claude

4.5 Nutzwertanalyse

Die Eignung der untersuchten KI-Modelle für den definierten Audit-Use-Case kann nicht anhand eines einzelnen Bewertungskriteriums bestimmt werden. Vielmehr müssen sowohl quantitative, als auch qualitative Kriterien berücksichtigt werden. Die Bewertung der Modelle erfordert somit die gleichzeitige Betrachtung mehrerer, teilweise konkurrierender Kriterien und stellt folglich ein mehrdimensionales Entscheidungsproblem dar (vgl. Kozłowska

2022, S. 116 f.). Zur strukturierten und nachvollziehbaren Berücksichtigung dieser unterschiedlichen Kriterien wird in dieser Arbeit eine Nutzwertanalyse durchgeführt. Die Nutzwertanalyse ermöglicht es, verschiedene Bewertungskriterien zu gewichten und zu einem Gesamtnutzenwert zu aggregieren. Dadurch können die untersuchten KI-Modelle objektiv und transparent hinsichtlich ihrer Eignung für den Audit-Use-Case verglichen werden (vgl. Kühnapfel 2021, S. 79, 272).

Die Evaluation wird anhand einer Nutzwertanalyse durchgeführt. Die Wahl der Nutzwertanalyse als Bewertungsmethode lässt sich auch methodisch begründen. He et al. (2026) zeigen, dass die in der Praxis verbreitete holistische Bewertung von LLMs, bei der ein Modell über einen einzigen Gesamtscore beurteilt wird, mehrere Bewertungsdimensionen implizit in einem einzigen Schritt zusammenfasst. Dadurch entstehen Urteile, die instabil und für Außenstehende kaum nachvollziehbar sind, da nicht ersichtlich wird, welche Kriterien in welchem Maß in das Endergebnis eingeflossen sind. Als Alternative beschreiben die Autoren die strukturierte Evaluation, bei der die Bewertung in mehrere explizite Kriterien zerlegt und anschließend über formale Multi Criteria Decision Making Verfahren wie den Analytic Hierarchy Process zu einem Gesamturteil aggregiert wird. In ihren empirischen Untersuchungen auf JudgeBench weisen sie nach, dass dieser kriterienbasierte Ansatz der direkten Gesamtbewertung konsistent überlegen ist und sowohl die Interpretierbarkeit der Ergebnisse als auch die Übereinstimmung mit menschlichen Urteilen deutlich verbessert (vgl. He et al. 2026, S. 1 bis 3).

Diese Argumentation bildet die methodische Grundlage für das Vorgehen in dieser Arbeit. Anstatt die untersuchten LLMs anhand eines einzelnen, wenig transparenten Gesamturteils zu vergleichen, wird die Bewertung in dieser Arbeit über eine Nutzwertanalyse durchgeführt. Dabei werden die relevanten Bewertungskriterien einzeln definiert, gewichtet und anschließend zu einem Gesamtnutzenwert zusammengeführt. Damit folgt das methodische Vorgehen dieser Arbeit exakt dem von He et al. (2026) empfohlenen Prinzip einer strukturierten, mehrdimensionalen Bewertung und vermeidet die Schwächen einer rein holistischen Einschätzung.

4.6 Entwicklung einer Bewertungsmatrix

Die Evaluation von LLMs sollte multidimensional erfolgen, da einzelne Kennzahlen die Leistungsfähigkeit eines Modells nur unzureichend abbilden. Daher werden in dieser Arbeit

ist das schlimm, das die Seitenzahlen so komisch sind?

Richtig machen + quelle aktuell nur fable / sonnet

mehrerer quantitative und qualitative Bewertungskriterien herangezogen (vgl. Liang et al. 2023, S.3)

Precision, Fals Positives, Qualität Begründungen, Konsistenz, Gewichtung, Gesamtbewertung, Begründung der Gewichtung

Dimension 1 (objektiv): Erkennungsleistung

1. Precision $\rightarrow TP // TP + FP$
2. Recall $\rightarrow TP // TP + FN$
3. F1 - Score $\rightarrow 2 * Precision * Recall // Precision + Recall$

Dimension 2 (subjektiv): Qualität der Begründung

1. Qualität der Begründung $\rightarrow$ Kann ein Auditor nachvollziehen, warum das Modell die Auffälligkeiten markiert hat (Skala 1 - 5)
2. Fachliche Korrektheit $\rightarrow$ Ist die Argumentation aus Auditsicht korrekt? Korrekt/-Nicht korrekt (Binär)
3. Halluzinationsrate

Dimension 3 (Konsistenz)

1. Ergebniskonsistenz $\rightarrow$ X Durchläufe
2. Begründungskonsistenz $\rightarrow$ Werden ähnliche Begründungen geliefert? Ähnliche Risiken priorisiert?

Dimension 4: Audit Nutzen

$\rightarrow$ vllt unnötig, aber wie stark würde die Analyse einen Auditor unterstützen $\rightarrow$ sehr subjektiv???

Dimension 5: Praktische Einsatzfähigkeit Antwortzeit?, Kosten ?, Datenschutz (sollte gegeben sein)

Einzelne Dimension und Punkte gewichten $\rightarrow$ Gesamtergebnis

4.7 Gewichtung der Bewertungsmatrix

Zur systematischen Evaluation der untersuchten LLMs wird eine mehrdimensionale Bewertungsmatrix entwickelt. Ziel dieser Matrix ist es, die Eignung der Modelle für die Unterstützung von Stichprobenanalysen im Internal Audit möglichst ganzheitlich zu bewerten. Die Leistungsfähigkeit der Modelle wird sowohl über objektive Kennzahlen als auch über qualitative Kriterien bewertet. Die einzelnen Bewertungskriterien werden gewichtet und anschließend zu einer Gesamtbewertung zusammengeführt.

Die erste Bewertungsdimension umfasst die Erkennungsleistung der Modelle. Diese bildet den Kern der Evaluation, da die zuverlässige Identifikation von Auffälligkeiten und Unregelmäßigkeiten die zentrale Anforderung eines KI-gestützten Audit-Tools darstellt.

5 Evaluationsdurchführung

5.1 Durchführung der Tests

5.2 Ergebnisse der Stichprobenanalysen

5.2.1 Rechnungen

5.2.2 Benutzerberechtigungen

5.2.3 Gesamtvergleich

5.3 Auswertung der Bewertungsmatrix

5.4 Vergleich der Modelle

5.5 Analyse der Ergebnisse

5.6 Beantwortung der Forschungsfrage

6 Fazit und Ausblick

6.1 Zusammenfassung der wichtigsten Erkenntnisse

6.2 Fazit zur Eignung von LLMs im Audit

6.3 Handlungsempfehlungen für Freudenberg

6.4 Zukünftige Entwicklungspotenziale

A Prompts

A.1 Prompt GPT

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

A.2 Prompt Claude

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy

eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a

turpis eu lacus commodo facilis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Literatur

- Artificial Analysis (2026). *Comparison of AI Models across Intelligence, Performance, and Price*. Artificial Analysis. URL: <https://artificialanalysis.ai/models> (besucht am 11.08.2026).
- Baumeister, Daniel (2019). „Sample size and error containment judgments in non-statistical audit sampling-the sensitivity of auditors to a revision of professional standards“. Diss. Dissertation, Dortmund, Technische Universität, 2019.
- Cantù, Elena, Cecilia Langella und Ilaria Elisa Vannini (2025). „Making sense of the internal audit function: toward internal controls integration and organizational learning“. In: *Financial Accountability & Management* 41.2, S. 262–273.
- Freudenberg, Corporate Audit (2026). „Internal Audit Sample Testing Guidance Examples“. Interne Excel-Datei, Freudenberg & Co. KG.
- G2 (2026). *DataSnipper Reviews 2026: Details, Pricing & Features*. URL: <https://www.g2.com/products/datasnipper/reviews> (besucht am 06.08.2026).
- Gartner Peer Insights (2026). *DataSnipper Reviews, Ratings & Features 2026*. Gartner, Inc. URL: <https://www.gartner.com/reviews/market/artificial-intelligence/vendor/datasnipper> (besucht am 06.08.2026).
- Kokina, Julia et al. (2025). „Challenges and opportunities for artificial intelligence in auditing: Evidence from the field“. In: *International Journal of Accounting Information Systems* 56, S. 100734. ISSN: 1467-0895. DOI: <https://doi.org/10.1016/j.accinf.2025.100734>. URL: <https://www.sciencedirect.com/science/article/pii/S1467089525000107>.
- Kozłowska, Justyna (2022). „Methods of Multi-Criteria Analysis in Technology Selection and Technology Assessment: A Systematic Literature Review“. In: *Engineering Management in Production and Services* 14.2, S. 116–137. DOI: 10.2478/emj-2022-0021.
- Kühnapfel, Jörg B. (2021). *Scoring und Nutzwertanalysen: Ein Leitfaden für die Praxis*. 2. Wiesbaden: Springer Gabler. DOI: 10.1007/978-3-658-34810-6.
- Liang, Percy et al. (2023). *Holistic Evaluation of Language Models*. arXiv: 2211.09110 [cs.CL]. URL: <https://arxiv.org/abs/2211.09110>.
- Lyell, David und Enrico Coiera (2017). „Automation bias and verification complexity: a systematic review“. In: *Journal of the American Medical Informatics Association* 24.2, S. 423–431.
- Wassie, Fekadu Agmas und László Péter Lakatos (2024). „Artificial intelligence and the future of the internal audit function“. In: *Humanities and Social Sciences Communications* 11.1, S. 386.
- YourAIFinder (2026). *DataSnipper – AI Audit Automation Platform Inside Excel*. URL: <https://youraifinder.com/tool/datasnipper> (besucht am 06.08.2026).

Hilfsmittelangabe zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten



Persönliche Angaben

Verclas, Leonard	3317974
Nachname, Vorname	Matrikelnummer
Gaußstrasse 5, 68775 Ketsch	WDSKI24B
Anschrift	Kurs
S242792@student.dhbw-mannheim.de	0176 45895734
E-Mail	Telefon- / Handynummer

Für das Modul

Praxismodul 2
Modulbezeichnung / Semester

muss ich am

09.11.2026
Datum der Frist

folgende Prüfungsleistung erbringen:

- ☐ Projektarbeit I ☒ Projektarbeit II
- ☐ Seminararbeit ☐ Bachelorarbeit
- ☐ Sonstige

genaue Bezeichnung der sonstigen Prüfungsleistung

Zur Verwendung KI-gestützter Werkzeuge erkläre ich in Kenntnis des Hinweisblatts "Hinweise zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung wissenschaftlicher Arbeiten und die prüfungsrechtlichen Folgen ihres Einsatzes" Folgendes:

- Ich habe mich aktiv über die Leistungsfähigkeit und Beschränkungen der in meiner Arbeit eingesetzten KI-Werkzeuge informiert.
- Bei der Anfertigung der Prüfungsleistung habe ich durchgehend eigenständig und beim Einsatz KI-gestützter Werkzeuge maßgeblich steuernd gearbeitet.
- Insbesondere habe ich die Inhalte entweder aus wissenschaftlichen oder anderen zugelassenen Quellen entnommen und diese gekennzeichnet oder diese unter Anwendung wissenschaftlicher Methoden selbst entwickelt.
- Mir ist bewusst, dass ich als Autor/in der Arbeit die Verantwortung für die in ihr gemachten Angaben und Aussagen trage.
- Ich habe keine weiteren als die nachstehend von mir benannten KI-gestützten Werkzeuge zur Erstellung der Arbeit eingesetzt und diese nur in der angegebenen Art und Weise.

- Soweit ich KI-gestützte Werkzeuge zur Erstellung der Arbeit eingesetzt habe, gebe ich diese in der nachstehenden "Übersicht verwendeter Hilfsmittel" mit ihrem Produkt-namen und ihres genutzten Funktionsumfangs vollständig an; wörtliche oder sinn-gemäße Übernahmen KI-generierter Inhalte habe ich in ein separates Verzeichnis aufgenommen und im Text belegt (z. B. als Fußnote). Diese Inhalte sind als pdf-Datei in den elektronischen Beigaben hinterlegt.

Produktname(n) eingesetzter Hilfsmittel:

--

Genutzter Funktionsumfang im Hinblick auf

- **Themenerfassung und Strukturierung** (Aufgabenstellung oder Präzisierung, Forschungsansatz, Gliederung)

--

- **Themenbearbeitung** (Darstellung/Beschreibung des Problems, Darlegung von wissenschaftlichen Grundlagen, Schlussfolgerungen allgemein und für das konkrete Thema / Erkenntnisgewinn, Evaluierung des Textes / Feedback der KI)

--

- **Quellenrecherche, -auswahl und -auswertung** (welche Quellen wurden durch das KI-Werkzeug gefunden, wie erfolgte die weitere Recherche)

--

- **Formale Gestaltung, insbesondere Sprache** (Welche Eingabe wurde an die KI getätigt? Textgenerierung, Textkorrektur, Paraphrasieren und Umschreiben, Übersetzen, kreatives Schreiben)

--

Hinweis:

Geben Sie in der jeweiligen Rubrik die Seitenzahl in ihrer wissenschaftlichen Arbeit an und erläutern Sie die Art und Weise sowie den Umfang der von Ihnen genutzten KI-basierten Werkzeuge.

--	--

Ort, Datum

Unterschrift der/des Studierenden