

Duale Hochschule Baden-Württemberg Mannheim

Projektarbeit 2

Einsatz von LLMs zur Unterstützung von Stichprobenanalysen im Audit-Bereich. Ein Vergleich verschiedener KI-Modelle hinsichtlich ihrer Eignung für interne Prüfungsprozesse bei der Freudenberg Group

Studiengang Wirtschaftsinformatik

Studienrichtung Data Science und Künstliche Intelligenz

Verfasser(in):	Leonard Verclas
Matrikelnummer:	3317974
Firma:	Freudenberg & Co. Kommanditgesellschaft
Kurs:	WDSKI24B
Studiengangsleiter:	Prof. Dr. Bernhard Drabant
Wissenschaftliche(r) Betreuer(in):	Stefanie Bell
Firmenbetreuer(in):	Andreas Hass
Bearbeitungszeitraum:	03.08.2026 - 09.11.2026

Todo list

Text Kapitel 4	2
Text Grundlagen und Kapitel 3	2
vllt. zu hypothetisch -> wie ght er über reine Compliance-Aspekte hinaus?	3
Hier zum Einstieg noch mehr Kontext. Das internal Audit hat verschiedene Methoden. ua Stichproben -> rechnungen aber auch user benutzeranlegen etc.	4
auch wieder sehr mystisch: mitteleinsatz prüfungseffizienz etwas menschlicher einfacher ausführen	4
noch durchgehe, quellen etc .-> siehe copilot chat	5
eine quelle ist hier für den ansatz sehr entscheidend. Ist die Quell so stark?	11
Quelle? ansonsten auch David	14
genaue zahlen begründen: 100 rechnunge, 24 %, 24 fehler, fehler 7, 54, 3, 3, 2	14
Freudenberg klar machen -> Freudenberg CO. KG	15
wissenschaftlich warum diese Kriterien	17
Gewichtung klar, aber man kann auch anders gewichten - siehe 1. PA	18
Sensitivitätsanalyse? Brauch ich die?	19

1. Erstellen von fehlerhaften Rechnungen und Tickets (Orientierung an historischen Auditfällen)
2. Modelle analysieren Dokumente
3. Anwendung der Bewertungsmatrix
4. Punktesystem auf Bewertungsmatrix anwenden
5. Auswertung der Ergebnisse
6. Zusätzlich: Modelle auf historische Ereignisse prüfen, bzw. historische Ereignisse nochmals auf Fehler überprüfen

Stichprobenrisiko erklärt: (vgl. Baumeister 2019, S.12) und detailliert S. 40 ff.

herausforderungen und möglichkeiten künstlicher Intelligenz im Auditbereich:

Möglichkeiten:

Große datenmengen anstelle von stichproben durch schnellere Bearbeitung. Herausfiltern von wichtigen Kennzahlen, wie kosten, vertragspartner etc. -> Pflichtproben herausfiltern, die menschliche oder maschinelle Prüfung benötigen. (vgl. (Kokina et al. 2025, S.3))

Anomalieerkennung -> z.b. finanzielle Informationen (vgl. (Kokina et al. 2025, S.2))

Herausforderungen:

Transparenz und Erklärbarkeit - Auditoren und Regulatoren müssen verstehen können, warum wurde eine Entscheidung getroffen, wie ist ein Ergebnis zustande gekommen? (Kokina et al. 2025, S.16)

Robustheit und Zuverlässigkeit - Es muss nachweisbar sein, dass die Ergebnisse reproduzierbar sind, das Modelle stabil arbeiten und kein Model drift stattfindet (Kokina et al. 2025, S. 13 f.)

Übermäßiges Vertrauen an die KI - Auditoren müssen Ergebnisse immernoch professional skeptisch auditieren. Die KI darf nur als Unterstützer gelten. Die finale Entscheidung bleibt beim Auditor. Durch den Einsatz von KI kann es hier zu AutomationBias führen. Hierbei kann es dazu kommen, dass Auditoren Fehler übersehen, weil das System keine gemeldet hat. (Lyell und Coiera 2017, S.425 f.)

0.1 Prompt Optimizing

Da die Literatur zeigt, dass die Auswahl des optimalen Prompts selbst ein schwieriges Modellselektionsproblem darstellt und die Few-Shot-Fähigkeit von LLMs häufig überschätzt wird, wurde in dieser Arbeit bewusst auf modellspezifische Promptoptimierung verzichtet. Stattdessen wurden identische Prompts für alle Modelle verwendet, um eine faire Vergleichbarkeit sicherzustellen. Perez, Kiela und Cho 2021

Inhaltsverzeichnis

0.1 Prompt Optimizing	ii
Abbildungsverzeichnis	v
Tabellenverzeichnis	vi
Quelltextverzeichnis	vii
Abkürzungsverzeichnis	viii
Kurzfassung (Abstract)	ix
1 Einleitung	1
1.1 Problemstellung & Motivation der Arbeit	1
1.2 Zielsetzung der Arbeit	1
1.3 Aufbau der Arbeit	2
2 Grundlagen	3
2.1 Internal Audit	3
2.2 Stichprobenanalyse im Internal Audit	4
2.3 Künstliche Intelligenz	4
2.3.1 Large Language Models	4
2.3.2 Prompt Engineering	4
2.4 Einsatz von Künstlicher Intelligenz im Audit	4
2.4.1 Potenziale in der Stichprobenanalyse	5
2.4.2 Risiken in der Stichprobenanalyse	5
3 State of the Art	6
3.1 Aktuelle Durchführung von Stichprobenanalysen bei Freudenberg	6
3.2 Einsatz von KI im Auditbereich	7
3.3 Verfügbare KI-Lösungen für den Auditbereich	8
3.3.1 Kommerzielle Lösungen	8
3.3.2 Open-Source-Lösungen	9
3.3.3 Spezialisierte KI-gestützte Audit-Lösungen	9
3.4 Einordnung des KI-Einsatzes bei Freudenberg	10

4	Evaluationsdesign	12
4.1	Forschungsdesign	12
4.2	Auswahl der zu untersuchenden Modelle	12
4.3	Entwicklung der Testdatensätze	13
4.4	Entwicklung eines geeigneten Prompts	14
4.5	Nutzwertanalyse	16
4.6	Entwicklung einer Bewertungsmatrix	17
4.7	Gewichtung der Bewertungsmatrix	18
5	Evaluationsdurchführung	20
5.1	Durchführung der Tests	20
5.2	Ergebnisse der Stichprobenanalysen	20
5.2.1	Rechnungen	20
5.2.2	Benutzerberechtigungen	20
5.2.3	Gesamtvergleich	20
5.3	Auswertung der Bewertungsmatrix	20
5.4	Vergleich der Modelle	20
5.5	Analyse der Ergebnisse	20
5.6	Beantwortung der Forschungsfrage	20
6	Fazit und Ausblick	21
6.1	Zusammenfassung der wichtigsten Erkenntnisse	21
6.2	Fazit zur Eignung von LLMs im Audit	21
6.3	Handlungsempfehlungen für Freudenberg	21
6.4	Zukünftige Entwicklungspotenziale	21
Anhang		
A	Prompts	22
A.1	Prompt GPT	22
A.2	Prompt Claude	23
Literatur		26

Abbildungsverzeichnis

Tabellenverzeichnis

4.1	Verteilung der eingebauten Fehler auf die Fehlergruppen	14
4.2	Gewichtung der Bewertungsmatrix	19

Quelltextverzeichnis

Abkürzungsverzeichnis

DHBW	Duale Hochschule Baden-Württemberg
LLM	Large Language Model
KI	Künstliche Intelligenz
FCo	Freudenberg & Co.

Kurzfassung (Abstract)

1 Einleitung

1.1 Problemstellung & Motivation der Arbeit

Mit der fortschreitenden Entwicklung Künstliche Intelligenz (KI) stehen Unternehmen vor der Herausforderung, ihre Geschäftsprozesse kontinuierlich zu optimieren und durch den gezielten Einsatz neuer Technologien effizienter zu gestalten. Insbesondere im Audit-Umfeld bietet der Einsatz von KI ein erhebliches Potenzial zur Steigerung von Effizienz, Prüfungsqualität und Transparenz. KI unterstützt interne Auditoren, indem der manuelle Analyseaufwand reduziert wird und umfassendere sowie schnellere Prüfungen ermöglicht werden. (vgl. Wassie und Lakatos 2024, S. 11–12).

Ein besonders vielversprechendes Anwendungsfeld stellt die Analyse von Audit-Stichproben dar. Im Rahmen dieser Prüfungen werden zum Beispiel Rechnungen untersucht, um Auffälligkeiten, Regelverstöße oder potenzielle Risiken zu identifizieren. Die manuelle Analyse dieser Unterlagen ist jedoch zeitaufwendig und bindet erhebliche personelle Ressourcen. Gleichzeitig steigt aufgrund wachsender Datenmengen und zunehmend komplexer Geschäftsprozesse die Schwierigkeit, relevante Auffälligkeiten zuverlässig zu erkennen.

Vor diesem Hintergrund gewinnt die Unterstützung von Stichprobenanalysen durch KI-basierte Verfahren zunehmend an Bedeutung. Für die Freudenberg-Gruppe stellt sich dabei die Frage, wie KI-Technologien gewinnbringend in die Stichprobenanalyse im Internal-Audit-Prozess integriert werden können. Neben der Verbesserung der Effizienz und Prüfungsqualität durch den Einsatz von KI spielt insbesondere die Einhaltung strenger Datenschutz- und Compliance-Anforderungen sowie die Auswahl eines geeigneten KI-Modells für die Analyse von Audit-Dokumenten eine zentrale Rolle. Daraus ergibt sich die Notwendigkeit, die Eignung verschiedener KI-Lösungen für die Unterstützung von Stichprobenanalysen im Internal Audit systematisch zu untersuchen.

1.2 Zielsetzung der Arbeit

Ziel dieser Projektarbeit ist die systematische Untersuchung und Bewertung verschiedener KI-gestützter Werkzeuge zur Unterstützung von Stichprobenanalysen im Internal Audit

der Freudenberg-Gruppe. Der Fokus liegt dabei auf Large Language Models (LLMs), die Auditoren bei der Analyse von Prüfungsdokumenten unterstützen können. Hierzu werden ausgewählte LLMs auf identische Audit-Stichproben angewendet. Die Modelle sollen potenzielle Auffälligkeiten, Risiken oder Regelverstöße in Rechnungen identifizieren sowie ihre Bewertungen nachvollziehbar begründen. Anschließend werden die Ergebnisse anhand einer Bewertungsmatrix miteinander verglichen. Dabei stehen insbesondere die Erkennungsqualität, die Nachvollziehbarkeit der Ergebnisse, die Konsistenz der Analysen sowie die praktische Einsetzbarkeit im Audit-Umfeld im Vordergrund. Auf Basis dieser Untersuchung soll ermittelt werden, welches KI-Modell die Anforderungen der Freudenberg-Gruppe im Kontext von Stichprobenanalysen im Internal Audit am besten erfüllt. Die gewonnenen Erkenntnisse sollen eine fundierte Grundlage für die Bewertung des Potenzials von LLMs im Audit-Bereich sowie für deren zukünftigen Einsatz innerhalb der Organisation schaffen. Daraus ergibt sich folgende Forschungsfrage: Wie unterscheiden sich verschiedene Large Language Models hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit-Bereich?

1.3 Aufbau der Arbeit

Text
Kapitel
4

Text
Grund-
lagen
und
Kapitel
3

2 Grundlagen

2.1 Internal Audit

Das Internal Audit stellt eine unabhängige und objektive Prüfungs- und Beratungsfunktion innerhalb einer Organisation dar. Die zentrale Aufgabe besteht darin, die Angemessenheit und Wirksamkeit von Governance-, Risikomanagement- und internen Kontrollsystemen zu bewerten sowie durch unabhängige Prüfungs- und Beratungsleistungen zur Verbesserung dieser Systeme beizutragen. Im Gegensatz zu externen Audits ist das Internal Audit organisatorisch in das Unternehmen eingebunden, wobei seine Unabhängigkeit durch geeignete Governance-Strukturen sichergestellt wird (vgl. The Institute of Internal Auditors 2024, S.15-16). Als Bestandteil des Internen Kontrollsystems unterstützt das Internal Audit die Organisation dabei, ihre strategischen und operativen Ziele wirksam und regelkonform zu erreichen. Dabei überprüft es bestehende Prozesse, identifiziert Risiken und bewertet die Wirksamkeit implementierter Kontrollmaßnahmen (vgl. Cantù, Langella und Vannini 2025, S. 263–264). Die Existenz von Audit-Funktionen begründet sich insbesondere durch die Notwendigkeit, Transparenz, Rechenschaftspflicht und Vertrauen innerhalb komplexer Organisationen sicherzustellen.

Moderne Audit-Ansätze beschränken sich jedoch nicht ausschließlich auf die Überprüfung der Regelkonformität. Vielmehr soll Internal Audit organisatorisches Lernen fördern, das Risikobewusstsein der beteiligten Akteure stärken und Verbesserungsmöglichkeiten in Geschäftsprozessen aufzeigen. Dadurch leistet die Funktion einen Beitrag zur kontinuierlichen Weiterentwicklung der Organisation und schafft einen Mehrwert, der über reine Compliance-Aspekte hinausgeht (vgl. Cantù, Langella und Vannini 2025, S. 18–21). Für die Durchführung der Prüfungen werden unter anderem Dokumente gesichtet, interpretiert und analysiert sowie deren Übereinstimmung mit gegebenen Anforderungen bewertet (vgl. Roussy 2013, S. 556–557). Ein Prozess, der ein erhebliches Potenzial für die Nutzung von KI mit sich bringt (vgl. Schumann und Marx Gómez 2021, S.1). Im Rahmen dieser Arbeit liegt der Fokus auf dem Internal Audit bei Freudenberg & Co. (FCo), welches für die Prüfung von Dokumenten und Abläufen aus verschiedenen Konzernfunktionen der Freudenberg Gruppe zuständig ist.

vllt. zu
hypote-
thisch
-> wie
geht er
über
reine
Compliance
Aspekte
hinaus?

2.2 Stichprobenanalyse im Internal Audit

Für das Internal Audit ist es in der Regel nicht möglich, alle Dokumente einer Grundgesamtheit zu prüfen. Daher wird unter anderem auf die Stichprobenanalyse zurückgegriffen. Bei der Stichprobenanalyse wird aus einer Grundgesamtheit eine Pflichtprobe und eine zufällige Stichprobe entnommen. Die Grundgesamtheit bildet eine abgegrenzte Menge gleichartiger Elemente, beispielsweise alle Rechnungen, die einem Konto zugeordnet sind. Die Pflichtprobe der Grundgesamtheit umfasst alle Elemente, die zuvor definierte Kriterien erfüllen, beispielsweise Rechnungen, die über einem bestimmten Betrag liegen. Diese Elemente müssen als Teil der Stichprobe geprüft werden. Weitergehend wird aus den restlichen Elementen der Grundgesamtheit eine zufällige Stichprobe entnommen, die zusätzlich zur Pflichtprobe geprüft wird (vgl. Freudenberg 2026). Die verbleibenden Elemente der Grundgesamtheit werden vorerst nicht geprüft und bedingen damit eine gewisse Unschärfe der Prüfungsaussagen, was als Stichprobenrisiko bezeichnet wird. Ziel ist es, eine möglichst hohe Prüfungseffizienz zu erreichen. Demnach wird versucht mit dem geringsten Mitteleinsatz ein hinreichend sicheres Prüfungsurteil zu erreichen (vgl. Baumeister 2019, S. 11–12).

Hier zum Einstieg noch mehr Kontext. Das internal Audit hat verschiedene Methoden, ua Stichproben -> rechnungen aber auch user benutzeranlegen etc.

2.3 Künstliche Intelligenz

2.3.1 Large Language Models

2.3.2 Prompt Engineering

Das Prompt Engineering beschreibt den wichtigsten Part der Nutzung eines KI-Systems. Erst durch den Prompt weiß die Maschine was der User erreichen möchte. Ein Prompt kann in verschiedenen klar definierte Teile unterteilt sein.

2.4 Einsatz von Künstlicher Intelligenz im Audit

Der Einsatz von KI im Audit ist kein rein konzeptionelles Zukunftsszenario, sondern bereits in der Prüfungspraxis etabliert (vgl. Kokina et al. 2025, S. 7 f.). KI unterstützt Auditoren bei der Analyse großer strukturierter und unstrukturierter Datenmengen, indem sie

auch wieder sehr mystisch: mitte-leinsatz prüfungseffizienz etwas menschlicher einfa

Muster erkennt, Anomalien identifiziert und Vorhersagen trifft (vgl. Ivakhnenkov 2023, S. 56). KI unterscheidet sich zu klassischen Datenanalysemethoden dadurch, dass sie auch nichtlinearer Zusammenhänge verarbeiten kann und somit flexibel auf unterschiedliche Auffälligkeiten aufmerksam machen kann (vgl. Kyriazos und Poga 2024, S. 1790 f.). Es zeigt sich, dass Auditfirmen mit höheren KI-Investitionen eine bessere Prüfungsqualität erreichen und gleichzeitig die Prüfungszeit verkürzen können (vgl. Fedyk et al. 2022, S. 940 ff.). Somit zeigen sich auch für das internal Audit bei FCo Potenziale, die Effizienz und Qualität der Prüfungen durch den gezielten Einsatz von KI zu steigern.

2.4.1 Potenziale in der Stichprobenanalyse

Besonders in der Stichprobenanalyse kann der Einsatz von KI zu einer signifikanten Effizienzsteigerung führen. Durch die Automatisierung der Dokumentenprüfung können Auditoren schneller und umfassender potenzielle Auffälligkeiten, Risiken oder Regelverstöße identifizieren. KI-gestützte Systeme können große Mengen an Rechnungen analysieren, Muster erkennen und Anomalien hervorheben, die menschlichen Prüfern möglicherweise entgehen würden. Dies ermöglicht eine gezieltere Auswahl von Stichproben und reduziert den manuellen Aufwand erheblich. Zudem kann KI dazu beitragen, die Konsistenz und Nachvollziehbarkeit der Prüfungsprozesse zu verbessern, indem sie standardisierte Bewertungsmaßstäbe anwendet und Ergebnisse transparent dokumentiert. Durch die Automatisierung durch KI kann eine deutlich größere Menge an Stichproben analysiert werden, wodurch die Aussagekraft der Prüfungsergebnisse steigt und das Stichprobenrisiko minimiert wird.

2.4.2 Risiken in der Stichprobenanalyse

Trotz der zahlreichen Vorteile birgt der Einsatz von KI in der Stichprobenanalyse auch Risiken. Ein zentrales Risiko besteht in der Abhängigkeit von den verwendeten KI-Modellen und deren Trainingsdaten. Wenn die Modelle auf unzureichenden oder verzerrten Daten trainiert wurden, können sie fehlerhafte oder voreingenommene Ergebnisse liefern oder Halluzinieren, was zu falschen Prüfungsurteilen führen kann. Zudem besteht die Gefahr des Automation-Bias. Auditoren können die Ergebnisse der KI-Systeme unkritisch übernehmen, ohne diese ausreichend zu hinterfragen und so Auffälligkeiten oder Risiken übersehen.

3 State of the Art

3.1 Aktuelle Durchführung von Stichprobenanalysen bei Freudenberg

Aktuell folgt die Stichprobenanalyse im Internal Audit bei Freudenberg einer strukturierten Vorgehensweise, die in den internen Vorgaben des Corporate Audit festgelegt ist (vgl. Freudenberg 2026). Der Prozess lässt sich exemplarisch anhand der Prüfung von Lieferantenrechnungen ohne Bestellnummer beschreiben und ist grundsätzlich auf weitere Anwendungsfälle übertragbar. Zunächst wird eine Grundgesamtheit relevanter Objekte definiert. Im Beispiel sind das alle im Prüfungszeitraum erfassten Rechnungen ohne Bestellnummer. Anschließend wird diese Grundgesamtheit anhand definierter Kriterien, wie Rechnungswert, Lieferant, manueller Buchung oder weiterer risikorelevanter Merkmale, klassifiziert.

Auf Basis dieser Klassifizierung wird ein Schwellenwert festgelegt. Alle Rechnungen, die diesen Schwellenwert überschreiten, werden verpflichtend in die Stichprobe aufgenommen. Dieser Teil bildet die Pflichtproben ab. Ergänzend dazu wird eine zufällige Auswahl weiterer Rechnungen aus der verbleibenden Grundgesamtheit getroffen, um eine angemessene Abdeckung des Prüffeldes sicherzustellen (vgl. Freudenberg 2026). Diese Kombination aus einer vollständigen Prüfung wesentlicher Elemente und einer Auswahl aus der restlichen Grundgesamtheit ist ein übliches Vorgehen bei nicht-statistischen Stichproben in der Prüfungspraxis (vgl. Baumeister 2019).

Die ausgewählten Stichprobenelemente werden anschließend durch den Auditor einer detaillierten Prüfung unterzogen. Hierbei werden sämtliche für die Bewertung relevanten Informationen und Nachweisdokumente gesammelt, geprüft und dokumentiert. Die Global Internal Audit Standards verlangen dabei, dass die gesammelten Informationen relevant, verlässlich und ausreichend sind, um die Ergebnisse der Prüfung zu stützen (vgl. The Institute of Internal Auditors 2024, Standard 14.1). Nach Abschluss der Analyse bewertet der Auditor die Ergebnisse hinsichtlich möglicher Auffälligkeiten, Abweichungen oder Regelverstöße. Werden Unregelmäßigkeiten festgestellt, werden diese dokumentiert und als Audit Exceptions erfasst.

Durch die Kombination aus risikobasierter Auswahl und zufälliger Stichprobenziehung wird sichergestellt, dass sowohl potenziell kritische Transaktionen als auch repräsentative Elemente der Grundgesamtheit in die Prüfung einbezogen werden. Dadurch kann mit vertretbarem Prüfungsaufwand ein hohes Maß an Prüfungssicherheit erreicht werden (vgl. Freudenberg 2026).

3.2 Einsatz von KI im Auditbereich

Die zuvor beschriebene Stichprobenanalyse erfolgt in weiten Teilen manuell. Für jedes Stichprobenelement sammelt, prüft und dokumentiert der Auditor die Nachweisdokumente einzeln. Genau an dieser Stelle setzt der Einsatz von KI an. In großen Prüfungsgesellschaften sind einfache KI-Anwendungen, etwa zur Extraktion von Informationen aus Dokumenten, bereits weit verbreitet, während komplexere Ansätze wie generative KI bislang überwiegend experimentell eingesetzt werden (vgl. Kokina et al. 2025, S. 2). Der Einsatz von KI im Audit zeigt sich messbar. Prüfungsgesellschaften, die stärker in KI investieren, erreichen eine höhere Prüfungsqualität und können gleichzeitig die Prüfungsdauer verkürzen (vgl. Fedyk et al. 2022, S. 940 ff.). Auch für das Internal Audit wird erwartet, dass KI die Arbeitsweise der Prüfungsfunktion grundlegend verändert und Prüfungen effizienter macht (vgl. Wassie und Lakatos 2024). Bisher lag der Schwerpunkt vor allem auf der Analyse strukturierter Daten, beispielsweise der Erkennung von Anomalien in Finanzinformationen (vgl. Kokina et al. 2025, S. 2). Mit generativen LLMs lassen sich nun auch unstrukturierte Dokumente wie Rechnungen, Verträge oder E-Mails auswerten. Verfahren zur Verarbeitung natürlicher Sprache werden im Internal Audit bereits für die Analyse solcher Textdaten untersucht (vgl. Schumann und Marx Gómez 2021). Damit rückt auch die dokumentenbasierte Prüfung einzelner Stichprobenelemente in den Fokus.

Wie der Einsatz generativer KI im Internal Audit eines Großkonzerns umgesetzt werden kann, zeigt das Beispiel Uniper. Die dortige Auditabteilung setzt ChatGPT in der Prüfungsvorbereitung, der Prüfungsdurchführung und der Berichterstattung ein. Erste Tests ergaben je nach Prozess geschätzte Effizienzgewinne von 50 % bis 80 % (vgl. Emmett et al. 2025, S. 125 ff.). Zugleich hat Uniper eigene Regeln für die Nutzung festgelegt, da mit dem Einsatz auch Risiken verbunden sind (vgl. Emmett et al. 2025, S. 125 ff.). Solche Risiken betreffen beim Einsatz von KI im Audit unter anderem die Verantwortlichkeit für Ergebnisse, die Transparenz der Verfahren und den Datenschutz (vgl. Munoko, Brown-

Liburd und Vasarhelyi 2020). Der Nutzen generativer KI hängt somit von klaren Vorgaben und einer Kontrolle der Nutzung und der Ergebnisse ab.

3.3 Verfügbare KI-Lösungen für den Auditbereich

Für den Einsatz von KI im Auditbereich stehen verschiedene Arten von Lösungen zur Verfügung. Diese lassen sich in drei Gruppen einteilen: kommerzielle LLMs, die von Anbietern wie Anthropic, OpenAI oder Google bereitgestellt werden, Open-Source-Modelle, die auf eigener Infrastruktur betrieben werden können, sowie spezialisierte Softwarelösungen, die gezielt für Prüfungsprozesse entwickelt wurden. Im Folgenden werden diese drei Gruppen vorgestellt und hinsichtlich Leistungsfähigkeit, Datenschutz, Kosten und Implementierungsaufwand eingeordnet.

3.3.1 Kommerzielle Lösungen

Generative KI und speziell LLMs werden in der Forschung zunehmend als neue Allzwecktechnologie eingeordnet, die in vielen Branchen und Tätigkeiten eingesetzt werden kann (vgl. Calvino, Haerle und S. Liu 2025). Damit kommen LLMs grundsätzlich auch für den Einsatz im Auditbereich in Frage. Generative LLMs sind in der Lage, große Mengen an Textdaten zu verarbeiten, Muster zu erkennen und Informationen aus unstrukturierten Dokumenten wie Rechnungen strukturiert wiederzugeben, was für die Prüfung von Stichproben im Auditbereich relevant ist. Jedoch ist zu berücksichtigen, dass die Modelle auch halluzinieren können, also falsche oder nicht belegbare Informationen generieren (vgl. Ji et al. 2023, S. 2; Huang et al. 2025, S. 2; Bang, Ji, Schelten et al. 2025, S. 1). Daher ist eine abschließende Bewertung der Ergebnisse durch den Auditor weiterhin erforderlich.

Die einzelnen Modelle werden kontinuierlich weiterentwickelt, wobei ihre Leistungsfähigkeit und Genauigkeit stetig zunimmt (vgl. Artificial Analysis 2026). Zum Stand der Arbeit (Oktober 2026) führen Modelle von Anthropic, OpenAI und Google die Benchmark-Rankings wie den Artificial Analysis Intelligence Index an. Modelle wie Claude Opus 5.5, Claude Sonnet 5.5, Claude Fable 5.1, GPT-6 Astra und Gemini 4 schneiden hierbei am besten ab (vgl. Artificial Analysis 2026). Der Artificial Analysis Intelligence Index kann jedoch nur als erster Referenzwert herangezogen werden (vgl. DeepLearning.AI o. D.). Für

den konkreten Anwendungsfall der Stichprobenanalyse im Audit sind weitere, spezifische Faktoren zu berücksichtigen, die im Rahmen der Evaluation untersucht werden.

Kommerzielle Modelle werden in der Regel als Cloud-Dienst bereitgestellt. Sie lassen sich mit geringem Implementierungsaufwand nutzen, die Verarbeitung der Daten erfolgt jedoch auf der Infrastruktur des Anbieters. Für den Einsatz mit vertraulichen Prüfungsdaten ist daher ein vertraglich abgesicherter Zugang notwendig, wie er bei Freudenberg über den Microsoft Copilot besteht (vgl. Microsoft 2026a).

3.3.2 Open-Source-Lösungen

Neben kommerziellen Modellen existieren Open-Source-Modelle. Als Open-Source-Modelle werden LLMs verstanden, deren Modellgewichte frei verfügbar sind (vgl. Kapoor et al. 2024, S. 2). Bekannte Beispiele sind Llama von Meta, die Modelle von Mistral, Qwen von Alibaba, Kimi von Moonshot AI oder DeepSeek (vgl. Artificial Analysis 2026). Open-Source-Modelle stellen grundsätzlich eine Alternative zu kommerziellen Lösungen dar. Durch den Betrieb auf unternehmensinterner Infrastruktur verlassen die Daten das Unternehmen nicht, wodurch Datenschutz- und Compliance-Anforderungen gezielt berücksichtigt werden können (vgl. Kapoor et al. 2024, S. 3). Zudem fallen keine nutzungsabhängigen Lizenzkosten an (vgl. Kapoor et al. 2024, S. 9).

Dem steht ein erheblicher Infrastruktur- und Implementierungsaufwand gegenüber. Für den Betrieb leistungsfähiger Modelle wird eigene Hardware mit ausreichender Rechenleistung benötigt. Hinzu kommen die Wartung, die Aktualisierung der Modelle und das notwendige Fachwissen im Unternehmen (vgl. Kapoor et al. 2024, S. 3). Außerdem liegen in den aktuellen Benchmark-Rankings die kommerziellen Modelle vor Open-Source Lösungen (vgl. Artificial Analysis 2026).

3.3.3 Spezialisierte KI-gestützte Audit-Lösungen

Abseits von generativen LLMs existieren spezialisierte Softwarelösungen, die KI gezielt für Prüfungsprozesse einsetzen. Ein bekanntes Beispiel dafür ist DataSnipper. Die Software erzielt auf Bewertungsplattformen gute Bewertungen (vgl. Gartner Peer Insights 2026) und wird laut Hersteller unter anderem von den Big 4 eingesetzt, wodurch sie eine hohe Marktrelevanz im Prüfungsumfeld besitzt (vgl. DataSnipper 2026). DataSnipper ist

als Erweiterung für Microsoft Excel umgesetzt und wurde speziell für die Anforderungen von Prüfungs- und Finanzprozessen entwickelt (vgl. YourAIFinder 2026). Zu den zentralen Funktionen gehören die automatisierte Extraktion von Daten aus Dokumenten, der Abgleich dieser Daten mit Arbeitspapieren sowie die Erstellung nachvollziehbarer Audit Trails. Fachliche Entscheidungen und die finale Bewertung verbleiben dabei weiterhin beim Auditor (vgl. G2 2026).

Spezialisierte Lösungen sind auf typische Prüfungsschritte zugeschnitten und lassen sich ohne eigene Prompt-Entwicklung nutzen. Sie sind jedoch an den Funktionsumfang des Herstellers gebunden und erfordern in der Regel eine zusätzliche Lizenz.

3.4 Einordnung des KI-Einsatzes bei Freudenberg

Die Freudenberg Gruppe nutzt aktuell gruppenweit die KI-Lösung von Microsoft, den Microsoft Copilot. Hierbei werden für alle Nutzer die Modelle GPT-5.6, GPT-6.1 sowie Claude Sonnet 5, Claude Sonnet 5.5 und Claude Opus 5.5 zur Verfügung gestellt (vgl. Freudenberg & Co. KG 2026). Der Copilot kann dabei unter Berücksichtigung der Datenschutz- und Compliance Richtlinien auf alle internen Dokumente zugreifen, für die der jeweilige Nutzer berechtigt ist. Zusätzlich bietet Microsoft die Möglichkeit, über das Copilot Studio eigene Agenten zu bauen. Hierbei können die Agenten auf interne Dokumente zugreifen und Aufgaben automatisiert ausführen. Für die Agenten sind aktuell die Modelle GPT-4.1, GPT-5, GPT-5.3, GPT-5.5 sowie Claude Sonnet 4.6, Claude Opus 4.6, Claude Opus 4.7 und Claude Opus 4.8 hinterlegt (vgl. Freudenberg & Co. KG 2026).

Für die Stichprobenanalyse von Rechnungen im Auditkontext empfiehlt sich der Einsatz eigener Agenten im Copilot Studio anstelle der reinen Chatnutzung des Microsoft Copilot. Der Grund liegt im Aufbau des Prüfprozesses. Wie in Abschnitt 3.1 beschrieben, besteht die Stichprobenanalyse aus mehreren aufeinander aufbauenden Schritten, die für jedes Stichprobenelement wiederholt werden. Es müssen Nachweisdokumente gesammelt werden, mit den Buchungsdaten abgeglichen werden, Auffälligkeiten identifiziert werden und das Ergebnis dokumentiert werden.

Grundsätzlich lassen sich alle Prüfschritte auch in einem einzelnen, ausführlichen Prompt im Microsoft Copilot beschreiben. Sprachmodelle reagieren jedoch empfindlich auf kleine Unterschiede in der Formulierung und Formatierung eines Prompts (vgl. Sclar et al. 2024, S. 16). Dienen unterschiedliche Dokumente als Grundlage, können dadurch voneinander

abweichende Ergebnisse entstehen. Bei einer größeren Anzahl an Stichprobenelementen kommt hinzu, dass ein einzelner Chatverlauf schnell sehr lang wird. Informationen in der Mitte langer Kontexte werden von den Modellen schlechter berücksichtigt (vgl. N. F. Liu et al. 2024, S. 157) und irrelevante Inhalte können die Ergebnisse zusätzlich verschlechtern (vgl. Shi et al. 2023). Frühere Anweisungen können dadurch an Wirkung verlieren. Für eine Prüfung, deren Ergebnisse nachvollziehbar und vergleichbar sein müssen, ist das ein Nachteil.

Ein Agent wird dagegen einmalig mit festen Anweisungen, definierten Wissensquellen und den benötigten Aktionen konfiguriert (vgl. Microsoft 2026b). Dadurch läuft jede Rechnung nach demselben Schema durch die Prüfung, und der Ablauf lässt sich dokumentieren und wiederverwenden. Schreyer et al. (2024, S. 1) beschreiben diesen Schritt als Übergang vom co-piloted Auditing, bei dem ein LLM einzelne Aufgaben auf Anfrage unterstützt, zum auto-piloted Auditing, bei dem Agenten zusammenhängende Prüfungshandlungen eigenständig ausführen. Als entscheidende Merkmale nennen sie die schrittweise Verfeinerung der Ergebnisse und den Einsatz spezialisierter Werkzeuge.

Dabei wird in Kauf genommen, dass im Copilot Studio aktuell ältere Modelle zur Verfügung stehen als im Chatfenster des Copilot. Für die Stichprobenanalyse wiegen ein einheitlicher Ablauf und die Nachvollziehbarkeit der Ergebnisse jedoch schwerer als die höhere Leistungsfähigkeit der neuesten Modelle. Die abschließende Bewertung der Ergebnisse und die Erfassung von Audit Exceptions verbleiben weiterhin beim Auditor. Das ist auch deshalb wichtig, weil Nutzer automatisierten Systemen häufig zu stark vertrauen und Fehler dadurch übersehen werden können (vgl. Lyell und Coiera 2017, S. 423). Zudem verlangen die Global Internal Audit Standards, dass Auditoren ihre Arbeit mit der gebotenen beruflichen Sorgfalt ausführen (vgl. The Institute of Internal Auditors 2024, Standard 4.2).

Für die Stichprobenanalyse von Rechnungen im Auditkontext empfiehlt sich daher der Einsatz eines Agenten im Microsoft Copilot Studio. Der Agent kann auf die internen Dokumente zugreifen, die für die Prüfung relevanten Informationen extrahieren und die Prüfschritte in einer standardisierten Weise durchführen. Es stellt sich jedoch die Frage, mit welchem Modell die besten Ergebnisse erzielt werden. Im weiteren Verlauf der Arbeit wird daher eine Evaluation durchgeführt, um die Leistungsfähigkeit der verfügbaren Modelle zu vergleichen und das am besten geeignete Modell für den Einsatz im Auditbereich zu identifizieren.

eine
quelle
ist hier
für den
ansatz
sehr
ent-
schei-
dend.
Ist die
Quell
so
stark?

4 Evaluationsdesign

4.1 Forschungsdesign

Zur Beantwortung der Forschungsfrage, wie sich verschiedene LLMs hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit unterscheiden, wird in dieser Arbeit eine vergleichende Evaluation der Modelle durchgeführt. Dazu werden die ausgewählten Modelle auf verschiedene Prüfungsdokumente angewendet. Die Modelle analysieren sowohl die Rechnungen als auch die Bestätigungen zur Freigabe der Rechnungen, markieren mögliche Auffälligkeiten und begründen ihre Befunde. Die Ergebnisse werden mithilfe einer Nutzwertanalyse ausgewertet. Damit Unterschiede in den Ergebnissen tatsächlich auf die Modelle zurückzuführen sind, werden alle übrigen Einflussfaktoren konstant gehalten. Für jedes Modell wird im Copilot Studio ein eigener Agent mit identischen Instruktionen angelegt. Alle Modelle erhalten dieselben Rechnungen und dieselben Freigaben sowie denselben Prompt, um identische Bedingungen zu gewährleisten.

4.2 Auswahl der zu untersuchenden Modelle

Die Auswahl der zu untersuchenden Modelle basiert auf der aktuellen Nutzung von KI-Lösungen in der Freudenberg Gruppe. Wie in Abschnitt 3.4 beschrieben, nutzt die Freudenberg Gruppe gruppenweit die Premium Version des Microsoft Copilot und die dort ausgerollten Modelle von OpenAI und Anthropic. Hierbei werden sowohl die internen Datenschutz- und Compliance-Richtlinien als auch EU-Richtlinien eingehalten. Ein weiterer Vorteil ist, dass durch die Nutzung der Modelle über den Microsoft Copilot keine weiteren Kosten anfallen. Zudem ist der Copilot bereits im Internal Audit ausgerollt, weshalb es keiner weiteren Schulungen und Gewöhnungszeiten für Mitarbeiter bedarf.

Von den in Abschnitt 3.3 vorgestellten Lösungen werden Open-Source-Modelle und spezialisierte Softwarelösungen im Rahmen dieser Arbeit nicht untersucht. Der Betrieb von Open-Source-Modellen wäre mit erheblichem Infrastruktur- und Implementierungsaufwand verbunden (siehe Abschnitt 3.3.2). Für den Einsatz von DataSnipper müsste eine zusätzliche Lizenz erworben werden, die weitere Kosten verursachen würde (siehe Abschnitt 3.3.3).

Der Microsoft Copilot ermöglicht es den Auditoren, auf verschiedene Modelle von Anthropic und OpenAI zuzugreifen. Da die Stichprobenanalyse, wie in Abschnitt 3.4 begründet, über eigene Agenten im Copilot Studio umgesetzt wird, werden im Rahmen dieser Arbeit alle Modelle berücksichtigt, die im Copilot Studio für die Erstellung von Agenten zur Verfügung stehen. Dies sind GPT 4.1, GPT 5, GPT 5.3 und GPT 5.5 sowie Sonnet 4.6, Opus 4.6, Opus 4.7 und Opus 4.8. Die in Abschnitt 3.3.1 genannten Modelle mit den höchsten Werten im Artificial Analysis Intelligence Index werden nicht untersucht, da sie im Copilot Studio derzeit nicht verfügbar sind. Opus 5.5 und Sonnet 5.5 stehen ausschließlich im Chatfenster des Copilot zur Verfügung, Fable 5.1, GPT-6 Astra und Gemini 4 werden bei Freudenberg aktuell nicht bereitgestellt.

4.3 Entwicklung der Testdatensätze

Für die Evaluation der betrachteten KI-Modelle ist eine Datenbasis erforderlich, die den realen Prüfungskontext möglichst genau abbildet. Die Verwendung originaler Rechnungsbelege aus dem Internal Audit der Freudenberg-Gruppe ist ausgeschlossen, da diese personenbezogene sowie geschäftskritische Informationen enthalten und daher im Rahmen dieser Evaluierung nicht herangezogen werden dürfen. Um dennoch eine hinreichend umfangreiche und belastbare Testbasis zu schaffen, werden die Testdatensätze mithilfe generativer KI erzeugt. Die künstlich erstellten Rechnungen orientieren sich in Struktur, Umfang und Informationsgehalt an realen Rechnungen und enthalten dieselben prüfungsrelevanten Kriterien wie die im Audit untersuchten Dokumente. Nach der Generierung der Rechnungen werden gezielt Fehler in die Dokumente eingebracht. Dieser Ansatz orientiert sich an Benchmark-Studien zur Evaluation von LLMs im Finanzkontext, bei denen vorhandene Finanzdokumente systematisch durch künstlich eingefügte Fehler verändert werden, um die Fähigkeit der Modelle zur Identifikation von Inkonsistenzen zu untersuchen (vgl. Panda 2026, S. 1). Neben den Rechnungen werden auch Screenshots von Mails zur Freigabe der einzelnen Rechnungen erstellt. Auch hier werden gezielt einzelne Fehler in die Datensätze eingebaut. Der Testdatensatz umfasst somit sowohl fehlerhafte als auch vollständig korrekte Rechnungen sowie die zugehörigen Freigaben. Für die vorliegende Arbeit wird eine Fehlerquote von 24 % festgelegt, was bei einem Datensatz von 100 Rechnungen insgesamt 24 fehlerhaften Belegen entspricht. Nach internen Angaben liegt die Quote für fehlerhafte oder unvollständige Rechnungen bei 18 % (vgl. internes Meeting David Goth). Durch eine Fehlerquote von 24 % ist die Anzahl fehlerhafter Rechnungen ausreichend groß, um

die Erkennungsleistung der Modelle repräsentativ zu untersuchen. Gleichzeitig bildet die Mehrheit an korrekten Rechnungen den realen Prüfungskontext realitätsnah ab. Bei der Fehlererzeugung wird bewusst auf eine breite Streuung unterschiedlicher Fehlertypen geachtet. Die Fehler werden in sechs Gruppen unterschieden. Die größte Gruppe bilden 7 Fehler, die typische Betrugsmuster abbilden. Sie zeigen den eigentlichen Nutzen eines solchen Systems im Audit. Bei 5 Fehlern liegt das Problem im Freigabeprozess, wenn eine Rechnung ohne die erforderliche Freigabe oder durch eine nicht berechtigte Person genehmigt wird. Weitere 4 Fehler betreffen den Abgleich mit den Stammdaten, bei denen die Angaben auf der Rechnung von den hinterlegten Lieferantendaten abweichen, zum Beispiel bei Anschrift oder Bankverbindung. Bei 4 Fehlern handelt es sich um einfache Rechen-, bzw. Zahlenfehler, die als Basisfälle gelten. Weitere 3 Fehler betreffen ein falsches Rechnungsdatum oder die Zuordnung zur falschen Periode, sodass der Aufwand im falschen Zeitraum gebucht wird. Die letzten 2 Fehler betreffen eine fehlende Rechnungsnummer. Tabelle 4.1 fasst die Fehlergruppen zusammen.

Anzahl	Fehlergruppe
7	Betrugsmuster
5	Fehler in der Rechnungsfreigabe
4	Abgleich mit Stammdaten
4	Rechnerische Fehler und Basisfälle
3	Datum und Periode
2	Fehlende Rechnungsnummer
24	Gesamt

Tabelle 4.1: Verteilung der eingebauten Fehler auf die Fehlergruppen

4.4 Entwicklung eines geeigneten Prompts

Die Qualität der von einem LLM erzeugten Ausgabe hängt maßgeblich von der Gestaltung des Prompts ab (vgl. Sclar et al. 2024). Prompt Engineering bezeichnet die systematische Gestaltung, Strukturierung und Optimierung von Eingabeaufforderungen (Prompts) für LLMs. Ziel ist es, durch die gezielte Auswahl von Aufgabenbeschreibungen, Kontextinformationen, Beispielen und Formatierungen das gewünschte Modellverhalten zu erzeugen und die Qualität der Ergebnisse zu verbessern (vgl. Schulhoff et al. 2025, S. 1). Der Prompt für diese Arbeit wird deshalb auf Basis etablierter Techniken des Prompt Engineering entwickelt. Um die Vergleichbarkeit der untersuchten Modelle sicherzustellen, wird auf eine

Quelle?
ansons-
ten
auch
David

genaue
zahlen
begrün-
den:
100
rech-
nun-
ge, 24
%, 24
fehler,
fehler
7, 54,
3, 3, 2

modellspezifische Optimierung verzichtet. Alle Modelle erhalten denselben Prompt. Dieser enthält klare Anweisungen zur Analyse der Rechnungen, zur Identifikation möglicher Auffälligkeiten und zur nachvollziehbaren Begründung der Ergebnisse.

Die inhaltlichen Anforderungen an den Prompt ergeben sich aus dem bestehenden Vorgehen der Stichprobenanalyse bei Freudenberg (vgl. Abschnitt 3.1). Der Prompt bildet die Prüfschritte ab, die ein Prüfer bei einer Eingangsrechnung durchführt. Dazu gehören die Extraktion der Rechnungsdaten, der Abgleich mit der Referenztabelle, die rechnerische und formale Prüfung sowie die Suche nach Betrugsindikatoren. Abschließend werden der Freigabeprozess und die Berechtigung des Genehmigers geprüft. Das Ergebnis dient als Arbeitspapier für die anschließende menschliche Prüfung. Das Modell unterstützt den Prüfer also, übernimmt aber nicht den vollständigen Prüfungsprozess und gibt lediglich eine Empfehlung für das weitere Vorgehen ab.

Der Prompt besteht aus zwei Teilen. Die Instruktionen sind in jedem Agenten identisch und dauerhaft hinterlegt und legen Rolle, Ziel, Quellen, Regeln, Prüfschritte und Ausgabeformat fest. Der Kurzprompt wird für jeden Prüffall mit identischem Wortlaut in den Chat eingegeben. Er startet die Prüfung und benennt die vorliegenden Unterlagen. Der vollständige Prompt, unterteilt in Instruktionen und Kurzprompt, befindet sich in Anhang ??.

Bei der Gestaltung des Prompts wurden mehrere etablierte Techniken angewendet. Zu Beginn erhält das Modell ein klar definiertes Ziel und eine eindeutige Rolle als Prüfagent des internen Audits. Die Rolle gibt dem Modell den fachlichen Rahmen der Aufgabe vor (vgl. Microsoft 2026b).

Für jede Eingabe ist festgelegt, welche Funktion sie erfüllt. Die Rechnung liefert die Istwerte, die Referenztabelle die Sollwerte und die Freigabematrix die Berechtigungen. Die Freigabeunterlagen gelten ausschließlich als Evidenz und werden nicht automatisch als gültig angenommen. Durch diese Quellenhierarchie muss das Modell bei widersprüchlichen Angaben nicht selbst entscheiden, welcher Quelle es folgt. Die einzelnen Wissensquellen werden in den Instruktionen ausdrücklich benannt und erklärt (vgl. Microsoft 2026b).

Die Aufgabe ist in elf Prüfschritte mit fester Reihenfolge zerlegt. Die Aufteilung in klar getrennte Einheiten verringert Mehrdeutigkeiten und verhindert, dass das Modell Aufgaben zusammenführt oder neu interpretiert (vgl. Microsoft 2026b). Zusätzlich wird die Prüfung dadurch nachvollziehbar, da jeder Schritt im Ergebnis sichtbar ist.

LLMs neigen dazu, fehlende Informationen durch plausibel klingende, aber falsche Inhalte zu ersetzen (vgl. Huang et al. 2025, S. 1). Der Prompt verbietet deshalb Annahmen und

Freudenberg
klar
machen
->
Freu-
denberg
CO. KG

Ergänzungen. Fehlt eine Information oder kann sie nicht geprüft werden, muss das Modell feste Statuswerte wie „nicht vorhanden“, „nicht lesbar“ oder „nicht prüfbar“ verwenden. Verdachtsmomente dürfen nur als „Hinweis auf“ formuliert werden, da die Feststellung eines Betrugs dem Prüfer vorbehalten bleibt (vgl. Anthropic 2026).

Die Ausgabe folgt einer festen Struktur mit vorgegebenen Feldern und Statuswerten. Ohne vorgegebenes Ausgabeformat kann es zu inkonsistentem Verhalten zwischen verschiedenen Modellen kommen (vgl. Microsoft 2026b). Das feste Format erleichtert die menschliche Prüfung und macht die Ergebnisse der Modelle direkt vergleichbar. Die Gesamtbewertung der Freigabe, die Auffälligkeiten mit Risikostufe sowie die Angabe zur menschlichen Nachprüfung bilden die Grundlage für die Auswertung.

Neben den inhaltlichen Anforderungen unterliegt der Prompt technischen und methodischen Rahmenbedingungen. Die Instruktionen eines Agenten in Copilot Studio sind auf 8000 Zeichen begrenzt (vgl. Microsoft 2026b). Eine ausführliche Fassung mit Definitionen, Beispielen und Beschreibungen aller Statuswerte umfasste rund 30.000 Zeichen und lag damit deutlich über diesem Limit. Zudem berücksichtigen LLMs Informationen in langen Kontexten weniger zuverlässig (vgl. N. F. Liu et al. 2024, S. 157). Irrelevante Informationen im Kontext können die Leistung der Modelle zusätzlich verschlechtern (vgl. Shi et al. 2023, S. 9). Der Prompt soll dem Modell deshalb nur die für die Aufgabe notwendigen Informationen bereitstellen.

Daraus ergeben sich folgende Anforderungen an den Prompt. Die Regeln werden stichpunktartig formuliert und auf ausführliche Erklärungen wird verzichtet. Alle elf Prüfschritte müssen dabei vollständig enthalten bleiben, damit der Prüfprozess unverändert abgebildet wird. Instruktionen und Kurzprompt dürfen sich nicht widersprechen, da das Modell sonst selbst entscheiden müsste, welcher Anweisung es folgt. Der finale Prompt wird vor Beginn der Evaluation festgelegt und für alle Modelle unverändert eingesetzt.

4.5 Nutzwertanalyse

Die Eignung der untersuchten LLMs für den definierten Anwendungsfall im Audit lässt sich nicht anhand eines einzelnen Kriteriums bestimmen. Um ein ganzheitliches Ergebnis zu erhalten, müssen sowohl quantitative als auch qualitative Kriterien berücksichtigt werden. Die Bewertung erfordert somit die gleichzeitige Betrachtung mehrerer, teilweise

konkurrierender Kriterien und stellt ein mehrdimensionales Entscheidungsproblem dar (vgl. Kozłowska 2022, S. 116 f.).

Zur strukturierten Berücksichtigung dieser Kriterien wird in dieser Arbeit eine Nutzwertanalyse durchgeführt. Sie ist eine bewährte Methode zur Lösung mehrdimensionaler Entscheidungsprobleme und ermöglicht es, verschiedene Bewertungskriterien zu gewichten und zu einem Gesamtnutzwert zusammenzufassen (vgl. Kühnapfel 2021, S. 79 f.). Dadurch lassen sich die untersuchten Modelle systematisch und nachvollziehbar hinsichtlich ihrer Eignung vergleichen. Da die Gewichtung der Kriterien auf einer subjektiven Einschätzung beruht, wird sie im Laufe der Arbeit offen dargelegt und begründet.

4.6 Entwicklung einer Bewertungsmatrix

Um die Evaluation basierend auf einer Nutzwertanalyse durchzuführen, muss eine Bewertungsmatrix mit mehreren quantitativen und qualitativen Kriterien entwickelt werden (vgl. Liang et al. 2023, S.3). Bei der Entwicklung der Bewertungsmatrix werden die Anforderungen für den Anwendungsfall der Corporate Audit Abteilung der FCo berücksichtigt. Die Bewertungsmatrix umfasst drei Hauptkriterien, die für die Eignung der Modelle für den definierten Use Case von zentraler Bedeutung sind. Diese Kriterien sind die Erkennungsleistung der Modelle, die Qualität der Begründungen und die Konsistenz der Ergebnisse. Sind alle drei Kriterien hinreichend erfüllt, können die Modelle als geeignet für den Einsatz im Audit-Use-Case betrachtet werden.

Als zentrales quantitatives Kriterium wird die Erkennungsleistung der Modelle herangezogen. Hierbei werden die Kennzahlen Precision und Recall berechnet. Der Precision-Wert gibt an, wie viele der vom Modell als fehlerhaft identifizierten Rechnungen tatsächlich fehlerhaft sind. Er berechnet sich aus dem Quotienten der richtig als fehlerhaft klassifizierten Rechnungen, den sogenannten True Positives, und der Summe aller als fehlerhaft klassifizierten Rechnungen, also der Summe aus True Positives und False Positives. Der Recall-Wert gibt an, wie viele der tatsächlich fehlerhaften Rechnungen vom Modell korrekt identifiziert wurden. Er berechnet sich aus dem Quotienten der True Positives und der Summe aller tatsächlich fehlerhaften Rechnungen, also der Summe aus True Positives und False Negatives.

Als weiteres Kriterium wird die Qualität der Begründungen der Modelle bewertet. Die qualitative Bewertung der Begründung erfolgt durch zwei Senior Auditoren der FCo. Die

wissenschaftlich
warum
diese
Kriterien

Auditoren bewerten die Begründungen der Modelle anhand der drei Kriterien Korrektheit, Nachvollziehbarkeit und Faktentreue. Jedes Kriterium wird auf einer Skala von 1 bis 5 bewertet, wobei 1 für „sehr schlecht“ und 5 für „sehr gut“ steht. Anschließend wird der Mittelwert der Bewertung der Auditoren gebildet und als Teilwert der Qualität der Begründung herangezogen.

Als letztes Kriterium wird die Konsistenz der Modelle bewertet. Dazu wird jede Rechnung mit identischem Prompt fünfmal von jedem Modell analysiert. Anschließend werden alle unterschiedlichen Befunde erfasst, die über die fünf Durchläufe hinweg gemeldet wurden. Für jeden dieser Befunde wird ermittelt, in wie vielen Durchläufen er auftaucht. Ein Befund, der in allen fünf Durchläufen gemeldet wird, erhält somit den Wert 1, ein Befund, der nur in einem Durchlauf auftaucht, den Wert 0,2. Die Konsistenz ergibt sich aus dem Mittelwert dieser Anteile über alle Befunde und wird in Prozent angegeben. Liefert ein Modell in allen Durchläufen exakt dieselben Befunde, erreicht es eine Konsistenz von 100 %. Je häufiger sich die gemeldeten Befunde zwischen den Durchläufen unterscheiden, desto geringer fällt der Wert aus.

4.7 Gewichtung der Bewertungsmatrix

Um die drei Hauptkriterien zu einem Gesamtergebnis zusammenzuführen, werden diese entsprechend ihrer Bedeutung für den Audit-Use-Case gewichtet. Die Gewichtung erfolgt auf Basis der Anforderungen der Corporate Audit Abteilung der FCo und wird in Tabelle 4.2 dargestellt.

Die Erkennungsleistung erhält mit 50 % das höchste Gewicht, da die zuverlässige Identifikation fehlerhafter Rechnungen die Kernaufgabe der Stichprobenanalyse darstellt. Innerhalb dieses Kriteriums wird der Recall mit 30 % höher gewichtet als die Precision mit 20 %. Ein False Positive, also ein Fehlalarm, wird vom Auditor im Rahmen der weiteren Prüfung erkannt und verursacht lediglich zusätzlichen Prüfaufwand. Wird ein Fehler hingegen vom Modell nicht gemeldet (False Negative), besteht die Gefahr, dass auch der Auditor diesen übersieht, da er sich auf das Ergebnis des Systems verlässt.

Die Qualität der Begründungen wird mit 30 % gewichtet. Auditoren müssen nachvollziehen können, wie ein Ergebnis zustande gekommen ist, um die Befunde prüfen und dokumentieren zu können. Die Korrektheit erhält hierbei mit 12 % das höchste Gewicht, da eine fachlich falsche Argumentation auch bei richtig erkanntem Fehler zu einer fehlerhaften

Gewichtung
klar,
aber
man
kann
auch
anders
gewich-
ten -
siehe 1.
PA

Dokumentation führen kann. Die Nachvollziehbarkeit wird mit 10 % und die Faktentreue mit 8 % gewichtet. Erfundene Angaben sind im Audit zwar besonders kritisch, werden aber teilweise bereits über die Korrektheit erfasst.

Die Konsistenz erhält mit 20 % das geringste Gewicht. Reproduzierbare Ergebnisse sind zwar eine Voraussetzung dafür, dass Auditoren einem Modell vertrauen können. Eine hohe Konsistenz sagt allein jedoch nichts über die Richtigkeit der Ergebnisse aus, da auch ein Modell, das dauerhaft dieselben Fehler übersieht, konsistent arbeitet. Tabelle 4.2 fasst die Gewichtung zusammen.

Hauptkriterium	Gewicht	Teilkriterium	Gewicht
Erkennungsleistung	50 %	Recall	30 %
		Precision	20 %
Qualität der Begründungen	30 %	Korrektheit	12 %
		Nachvollziehbarkeit	10 %
		Faktentreue	8 %
Konsistenz	20 %	Konsistenz	20 %

Tabelle 4.2: Gewichtung der Bewertungsmatrix

Da die Kriterien auf unterschiedlichen Skalen erfasst werden, müssen sie vor der Verrechnung vereinheitlicht werden. Precision, Recall und Konsistenz liegen bereits als Prozentwerte vor. Für die Teilkriterien der Begründungsqualität wird zunächst der Mittelwert über alle Auditoren gebildet. Dieser wird anschließend über $e = \frac{x-1}{4} \cdot 100$ in einen Wert zwischen 0 und 100 umgerechnet, sodass die schlechteste Bewertung den Wert 0 und die beste Bewertung den Wert 100 erhält. Somit sind alle Kriterien auf einer gemeinsamen Skala. Der Nutzwert eines Modells ergibt sich dann als Summe der gewichteten Einzelwerte:

$$N_j = \sum_{i=1}^6 w_i \cdot e_{ij} \quad (4.1)$$

Dabei steht N_j für den Nutzwert des Modells j , w_i für das Gewicht des Teilkriteriums i und e_{ij} für den normierten Wert des Modells j im Teilkriterium i .

Da jede Gewichtung eine gewisse Subjektivität enthält, wird im Rahmen der Auswertung zusätzlich eine Sensitivitätsanalyse durchgeführt. Hierbei werden die Gewichte der Hauptkriterien verändert, um zu prüfen, ob sich die Rangfolge der Modelle dadurch verschiebt. Bleibt die Rangfolge stabil, kann das Ergebnis als robust betrachtet werden.

Sensitivitäts-
Brauch
ich die?

5 Evaluationsdurchführung

5.1 Durchführung der Tests

5.2 Ergebnisse der Stichprobenanalysen

5.2.1 Rechnungen

5.2.2 Benutzerberechtigungen

5.2.3 Gesamtvergleich

5.3 Auswertung der Bewertungsmatrix

5.4 Vergleich der Modelle

5.5 Analyse der Ergebnisse

5.6 Beantwortung der Forschungsfrage

6 Fazit und Ausblick

6.1 Zusammenfassung der wichtigsten Erkenntnisse

6.2 Fazit zur Eignung von LLMs im Audit

6.3 Handlungsempfehlungen für Freudenberg

6.4 Zukünftige Entwicklungspotenziale

A Prompts

A.1 Prompt GPT

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

A.2 Prompt Claude

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy

eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a

turpis eu lacus commodo facilis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Literatur

- Anthropic (2026). *Reduce hallucinations*. URL: <https://platform.claude.com/docs/en/test-and-evaluate/strengthen-guardrails/reduce-hallucinations> (besucht am 02.10.2026).
- Artificial Analysis (2026). *Comparison of AI Models across Intelligence, Performance, and Price*. Artificial Analysis. URL: <https://artificialanalysis.ai/models> (besucht am 11.08.2026).
- Bang, Yejin, Ziwei Ji, Alan Schelten et al. (2025). „HalluLens: LLM Hallucination Benchmark“. In: *arXiv preprint arXiv:2504.17550*. URL: <https://arxiv.org/abs/2504.17550>.
- Baumeister, Daniel (2019). „Sample size and error containment judgments in non-statistical audit sampling-the sensitivity of auditors to a revision of professional standards“. Diss. Dissertation, Dortmund, Technische Universität, 2019.
- Calvino, Flavio, Daniel Haerle und Sarah Liu (Juni 2025). *Is generative AI a General Purpose Technology? Implications for productivity and policy*. OECD Artificial Intelligence Papers 40. Paris: OECD Publishing. DOI: 10.1787/704e2d12-en. URL: https://www.oecd.org/content/dam/oecd/en/publications/reports/2025/06/is-generative-ai-a-general-purpose-technology_6c76e7b2/704e2d12-en.pdf.
- Cantù, Elena, Cecilia Langella und Ilaria Elisa Vannini (2025). „Making sense of the internal audit function: toward internal controls integration and organizational learning“. In: *Financial Accountability & Management* 41.2, S. 262–273.
- DataSnipper (2026). *About DataSnipper*. URL: <https://datasnipper.com/about-us> (besucht am 09.10.2026).
- DeepLearning.AI (o. D.). *Artificial Analysis Revamps Intelligence Index: Independent AI Testing Authority Turns from Saturated Knowledge Benchmarks to Harder Business Tests*. <https://www.deeplearning.ai/the-batch/independent-ai-testing-authority-turns-from-saturated-knowledge-benchmarks-to-harder-business-tests>. Abgerufen am 08.10.2026.
- Emett, Scott et al. (2025). „Leveraging ChatGPT for enhancing the internal audit process—a real-world example from Uniper, a large multinational company“. In: *Accounting Horizons* 39.2, S. 125–135.
- Fedyk, Anastassia et al. (2022). „Is artificial intelligence improving the audit process?“ In: *Review of Accounting Studies* 27.3, S. 938–985. DOI: 10.1007/s11142-022-09697-x.
- Freudenberg, Corporate Audit (2026). „Internal Audit Sample Testing Guidance Examples“. Interne Excel-Datei, Freudenberg & Co. KG.
- Freudenberg & Co. KG (2026). „Verfügbare Modelle im Microsoft Copilot und im Copilot Studio“. Interne Systemkonfiguration, Stand: Oktober 2026.
- G2 (2026). *DataSnipper Reviews 2026: Details, Pricing & Features*. URL: <https://www.g2.com/products/datasnipper/reviews> (besucht am 06.08.2026).

- Gartner Peer Insights (2026). *DataSnipper Reviews, Ratings & Features 2026*. Gartner, Inc. URL: <https://www.gartner.com/reviews/market/artificial-intelligence/vendor/datasnipper> (besucht am 06.08.2026).
- Huang, Lei et al. (2025). „A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions“. In: *ACM transactions on information systems* 43.2, S. 1–55.
- Ivakhnenkov, Serhii (2023). „Artificial intelligence application in auditing“. In: Ji, Ziwei et al. (2023). „Survey of Hallucination in Natural Language Generation“. In: *ACM Computing Surveys* 55.12, S. 1–38. DOI: 10.1145/3571730.
- Kapoor, Sayash et al. (2024). „Position: On the Societal Impact of Open Foundation Models“. In: *Proceedings of the 41st International Conference on Machine Learning*. Bd. 235. Proceedings of Machine Learning Research. PMLR, S. 23082–23104. URL: <https://proceedings.mlr.press/v235/kapoor24a.html>.
- Kokina, Julia et al. (2025). „Challenges and opportunities for artificial intelligence in auditing: Evidence from the field“. In: *International Journal of Accounting Information Systems* 56, S. 100734. ISSN: 1467-0895. DOI: <https://doi.org/10.1016/j.accinf.2025.100734>. URL: <https://www.sciencedirect.com/science/article/pii/S1467089525000107>.
- Kozłowska, Justyna (2022). „Methods of Multi-Criteria Analysis in Technology Selection and Technology Assessment: A Systematic Literature Review“. In: *Engineering Management in Production and Services* 14.2, S. 116–137. DOI: 10.2478/emj-2022-0021.
- Kühnapfel, Jörg B. (2021). *Scoring und Nutzwertanalysen: Ein Leitfaden für die Praxis*. 2. Wiesbaden: Springer Gabler. DOI: 10.1007/978-3-658-34810-6.
- Kyriazos, Theodoros und Mary Poga (2024). „Application of Machine Learning Models in Social Sciences: Managing Nonlinear Relationships“. In: *Encyclopedia* 4.4, S. 1790–1805. DOI: 10.3390/encyclopedia4040118.
- Liang, Percy et al. (2023). *Holistic Evaluation of Language Models*. arXiv: 2211.09110 [cs.CL]. URL: <https://arxiv.org/abs/2211.09110>.
- Liu, Nelson F. et al. (2024). „Lost in the Middle: How Language Models Use Long Contexts“. In: *Transactions of the Association for Computational Linguistics* 12, S. 157–173. DOI: 10.1162/tac1_a_00638.
- Lyell, David und Enrico Coiera (2017). „Automation bias and verification complexity: a systematic review“. In: *Journal of the American Medical Informatics Association* 24.2, S. 423–431.
- Microsoft (2026a). *Daten, Datenschutz und Sicherheit für Microsoft Copilot*. Microsoft Learn. URL: <https://learn.microsoft.com/de-de/microsoft-365/copilot/microsoft-365-copilot-privacy> (besucht am 08.10.2026).
- (11. Mai 2026b). *Schreiben effektiver Anweisungen für deklarative Agents*. URL: <https://learn.microsoft.com/en-us/microsoft-365/copilot/extensibility/declarative-agent-instructions> (besucht am 02.10.2026).
- Munoko, Ivy, Helen L. Brown-Liburd und Miklos Vasarhelyi (2020). „The Ethical Implications of Using Artificial Intelligence in Auditing“. In: *Journal of Business Ethics* 167.2, S. 209–234. DOI: 10.1007/s10551-019-04407-1.

- Panda, Silu (2026). *FinVerBench: Evaluating Large Language Models on Numerical Consistency Verification of Financial Statements*. Preprint, eingereicht am 28.05.2026. DOI: 10.48550/arXiv.2605.29586. arXiv: 2605.29586 [cs.CL]. URL: <https://arxiv.org/abs/2605.29586> (besucht am 07.09.2026).
- Perez, Ethan, Douwe Kiela und Kyunghyun Cho (2021). „True Few-Shot Learning with Language Models“. In: *Advances in Neural Information Processing Systems*. Hrsg. von M. Ranzato et al. Bd. 34. Curran Associates, Inc., S. 11054–11070. URL: https://proceedings.neurips.cc/paper_files/paper/2021/file/5c04925674920eb58467fb52ce4ef7Paper.pdf.
- Roussy, Mélanie (2013). „Internal auditors' roles: From watchdogs to helpers and protectors of the top manager“. In: *Critical Perspectives on Accounting* 24.7, S. 550–571. ISSN: 1045-2354. DOI: <https://doi.org/10.1016/j.cpa.2013.08.004>. URL: <https://www.sciencedirect.com/science/article/pii/S1045235413000932>.
- Schreyer, Marco et al. (2024). *Artificial Intelligence Agentic Auditing*. SSRN Working Paper. DOI: 10.2139/ssrn.4909147. URL: <https://ssrn.com/abstract=4909147>.
- Schulhoff, Sander et al. (2025). *The Prompt Report: A Systematic Survey of Prompt Engineering Techniques*. arXiv: 2406.06608 [cs.CL]. URL: <https://arxiv.org/abs/2406.06608>.
- Schumann, Gerrit und Jorge Marx Gómez (2021). „Natural language processing in internal auditing—A structured literature review“. In.
- Sclar, Melanie et al. (2024). „Quantifying Language Models' Sensitivity to Spurious Features in Prompt Design or: How I learned to start worrying about prompt formatting“. In: *International Conference on Learning Representations*. Hrsg. von B. Kim et al. Bd. 2024, S. 25055–25083. URL: https://proceedings.iclr.cc/paper_files/paper/2024/file/6c0e99d736da621403018ca7b32b1a4d-Paper-Conference.pdf.
- Shi, Freda et al. (2023). „Large Language Models Can Be Easily Distracted by Irrelevant Context“. In: *Proceedings of the 40th International Conference on Machine Learning*. Bd. 202. Proceedings of Machine Learning Research. URL: <https://arxiv.org/abs/2302.00093>.
- The Institute of Internal Auditors (2024). *Global Internal Audit Standards*. Accessed: 2026-09-02. Lake Mary, FL: The Institute of Internal Auditors. URL: https://www.theiia.org/globalassets/site/standards/globalinternalauditstandards_2024january9.pdf.
- Wassie, Fekadu Agmas und László Péter Lakatos (2024). „Artificial intelligence and the future of the internal audit function“. In: *Humanities and Social Sciences Communications* 11.1, S. 386.
- YourAIFinder (2026). *DataSnipper – AI Audit Automation Platform Inside Excel*. URL: <https://youraifinder.com/tool/datasnipper> (besucht am 06.08.2026).

Hilfsmittelangabe zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten



Persönliche Angaben

Verclas, Leonard	3317974
Nachname, Vorname	Matrikelnummer
Gaußstrasse 5, 68775 Ketsch	WDSKI24B
Anschrift	Kurs
S242792@student.dhbw-mannheim.de	0176 45895734
E-Mail	Telefon- / Handynummer

Für das Modul

Praxismodul 2
Modulbezeichnung / Semester

muss ich am

09.11.2026
Datum der Frist

folgende Prüfungsleistung erbringen:

- ☐ Projektarbeit I ☒ Projektarbeit II
- ☐ Seminararbeit ☐ Bachelorarbeit
- ☐ Sonstige

genaue Bezeichnung der sonstigen Prüfungsleistung

Zur Verwendung KI-gestützter Werkzeuge erkläre ich in Kenntnis des Hinweisblatts "Hinweise zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung wissenschaftlicher Arbeiten und die prüfungsrechtlichen Folgen ihres Einsatzes" Folgendes:

- Ich habe mich aktiv über die Leistungsfähigkeit und Beschränkungen der in meiner Arbeit eingesetzten KI-Werkzeuge informiert.
- Bei der Anfertigung der Prüfungsleistung habe ich durchgehend eigenständig und beim Einsatz KI-gestützter Werkzeuge maßgeblich steuernd gearbeitet.
- Insbesondere habe ich die Inhalte entweder aus wissenschaftlichen oder anderen zugelassenen Quellen entnommen und diese gekennzeichnet oder diese unter Anwendung wissenschaftlicher Methoden selbst entwickelt.
- Mir ist bewusst, dass ich als Autor/in der Arbeit die Verantwortung für die in ihr gemachten Angaben und Aussagen trage.
- Ich habe keine weiteren als die nachstehend von mir benannten KI-gestützten Werkzeuge zur Erstellung der Arbeit eingesetzt und diese nur in der angegebenen Art und Weise.

- Soweit ich KI-gestützte Werkzeuge zur Erstellung der Arbeit eingesetzt habe, gebe ich diese in der nachstehenden "Übersicht verwendeter Hilfsmittel" mit ihrem Produkt-namen und ihres genutzten Funktionsumfangs vollständig an; wörtliche oder sinn-gemäße Übernahmen KI-generierter Inhalte habe ich in ein separates Verzeichnis aufgenommen und im Text belegt (z. B. als Fußnote). Diese Inhalte sind als pdf-Datei in den elektronischen Beigaben hinterlegt.

Produktname(n) eingesetzter Hilfsmittel:

--

Genutzter Funktionsumfang im Hinblick auf

- **Themenerfassung und Strukturierung** (Aufgabenstellung oder Präzisierung, Forschungsansatz, Gliederung)

--

- **Themenbearbeitung** (Darstellung/Beschreibung des Problems, Darlegung von wissenschaftlichen Grundlagen, Schlussfolgerungen allgemein und für das konkrete Thema / Erkenntnisgewinn, Evaluierung des Textes / Feedback der KI)

--

- **Quellenrecherche, -auswahl und -auswertung** (welche Quellen wurden durch das KI-Werkzeug gefunden, wie erfolgte die weitere Recherche)

--

- **Formale Gestaltung, insbesondere Sprache** (Welche Eingabe wurde an die KI getätigt? Textgenerierung, Textkorrektur, Paraphrasieren und Umschreiben, Übersetzen, kreatives Schreiben)

--

Hinweis:

Geben Sie in der jeweiligen Rubrik die Seitenzahl in ihrer wissenschaftlichen Arbeit an und erläutern Sie die Art und Weise sowie den Umfang der von Ihnen genutzten KI-basierten Werkzeuge.

--	--

Ort, Datum

Unterschrift der/des Studierenden