

Duale Hochschule Baden-Württemberg Mannheim

Projektarbeit 2

Einsatz von LLMs zur Unterstützung von Stichprobenanalysen im Audit-Bereich. Ein Vergleich verschiedener KI-Modelle hinsichtlich ihrer Eignung für interne Prüfungsprozesse bei der Freudenberg Group

Studiengang Wirtschaftsinformatik

Studienrichtung Data Science und Künstliche Intelligenz

Verfasser(in):	Leonard Verclas
Matrikelnummer:	3317974
Firma:	Freudenberg & Co. Kommanditgesellschaft
Kurs:	WDSKI24B
Studiengangsleiter:	Prof. Dr. Bernhard Drabant
Wissenschaftliche(r) Betreuer(in):	Stefanie Bell
Firmenbetreuer(in):	Andreas Hass
Bearbeitungszeitraum:	03.08.2026 - 09.11.2026

Todo list

Text Kapitel 4	2
Text Grundlagen und Kapitel 3	2
vllt. zu hypothetisch -> wie ght er über reine Compliance-Aspekte hinaus?	3
Hier zum Einstieg noch mehr Kontext. Das internal Audit hat verschiedene Methoden. ua Stichproben -> rechnungen aber auch user benutzeranlegen etc.	4
auch wieder sehr mystisch: mitteleinsatz prüfungseffizienz etwas menschlicher einfacher ausführen	4
noch durchgehe, quellen etc .-> siehe copilot chat	5
nochmal schauen welche modelle es jetzt gibt	11
Quelle? ansonsten auch David	11
genaue zahlen begründen: 100 rechnungen, 24 %, 24 fehler, fehler 7, 54, 3, 3, 2	12
Freudenberg klar machen -> Freudenberg CO. KG	13
wissenschaftlich warum diese Kriterien	16
Gewichtung klar, aber man kann auch anders gewichten - siehe 1. PA	17
Sensitivitätsanalyse? Brauch ich die?	18

1. Erstellen von fehlerhaften Rechnungen und Tickets (Orientierung an historischen Auditfällen)
2. Modelle analysieren Dokumente
3. Anwendung der Bewertungsmatrix
4. Punktesystem auf Bewertungsmatrix anwenden
5. Auswertung der Ergebnisse
6. Zusätzlich: Modelle auf historische Ereignisse prüfen, bzw. historische Ereignisse nochmals auf Fehler überprüfen

Stichprobenrisiko erklärt: (vgl. Baumeister 2019, S.12) und detailliert S. 40 ff.

herausforderungen und möglichkeiten künstlicher Intelligenz im Auditbereich:

Möglichkeiten:

Große datenmengen anstelle von stichproben durch schnellere Bearbeitung. Herausfiltern von wichtigen Kennzahlen, wie kosten, vertragspartner etc. -> Pflichtproben herausfiltern, die menschliche oder maschinelle Prüfung benötigen. (vgl. (Kokina et al. 2025, S.3))

Anomalieerkennung -> z.b. finanzielle Informationen (vgl. (Kokina et al. 2025, S.2))

Herausforderungen:

Transparenz und Erklärbarkeit - Auditoren und Regulatoren müssen verstehen können, warum wurde eine Entscheidung getroffen, wie ist ein Ergebnis zustande gekommen? (Kokina et al. 2025, S.16)

Robustheit und Zuverlässigkeit - Es muss nachweisbar sein, dass die Ergebnisse reproduzierbar sind, das Modelle stabil arbeiten und kein Model drift stattfindet (Kokina et al. 2025, S. 13 f.)

Übermäßiges Vertrauen an die KI - Auditoren müssen Ergebnisse immernoch professional skeptisch auditieren. Die KI darf nur als Unterstützer gelten. Die finale Entscheidung bleibt beim Auditor. Durch den Einsatz von KI kann es hier zu AutomationBias führen. Hierbei kann es dazu kommen, dass Auditoren Fehler übersehen, weil das System keine gemeldet hat. (Lyell und Coiera 2017, S.425 f.)

0.1 Prompt Optimizing

Da die Literatur zeigt, dass die Auswahl des optimalen Prompts selbst ein schwieriges Modellselektionsproblem darstellt und die Few-Shot-Fähigkeit von LLMs häufig überschätzt wird, wurde in dieser Arbeit bewusst auf modellspezifische Promptoptimierung verzichtet. Stattdessen wurden identische Prompts für alle Modelle verwendet, um eine faire Vergleichbarkeit sicherzustellen. Perez, Kiela und Cho 2021

Inhaltsverzeichnis

0.1 Prompt Optimizing	ii
Abbildungsverzeichnis	v
Tabellenverzeichnis	vi
Quelltextverzeichnis	vii
Abkürzungsverzeichnis	viii
Kurzfassung (Abstract)	ix
1 Einleitung	1
1.1 Problemstellung & Motivation	1
1.2 Zielsetzung der Arbeit	1
1.3 Aufbau der Arbeit	2
2 Grundlagen	3
2.1 Internal Audit	3
2.2 Stichprobenanalyse im Internal Audit	4
2.3 Künstliche Intelligenz	4
2.3.1 Large Language Models	4
2.3.2 Prompt Engineering	4
2.4 Einsatz von Künstlicher Intelligenz im Audit	4
2.4.1 Potenziale in der Stichprobenanalyse	5
2.4.2 Risiken in der Stichprobenanalyse	5
3 State of the Art	6
3.1 Aktuelle Durchführung von Stichprobenanalyse bei Freudenberg	6
3.2 Einsatz von KI im Auditbereich	7
3.3 Verfügbare KI-Lösungen für Audits	7
3.3.1 Kommerzielle Lösungen	8
3.3.2 Open-Source-Lösungen	8
3.3.3 Spezialisierte KI-gestützte Audit-Lösung	8
3.4 Einordnung des KI-Einsatzes bei Freudenberg	9

4	Evaluationsdesign	10
4.1	Forschungsdesign	10
4.2	Auswahl der zu untersuchende Modelle	10
4.3	Entwicklung der Testdatensätze	11
4.4	Entwicklung eines geeigneten Prompts	12
4.5	Nutzwertanalyse	15
4.6	Entwicklung einer Bewertungsmatrix	16
4.7	Gewichtung der Bewertungsmatrix	17
5	Evaluationsdurchführung	19
5.1	Durchführung der Tests	19
5.2	Ergebnisse der Stichprobenanalysen	19
5.2.1	Rechnungen	19
5.2.2	Benutzerberechtigungen	19
5.2.3	Gesamtvergleich	19
5.3	Auswertung der Bewertungsmatrix	19
5.4	Vergleich der Modelle	19
5.5	Analyse der Ergebnisse	19
5.6	Beantwortung der Forschungsfrage	19
6	Fazit und Ausblick	20
6.1	Zusammenfassung der wichtigsten Erkenntnisse	20
6.2	Fazit zur Eignung von LLMs im Audit	20
6.3	Handlungsempfehlungen für Freudenberg	20
6.4	Zukünftige Entwicklungspotenziale	20
Anhang		
A	Prompts	21
A.1	Prompt GPT	21
A.2	Prompt Claude	22
Literatur		25

Abbildungsverzeichnis

Tabellenverzeichnis

4.1	Verteilung der eingebauten Fehler auf die Fehlergruppen	12
4.2	Versionen des Prompts	15
4.3	Gewichtung der Bewertungsmatrix	18

Quelltextverzeichnis

Abkürzungsverzeichnis

DHBW	Duale Hochschule Baden-Württemberg
LLM	Large Language Model
KI	Künstliche Intelligenz
FCo	Freudenberg & Co.

Kurzfassung (Abstract)

1 Einleitung

1.1 Problemstellung & Motivation

Mit der fortschreitenden Entwicklung Künstliche Intelligenz (KI) stehen Unternehmen vor der Herausforderung, ihre Geschäftsprozesse kontinuierlich zu optimieren und durch den gezielten Einsatz neuer Technologien effizienter zu gestalten. Insbesondere im Audit-Umfeld bietet der Einsatz von KI ein erhebliches Potenzial zur Steigerung von Effizienz, Prüfungsqualität und Transparenz. KI unterstützt interne Auditoren, indem der manuelle Analyseaufwand reduziert wird und umfassendere sowie schnellere Prüfungen ermöglicht werden. (vgl. Wassie und Lakatos 2024, S. 11–12).

Ein besonders vielversprechendes Anwendungsfeld stellt die Analyse von Audit-Stichproben dar. Im Rahmen dieser Prüfungen werden zum Beispiel Rechnungen untersucht, um Auffälligkeiten, Regelverstöße oder potenzielle Risiken zu identifizieren. Die manuelle Analyse dieser Unterlagen ist jedoch zeitaufwendig und bindet erhebliche personelle Ressourcen. Gleichzeitig steigt aufgrund wachsender Datenmengen und zunehmend komplexer Geschäftsprozesse die Schwierigkeit, relevante Auffälligkeiten zuverlässig zu erkennen.

Vor diesem Hintergrund gewinnt die Unterstützung von Stichprobenanalysen durch KI-basierte Verfahren zunehmend an Bedeutung. Für die Freudenberg-Gruppe stellt sich dabei die Frage, wie KI-Technologien gewinnbringend in die Stichprobenanalyse im Internal-Audit-Prozess integriert werden können. Neben der Verbesserung der Effizienz und Prüfungsqualität durch den Einsatz von KI spielt insbesondere die Einhaltung strenger Datenschutz- und Compliance-Anforderungen sowie die Auswahl eines geeigneten KI-Modells für die Analyse von Audit-Dokumenten eine zentrale Rolle. Daraus ergibt sich die Notwendigkeit, die Eignung verschiedener KI-Lösungen für die Unterstützung von Stichprobenanalysen im Internal Audit systematisch zu untersuchen.

1.2 Zielsetzung der Arbeit

Ziel dieser Projektarbeit ist die systematische Untersuchung und Bewertung verschiedener KI-gestützter Werkzeuge zur Unterstützung von Stichprobenanalysen im Internal Audit

der Freudenberg-Gruppe. Der Fokus liegt dabei auf Large Language Models (LLMs), die Auditoren bei der Analyse von Prüfungsdokumenten unterstützen können. Hierzu werden ausgewählte LLMs auf identische Audit-Stichproben angewendet. Die Modelle sollen potenzielle Auffälligkeiten, Risiken oder Regelverstöße in Rechnungen identifizieren sowie ihre Bewertungen nachvollziehbar begründen. Anschließend werden die Ergebnisse anhand einer Bewertungsmatrix miteinander verglichen. Dabei stehen insbesondere die Erkennungsqualität, die Nachvollziehbarkeit der Ergebnisse, die Konsistenz der Analysen sowie die praktische Einsetzbarkeit im Audit-Umfeld im Vordergrund. Auf Basis dieser Untersuchung soll ermittelt werden, welches KI-Modell die Anforderungen der Freudenberg-Gruppe im Kontext von Stichprobenanalysen im Internal Audit am besten erfüllt. Die gewonnenen Erkenntnisse sollen eine fundierte Grundlage für die Bewertung des Potenzials von LLMs im Audit-Bereich sowie für deren zukünftigen Einsatz innerhalb der Organisation schaffen. Daraus ergibt sich folgende Forschungsfrage: Wie unterscheiden sich verschiedene Large Language Models hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit-Bereich?

1.3 Aufbau der Arbeit

Text
Kapitel
4

Text
Grund-
lagen
und
Kapitel
3

2 Grundlagen

2.1 Internal Audit

Das Internal Audit stellt eine unabhängige und objektive Prüfungs- und Beratungsfunktion innerhalb einer Organisation dar. Die zentrale Aufgabe besteht darin, die Angemessenheit und Wirksamkeit von Governance-, Risikomanagement- und internen Kontrollsystemen zu bewerten sowie durch unabhängige Prüfungs- und Beratungsleistungen zur Verbesserung dieser Systeme beizutragen. Im Gegensatz zu externen Audits ist das Internal Audit organisatorisch in das Unternehmen eingebunden, wobei seine Unabhängigkeit durch geeignete Governance-Strukturen sichergestellt wird (vgl. The Institute of Internal Auditors 2024, S.15-16). Als Bestandteil des Internen Kontrollsystems unterstützt das Internal Audit die Organisation dabei, ihre strategischen und operativen Ziele wirksam und regelkonform zu erreichen. Dabei überprüft es bestehende Prozesse, identifiziert Risiken und bewertet die Wirksamkeit implementierter Kontrollmaßnahmen (vgl. Cantù, Langella und Vannini 2025, S. 263–264). Die Existenz von Audit-Funktionen begründet sich insbesondere durch die Notwendigkeit, Transparenz, Rechenschaftspflicht und Vertrauen innerhalb komplexer Organisationen sicherzustellen.

Moderne Audit-Ansätze beschränken sich jedoch nicht ausschließlich auf die Überprüfung der Regelkonformität. Vielmehr soll Internal Audit organisatorisches Lernen fördern, das Risikobewusstsein der beteiligten Akteure stärken und Verbesserungsmöglichkeiten in Geschäftsprozessen aufzeigen. Dadurch leistet die Funktion einen Beitrag zur kontinuierlichen Weiterentwicklung der Organisation und schafft einen Mehrwert, der über reine Compliance-Aspekte hinausgeht (vgl. Cantù, Langella und Vannini 2025, S. 18–21). Für die Durchführung der Prüfungen werden unter anderem Dokumente gesichtet, interpretiert und analysiert sowie deren Übereinstimmung mit gegebenen Anforderungen bewertet (vgl. Roussy 2013, S. 556–557). Ein Prozess, der ein erhebliches Potenzial für die Nutzung von KI mit sich bringt (vgl. Schumann und Marx Gómez 2021, S.1). Im Rahmen dieser Arbeit liegt der Fokus auf dem Internal Audit bei Freudenberg & Co. (FCo), welches für die Prüfung von Dokumenten und Abläufen aus verschiedenen Konzernfunktionen der Freudenberg Gruppe zuständig ist.

vllt. zu
hypote-
thisch
-> wie
geht er
über
reine
Compliance
Aspekte
hinaus?

2.2 Stichprobenanalyse im Internal Audit

Für das Internal Audit ist es in der Regel nicht möglich, alle Dokumente einer Grundgesamtheit zu prüfen. Daher wird unter anderem auf die Stichprobenanalyse zurückgegriffen. Bei der Stichprobenanalyse wird aus einer Grundgesamtheit eine Pflichtprobe und eine zufällige Stichprobe entnommen. Die Grundgesamtheit bildet eine abgegrenzte Menge gleichartiger Elemente, beispielsweise alle Rechnungen, die einem Konto zugeordnet sind. Die Pflichtprobe der Grundgesamtheit umfasst alle Elemente, die zuvor definierte Kriterien erfüllen, beispielsweise Rechnungen, die über einem bestimmten Betrag liegen. Diese Elemente müssen als Teil der Stichprobe geprüft werden. Weitergehend wird aus den restlichen Elementen der Grundgesamtheit eine zufällige Stichprobe entnommen, die zusätzlich zur Pflichtprobe geprüft wird (vgl. Freudenberg 2026). Die verbleibenden Elemente der Grundgesamtheit werden vorerst nicht geprüft und bedingen damit eine gewisse Unschärfe der Prüfungsaussagen, was als Stichprobenrisiko bezeichnet wird. Ziel ist es, eine möglichst hohe Prüfungseffizienz zu erreichen. Demnach wird versucht mit dem geringsten Mitteleinsatz ein hinreichend sicheres Prüfungsurteil zu erreichen (vgl. Baumeister 2019, S. 11–12).

Hier zum Einstieg noch mehr Kontext. Das internal Audit hat verschiedene Methoden, ua Stichproben -> rechnungen aber auch user benutzeranlegen etc.

2.3 Künstliche Intelligenz

2.3.1 Large Language Models

2.3.2 Prompt Engineering

Das Prompt Engineering beschreibt den wichtigsten Part der Nutzung eines KI-Systems. Erst durch den Prompt weiß die Maschine was der User erreichen möchte. Ein Prompt kann in verschiedenen klar definierte Teile unterteilt sein.

2.4 Einsatz von Künstlicher Intelligenz im Audit

Der Einsatz von KI im Audit ist kein rein konzeptionelles Zukunftsszenario, sondern bereits in der Prüfungspraxis etabliert (vgl. Kokina et al. 2025, S. 7 f.). KI unterstützt Auditoren bei der Analyse großer strukturierter und unstrukturierter Datenmengen, indem sie

auch wieder sehr mystisch: mitte-leinsatz prüfungseffizienz etwas menschlicher einfa

Muster erkennt, Anomalien identifiziert und Vorhersagen trifft (vgl. Ivakhnenkov 2023, S. 56). KI unterscheidet sich zu klassischen Datenanalysemethoden dadurch, dass sie auch nichtlinearer Zusammenhänge verarbeiten kann und somit flexibel auf unterschiedliche Auffälligkeiten aufmerksam machen kann (vgl. Kyriazos und Poga 2024, S. 1790 f.). Es zeigt sich, dass Auditfirmen mit höheren KI-Investitionen eine bessere Prüfungsqualität erreichen und gleichzeitig die Prüfungszeit verkürzen können (vgl. Fedyk et al. 2022, S. 940 ff.). Somit zeigen sich auch für das internal Audit bei FCo Potenziale, die Effizienz und Qualität der Prüfungen durch den gezielten Einsatz von KI zu steigern.

2.4.1 Potenziale in der Stichprobenanalyse

Besonders in der Stichprobenanalyse kann der Einsatz von KI zu einer signifikanten Effizienzsteigerung führen. Durch die Automatisierung der Dokumentenprüfung können Auditoren schneller und umfassender potenzielle Auffälligkeiten, Risiken oder Regelverstöße identifizieren. KI-gestützte Systeme können große Mengen an Rechnungen analysieren, Muster erkennen und Anomalien hervorheben, die menschlichen Prüfern möglicherweise entgehen würden. Dies ermöglicht eine gezieltere Auswahl von Stichproben und reduziert den manuellen Aufwand erheblich. Zudem kann KI dazu beitragen, die Konsistenz und Nachvollziehbarkeit der Prüfungsprozesse zu verbessern, indem sie standardisierte Bewertungsmaßstäbe anwendet und Ergebnisse transparent dokumentiert. Durch die Automatisierung durch KI kann eine deutlich größere Menge an Stichproben analysiert werden, wodurch die Aussagekraft der Prüfungsergebnisse steigt und das Stichprobenrisiko minimiert wird.

2.4.2 Risiken in der Stichprobenanalyse

Trotz der zahlreichen Vorteile birgt der Einsatz von KI in der Stichprobenanalyse auch Risiken. Ein zentrales Risiko besteht in der Abhängigkeit von den verwendeten KI-Modellen und deren Trainingsdaten. Wenn die Modelle auf unzureichenden oder verzerrten Daten trainiert wurden, können sie fehlerhafte oder voreingenommene Ergebnisse liefern oder Halluzinieren, was zu falschen Prüfungsurteilen führen kann. Zudem besteht die Gefahr des Automation-Bias. Auditoren können die Ergebnisse der KI-Systeme unkritisch übernehmen, ohne diese ausreichend zu hinterfragen und so Auffälligkeiten oder Risiken übersehen.

3 State of the Art

3.1 Aktuelle Durchführung von Stichprobenanalyse bei Freudenberg

Aktuell folgen die Stichprobenanalysen im Internal Audit bei Freudenberg einer strukturierten und risikoorientierten Vorgehensweise. Der Prozess lässt sich exemplarisch anhand der Prüfung von Lieferantenrechnungen ohne Bestellnummer beschreiben und ist grundsätzlich auf weitere Anwendungsfälle übertragbar. Zunächst wird eine Grundgesamtheit relevanter Objekte definiert, hier aller im Prüfungszeitraum erfassten Rechnungen ohne Bestellnummer. Anschließend wird diese Grundgesamtheit anhand definierter Kriterien, wie Rechnungswert, Lieferant, manueller Buchung oder weiterer risikorelevanter Merkmale, kategorisiert und analysiert.

Auf Basis dieser Klassifizierung wird ein Threshold festgelegt. Alle Rechnungen, die diesen Schwellenwert überschreiten, werden verpflichtend in die Stichprobe aufgenommen. Ergänzend dazu wird eine zufällige Auswahl weiterer Rechnungen aus der verbleibenden Grundgesamtheit getroffen, um eine angemessene Abdeckung des Prüffeldes sicherzustellen.

Die ausgewählten Stichprobenelemente werden anschließend durch den Auditor einer detaillierten Prüfung unterzogen. Hierbei werden sämtliche für die Bewertung relevanten Informationen und Nachweisdokumente gesammelt, geprüft und dokumentiert. Nach Abschluss der Analyse bewertet der Auditor die Ergebnisse hinsichtlich möglicher Auffälligkeiten, Abweichungen oder Regelverstöße. Werden Unregelmäßigkeiten festgestellt, werden diese dokumentiert und als Audit Exceptions erfasst.

Durch die Kombination aus risikobasierter Auswahl und zufälliger Stichprobenziehung wird sichergestellt, dass sowohl potenziell kritische Transaktionen als auch repräsentative Elemente der Grundgesamtheit in die Prüfung einbezogen werden. Dadurch kann mit vertretbarem Prüfungsaufwand ein hohes Maß an Prüfungssicherheit erreicht werden. (vgl. (Freudenberg 2026))

3.2 Einsatz von KI im Auditbereich

Forschungsstand, vergleichbare studien, andere Unternehmen

3.3 Verfügbare KI-Lösungen für Audits

Auswahlverfahren basierend auf AI Benchmarks:

Modell muss Dokumente interpretieren, Belege verknüpfen, Inkonsistenzen finden, Schlussfolgerungen begründen

Intelligence Index: aggregiert mehrere Test, GPQA (5 Sterne) , Humanity's Last Exam (5 Sterne), Browse Comp (4 Sterne), SimpleQA (4 Sterne), MRCR (4 Sterne), SciCode (2 Sterne) etc. -> allgemeiner Index

Agentic Index: nutzen wir agenten?

Context Window -> Audit prüfung viele dateien und Daten -> je größer, desto mehr Dokumente können gleichzeitig verarbeitet werden

Coding Index -> Excel-Datei analysieren? Stichproben automatisch ziehen?

Cost per Task -> in vergleich zu den oben stehenden benchmarks

wenig relevant : speed, latency, output tokens

Intelligence Index: Opus 5 , Fable 5, GPT 5.6, Kimi K3, Grok 4.5, Sonnet 5, GLM 5.2

Intelligence Index vs. Cost per Intelligence Index Task:

DeepSeek V4 Flash, GPT-5.6(Luna), Grok 4.5, Kimi K3

Context Window: Kimi K3, GPT 5.6 (Luna, Terra, Sol) GLM 5.2, Sonnet 5, Haiku 4.5, Opus 5, Fable 5

(Artificial Analysis 2026)

3.3.1 Kommerzielle Lösungen

- Microsoft Copilot (Audit hat Zugriff): GPT 5.6 (nicht klar, ob sol, terra, luna), GPT 5.5 - Claude (Zuhause - keine sensiblen Daten (Daten selber erstellen)): Fable 5. Opus 5, Sonnet 5, Haiku 4.5 - Grok 4 - nur standard

3.3.2 Open-Source-Lösungen

Kimi K3 -> aber das kann man nirgendwo laufen lassen

Laptop (16 GB RAM) -> Qwen 3.5 PB, Phi-4 -> deutlich schlechter, wo kann ich das laufen lassen? LM studio zum manuellen testen OLLama zur python evaluierung

3.3.3 Spezialisierte KI-gestützte Audit-Lösung

Abseites von generativen LLMs gibt es spezialisierte KI-gestützte Audit-Lösungen. In dieser Arbeit wird DataSnipper als die Vergleichssoftware zu den herkömmlichen LLMs genutzt. DataSnipper erzielt an mehreren Rankings sehr gute Rankings unter KI-gestützten Audit-Lösungen und wird auch von den Big 4 als Audit-Tool verwendet, was das Tool zu einer der weit verbreitesten spezialisierten KI-Lösungen im Audit-Bereich macht und eine hohe Marktrelevanz besitzt (vgl. G2 2026, Gartner Peer Insights 2026, YourAIFinder 2026). DataSnipper fungiert als Excel-Add-In und stellt verschiedene KI-Funktionen zur Unterstützung von Auditprozessen bereit. Im Gegensatz zu herkömmlichen LLMs wurde DataSnipper speziell für die Anforderungen von Audit- und Finance-Prozessen entwickelt. Zu den zentralen Funktionalitäten gehören die automatisierte Datenextraktion, der Abgleich von Dokumenten mit Arbeitspapieren, die Erstellung nachvollziehbarer Audit Trails sowie die KI-gestützte Analyse von Dokumenten. Darauf aufbauend gibt es erweiterte Funktionen durch sogenannte Excel Agent, die Audit Aufgaben innerhalb bestehender Workflows unterstützen. Ein wesentliches Merkmal ist der Human-in-the-Loop-Ansatz. Dbai übernimmt die Software repetitive Prüfungs- und Dokumentationsschritte, während fachliche Entscheidungen und die finale Bewertung weiterhin durch den Auditor erfolgt. Zudem bleibt jede Analyse mit den zugrunde liegenden Dokumenten verknüpft, wodurch eine hohe Nachvollziehbarkeit der Ergebnisse gewährleistet wird.

3.4 Einordnung des KI-Einsatzes bei Freudenberg

Die Freudenberg Gruppe nutzt aktuell gruppenweit die KI-Lösung von Microsoft Microsoft Copilot. Hierbei werden für alle Nutzer die Modelle GPT 4.5 und GPT 4.6 zur Verfügung gestellt. Der Copilot darf hierbei Zugriff auf alle internen Dokumente haben und bietet volle Datensicherheit- und integrität. Zusätzlich zum Microsoft Copilot gibt es für eine geringe Anzahl an Nutzern über GitHub Copilot die Möglichkeit auf begrenzte Ressourcen von Claude Sonnet und Claude Opus zuzugreifen. Hierbei lagte der Fokus jedoch auf der Software-Entwicklung. Die Anwendung auf den Auditbereich ist hierbei auf Grund von begrenzter Ressourcen nicht empfehlenswert.

4 Evaluationsdesign

4.1 Forschungsdesign

Zur Beantwortung der Forschungsfrage, wie sich verschiedene LLMs hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit unterscheiden, wird in dieser Arbeit eine vergleichende Evaluation der Modelle durchgeführt. Dazu werden die ausgewählte Modelle auf verschiedene Prüfungsdokumente angewendet. Die Modelle analysieren die Dokumente als auch die Bestätigungen zur Freigabe der Rechnungen, markieren mögliche Auffälligkeiten und begründen ihre Befunde. Die Ergebnisse werden anschließend anhand festgelegter Kriterien bewertet und miteinander verglichen. Damit Unterschiede in den Ergebnissen tatsächlich auf die Modelle zurückzuführen sind, werden alle übrigen Einflussfaktoren konstant gehalten. Alle Modelle erhalten dieselben Rechnungen und dieselben Freigaben sowie denselben Prompt um identische Bedingungen zu gewährleisten.

4.2 Auswahl der zu untersuchende Modelle

Die Auswahl der zu untersuchenden Modelle basiert auf der aktuellen Nutzung von KI-Lösungen für die Freudenberg Gruppe. Wie in 3.4 beschrieben nutzt die Freudenberg Gruppe gruppenweit den Microsoft Copilot Premium Version und die dort ausgerollten Modelle von OpenAI und Anthropic. Hierbei werden sowohl die internen Datenschutz- und Compliance Richtlinien als auch EU-Richtlinien eingehalten. Ein weiterer Vorteil ist, dass durch die Nutzung der Modelle über den Microsoft Copilot keine weiteren Kosten aufkommen. Zudem ist der Copilot schon im internal Audit ausgerollt, weshalb es keiner weiteren Schulungen und Gewöhnungszeiten für Mitarbeiter braucht.

Auch die Nutzung von Open-Source-Modellen stellt grundsätzlich eine Alternative zu kommerziellen Lösungen dar. Durch den Betrieb auf unternehmensinterner Infrastruktur können Datenschutz- und Compliance-Anforderungen gezielt berücksichtigt werden. Da die Bereitstellung und der Betrieb solcher Modelle jedoch mit erheblichem Infrastruktur- und Implementierungsaufwand verbunden sind, werden Open-Source-Modelle im Rahmen dieser Arbeit nicht betrachtet.

Der Microsoft Copilot ermöglicht es den Auditieren auf die Modelle Claude Sonnet, Claude Opus, GPT 5.6 Sol (Schnelle Analyse), GPT 5.6 Sol (Tiefere Analyse) zuzugreifen. Genauere Details, bei welcher Anfrage der Copilot auf GPT 5.6 Sol, GPT 5.6 Terra oder GPT 5.6 Luna zugreift sind nicht bekannt. Die vier Modelle gehören laut dem Artificial Analysis Intelligence Index zu den aktuell mit am besten gewerteten kommerziellen KI-Modellen und sind somit für den Anwendungsfall bei der FCo geeignet (vgl. Artificial Analysis 2026).

nochmal
schauen
welche
modelle
es jetzt
gibt

4.3 Entwicklung der Testdatensätze

Für die Evaluation der betrachteten KI-Modelle ist eine Datenbasis erforderlich, die den realen Prüfungskontext möglichst genau abbildet. Die Verwendung originaler Rechnungsbelege aus dem Internal Audit der Freudenberg-Gruppe ist ausgeschlossen, da diese personenbezogene sowie geschäftskritische Informationen enthalten und daher im Rahmen dieser Evaluierung nicht herangezogen werden dürfen. Um dennoch eine hinreichend umfangreiche und belastbare Testbasis zu schaffen, werden die Testdatensätze mithilfe generativer KI erzeugt. Die künstlich erstellten Rechnungen orientieren sich in Struktur, Umfang und Informationsgehalt an realen Rechnungen und enthalten dieselben prüfungsrelevanten Kriterien wie die im Audit untersuchten Dokumente. Nach der Generierung der Rechnungen werden gezielt Fehler in die Dokumente eingebracht. Dieser Ansatz orientiert sich an Benchmark-Studien zur Evaluation von LLMs im Finanzkontext, bei denen vorhandene Finanzdokumente systematisch durch künstlich eingefügte Fehler verändert werden, um die Fähigkeit der Modelle zur Identifikation von Inkonsistenzen zu untersuchen (vgl. Panda 2026, S. 1). Neben den Rechnungen werden auch Screenshots von Mails zur Freigabe der einzelnen Rechnungen erstellt. Auch hier werden gezielt einzelnen Fehler in die Datensätze eingebaut. Der Testdatensatz umfasst somit sowohl fehlerhafte als auch vollständig korrekte Rechnungen sowie die zugehörigen Freigaben. Für die vorliegende Arbeit wird eine Fehlerquote von 24 % festgelegt, was bei einem Datensatz von 100 Rechnungen insgesamt 24 fehlerhaften Belegen entspricht. Nach internen Angaben ist die Quote für fehlerhafte oder unvollständige Rechnungen bei 18% (vgl. internes Meeting David Goth). Durch eine Fehlerquote von 24 % ist die Anzahl fehlerhafter Rechnungen ausreichend groß, um die Erkennungsleistung der Modelle repräsentativ zu untersuchen. Gleichzeitig bildet die Mehrheit an korrekten Rechnungen den realen Prüfungskontext realitätsnah ab. Bei der Fehlererzeugung wird bewusst auf eine breite Streuung unterschiedlicher Fehlertypen geachtet. Die Fehler werden in sechs Gruppen unterschieden. Die größte Gruppe bilden 7

Quelle?
ansonsten
auch
David

Fehler, die typische Betrugsmuster abbilden. Sie zeigen den eigentlichen Nutzen eines solchen Systems im Audit. Bei 5 Fehlern liegt das Problem im Freigabeprozess, wenn eine Rechnung ohne die erforderliche Freigabe oder durch eine nicht berechtigte Person genehmigt wird. Weitere 4 Fehler betreffen den Abgleich mit den Stammdaten, bei denen die Angaben auf der Rechnung von den hinterlegten Lieferantendaten abweichen, zum Beispiel bei Anschrift oder Bankverbindung. Bei 4 Fehlern handelt es sich um einfache Rechen-, bzw. Zahlenfehler, die als Basisfälle gelten. Ebenfalls 3 Fehler betreffen ein falsches Rechnungsdatum oder die Zuordnung zur falschen Periode, sodass der Aufwand im falschen Zeitraum gebucht wird. Die letzten 2 Fehler betreffen eine fehlende Rechnungsnummer. Tabelle 4.1 fasst die Fehlergruppen zusammen.

Tabelle 4.1: Verteilung der eingebauten Fehler auf die Fehlergruppen

Anzahl	Fehlergruppe
7	Betrugsmuster
5	Fehler in der Rechnungsfreigabe
4	Abgleich mit Stammdaten
4	Rechnerische Fehler und Basisfälle
3	Datum und Periode
2	Fehlende Rechnungsnummer
24	Gesamt

genaue
zahlen
begründen:
100
rech-
nun-
ge, 24
%, 24
fehler,
fehler
7, 54,
3, 3, 2

4.4 Entwicklung eines geeigneten Prompts

Die Qualität der von einem LLM erzeugten Ausgabe wird maßgeblich durch die Gestaltung des Prompts beeinflusst (vgl. Sclar et al. 2024). Prompt Engineering bezeichnet die systematische Gestaltung, Strukturierung und Optimierung von Eingabeanweisungen (Prompts) für LLMs. Ziel ist es, durch die gezielte Auswahl von Aufgabenbeschreibungen, Kontextinformationen, Beispielen und Formatierungen das gewünschte Modellverhalten zu erzeugen und die Qualität der generierten Ergebnisse zu verbessern (vgl. Schulhoff et al. 2025, S. 1). Daher wird der Prompt auf Basis etablierter Prompt-Engineering-Techniken entwickelt. Um die Vergleichbarkeit der untersuchten Modelle sicherzustellen, wird auf eine modellspezifische Optimierung der Prompts verzichtet. Stattdessen werden für alle Modelle identische Prompts verwendet. Der Prompt enthält klare Anweisungen zur Analyse der Rechnungen, zur Identifikation potenzieller Auffälligkeiten sowie zur nachvollziehbaren Begründung der Ergebnisse.

Die inhaltlichen Anforderungen an den Prompt ergeben sich aus dem bestehenden Vorgehen der Stichprobenanalyse bei Freudenberg (vgl. Abschnitt 3.1). Der Prompt bildet die Prüfschritte ab, die ein Prüfer bei einer Eingangsrechnung durchführt. Zuerst die Extraktion der Rechnungsdaten, dann den Abgleich mit der Referenztabelle, sowie die rechnerische und formale Prüfung und die Suche nach Betrugsindikatoren. Abschließend noch die Prüfung des Freigabeprozesses und der Berechtigung des Genehmigers. Das Ergebnis soll als Arbeitspapier für die anschließende menschliche Prüfung dienen. Das Modell unterstützt den Prüfer also, trifft aber lediglich eine abschließende Empfehlung für weiteres Vorgehen und übernimmt nicht den vollständigen Prüfungsprozess.

Der Prompt besteht aus zwei Teilen. Die Instruktionen sind dauerhaft im Agenten hinterlegt und legen Rolle, Ziel, Quellen, Regeln, Prüfschritte und Ausgabeformat fest. Der Kurzprompt wird für jeden Prüffall mit gleichem Wortlaut in den Chat eingegeben. Dieser Prompt führt den Agent aus und benennt die vorliegenden Unterlagen.. Tabelle ?? zeigt die Abschnitte der Instruktionen. Der vollständige Prompt unterteilt in Agenteninstructions und Kurzprompt befindet sich in Anhang

Bei der Gestaltung des Prompts wurden mehrere etablierte Techniken angewendet. Zu Beginn erhält das Modell eine klar definierte Rolle als Prüfagent des internen Audits. Die Rolle gibt dem Modell den fachlichen Rahmen der Aufgabe vor (vgl. Microsoft 2026).

Für jede Eingabe ist festgelegt, welche Funktion sie hat. Die Rechnung liefert die Istwerte, die Referenztabelle die Sollwerte und die Freigabematrix die Berechtigungen. Die Freigabeunterlagen gelten ausschließlich als Evidenz und sind nicht automatisch gültig. Durch diese Quellenhierarchie entscheidet das Modell bei widersprüchlichen Angaben nicht selbst, welcher Quelle es folgt. Die ausdrückliche Benennung der verwendeten Wissensquellen wird auch in der Anleitung von Microsoft empfohlen (vgl. Microsoft 2026, Abschnitt „Explizites Verweisen auf Funktionen, Wissen und Aktionen“).

Die Aufgabe ist in elf Prüfschritte mit fester Reihenfolge zerlegt. Die Aufteilung in einzelne, klar getrennte Schritte verringert Mehrdeutigkeiten und verhindert, dass das Modell Aufgaben zusammenführt oder neu interpretiert (vgl. Microsoft 2026, Abschnitt „Aufgaben atomisch machen“). Zusätzlich wird die Prüfung dadurch nachvollziehbar, da jeder Schritt im Ergebnis sichtbar ist.

LLMs neigen dazu, fehlende Informationen durch plausibel klingende, aber falsche Inhalte zu ersetzen **Q4**. Der Prompt verbietet deshalb Annahmen und Ergänzungen und gibt feste

Freudenberg
klar
machen
->
Freu-
denberg
CO. KG

Statuswerte wie „nicht vorhanden“, „nicht lesbar“ und „nicht prüfbar“ vor. Verdachtsmomente dürfen nur als „Hinweis auf“ formuliert werden, da die Feststellung eines Betrugs dem Prüfer vorbehalten bleibt.

Rechnungen und Screenshots stammen teilweise von Dritten und können Text enthalten, den ein Modell als Anweisung missversteht **Q5**. Der Prompt legt daher fest, dass Dokumentinhalte als Daten und nicht als Anweisungen zu behandeln sind. Ein Freigabevermerk auf der Rechnung selbst gilt ebenfalls nicht als Freigabenachweis.

Die Ausgabe folgt einer festen Struktur mit vorgegebenen Feldern und Statuswerten. Ohne vorgegebenes Ausgabeformat leitet das Modell Ton und Detailgrad selbst ab, was zu inkonsistentem Verhalten zwischen verschiedenen Modellen führen kann (vgl. Microsoft 2026, Abschnitt „Geben Sie immer Ton, Ausführlichkeit und Ausgabeformat an“). Das feste Format erleichtert die menschliche Prüfung und macht die Ergebnisse der Modelle direkt vergleichbar. Die Gesamtbewertung der Freigabe, die Auffälligkeiten mit Risikostufe sowie die Angabe zur menschlichen Nachprüfung bilden die Grundlage für die Auswertung (vgl. Abschnitt ??).

Der Prompt legt außerdem fest, wann eine menschliche Nachprüfung erforderlich ist, etwa bei nicht eindeutig nachgewiesener Freigabe oder hohem Risiko. Solche Kontrollpunkte werden für den Einsatz von Agenten bei kritischen Entscheidungen empfohlen **Q7**.

Im Prüfkontext ist ein übersehener Fehler kritischer als ein zusätzlicher Hinweis, da eine fehlerhafte Rechnung sonst unentdeckt bleibt. Der Prompt gibt diese Gewichtung ausdrücklich vor. Sie wird in der Gewichtung der Bewertungsmatrix wieder aufgegriffen (vgl. Abschnitt ??).

Im Prüfkontext ist ein übersehener Fehler kritischer als ein zusätzlicher Hinweis, da eine fehlerhafte Rechnung sonst unentdeckt bleibt. Der Prompt gibt diese Gewichtung ausdrücklich vor. Sie wird in der Gewichtung der Bewertungsmatrix wieder aufgegriffen (vgl. Abschnitt ??).

Iterative Entwicklung Der Prompt wurde in mehreren Versionen entwickelt. Getestet wurde dabei ausschließlich mit einem separaten Entwicklungsdatensatz, der nicht in die spätere Evaluation eingeht. Würde der Prompt anhand der Testfälle verbessert, wären die gemessenen Ergebnisse zu positiv **Q8**.

Die erste Version enthielt ausführliche Definitionen, Beispiele und Statusbeschreibungen. Mit etwa [X] Zeichen überschritt sie das Zeichenlimit der eingesetzten Agentenplattform von [Y] Zeichen. Zudem berücksichtigen LLMs Informationen in langen Kontexten weniger zuverlässig **Q9**. Ziel der Überarbeitung war daher, dem Modell nur die für die Aufgabe notwendigen Informationen bereitzustellen **Q1**. Die zweite Version fasst die Regeln stichpunktartig zusammen, ohne Prüfschritte zu streichen. In der dritten Version wurden Widersprüche zwischen Instruktionen und Kurzprompt beseitigt. Tabelle 4.2 fasst die Änderungen zusammen.

Version	Änderung	Grund
v1	Ausführliche Fassung mit Platzhaltern für die Eingaben, Beispielen und Statusdefinitionen	Ausgangsversion
v2	Kompakte Fassung, Regeln stichpunktartig zusammengefasst	Zeichenlimit der Plattform, Fokus auf notwendige Informationen
v3	Dateinamen und Ablageorte der Quellen ergänzt, Freigabematrix im Kurzprompt ergänzt, Rundungstoleranz wiederhergestellt, Begriffe vereinheitlicht, Prüfung mehrstufiger Freigaben entfernt	Widersprüche zwischen Instruktionen und Kurzprompt, Verlust von Regeln durch die Kürzung, mehrstufige Freigaben im Prüfprozess nicht vorgesehen

Tabelle 4.2: Versionen des Prompts

Nach Abschluss der Entwicklung wurde der Prompt eingefroren und für alle Modelle unverändert verwendet. Die Rahmenbedingungen der Testdurchführung, etwa ein neuer Chat je Rechnung, werden in Abschnitt ?? beschrieben.

4.5 Nutzwertanalyse

Die Eignung der untersuchten KI-Modelle für den definierten Audit-Use-Case kann nicht anhand eines einzelnen Bewertungskriteriums bestimmt werden. Vielmehr müssen sowohl quantitative, als auch qualitative Kriterien berücksichtigt werden um ein umfangreiches Ergebnis zu erlangen. Die Bewertung der Modelle erfordert somit die gleichzeitige Betrachtung mehrerer, teilweise konkurrierender Kriterien und stellt ein mehrdimensionales Entscheidungsproblem dar (vgl. Kozłowska 2022, S. 116 f.). Zur strukturierten und nachvollziehbaren Berücksichtigung dieser unterschiedlichen Kriterien wird in dieser Arbeit eine

Nutzwertanalyse durchgeführt. Die Nutzwertanalyse ermöglicht es, verschiedene Bewertungskriterien zu gewichten und zu einem Gesamtnutzenwert zu aggregieren. Dadurch können die untersuchten KI-Modelle objektiv und transparent hinsichtlich ihrer Eignung für den Audit-Use-Case verglichen werden (vgl. Kühnapfel 2021, S. 79 f.).

4.6 Entwicklung einer Bewertungsmatrix

Um die Evaluation basierend auf einer Nutzwertanalyse durchzuführen, muss eine Bewertungsmatrix mit mehreren quantitativen und qualitativen Kriterien entwickelt werden (vgl. Liang et al. 2023, S.3). Bei der Entwicklung der Bewertungsmatrix werden die Anforderungen für den Anwendungsfall der Corporate Audit Abteilung der FCo berücksichtigt. Die Bewertungsmatrix umfasst drei Hauptkriterien, die für die Eignung der Modelle für den definierten Use Case von zentraler Bedeutung sind. Diese Kriterien sind die Erkennungsleistung der Modelle, die Qualität der Begründungen und die Konsistenz der Ergebnisse. Sind alle drei Kriterien hinreichend erfüllt, können die Modelle als geeignet für den Einsatz im Audit-Use-Case betrachtet werden.

Als zentrales quantitatives Kriterium wird die Erkennungsleistung der Modelle herangezogen. Hierbei werden die Kennzahlen Precision und Recall berechnet. Der Precision-Wert gibt an, wie viele der vom Modell als fehlerhaft identifizierten Rechnungen tatsächlich fehlerhaft sind. Er berechnet sich aus dem Quotient aller richtig als fehlerhafte klassifizierten Rechnungen, den sogenannten True Positives, und der Summe aller als fehlerhaft klassifizierten Rechnungen, also der Summe aus True Positives und False Positives. Der Recall-Wert gibt an, wie viele der tatsächlich fehlerhaften Rechnungen vom Modell korrekt identifiziert wurden. Er berechnet sich aus dem Quotient der True Positives, und der Summe aller tatsächlich fehlerhaften Rechnungen, also der Summe aus True Positives und False Negatives.

Als weiteres Kriterium wird die Qualität der Begründungen der Modelle bewertet. Die qualitative Bewertung der Begründung erfolgt durch 2 Senior Auditoren der FCo. Die Auditoren bewerten die Begründungen der Modelle anhand von den drei Kriterien Korrektheit, Nachvollziehbarkeit und Halluzination. Jedes Kriterium wird auf einer Skala von 1 bis 5 bewertet, wobei 1 für Behr schlecht und 5 für Behr gutsteht. Anschließend wird der Mittelwert der Bewertung der Auditoren gebildet und als Nutzwert der Qualität der Begründung herangezogen. Als letztes Kriterium wird die Konsistenz der Modelle bewertet. Dazu wird

wissenschaftlich
warum
diese
Kriterien

jede Rechnung mit identischem Prompt fünfmal von jedem Modell analysiert. Anschließend werden alle unterschiedlichen Befunde erfasst, die über die fünf Durchläufe hinweg gemeldet wurden. Für jeden dieser Befunde wird ermittelt, in wie vielen Durchläufen er auftaucht. Ein Befund, der in allen fünf Durchläufen gemeldet wird, erhält somit den Wert 1, ein Befund, der nur in einem Durchlauf auftaucht, den Wert 0,2. Die Konsistenz ergibt sich aus dem Mittelwert dieser Anteile über alle Befunde und wird in Prozent angegeben. Liefert ein Modell in allen Durchläufen exakt dieselben Befunde, erreicht es eine Konsistenz von 100 %. Je häufiger sich die gemeldeten Befunde zwischen den Durchläufen unterscheiden, desto geringer fällt der Wert aus.

4.7 Gewichtung der Bewertungsmatrix

Um die drei Hauptkriterien zu einem Gesamtergebnis zusammenzuführen, werden diese entsprechend ihrer Bedeutung für den Audit-Use-Case gewichtet. Die Gewichtung erfolgt auf Basis der Anforderungen der Corporate Audit Abteilung der FCo und wird in Tabelle 4.3 dargestellt.

Die Erkennungsleistung erhält mit 50 % das höchste Gewicht, da die zuverlässige Identifikation fehlerhafter Rechnungen die Kernaufgabe der Stichprobenanalyse darstellt. Innerhalb dieses Kriteriums wird der Recall mit 30 % höher gewichtet als die Precision mit 20 %. Ein False Positive also ein Fehlalarm, wird vom Auditor im Rahmen der weiteren Prüfung erkannt und verursacht lediglich zusätzlichen Prüfaufwand. Wird ein Fehler hingegen vom Modell nicht gemeldet, False Negative, besteht die Gefahr, dass auch der Auditor diesen übersieht, da er sich auf das Ergebnis des Systems verlässt.

Die Qualität der Begründungen wird mit 30 % gewichtet. Auditoren müssen nachvollziehen können, wie ein Ergebnis zustande gekommen ist, um die Befunde prüfen und dokumentieren zu können. Die Korrektheit erhält hierbei mit 12 % das höchste Gewicht, da eine fachlich falsche Argumentation auch bei richtig erkanntem Fehler zu einer fehlerhaften Dokumentation führen kann. Die Nachvollziehbarkeit wird mit 10 % und die Halluzination mit 8 % gewichtet. Erfundene Angaben sind im Audit zwar besonders kritisch, werden aber teilweise bereits über die Korrektheit erfasst.

Die Konsistenz erhält mit 20 % das geringste Gewicht. Reproduzierbare Ergebnisse sind zwar eine Voraussetzung dafür, dass Auditoren einem Modell vertrauen können. Eine hohe Konsistenz sagt allein jedoch nichts über die Richtigkeit der Ergebnisse aus, da auch ein

Gewichtung
klar,
aber
man
kann
auch
anders
gewich-
ten -
siehe 1.
PA

Modell, das dauerhaft dieselben Fehler übersieht, konsistent arbeitet. Tabelle 4.3 fasst die Gewichtung zusammen.

Hauptkriterium	Gewicht	Teilkriterium	Gewicht
Erkennungsleistung	50 %	Recall	30 %
		Precision	20 %
Qualität der Begründungen	30 %	Korrektheit	12 %
		Nachvollziehbarkeit	10 %
		Faktentreue	8 %
Konsistenz	20 %	Konsistenz	20 %

Tabelle 4.3: Gewichtung der Bewertungsmatrix

Da die Kriterien auf unterschiedlichen Skalen erfasst werden, müssen sie vor der Verrechnung vereinheitlicht werden. Precision, Recall und Konsistenz liegen bereits als Prozentwerte vor. Für die Teilkriterien der Begründungsqualität wird zunächst der Mittelwert über alle Auditoren gebildet. Dieser wird anschließend über $e = \frac{x-1}{4} \cdot 100$ in einen Wert zwischen 0 und 100 umgerechnet, sodass die schlechteste Bewertung den Wert 0 und die beste Bewertung den Wert 100 erhält. Somit sind alle Kriterien auf einer gemeinsamen Skala. Der Nutzwert eines Modells ergibt sich dann als Summe der gewichteten Einzelwerte:

$$N_j = \sum_{i=1}^6 w_i \cdot e_{ij} \quad (4.1)$$

Dabei steht N_j für den Nutzwert des Modells j , w_i für das Gewicht des Teilkriteriums i und e_{ij} für den normierten Wert des Modells j im Teilkriterium i .

Da jede Gewichtung eine gewisse Subjektivität enthält, wird im Rahmen der Auswertung zusätzlich eine Sensitivitätsanalyse durchgeführt. Hierbei werden die Gewichte der Hauptkriterien verändert, um zu prüfen, ob sich die Rangfolge der Modelle dadurch verschiebt. Bleibt die Rangfolge stabil, kann das Ergebnis als robust betrachtet werden.

Sensitivitäts-
Brauch
ich die?

5 Evaluationsdurchführung

5.1 Durchführung der Tests

5.2 Ergebnisse der Stichprobenanalysen

5.2.1 Rechnungen

5.2.2 Benutzerberechtigungen

5.2.3 Gesamtvergleich

5.3 Auswertung der Bewertungsmatrix

5.4 Vergleich der Modelle

5.5 Analyse der Ergebnisse

5.6 Beantwortung der Forschungsfrage

6 Fazit und Ausblick

6.1 Zusammenfassung der wichtigsten Erkenntnisse

6.2 Fazit zur Eignung von LLMs im Audit

6.3 Handlungsempfehlungen für Freudenberg

6.4 Zukünftige Entwicklungspotenziale

A Prompts

A.1 Prompt GPT

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

A.2 Prompt Claude

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy

eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a

turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Literatur

- Artificial Analysis (2026). *Comparison of AI Models across Intelligence, Performance, and Price*. Artificial Analysis. URL: <https://artificialanalysis.ai/models> (besucht am 11.08.2026).
- Baumeister, Daniel (2019). „Sample size and error containment judgments in non-statistical audit sampling-the sensitivity of auditors to a revision of professional standards“. Diss. Dissertation, Dortmund, Technische Universität, 2019.
- Cantù, Elena, Cecilia Langella und Ilaria Elisa Vannini (2025). „Making sense of the internal audit function: toward internal controls integration and organizational learning“. In: *Financial Accountability & Management* 41.2, S. 262–273.
- Fedyk, Anastassia et al. (2022). „Is artificial intelligence improving the audit process?“ In: *Review of Accounting Studies* 27.3, S. 938–985. DOI: 10.1007/s11142-022-09697-x.
- Freudenberg, Corporate Audit (2026). „Internal Audit Sample Testing Guidance Examples“. Interne Excel-Datei, Freudenberg & Co. KG.
- G2 (2026). *DataSnipper Reviews 2026: Details, Pricing & Features*. URL: <https://www.g2.com/products/datasnipper/reviews> (besucht am 06.08.2026).
- Gartner Peer Insights (2026). *DataSnipper Reviews, Ratings & Features 2026*. Gartner, Inc. URL: <https://www.gartner.com/reviews/market/artificial-intelligence/vendor/datasnipper> (besucht am 06.08.2026).
- Ivakhnenkov, Serhii (2023). „Artificial intelligence application in auditing“. In.
- Kokina, Julia et al. (2025). „Challenges and opportunities for artificial intelligence in auditing: Evidence from the field“. In: *International Journal of Accounting Information Systems* 56, S. 100734. ISSN: 1467-0895. DOI: <https://doi.org/10.1016/j.accinf.2025.100734>. URL: <https://www.sciencedirect.com/science/article/pii/S1467089525000107>.
- Kozłowska, Justyna (2022). „Methods of Multi-Criteria Analysis in Technology Selection and Technology Assessment: A Systematic Literature Review“. In: *Engineering Management in Production and Services* 14.2, S. 116–137. DOI: 10.2478/emj-2022-0021.
- Kühnapfel, Jörg B. (2021). *Scoring und Nutzwertanalysen: Ein Leitfaden für die Praxis*. 2. Wiesbaden: Springer Gabler. DOI: 10.1007/978-3-658-34810-6.
- Kyriazos, Theodoros und Mary Poga (2024). „Application of Machine Learning Models in Social Sciences: Managing Nonlinear Relationships“. In: *Encyclopedia* 4.4, S. 1790–1805. DOI: 10.3390/encyclopedia4040118.
- Liang, Percy et al. (2023). *Holistic Evaluation of Language Models*. arXiv: 2211.09110 [cs.CL]. URL: <https://arxiv.org/abs/2211.09110>.
- Lyell, David und Enrico Coiera (2017). „Automation bias and verification complexity: a systematic review“. In: *Journal of the American Medical Informatics Association* 24.2, S. 423–431.

- Microsoft (11. Mai 2026). *Schreiben effektiver Anweisungen für deklarative Agents*. URL: <https://learn.microsoft.com/en-us/microsoft-365/copilot/extensibility/declarative-agent-instructions> (besucht am 02.10.2026).
- Panda, Silu (2026). *FinVerBench: Evaluating Large Language Models on Numerical Consistency Verification of Financial Statements*. Preprint, eingereicht am 28.05.2026. DOI: 10.48550/arXiv.2605.29586. arXiv: 2605.29586 [cs.CL]. URL: <https://arxiv.org/abs/2605.29586> (besucht am 07.09.2026).
- Perez, Ethan, Douwe Kiela und Kyunghyun Cho (2021). „True Few-Shot Learning with Language Models“. In: *Advances in Neural Information Processing Systems*. Hrsg. von M. Ranzato et al. Bd. 34. Curran Associates, Inc., S. 11054–11070. URL: https://proceedings.neurips.cc/paper_files/paper/2021/file/5c04925674920eb58467fb52ce4ef7Paper.pdf.
- Roussy, Mélanie (2013). „Internal auditors' roles: From watchdogs to helpers and protectors of the top manager“. In: *Critical Perspectives on Accounting* 24.7, S. 550–571. ISSN: 1045-2354. DOI: <https://doi.org/10.1016/j.cpa.2013.08.004>. URL: <https://www.sciencedirect.com/science/article/pii/S1045235413000932>.
- Schulhoff, Sander et al. (2025). *The Prompt Report: A Systematic Survey of Prompt Engineering Techniques*. arXiv: 2406.06608 [cs.CL]. URL: <https://arxiv.org/abs/2406.06608>.
- Schumann, Gerrit und Jorge Marx Gómez (2021). „Natural language processing in internal auditing—A structured literature review“. In: .
- Sclar, Melanie et al. (2024). „Quantifying Language Models' Sensitivity to Spurious Features in Prompt Design or: How I learned to start worrying about prompt formatting“. In: *International Conference on Learning Representations*. Hrsg. von B. Kim et al. Bd. 2024, S. 25055–25083. URL: https://proceedings.iclr.cc/paper_files/paper/2024/file/6c0e99d736da621403018ca7b32b1a4d-Paper-Conference.pdf.
- The Institute of Internal Auditors (2024). *Global Internal Audit Standards*. Accessed: 2026-09-02. Lake Mary, FL: The Institute of Internal Auditors. URL: https://www.theiia.org/globalassets/site/standards/globalinternalauditstandards_2024january9.pdf.
- Wassie, Fekadu Agmas und László Péter Lakatos (2024). „Artificial intelligence and the future of the internal audit function“. In: *Humanities and Social Sciences Communications* 11.1, S. 386.
- YourAIFinder (2026). *DataSnipper – AI Audit Automation Platform Inside Excel*. URL: <https://youraifinder.com/tool/datasnipper> (besucht am 06.08.2026).

Hilfsmittelangabe zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten



Persönliche Angaben

Verclas, Leonard	3317974
Nachname, Vorname	Matrikelnummer
Gaußstrasse 5, 68775 Ketsch	WDSKI24B
Anschrift	Kurs
S242792@student.dhbw-mannheim.de	0176 45895734
E-Mail	Telefon- / Handynummer

Für das Modul

Praxismodul 2
Modulbezeichnung / Semester

muss ich am

09.11.2026
Datum der Frist

folgende Prüfungsleistung erbringen:

- ☐ Projektarbeit I ☒ Projektarbeit II
- ☐ Seminararbeit ☐ Bachelorarbeit
- ☐ Sonstige

genaue Bezeichnung der sonstigen Prüfungsleistung

Zur Verwendung KI-gestützter Werkzeuge erkläre ich in Kenntnis des Hinweisblatts "Hinweise zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung wissenschaftlicher Arbeiten und die prüfungsrechtlichen Folgen ihres Einsatzes" Folgendes:

- Ich habe mich aktiv über die Leistungsfähigkeit und Beschränkungen der in meiner Arbeit eingesetzten KI-Werkzeuge informiert.
- Bei der Anfertigung der Prüfungsleistung habe ich durchgehend eigenständig und beim Einsatz KI-gestützter Werkzeuge maßgeblich steuernd gearbeitet.
- Insbesondere habe ich die Inhalte entweder aus wissenschaftlichen oder anderen zugelassenen Quellen entnommen und diese gekennzeichnet oder diese unter Anwendung wissenschaftlicher Methoden selbst entwickelt.
- Mir ist bewusst, dass ich als Autor/in der Arbeit die Verantwortung für die in ihr gemachten Angaben und Aussagen trage.
- Ich habe keine weiteren als die nachstehend von mir benannten KI-gestützten Werkzeuge zur Erstellung der Arbeit eingesetzt und diese nur in der angegebenen Art und Weise.

- Soweit ich KI-gestützte Werkzeuge zur Erstellung der Arbeit eingesetzt habe, gebe ich diese in der nachstehenden "Übersicht verwendeter Hilfsmittel" mit ihrem Produkt-namen und ihres genutzten Funktionsumfangs vollständig an; wörtliche oder sinn-gemäße Übernahmen KI-generierter Inhalte habe ich in ein separates Verzeichnis aufgenommen und im Text belegt (z. B. als Fußnote). Diese Inhalte sind als pdf-Datei in den elektronischen Beigaben hinterlegt.

Produktname(n) eingesetzter Hilfsmittel:

--

Genutzter Funktionsumfang im Hinblick auf

- **Themenerfassung und Strukturierung** (Aufgabenstellung oder Präzisierung, Forschungsansatz, Gliederung)

--

- **Themenbearbeitung** (Darstellung/Beschreibung des Problems, Darlegung von wissenschaftlichen Grundlagen, Schlussfolgerungen allgemein und für das konkrete Thema / Erkenntnisgewinn, Evaluierung des Textes / Feedback der KI)

--

- **Quellenrecherche, -auswahl und -auswertung** (welche Quellen wurden durch das KI-Werkzeug gefunden, wie erfolgte die weitere Recherche)

--

- **Formale Gestaltung, insbesondere Sprache** (Welche Eingabe wurde an die KI getätigt? Textgenerierung, Textkorrektur, Paraphrasieren und Umschreiben, Übersetzen, kreatives Schreiben)

--

Hinweis:

Geben Sie in der jeweiligen Rubrik die Seitenzahl in ihrer wissenschaftlichen Arbeit an und erläutern Sie die Art und Weise sowie den Umfang der von Ihnen genutzten KI-basierten Werkzeuge.

--	--

Ort, Datum

Unterschrift der/des Studierenden