

Duale Hochschule Baden-Württemberg Mannheim

Projektarbeit 2

Einsatz von LLMs zur Unterstützung von Stichprobenanalysen im Audit-Bereich. Ein Vergleich verschiedener KI-Modelle hinsichtlich ihrer Eignung für interne Prüfungsprozesse bei der Freudenberg Group

Studiengang Wirtschaftsinformatik

Studienrichtung Data Science und Künstliche Intelligenz

Verfasser(in):	Leonard Verclas
Matrikelnummer:	3317974
Firma:	Freudenberg & Co. Kommanditgesellschaft
Kurs:	WDSKI24B
Studiengangsleiter:	Prof. Dr. Bernhard Drabant
Wissenschaftliche(r) Betreuer(in):	Stefanie Bell
Firmenbetreuer(in):	Andreas Hass
Bearbeitungszeitraum:	03.08.2026 - 09.11.2026

Todo list

Rechnungen fälschen	2
Prompt Optimizing	2
Workflow bauen für transparente Durchführung	2
Durchführen + Lösung für die subjektiven Punkte -> Bewertungsskala	2
Text Kapitel 4	2
Text Grundlagen und Kapitel 3	2
vllt. zu hypothetisch -> wie ght er über reine Compliance-Aspekte hinaus?	3
Hier zum Einstieg noch mehr Kontext. Das internal Audit hat verschiedene Methoden. ua Stichproben -> rechnungen aber auch user benutzeranlegen etc.	4
auch wieder sehr mystisch: mitteleinsatz prüfungseffizienz etwas menschlicher einfacher ausführen	4
noch durchgehe, quellen etc .-> siehe copilot chat	5
Quelle -> Maurice (interens Meeting AI Specialist)	11
Quelle für die 24% nötig	11
ist das schlimm, das die Seitenzahlen so komisch sind?	15

1. Erstellen von fehlerhaften Rechnungen und Tickets (Orientierung an historischen Auditfällen)
2. Modelle analysieren Dokumente
3. Anwendung der Bewertungsmatrix
4. Punktesystem auf Bewertungsmatrix anwenden
5. Auswertung der Ergebnisse
6. Zusätzlich: Modelle auf historische Ereignisse prüfen, bzw. historische Ereignisse nochmals auf Fehler überprüfen

Stichprobenrisiko erklärt: (vgl. Baumeister 2019, S.12) und detailliert S. 40 ff.

herausforderungen und möglichkeiten künstlicher Intelligenz im Auditbereich:

Möglichkeiten:

Große datenmengen anstelle von stichproben durch schnellere Bearbeitung. Herausfiltern von wichtigen Kennzahlen, wie kosten, vertragspartner etc. -> Pflichtproben herausfiltern, die menschliche oder maschinelle Prüfung benötigen. (vgl. (Kokina et al. 2025, S.3))

Anomalieerkennung -> z.b. finanzielle Informationen (vgl. (Kokina et al. 2025, S.2))

Herausforderungen:

Transparenz und Erklärbarkeit - Auditoren und Regulatoren müssen verstehen können, warum wurde eine Entscheidung getroffen, wie ist ein Ergebnis zustande gekommen? (Kokina et al. 2025, S.16)

Robustheit und Zuverlässigkeit - Es muss nachweisbar sein, dass die Ergebnisse reproduzierbar sind, das Modelle stabil arbeiten und kein Model drift stattfindet (Kokina et al. 2025, S. 13 f.)

Übermäßiges Vertrauen an die KI - Auditoren müssen Ergebnisse immernoch professional skeptisch auditieren. Die KI darf nur als Unterstützer gelten. Die finale Entscheidung bleibt beim Auditor. Durch den Einsatz von KI kann es hier zu AutomationBias führen. Hierbei kann es dazu kommen, dass Auditoren Fehler übersehen, weil das System keine gemeldet hat. (Lyell und Coiera 2017, S.425 f.)

Inhaltsverzeichnis

Abbildungsverzeichnis	v
Tabellenverzeichnis	vi
Quelltextverzeichnis	vii
Abkürzungsverzeichnis	viii
Kurzfassung (Abstract)	ix
1 Einleitung	1
1.1 Problemstellung & Motivation	1
1.2 Zielsetzung der Arbeit	1
1.3 Aufbau der Arbeit	2
2 Grundlagen	3
2.1 Internal Audit	3
2.2 Stichprobenanalyse im Internal Audit	4
2.3 Künstliche Intelligenz	4
2.3.1 Large Language Models	4
2.3.2 Prompt Engineering	4
2.4 Einsatz von Künstlicher Intelligenz im Audit	4
2.4.1 Potenziale in der Stichprobenanalyse	5
2.4.2 Risiken in der Stichprobenanalyse	5
3 State of the Art	6
3.1 Aktuelle Durchführung von Stichprobenanalyse bei Freudenberg	6
3.2 Einsatz von KI im Auditbereich	7
3.3 Verfügbare KI-Lösungen für Audits	7
3.3.1 Kommerzielle Lösungen	8
3.3.2 Open-Source-Lösungen	8
3.3.3 Spezialisierte KI-gestützte Audit-Lösung	8
3.4 Einordnung des KI-Einsatzes bei Freudenberg	9
4 Evaluationsdesign	10
4.1 Forschungsdesign	10
4.2 Auswahl der zu untersuchende Modelle	10

4.3	Entwicklung der Testdatensätze	11
4.4	Entwicklung der Testdatensätze 2	11
4.5	Entwicklung eines geeigneten Prompts	12
4.6	Nutzwertanalyse	14
4.7	Entwicklung einer Bewertungsmatrix	15
4.8	Gewichtung der Bewertungsmatrix	17
5	Evaluationsdurchführung	18
5.1	Durchführung der Tests	18
5.2	Ergebnisse der Stichprobenanalysen	18
5.2.1	Rechnungen	18
5.2.2	Benutzerberechtigungen	18
5.2.3	Gesamtvergleich	18
5.3	Auswertung der Bewertungsmatrix	18
5.4	Vergleich der Modelle	18
5.5	Analyse der Ergebnisse	18
5.6	Beantwortung der Forschungsfrage	18
6	Fazit und Ausblick	19
6.1	Zusammenfassung der wichtigsten Erkenntnisse	19
6.2	Fazit zur Eignung von LLMs im Audit	19
6.3	Handlungsempfehlungen für Freudenberg	19
6.4	Zukünftige Entwicklungspotenziale	19
Anhang		
A	Prompts	20
A.1	Prompt GPT	20
A.2	Prompt Claude	21
Literatur		24

Abbildungsverzeichnis

Tabellenverzeichnis

Quelltextverzeichnis

Abkürzungsverzeichnis

DHBW	Duale Hochschule Baden-Württemberg
LLM	Large Language Model
KI	Künstliche Intelligenz
FCo	Freudenberg & Co.

Kurzfassung (Abstract)

1 Einleitung

1.1 Problemstellung & Motivation

Mit der fortschreitenden Entwicklung Künstliche Intelligenz (KI) stehen Unternehmen vor der Herausforderung, ihre Geschäftsprozesse kontinuierlich zu optimieren und durch den gezielten Einsatz neuer Technologien effizienter zu gestalten. Insbesondere im Audit-Umfeld bietet der Einsatz von KI ein erhebliches Potenzial zur Steigerung von Effizienz, Prüfungsqualität und Transparenz. KI unterstützt interne Auditoren, indem der manuelle Analyseaufwand reduziert wird und umfassendere sowie schnellere Prüfungen ermöglicht werden. (vgl. Wassie und Lakatos 2024, S. 11–12).

Ein besonders vielversprechendes Anwendungsfeld stellt die Analyse von Audit-Stichproben dar. Im Rahmen dieser Prüfungen werden zum Beispiel Rechnungen untersucht, um Auffälligkeiten, Regelverstöße oder potenzielle Risiken zu identifizieren. Die manuelle Analyse dieser Unterlagen ist jedoch zeitaufwendig und bindet erhebliche personelle Ressourcen. Gleichzeitig steigt aufgrund wachsender Datenmengen und zunehmend komplexer Geschäftsprozesse die Schwierigkeit, relevante Auffälligkeiten zuverlässig zu erkennen.


Vor diesem Hintergrund gewinnt die Unterstützung von Stichprobenanalysen durch KI-basierte Verfahren zunehmend an Bedeutung. Für die Freudenberg-Gruppe stellt sich dabei die Frage, wie KI-Technologien gewinnbringend in die Stichprobenanalyse im Internal-Audit-Prozess integriert werden können. Neben der Verbesserung der Effizienz und Prüfungsqualität durch den Einsatz von KI spielt insbesondere die Einhaltung strenger Datenschutz- und Compliance-Anforderungen sowie die Auswahl eines geeigneten KI-Modells für die Analyse von Audit-Dokumenten eine zentrale Rolle. Daraus ergibt sich die Notwendigkeit, die Eignung verschiedener KI-Lösungen für die Unterstützung von Stichprobenanalysen im Internal Audit systematisch zu untersuchen.

1.2 Zielsetzung der Arbeit

Ziel dieser Projektarbeit ist die systematische Untersuchung und Bewertung verschiedener KI-gestützter Werkzeuge zur Unterstützung von Stichprobenanalysen im Internal Audit

der Freudenberg-Gruppe. Der Fokus liegt dabei auf Large Language Models (LLMs), die Auditoren bei der Analyse von Prüfungsdokumenten unterstützen können. Hierzu werden ausgewählte LLMs auf identische Audit-Stichproben angewendet. Die Modelle sollen potenzielle Auffälligkeiten, Risiken oder Regelverstöße in Rechnungen identifizieren sowie ihre Bewertungen nachvollziehbar begründen. Anschließend werden die Ergebnisse anhand einer Bewertungsmatrix miteinander verglichen. Dabei stehen insbesondere die Erkennungsqualität, die Nachvollziehbarkeit der Ergebnisse, die Konsistenz der Analysen sowie die praktische Einsetzbarkeit im Audit-Umfeld im Vordergrund. Auf Basis dieser Untersuchung soll ermittelt werden, welches KI-Modell die Anforderungen der Freudenberg-Gruppe im Kontext von Stichprobenanalysen im Internal Audit am besten erfüllt. Die gewonnenen Erkenntnisse sollen eine fundierte Grundlage für die Bewertung des Potenzials von LLMs im Audit-Bereich sowie für deren zukünftigen Einsatz innerhalb der Organisation schaffen. Daraus ergibt sich folgende Forschungsfrage: Wie unterscheiden sich verschiedene Large Language Models hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit-Bereich?

1.3 Aufbau der Arbeit



2 Grundlagen

2.1 Internal Audit

Das Internal Audit stellt eine unabhängige und objektive Prüfungs- und Beratungsfunktion innerhalb einer Organisation dar. Die zentrale Aufgabe besteht darin, die Angemessenheit und Wirksamkeit von Governance-, Risikomanagement- und internen Kontrollsystemen zu bewerten sowie durch unabhängige Prüfungs- und Beratungsleistungen zur Verbesserung dieser Systeme beizutragen. Im Gegensatz zu externen Audits ist das Internal Audit organisatorisch in das Unternehmen eingebunden, wobei seine Unabhängigkeit durch geeignete Governance-Strukturen sichergestellt wird (vgl. The Institute of Internal Auditors 2024, S.15-16). Als Bestandteil des Internen Kontrollsystems unterstützt das Internal Audit die Organisation dabei, ihre strategischen und operativen Ziele wirksam und regelkonform zu erreichen. Dabei überprüft es bestehende Prozesse, identifiziert Risiken und bewertet die Wirksamkeit implementierter Kontrollmaßnahmen (vgl. Cantù, Langella und Vannini 2025, S. 263–264). Die Existenz von Audit-Funktionen begründet sich insbesondere durch die Notwendigkeit, Transparenz, Rechenschaftspflicht und Vertrauen innerhalb komplexer Organisationen sicherzustellen.

Moderne Audit-Ansätze beschränken sich jedoch nicht ausschließlich auf die Überprüfung der Regelkonformität. Vielmehr soll Internal Audit organisatorisches Lernen fördern, das Risikobewusstsein der beteiligten Akteure stärken und Verbesserungsmöglichkeiten in Geschäftsprozessen aufzeigen. Dadurch leistet die Funktion einen Beitrag zur kontinuierlichen Weiterentwicklung der Organisation und schafft einen Mehrwert, der über reine Compliance-Aspekte hinausgeht (vgl. Cantù, Langella und Vannini 2025, S. 18–21). Für die Durchführung der Prüfungen werden unter anderem Dokumente gesichtet, interpretiert und analysiert sowie deren Übereinstimmung mit gegebenen Anforderungen bewertet (vgl. Roussy 2013, S. 556–557). Ein Prozess, der ein erhebliches Potenzial für die Nutzung von KI mit sich bringt (vgl. Schumann und Marx Gómez 2021, S.1). Im Rahmen dieser Arbeit liegt der Fokus auf dem Internal Audit bei Freudenberg & Co. (FCo), welches für die Prüfung von Dokumenten und Abläufen aus verschiedenen Konzernfunktionen der Freudenberg Gruppe zuständig ist.

vllt. zu
hypote-
thisch
-> wie
geht er
über
reine
Compliance
Aspekte
hinaus?

2.2 Stichprobenanalyse im Internal Audit

Für das Internal Audit ist es in der Regel nicht möglich, alle Dokumente einer Grundgesamtheit zu prüfen. Daher wird unter anderem auf die Stichprobenanalyse zurückgegriffen. Bei der Stichprobenanalyse wird aus einer Grundgesamtheit eine Pflichtprobe und eine zufällige Stichprobe entnommen. Die Grundgesamtheit bildet eine abgegrenzte Menge gleichartiger Elemente, beispielsweise alle Rechnungen, die einem Konto zugeordnet sind. Die Pflichtprobe der Grundgesamtheit umfasst alle Elemente, die zuvor definierte Kriterien erfüllen, beispielsweise Rechnungen, die über einem bestimmten Betrag liegen. Diese Elemente müssen als Teil der Stichprobe geprüft werden. Weitergehend wird aus den restlichen Elementen der Grundgesamtheit eine zufällige Stichprobe entnommen, die zusätzlich zur Pflichtprobe geprüft wird (vgl. Freudenberg 2026). Die verbleibenden Elemente der Grundgesamtheit werden vorerst nicht geprüft und bedingen damit eine gewisse Unschärfe der Prüfungsaussagen, was als Stichprobenrisiko bezeichnet wird. Ziel ist es, eine möglichst hohe Prüfungseffizienz zu erreichen. Demnach wird versucht mit dem geringsten Mitteleinsatz ein hinreichend sicheres Prüfungsurteil zu erreichen (vgl. Baumeister 2019, S. 11–12).

Hier zum Einstieg noch mehr Kontext. Das internal Audit hat verschiedene Methoden, ua Stichproben -> rechnungen aber auch user benutzeranlegen etc.

2.3 Künstliche Intelligenz

2.3.1 Large Language Models

2.3.2 Prompt Engineering

Das Prompt Engineering beschreibt den wichtigsten Part der Nutzung eines KI-Systems. Erst durch den Prompt weiß die Maschine was der User erreichen möchte. Ein Prompt kann in verschiedenen klar definierte Teile unterteilt sein.

2.4 Einsatz von Künstlicher Intelligenz im Audit

Der Einsatz von KI im Audit ist kein rein konzeptionelles Zukunftsszenario, sondern bereits in der Prüfungspraxis etabliert (vgl. Kokina et al. 2025, S. 7 f.). KI unterstützt Auditoren bei der Analyse großer strukturierter und unstrukturierter Datenmengen, indem sie

auch wieder sehr mystisch: mitte-leinsatz prüfungseffizienz etwas menschlicher einfa

Muster erkennt, Anomalien identifiziert und Vorhersagen trifft (vgl. Ivakhnenkov 2023, S. 56). KI unterscheidet sich zu klassischen Datenanalysemethoden dadurch, dass sie auch nichtlineare Zusammenhänge verarbeiten kann und somit flexibel auf unterschiedliche Auffälligkeiten aufmerksam machen kann (vgl. Kyriazos und Poga 2024, S. 1790 f.). Es zeigt sich, dass Auditfirmen mit höheren KI-Investitionen eine bessere Prüfungsqualität erreichen und gleichzeitig die Prüfungszeit verkürzen können (vgl. Fedyk et al. 2022, S. 940 ff.). Somit zeigen sich auch für das internal Audit bei FCo Potenziale, die Effizienz und Qualität der Prüfungen durch den gezielten Einsatz von KI zu steigern.

2.4.1 Potenziale in der Stichprobenanalyse

Besonders in der Stichprobenanalyse kann der Einsatz von KI zu einer signifikanten Effizienzsteigerung führen. Durch die Automatisierung der Dokumentenprüfung können Auditoren schneller und umfassender potenzielle Auffälligkeiten, Risiken oder Regelverstöße identifizieren. KI-gestützte Systeme können große Mengen an Rechnungen analysieren, Muster erkennen und Anomalien hervorheben, die menschlichen Prüfern möglicherweise entgehen würden. Dies ermöglicht eine gezieltere Auswahl von Stichproben und reduziert den manuellen Aufwand erheblich. Zudem kann KI dazu beitragen, die Konsistenz und Nachvollziehbarkeit der Prüfungsprozesse zu verbessern, indem sie standardisierte Bewertungsmaßstäbe anwendet und Ergebnisse transparent dokumentiert. Durch die Automatisierung durch KI kann eine deutlich größere Menge an Stichproben analysiert werden, wodurch die Aussagekraft der Prüfungsergebnisse steigt und das Stichprobenrisiko minimiert wird.

2.4.2 Risiken in der Stichprobenanalyse

Trotz der zahlreichen Vorteile birgt der Einsatz von KI in der Stichprobenanalyse auch Risiken. Ein zentrales Risiko besteht in der Abhängigkeit von den verwendeten KI-Modellen und deren Trainingsdaten. Wenn die Modelle auf unzureichenden oder verzerrten Daten trainiert wurden, können sie fehlerhafte oder voreingenommene Ergebnisse liefern oder Halluzinieren, was zu falschen Prüfungsurteilen führen kann. Zudem besteht die Gefahr des Automation-Bias. Auditoren können die Ergebnisse der KI-Systeme unkritisch übernehmen, ohne diese ausreichend zu hinterfragen und so Auffälligkeiten oder Risiken übersehen.

3 State of the Art

3.1 Aktuelle Durchführung von Stichprobenanalyse bei Freudenberg

Aktuell folgen die Stichprobenanalysen im Internal Audit bei Freudenberg einer strukturierten und risikoorientierten Vorgehensweise. Der Prozess lässt sich exemplarisch anhand der Prüfung von Lieferantenrechnungen ohne Bestellnummer beschreiben und ist grundsätzlich auf weitere Anwendungsfälle übertragbar. Zunächst wird eine Grundgesamtheit relevanter Objekte definiert, hier aller im Prüfungszeitraum erfassten Rechnungen ohne Bestellnummer. Anschließend wird diese Grundgesamtheit anhand definierter Kriterien, wie Rechnungswert, Lieferant, manueller Buchung oder weiterer risikorelevanter Merkmale, kategorisiert und analysiert.

Auf Basis dieser Klassifizierung wird ein Threshold festgelegt. Alle Rechnungen, die diesen Schwellenwert überschreiten, werden verpflichtend in die Stichprobe aufgenommen. Ergänzend dazu wird eine zufällige Auswahl weiterer Rechnungen aus der verbleibenden Grundgesamtheit getroffen, um eine angemessene Abdeckung des Prüffeldes sicherzustellen.

Die ausgewählten Stichprobenelemente werden anschließend durch den Auditor einer detaillierten Prüfung unterzogen. Hierbei werden sämtliche für die Bewertung relevanten Informationen und Nachweisdokumente gesammelt, geprüft und dokumentiert. Nach Abschluss der Analyse bewertet der Auditor die Ergebnisse hinsichtlich möglicher Auffälligkeiten, Abweichungen oder Regelverstöße. Werden Unregelmäßigkeiten festgestellt, werden diese dokumentiert und als Audit Exceptions erfasst.

Durch die Kombination aus risikobasierter Auswahl und zufälliger Stichprobenziehung wird sichergestellt, dass sowohl potenziell kritische Transaktionen als auch repräsentative Elemente der Grundgesamtheit in die Prüfung einbezogen werden. Dadurch kann mit vertretbarem Prüfungsaufwand ein hohes Maß an Prüfungssicherheit erreicht werden. (vgl. (Freudenberg 2026))

3.2 Einsatz von KI im Auditbereich

Forschungsstand, vergleichbare studien, andere Unternehmen

3.3 Verfügbare KI-Lösungen für Audits

Auswahlverfahren basierend auf AI Benchmarks:

Modell muss Dokumente interpretieren, Belege verknüpfen, Inkonsistenzen finden, Schlussfolgerungen begründen

Intelligence Index: aggregiert mehrere Test, GPQA (5 Sterne) , Humanity's Last Exam (5 Sterne), Browse Comp (4 Sterne), SimpleQA (4 Sterne), MRCR (4 Sterne), SciCode (2 Sterne) etc. -> allgemeiner Index

Agentic Index: nutzen wir agenten?

Context Window -> Audit prüfung viele dateien und Daten -> je größer, desto mehr Dokumente können gleichzeitig verarbeitet werden

Coding Index -> Excel-Datei analysieren? Stichproben automatisch ziehen?

Cost per Task -> in vergleich zu den oben stehenden benchmarks

wenig relevant : speed, latency, output tokens

Intelligence Index: Opus 5 , Fable 5, GPT 5.6, Kimi K3, Grok 4.5, Sonnet 5, GLM 5.2

Intelligence Index vs. Cost per Intelligence Index Task:

DeepSeek V4 Flash, GPT-5.6(Luna), Grok 4.5, Kimi K3

Context Window: Kimi K3, GPT 5.6 (Luna, Terra, Sol) GLM 5.2, Sonnet 5, Haiku 4.5, Opus 5, Fable 5

(Artificial Analysis 2026)

3.3.1 Kommerzielle Lösungen

- Microsoft Copilot (Audit hat Zugriff): GPT 5.6 (nicht klar, ob sol, terra, luna), GPT 5.5 - Claude (Zuhause - keine sensiblen Daten (Daten selber erstellen)): Fable 5. Opus 5, Sonnet 5, Haiku 4.5 - Grok 4 - nur standard

3.3.2 Open-Source-Lösungen

Kimi K3 -> aber das kann man nirgendwo laufen lassen

Laptop (16 GB RAM) -> Qwen 3.5 PB, Phi-4 -> deutlich schlechter, wo kann ich das laufen lassen? LM studio zum manuellen testen OLLama zur python evaluierung

3.3.3 Spezialisierte KI-gestützte Audit-Lösung

Abseites von generativen LLMs gibt es spezialisierte KI-gestützte Audit-Lösungen. In dieser Arbeit wird DataSnipper als die Vergleichssoftware zu den herkömmlichen LLMs genutzt. DataSnipper erzielt an mehreren Rankings sehr gute Rankings unter KI-gestützten Audit-Lösungen und wird auch von den Big 4 als Audit-Tool verwendet, was das Tool zu einer der weit verbreitetsten spezialisierten KI-Lösungen im Audit-Bereich macht und eine hohe Marktrelevanz besitzt (vgl. G2 2026, Gartner Peer Insights 2026, YourAIFinder 2026). DataSnipper fungiert als Excel-Add-In und stellt verschiedene KI-Funktionen zur Unterstützung von Auditprozessen bereit. Im Gegensatz zu herkömmlichen LLMs wurde DataSnipper speziell für die Anforderungen von Audit- und Finance-Prozessen entwickelt. Zu den zentralen Funktionalitäten gehören die automatisierte Datenextraktion, der Abgleich von Dokumenten mit Arbeitspapieren, die Erstellung nachvollziehbarer Audit Trails sowie die KI-gestützte Analyse von Dokumenten. Darauf aufbauend gibt es erweiterte Funktionen durch sogenannte Excel Agent, die Audit Aufgaben innerhalb bestehender Workflows unterstützen. Ein wesentliches Merkmal ist der Human-in-the-Loop-Ansatz. Dbai übernimmt die Software repetitive Prüfungs- und Dokumentationsschritte, während fachliche Entscheidungen und die finale Bewertung weiterhin durch den Auditor erfolgt. Zudem bleibt jede Analyse mit den zugrunde liegenden Dokumenten verknüpft, wodurch eine hohe Nachvollziehbarkeit der Ergebnisse gewährleistet wird.

3.4 Einordnung des KI-Einsatzes bei Freudenberg

Die Freudenberg Gruppe nutzt aktuell gruppenweit die KI-Lösung von Microsoft Microsoft Copilot. Hierbei werden für alle Nutzer die Modelle GPT 4.5 und GPT 4.6 zur Verfügung gestellt. Der Copilot darf hierbei Zugriff auf alle internen Dokumente haben und bietet volle Datensicherheit- und integrität. Zusätzlich zum Microsoft Copilot gibt es für eine geringe Anzahl an Nutzern über GitHub Copilot die Möglichkeit auf begrenzte Ressourcen von Claude Sonnet und Claude Opus zuzugreifen. Hierbei lagte der Fokus jedoch auf der Software-Entwicklung. Die Anwendung auf den Auditbereich ist hierbei auf Grund von begrenzter Ressourcen nicht empfehlenswert.

4 Evaluationsdesign

Ziel, Anwendungsfall, Auswahlkriterien LLMs, Vorstellung ausgewählter LLMs, Evaluationsmetriken

4.1 Forschungsdesign

Um die Evaluation der für den Use Case am besten geeigneten Lösung durchzuführen wird eine Bewertungsmatrix aufgesetzt. Auf diese Matrix werden die Modelle GPT 5.3, GPT 5.5, Claude Sonnet 4.6, Claude Opus 4.6, Claude Opus 4.7 und Claude Opus 4.8 angewandt und anhand von definierten Kriterien anhand einer Bewertungsmatrix bewertet.

4.2 Auswahl der zu untersuchenden Modelle

Die Auswahl der zu untersuchenden Modelle basiert auf der aktuellen Nutzung von KI-Lösungen für die Freudenberg Gruppe. Wie in 3.4 beschrieben nutzt die Freudenberg Gruppe gruppenweit den Microsoft Copilot Premium Version und die dort ausgerollten Modelle von OpenAI und Anthropic. Hierbei werden sowohl die internen Datenschutz- und Compliance Richtlinien als auch EU-Richtlinien eingehalten. Durch die Nutzung der Modelle über den Microsoft Copilot zur Stichprobenanalyse kommen keine weiteren Kosten auf. Zudem ist dem Copilot schon im internal Audit ausgerollt, weshalb es keiner neuen Gewöhnung und Schulungen zu weiteren KI-Lösungen bedarf.

Auch die Nutzung von Open-Source-Modellen stellt grundsätzlich eine Alternative zu kommerziellen Lösungen dar. Durch den Betrieb auf unternehmensinterner Infrastruktur können Datenschutz- und Compliance-Anforderungen gezielt berücksichtigt werden. Da die Bereitstellung und der Betrieb solcher Modelle jedoch mit erheblichem Infrastruktur- und Implementierungsaufwand verbunden sind, werden Open-Source-Modelle im Rahmen dieser Arbeit nicht betrachtet.

Der Microsoft Copilot ermöglicht es den Auditieren auf die Modelle GPT 5.3, GPT 5.5, Claude Sonnet 4.6, Claude Opus 4.6, Claude Opus 4.7 und Claude Opus 4.8 zuzugreifen.

Genauere Details, bei welcher Anfrage der Copilot zum Beispiel auf GPT 5.6 Sol, GPT 5.6 Terra oder GPT 5.6 Luna zugreift sind nicht bekannt. Die vier Modelle gehören laut dem Artificial Analysis Intelligence Index zu den aktuell am besten gewerteten kommerziellen KI-Modellen nach Claude Opus 5, Claude Fable oder Grok 4.5. Da die Modelle mit höherem Artificial Analysis Intelligence Index nur durch höhere zusätzliche Kosten nutzbar sind, sind die aktuell unter dem Copilot Studio nutzbaren Modelle für die Evaluierung vollkommen geeignet (vgl. Artificial Analysis 2026).

Quelle -
> Maurice (interens Meeting AI Specialist)

4.3 Entwicklung der Testdatensätze

Für die Evaluation der betrachteten KI-Modelle ist eine Datenbasis erforderlich, die den realen Prüfungskontext möglichst genau abbildet. Die Verwendung originaler Rechnungsbelege aus dem Internal Audit der Freudenberg-Gruppe ist dabei ausgeschlossen, da diese personenbezogene sowie geschäftskritische Informationen enthalten und deshalb im Rahmen dieser Evaluierung nicht verwendet werden dürfen. Um dennoch eine hinreichend umfangreiche und belastbare Testbasis zu schaffen, werden die Testdatensätze mithilfe generativer KI erzeugt. Die künstlich erstellen Rechnungen orientieren sich in Struktur, Umfang und Informationsgehalt an realen Rechnungen. Sie enthalten somit dieselben prüfungsrelevanten Kriterien wie die im Audit untersuchten Dokumente. Um den realen Prüfungsprozess abzubilden wird eine Fehlerquote von 24 % festgelegt, dies entspricht 12 von 50 fehlerhafter Rechnungen. Damit wird sichergestellt eine ausreichende Anzahl fehlerhafter Rechnungen für die Bewertung der Erkennungsleistung bereitzustellen und andererseits die reale Situation einer überwiegenden Anzahl korrekter Rechnungen abzubilden. Bei der Fehlererzeugung wird bewusst auf eine breite Streuung unterschiedlicher Fehlertypen geachtet. Auf diese Weise wird vermieden, dass die Modelle lediglich auf ein eng begrenztes Fehlermuster hin getestet werden, und es lässt sich differenziert beurteilen, bei welchen Fehlerarten die Modelle zuverlässig arbeiten und bei welchen Fehlerarten Schwächen auftreten.

Quelle für die 24% nötig

4.4 Entwicklung der Testdatensätze 2

Für die Evaluation der betrachteten KI-Modelle ist eine Datenbasis erforderlich, die den realen Prüfungskontext möglichst genau abbildet. Die Verwendung originaler Rechnungsbelege aus dem Internal Audit der Freudenberg-Gruppe ist ausgeschlossen, da diese perso-

nenbezogene sowie geschäftskritische Informationen enthalten und daher im Rahmen dieser Evaluierung nicht herangezogen werden dürfen. Um dennoch eine hinreichend umfangreiche und belastbare Testbasis zu schaffen, werden die Testdatensätze mithilfe generativer KI erzeugt. Die künstlich erstellten Rechnungen orientieren sich in Struktur, Umfang und Informationsgehalt an realen Rechnungen und enthalten dieselben prüfungsrelevanten Kriterien wie die im Audit untersuchten Dokumente. Nach der künstlichen Erstellung der Rechnungen werden gezielte Fehler eingebracht, wie es auch in vergleichbaren Benchmark-Studien zur Prüfung finanzbezogener Dokumente durch LLMs angewandt wird Panda 2026. Der Testdatensatz umfasst somit sowohl fehlerhafte als auch vollständig korrekte Rechnungen. Für die vorliegende Arbeit wird eine Fehlerquote von 24 % festgelegt, was 12 von 50 fehlerhaften Rechnungen entspricht. Durch diese Quote ist die Anzahl der fehlerhaften Belege groß genug, um die Erkennungsleistung der Modelle repräsentativ zu untersuchen. Gleichzeitig spiegelt das Übergewicht korrekter Rechnungen den realen Prüfungskontext wieder. Bei der Fehlererzeugung wird bewusst auf eine breite Streuung unterschiedlicher Fehlertypen geachtet. Auf diese Weise wird vermieden, dass die Modelle lediglich auf ein eng begrenztes Fehlermuster hin getestet werden, und es lässt sich differenziert beurteilen, bei welchen Fehlerarten die Modelle zuverlässig arbeiten und bei welchen Fehlerarten Schwächen auftreten.

4.5 Entwicklung eines geeigneten Prompts

Die Qualität der von einem LLM erzeugten Ausgabe hängt in hohem Maße von der Formulierung der Eingabeaufforderung, dem sogenannten Prompt, ab. Da die untersuchten Modelle im Rahmen dieser Evaluation nicht durch ein aufgabenspezifisches Nachtraining (Fine-Tuning) an den Audit-Use-Case angepasst werden, ist der Prompt das zentrale Steuerungsinstrument, über das das gewünschte Modellverhalten ausschließlich durch natürlichsprachliche Anweisungen hervorgerufen wird, ohne die Modellparameter zu verändern (vgl. Sahoo et al. 2024, S. 1). Der systematische Entwurf, die Analyse und die iterative Verbesserung solcher Eingaben werden als Prompt Engineering bezeichnet und haben sich zu einer eigenständigen Methodik mit einer umfangreichen Sammlung empirisch untersuchter Techniken entwickelt; allein die aktuellste Übersichtsarbeit systematisiert auf Basis von über 1.500 Publikationen 58 textbasierte Prompting-Techniken (vgl. Schulhoff et al. 2024, S. 3, 6 f.). Um eine faire Vergleichbarkeit der Modelle sicherzustellen, wird für alle untersuchten LLMs derselbe, nach etablierten Prompt-Engineering-Prinzipien konstruierte

Prompt verwendet und über sämtliche Testdurchläufe hinweg unverändert gehalten.

Bei der Konstruktion des Prompts werden folgende in der Literatur als wirksam belegte Gestaltungsprinzipien berücksichtigt:

Rollenzuweisung (Role Prompting). Dem Modell wird zu Beginn des Prompts eine eindeutige Rolle – die eines Internal Auditors mit Schwerpunkt auf der Prüfung von Rechnungsbelegen – zugewiesen. Die Vorgabe einer Persona ist eine etablierte Technik, um Tonalität, Fachsprache und Bewertungsmaßstab der Antwort an den Anwendungskontext anzupassen und den Interpretationsspielraum des Modells einzugrenzen (vgl. Sahoo et al. 2024, S. 4). Auch Anthropic empfiehlt in den Entwicklerrichtlinien für die eingesetzten Claude-Modelle ausdrücklich, dem Modell über die Systemnachricht eine Rolle zu geben, da dies die Genauigkeit bei fachlich anspruchsvollen Aufgaben erhöht (vgl. Anthropic 2026).

Eindeutige Aufgaben- und Kontextbeschreibung. Das Modell erhält eine präzise formulierte Aufgabenstellung sowie den fachlichen Kontext des Prüfungsprozesses, einschließlich der konkret zu prüfenden Rechnungsmerkmale und der Definition, was im vorliegenden Anwendungsfall als Auffälligkeit gilt. Spezifische, kontextreiche Anweisungen reduzieren mehrdeutige oder thematisch abweichende Antworten und zählen sowohl in der Forschungsliteratur als auch in den Herstellerempfehlungen zu den grundlegendsten und wirksamsten Maßnahmen des Prompt Engineerings (vgl. Sahoo et al. 2024, S. 3 f. Anthropic 2026).

Strukturierung der Eingabe. Die einzelnen Bestandteile des Prompts – Rolle, Aufgabe, Prüfkriterien, zu analysierende Rechnung und Ausgabevorgaben – werden durch klar erkennbare Abgrenzungen (Delimiter bzw. XML-artige Auszeichnungen) voneinander getrennt. Eine solche Strukturierung erleichtert dem Modell die korrekte Zuordnung der Prompt-Bestandteile und erhöht die Verlässlichkeit der Ausgabe; für die Claude-Modelle wird die Verwendung von XML-Tags explizit als bewährte Praxis genannt (vgl. Anthropic 2026). Prompt-Muster dieser Art sind auch in der Literatur als wiederverwendbare Entwurfsvorlagen dokumentiert (vgl. White et al. 2023, S. 4 ff.).

Vorgabe eines festen Ausgabeformats. Um die Antworten der Modelle automatisiert auswerten und über die Modelle hinweg vergleichen zu können, gibt der Prompt ein maschinenlesbares Ausgabeschema vor. Dieses umfasst je Rechnung eine binäre Klassifikation (auffällig/unauffällig), eine strukturierte Begründung sowie eine Angabe zu den betroffenen Prüfkriterien. Die explizite Formatvorgabe ist eine gängige Prompt-Engineering-Technik zur Sicherung von Konsistenz und Weiterverarbeitbarkeit der Modellausgabe (vgl. Schulhoff et al. 2024, S. 6).

Few-Shot-Beispiele. Dem Prompt werden einige wenige vollständig ausgearbeitete Beispielfälle vorangestellt, die je eine korrekt und eine nicht korrekt geprüfte Rechnung samt erwarteter Ausgabe zeigen. Dieses In-Context-Learning ermöglicht es dem Modell, das gewünschte Bewertungs- und Ausgabeverhalten aus Demonstrationen abzuleiten, ohne dass die Modellparameter angepasst werden (vgl. Brown et al. 2020, S. 5). Bei der Auswahl der Beispiele wird auf eine ausgewogene Verteilung der Klassen und Fehlertypen geachtet, um eine Verzerrung des Modells in Richtung einer bestimmten Antwort zu vermeiden (vgl. Sahoo et al. 2024, S. 4 f.).

Schrittweises Schlussfolgern (Chain-of-Thought). Der Prompt fordert das Modell auf, seine Prüfung nachvollziehbar in einzelnen Schritten entlang der definierten Prüfkriterien durchzuführen, bevor es das abschließende Urteil ausgibt. Das explizite Anleiten zu einer schrittweisen Argumentation verbessert nachweislich die Leistung bei mehrstufigen Schlussfolgerungsaufgaben (vgl. Wei et al. 2022, S. 1 f.) und lässt sich bereits durch eine kurze Zusatzanweisung ohne eigene Beispiele auslösen (vgl. Kojima et al. 2022, S. 1). Für den Audit-Use-Case erfüllt die offengelegte Argumentationskette zugleich den Zweck, die in der Bewertungsmatrix erfasste Nachvollziehbarkeit der Begründung überhaupt beurteilbar zu machen.

Der so entwickelte Prompt wird vor der eigentlichen Evaluation an einer kleinen Auswahl von Testrechnungen erprobt und in mehreren Iterationen anhand der beobachteten Modellausgaben nachgeschärft, etwa hinsichtlich unklarer Formulierungen, unvollständiger Begründungen oder Abweichungen vom vorgegebenen Ausgabeformat. Dieses iterative Vorgehen entspricht dem in der Literatur beschriebenen Kern des Prompt Engineerings als empirisch-experimentellem Optimierungsprozess (vgl. Sahoo et al. 2024, S. 2). Der finale Prompt wird anschließend unverändert auf alle Modelle angewendet, sodass Leistungsunterschiede in der Evaluation auf die Modelle selbst und nicht auf unterschiedliche Eingaben zurückzuführen sind.

4.6 Nutzwertanalyse

Die Eignung der untersuchten KI-Modelle für den definierten Audit-Use-Case kann nicht anhand eines einzelnen Bewertungskriteriums bestimmt werden. Vielmehr müssen sowohl quantitative, als auch qualitative Kriterien berücksichtigt werden um ein umfangreiches

Ergebnis zu erlangen. Die Bewertung der Modelle erfordert somit die gleichzeitige Betrachtung mehrerer, teilweise konkurrierender Kriterien und stellt ein mehrdimensionales Entscheidungsproblem dar (vgl. Kozłowska 2022, S. 116 f.). Zur strukturierten und nachvollziehbaren Berücksichtigung dieser unterschiedlichen Kriterien wird in dieser Arbeit eine Nutzwertanalyse durchgeführt. Die Nutzwertanalyse ermöglicht es, verschiedene Bewertungskriterien zu gewichten und zu einem Gesamtnutzenwert zu aggregieren. Dadurch können die untersuchten KI-Modelle objektiv und transparent hinsichtlich ihrer Eignung für den Audit-Use-Case verglichen werden (vgl. Kühnapfel 2021, S. 79, 272).

4.7 Entwicklung einer Bewertungsmatrix

Um die Evaluation basierend auf einer Nutzwertanalyse durchzuführen, muss eine Bewertungsmatrix mit mehreren quantitativen und qualitativen Kriterien entwickelt werden (vgl. Liang et al. 2023, S.3). Die Bewertungsmatrix gliedert sich hierzu in fünf Dimensionen, die jeweils unterschiedliche, für den Audit-Use-Case relevante Aspekte der Modellleistung abbilden und in ihrer Gesamtheit ein möglichst vollständiges Bild der Eignung der untersuchten Modelle liefern sollen.

Die erste Dimension bildet die objektiv messbare Erkennungsleistung der Modelle ab. Sie umfasst die Kennzahl Precision, die sich als Quotient aus den korrekt als auffällig erkannten Rechnungen (True Positives) und der Summe aus True Positives und der fälschlicherweise als auffällig markierten Rechnungen (False Positives) berechnet, sowie die Kennzahl Recall, die sich als Quotient aus den True Positives und der Summe aus True Positives und den nicht erkannten Auffälligkeiten (False Negatives) ergibt. Da eine hohe Precision und ein hoher Recall teilweise gegenläufige Anforderungen an ein Auditunterstützungssystem darstellen, wird ergänzend der F1-Score als harmonisches Mittel aus Precision und Recall herangezogen, um die Erkennungsleistung der Modelle in einer einzelnen, ausgewogenen Kennzahl zusammenzufassen (vgl. Sokolova und Lapalme 2009, S. 429)

Die zweite Dimension erfasst die stärker subjektiv geprägte Qualität der von den Modellen gelieferten Begründungen. Da eine Auffälligkeit für den Prüfungsprozess erst dann einen Mehrwert besitzt, wenn ein Auditor die Argumentation des Modells nachvollziehen kann, wird die Nachvollziehbarkeit der Begründung auf einer fünfstufigen Skala bewertet. Ergänzend wird die fachliche Korrektheit der Argumentation binär als korrekt oder nicht korrekt

ist das
schlimm,
das die
Seiten-
zahlen
so
komisch
sind?

beurteilt, um abzubilden, ob die vom Modell angeführten Gründe auch aus fachlicher Auditsicht Bestand haben. Zusätzlich wird die Halluzinationsrate der Modelle erhoben, da insbesondere frei erfundene oder inhaltlich nicht durch die Rechnung gedeckte Begründungen das Vertrauen in die Modellergebnisse und damit deren praktische Einsatzfähigkeit im Audit maßgeblich beeinträchtigen würden.

Die dritte Dimension widmet sich der Konsistenz der Modelle. Hierzu wird zum einen die Ergebniskonsistenz betrachtet, indem dieselbe Anfrage über mehrere Durchläufe hinweg wiederholt und die Stabilität der erzielten Ergebnisse beurteilt wird. Zum anderen wird die Begründungskonsistenz untersucht, also die Frage, ob die Modelle über die Durchläufe hinweg ähnliche Begründungen liefern und vergleichbare Risiken priorisieren. Beide Teilkriterien sind für den Audit-Use-Case von besonderer Bedeutung, da ein Prüfungsergebnis nur dann als verlässlich gelten kann, wenn es bei wiederholter Anwendung reproduzierbar ist.

Die vierte Dimension bewertet den unmittelbaren Nutzen der Modellanalyse für den Auditor, also inwieweit die generierte Auffälligkeitsanalyse den Auditor bei seiner Prüfungstätigkeit tatsächlich unterstützt. Dieses Kriterium ist naturgemäß in besonderem Maße subjektiv geprägt, da es weniger die technische Leistungsfähigkeit als vielmehr den wahrgenommenen praktischen Mehrwert der Modellausgabe für den Prüfungsprozess erfasst, und wird bei der Auswertung entsprechend vorsichtig interpretiert.

Die fünfte Dimension berücksichtigt die praktische Einsatzfähigkeit der Modelle jenseits ihrer inhaltlichen Leistung. Hierzu zählen die Antwortzeit der Modelle, die für die Integration in den Prüfungsprozess von Bedeutung ist, die mit der Nutzung verbundenen Kosten sowie die Einhaltung datenschutzrechtlicher Anforderungen, deren Erfüllung angesichts der sensiblen, geschäftskritischen Inhalte der geprüften Dokumente eine notwendige Voraussetzung für den produktiven Einsatz der Modelle im Internal Audit darstellt.

Die auf diese Weise entwickelten fünf Dimensionen mit ihren jeweiligen Einzelkriterien bilden die Grundlage der Bewertungsmatrix. Im Rahmen der Nutzwertanalyse werden die einzelnen Kriterien sowie die übergeordneten Dimensionen anschließend gewichtet und zu einem Gesamtergebnis je Modell zusammengeführt, das im nachfolgenden Abschnitt näher erläutert wird.

4.8 Gewichtung der Bewertungsmatrix

Zur systematischen Evaluation der untersuchten LLMs wird eine mehrdimensionale Bewertungsmatrix entwickelt. Ziel dieser Matrix ist es, die Eignung der Modelle für die Unterstützung von Stichprobenanalysen im Internal Audit möglichst ganzheitlich zu bewerten. Die Leistungsfähigkeit der Modelle wird sowohl über objektive Kennzahlen als auch über qualitative Kriterien bewertet. Die einzelnen Bewertungskriterien werden gewichtet und anschließend zu einer Gesamtbewertung zusammengeführt.

Die erste Bewertungsdimension umfasst die Erkennungsleistung der Modelle. Diese bildet den Kern der Evaluation, da die zuverlässige Identifikation von Auffälligkeiten und Unregelmäßigkeiten die zentrale Anforderung eines KI-gestützten Audit-Tools darstellt.

5 Evaluationsdurchführung

5.1 Durchführung der Tests

5.2 Ergebnisse der Stichprobenanalysen

5.2.1 Rechnungen

5.2.2 Benutzerberechtigungen

5.2.3 Gesamtvergleich

5.3 Auswertung der Bewertungsmatrix

5.4 Vergleich der Modelle

5.5 Analyse der Ergebnisse

5.6 Beantwortung der Forschungsfrage

6 Fazit und Ausblick

6.1 Zusammenfassung der wichtigsten Erkenntnisse

6.2 Fazit zur Eignung von LLMs im Audit

6.3 Handlungsempfehlungen für Freudenberg

6.4 Zukünftige Entwicklungspotenziale

A Prompts

A.1 Prompt GPT

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

A.2 Prompt Claude

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy

eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a

turpis eu lacus commodo facilis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Literatur

- Anthropic (2026). *Prompt Engineering Overview – Claude Developer Documentation*. Anthropic. URL: <https://docs.anthropic.com/en/docs/build-with-claude/prompt-engineering/overview> (besucht am 31.08.2026).
- Artificial Analysis (2026). *Comparison of AI Models across Intelligence, Performance, and Price*. Artificial Analysis. URL: <https://artificialanalysis.ai/models> (besucht am 11.08.2026).
- Baumeister, Daniel (2019). „Sample size and error containment judgments in non-statistical audit sampling-the sensitivity of auditors to a revision of professional standards“. Diss. Dissertation, Dortmund, Technische Universität, 2019.
- Brown, Tom B. et al. (2020). „Language Models are Few-Shot Learners“. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Bd. 33, S. 1877–1901. URL: <https://arxiv.org/abs/2005.14165>.
- Cantù, Elena, Cecilia Langella und Ilaria Elisa Vannini (2025). „Making sense of the internal audit function: toward internal controls integration and organizational learning“. In: *Financial Accountability & Management* 41.2, S. 262–273.
- Fedyk, Anastassia et al. (2022). „Is artificial intelligence improving the audit process?“ In: *Review of Accounting Studies* 27.3, S. 938–985. DOI: 10.1007/s11142-022-09697-x.
- Freudenberg, Corporate Audit (2026). „Internal Audit Sample Testing Guidance Examples“. Interne Excel-Datei, Freudenberg & Co. KG.
- G2 (2026). *DataSnipper Reviews 2026: Details, Pricing & Features*. URL: <https://www.g2.com/products/datasnipper/reviews> (besucht am 06.08.2026).
- Gartner Peer Insights (2026). *DataSnipper Reviews, Ratings & Features 2026*. Gartner, Inc. URL: <https://www.gartner.com/reviews/market/artificial-intelligence/vendor/datasnipper> (besucht am 06.08.2026).
- Ivakhnenkov, Serhii (2023). „Artificial intelligence application in auditing“. In.
- Kojima, Takeshi et al. (2022). „Large Language Models are Zero-Shot Reasoners“. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Bd. 35, S. 22199–22213. URL: <https://arxiv.org/abs/2205.11916>.
- Kokina, Julia et al. (2025). „Challenges and opportunities for artificial intelligence in auditing: Evidence from the field“. In: *International Journal of Accounting Information Systems* 56, S. 100734. ISSN: 1467-0895. DOI: <https://doi.org/10.1016/j.accinf.2025.100734>. URL: <https://www.sciencedirect.com/science/article/pii/S1467089525000107>.
- Kozłowska, Justyna (2022). „Methods of Multi-Criteria Analysis in Technology Selection and Technology Assessment: A Systematic Literature Review“. In: *Engineering Management in Production and Services* 14.2, S. 116–137. DOI: 10.2478/emj-2022-0021.
- Kühnapfel, Jörg B. (2021). *Scoring und Nutzwertanalysen: Ein Leitfaden für die Praxis*. 2. Wiesbaden: Springer Gabler. DOI: 10.1007/978-3-658-34810-6.

- Kyriazos, Theodoros und Mary Poga (2024). „Application of Machine Learning Models in Social Sciences: Managing Nonlinear Relationships“. In: *Encyclopedia* 4.4, S. 1790–1805. DOI: 10.3390/encyclopedia4040118.
- Liang, Percy et al. (2023). *Holistic Evaluation of Language Models*. arXiv: 2211.09110 [cs.CL]. URL: <https://arxiv.org/abs/2211.09110>.
- Lyell, David und Enrico Coiera (2017). „Automation bias and verification complexity: a systematic review“. In: *Journal of the American Medical Informatics Association* 24.2, S. 423–431.
- Panda, Silu (2026). *FinVerBench: Evaluating Large Language Models on Numerical Consistency Verification of Financial Statements*. Preprint, eingereicht am 28.05.2026. DOI: 10.48550/arXiv.2605.29586. arXiv: 2605.29586 [cs.CL]. URL: <https://arxiv.org/abs/2605.29586> (besucht am 07.09.2026).
- Roussy, Mélanie (2013). „Internal auditors' roles: From watchdogs to helpers and protectors of the top manager“. In: *Critical Perspectives on Accounting* 24.7, S. 550–571. ISSN: 1045-2354. DOI: <https://doi.org/10.1016/j.cpa.2013.08.004>. URL: <https://www.sciencedirect.com/science/article/pii/S1045235413000932>.
- Sahoo, Pranab et al. (2024). *A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications*. arXiv: 2402.07927 [cs.AI]. URL: <https://arxiv.org/abs/2402.07927>.
- Schulhoff, Sander et al. (2024). *The Prompt Report: A Systematic Survey of Prompt Engineering Techniques*. arXiv: 2406.06608 [cs.CL]. URL: <https://arxiv.org/abs/2406.06608>.
- Schumann, Gerrit und Jorge Marx Gómez (2021). „Natural language processing in internal auditing—A structured literature review“. In:
- Sokolova, Marina und Guy Lapalme (2009). „A Systematic Analysis of Performance Measures for Classification Tasks“. In: *Information Processing & Management* 45.4, S. 427–437. DOI: 10.1016/j.ipm.2009.03.002.
- The Institute of Internal Auditors (2024). *Global Internal Audit Standards*. Accessed: 2026-09-02. Lake Mary, FL: The Institute of Internal Auditors. URL: https://www.theiia.org/globalassets/site/standards/globalinternalauditstandards_2024january9.pdf.
- Wassie, Fekadu Agmas und László Péter Lakatos (2024). „Artificial intelligence and the future of the internal audit function“. In: *Humanities and Social Sciences Communications* 11.1, S. 386.
- Wei, Jason et al. (2022). „Chain-of-Thought Prompting Elicits Reasoning in Large Language Models“. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Bd. 35, S. 24824–24837. URL: <https://arxiv.org/abs/2201.11903>.
- White, Jules et al. (2023). *A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT*. arXiv: 2302.11382 [cs.SE]. URL: <https://arxiv.org/abs/2302.11382>.
- YourAIFinder (2026). *DataSnipper – AI Audit Automation Platform Inside Excel*. URL: <https://youraifinder.com/tool/datasnipper> (besucht am 06.08.2026).

Hilfsmittelangabe zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten



Persönliche Angaben

Verclas, Leonard	3317974
Nachname, Vorname	Matrikelnummer
Gaußstrasse 5, 68775 Ketsch	WDSKI24B
Anschrift	Kurs
S242792@student.dhbw-mannheim.de	0176 45895734
E-Mail	Telefon- / Handynummer

Für das Modul

Praxismodul 2
Modulbezeichnung / Semester

muss ich am

09.11.2026
Datum der Frist

folgende Prüfungsleistung erbringen:

- ☐ Projektarbeit I X Projektarbeit II
- ☐ Seminararbeit ☐ Bachelorarbeit
- ☐ Sonstige

genaue Bezeichnung der sonstigen Prüfungsleistung

Zur Verwendung KI-gestützter Werkzeuge erkläre ich in Kenntnis des Hinweisblatts "Hinweise zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung wissenschaftlicher Arbeiten und die prüfungsrechtlichen Folgen ihres Einsatzes" Folgendes:

- Ich habe mich aktiv über die Leistungsfähigkeit und Beschränkungen der in meiner Arbeit eingesetzten KI-Werkzeuge informiert.
- Bei der Anfertigung der Prüfungsleistung habe ich durchgehend eigenständig und beim Einsatz KI-gestützter Werkzeuge maßgeblich steuernd gearbeitet.
- Insbesondere habe ich die Inhalte entweder aus wissenschaftlichen oder anderen zugelassenen Quellen entnommen und diese gekennzeichnet oder diese unter Anwendung wissenschaftlicher Methoden selbst entwickelt.
- Mir ist bewusst, dass ich als Autor/in der Arbeit die Verantwortung für die in ihr gemachten Angaben und Aussagen trage.
- Ich habe keine weiteren als die nachstehend von mir benannten KI-gestützten Werkzeuge zur Erstellung der Arbeit eingesetzt und diese nur in der angegebenen Art und Weise.

- Soweit ich KI-gestützte Werkzeuge zur Erstellung der Arbeit eingesetzt habe, gebe ich diese in der nachstehenden "Übersicht verwendeter Hilfsmittel" mit ihrem Produkt-namen und ihres genutzten Funktionsumfangs vollständig an; wörtliche oder sinn-gemäße Übernahmen KI-generierter Inhalte habe ich in ein separates Verzeichnis aufgenommen und im Text belegt (z. B. als Fußnote). Diese Inhalte sind als pdf-Datei in den elektronischen Beigaben hinterlegt.

Produktname(n) eingesetzter Hilfsmittel:

--

Genutzter Funktionsumfang im Hinblick auf

- **Themenerfassung und Strukturierung** (Aufgabenstellung oder Präzisierung, Forschungsansatz, Gliederung)

--

- **Themenbearbeitung** (Darstellung/Beschreibung des Problems, Darlegung von wissenschaftlichen Grundlagen, Schlussfolgerungen allgemein und für das konkrete Thema / Erkenntnisgewinn, Evaluierung des Textes / Feedback der KI)

--

- **Quellenrecherche, -auswahl und -auswertung** (welche Quellen wurden durch das KI-Werkzeug gefunden, wie erfolgte die weitere Recherche)

--

- **Formale Gestaltung, insbesondere Sprache** (Welche Eingabe wurde an die KI getätigt? Textgenerierung, Textkorrektur, Paraphrasieren und Umschreiben, Übersetzen, kreatives Schreiben)

--

Hinweis:

Geben Sie in der jeweiligen Rubrik die Seitenzahl in ihrer wissenschaftlichen Arbeit an und erläutern Sie die Art und Weise sowie den Umfang der von Ihnen genutzten KI-basierten Werkzeuge.

--	--

Ort, Datum

Unterschrift der/des Studierenden