FREUDENBERG
INNOVATING TOGETHER

DHBW
Duale Hochschule
Baden-Württemberg
Mannheim

Duale Hochschule Baden-Württemberg Mannheim

Projektarbeit 2

Einsatz von LLMs zur Unterstützung von Stichprobenanalysen im Audit-Bereich. Ein Vergleich verschiedener KI-Modelle hinsichtlich ihrer Eignung für interne Prüfungsprozesse bei der Freudenberg Group

Studiengang Wirtschaftsinformatik

Studienrichtung Data Science und Künstliche Intelligenz

Verfasser(in):	Leonard Verclas
Matrikelnummer:	3317974
Firma:	Freudenberg & Co. Kommanditgesellschaft
Kurs:	WDSKI24B
Studiengangsleiter:	Prof. Dr. Bernhard Drabant
Wissenschaftliche(r) Betreuer(in):	Stefanie Bell
Firmenbetreuer(in):	Andreas Hass
Bearbeitungszeitraum:	03.08.2026 - 09.11.2026

Todo list

Text Kapitel 4 . . . 2

Text Grundlagen und Kapitel 3 . . . 2

Seite ergänzen: Abschnitt zu den Bestandteilen eines Prompts . . . 6

Seite ergänzen . . . 6

Seite ergänzen: Einleitung . . . 6

Seite ergänzen: Abschnitt 2.1 . . . 6

Seite ergänzen . . . 6

Quelle: Microsoft Learn, Seite zur Modellauswahl . . . 6

Dopplung mit 3.2 prüfen: Kokina und Fedyk dort mit gleicher Aussage . . . 7

Seite ergänzen . . . 7

Seite ergänzen: Abschnitt 3.1, Hallucination from Data . . . 7

Dopplung mit 3.2 prüfen: Kokina und Fedyk dort mit gleicher Aussage . . . 8

Quelle . . . 8

Seite ergänzen . . . 8

Seite ergänzen: Abschnitt zu datenbedingten Ursachen . . . 8

noch besser erklären . . . 12

so rihcitg zitiert oder zusammenfassen? . . . 12

nochmal gucken bzgl. auto pilot auditing . . . 17

Freudenberg einheitlich benennen: Freudenberg Gruppe vs. Freudenberg & Co. (FCo), Internal Audit vs. Corporate Audit schon am anfang der arbeit . . . 17

Quelle . . . 18

besser formulieren im bezug zu oben, dass wir den ja schon haben . . . 18

kapitel 4.2 und 4.3 tauschen? . . . 18

Stefanie Bell: Finanzkontext hier eine repräsentative Quelle? -> Ich finde schon, da das auch Teil des Audits sein könnte . . . 19

fehler eingebaut ja aber auch freigabematrix berücksichtigen . . . 19

wirkt bissl abgehakt . . . 19

Schreib ich hier 6 oder sechs generell überall 19
es muss noch erwähnt werden irgendwo im text eher am anfang, dass es eine referenztabelle und eine freigabematrix gibt 19
genaue Zahlen begründen: 100 Rechnungen, 24 %, 24 Fehler, Verteilung 6, 5, 4, 4, 3, 2 19
hier nur struktur, nicht inhaltlich 20
Quelle 20
muss ich die älteren prompts auch mit rein nehmen? Ich will eigentlich nicht 22
ist das kapitel an der richitgen Stelle? 23
haben wir das mit den mehereren kriterien nicht gerade schon gesagt? 23
wissenschaftlich begründen, warum diese Kriterien 23
Quelle 25
Sensivitätsanalyse muss noch gemacht werden 28
Ergänzen, wie damit umgegangen wurde und ob es die Ergebnisse beeinflusst 29
Reihenfolge prüfen, sobald die Werte für Opus 4.6 und GPT 5.5 vorliegen 31
Reihenfolge von Sonnet 4.6 und Opus 4.6 prüfen 32
Aussage zur Konsistenz mit den Werten für Opus 4.6 und GPT 5.5 prüfen 33

Inhaltsverzeichnis

Abbildungsverzeichnis v

Tabellenverzeichnis vi

Quelltextverzeichnis vii

Abkürzungsverzeichnis viii

Kurzfassung (Abstract) ix

1 Einleitung 1
- 1.1 Problemstellung & Motivation der Arbeit . . . 1
- 1.2 Zielsetzung der Arbeit . . . 1
- 1.3 Aufbau der Arbeit . . . 2

2 Grundlagen 3
- 2.1 Internal Audit . . . 3
- 2.2 Stichprobenanalyse im Internal Audit . . . 3
- 2.3 Large Language Models . . . 4
- 2.4 Prompt Engineering . . . 6
- 2.5 KI-Agenten . . . 6
- 2.6 Einsatz von Künstlicher Intelligenz im Audit . . . 7
- 2.7 Einsatz von Künstlicher Intelligenz im Audit . . . 7
  - 2.7.1 Potenziale in der Stichprobenanalyse . . . 8
  - 2.7.2 Risiken in der Stichprobenanalyse . . . 8

3 State of the Art 9
- 3.1 Aktuelle Durchführung von Stichprobenanalysen bei Freudenberg . . . 9
- 3.2 Einsatz von KI im Auditbereich . . . 10
- 3.3 Verfügbare KI-Lösungen für den Auditbereich . . . 11
  - 3.3.1 Kommerzielle Lösungen . . . 11
  - 3.3.2 Open-Source-Lösungen . . . 12
  - 3.3.3 Spezialisierte KI-gestützte Audit-Lösungen . . . 13
- 3.4 Chatnutzung und KI-Agenten . . . 13
- 3.5 Einordnung des KI-Einsatzes bei Freudenberg . . . 14

4 Evaluationsdesign **16**
4.1 Forschungsdesign . . . 16
4.2 Wahl der Untersuchungsumgebung . . . 16
4.3 Auswahl der zu untersuchenden Modelle . . . 17
4.4 Entwicklung der Testdatensätze . . . 18
4.5 Entwicklung eines geeigneten Prompts . . . 20
4.6 Nutzwertanalyse . . . 23
4.7 Entwicklung einer Bewertungsmatrix . . . 23
4.8 Gewichtung der Bewertungsmatrix . . . 26

5 Durchführung und Ergebnisse der Evaluation **29**
5.1 Durchführung der Tests . . . 29
5.2 Ergebnisse der Stichprobenanalysen . . . 30
5.3 Auswertung der Bewertungsmatrix . . . 32
5.4 Vergleich der Modelle . . . 33

6 Fazit und Ausblick **35**
6.1 Zusammenfassung der wichtigsten Erkenntnisse . . . 35
6.2 Fazit zur Eignung von LLMs im Audit . . . 35
6.3 Handlungsempfehlungen für Freudenberg . . . 35
6.4 Zukünfige Entwicklungspotenziale . . . 35

Anhang

A Anhang **36**
A.1 Instruktionen . . . 36

Literatur **41**

Abbildungsverzeichnis

Tabellenverzeichnis

4.1 Verteilung der eingebauten Fehler auf die Fehlerkategorien 20
4.2 Gewichtung der Bewertungsmatrix 27

5.1 Konfusionswerte je Modell 30
5.2 Kennzahlen der Erkennungsleistung je Modell (in %) 30
5.3 Konsistenz je Modell 31
5.4 Bewertungsmatrix der Nutzwertanalyse 32

Quelltextverzeichnis

Abkürzungsverzeichnis

DHBW	Duale Hochschule Baden-Württemberg
LLM	Large Language Model
KI	Künstliche Intelligenz
FCo	Freudenberg & Co.
TP	True Positive
FP	False Positive
TN	True Negative
FN	False Negative
DL	Deep Learning
NLP	Natural Language Processing
ML	Machine Learning

Kurzfassung (Abstract)

1 Einleitung

1.1 Problemstellung & Motivation der Arbeit

Mit der fortschreitenden Entwicklung Künstliche Intelligenz (KI) stehen Unternehmen vor der Herausforderung, ihre Geschäftsprozesse kontinuierlich zu optimieren und durch den gezielten Einsatz neuer Technologien effizienter zu gestalten. Insbesondere im Audit-Umfeld bietet der Einsatz von KI ein erhebliches Potenzial zur Steigerung von Effizienz, Prüfungsqualität und Transparenz. KI unterstützt interne Auditoren, indem der manuelle Analyseaufwand reduziert wird und umfassendere sowie schnellere Prüfungen ermöglicht werden. (vgl. Wassie und Lakatos 2024, S. 11–12).

Ein besonders vielversprechendes Anwendungsfeld stellt die Analyse von Audit-Stichproben dar. Im Rahmen dieser Prüfungen werden zum Beispiel Rechnungen untersucht, um Auffälligkeiten, Regelverstöße oder potenzielle Risiken zu identifizieren. Die manuelle Analyse dieser Unterlagen ist jedoch zeitaufwendig und bindet erhebliche personelle Ressourcen. Gleichzeitig steigt aufgrund wachsender Datenmengen und zunehmend komplexer Geschäftsprozesse die Schwierigkeit, relevante Auffälligkeiten zuverlässig zu erkennen.

Vor diesem Hintergrund gewinnt die Unterstützung von Stichprobenanalysen durch KI-basierte Verfahren zunehmend an Bedeutung. Für die Freudenberg-Gruppe stellt sich dabei die Frage, wie KI-Technologien gewinnbringend in die Stichprobenanalyse im Internal-Audit-Prozess integriert werden können. Neben der Verbesserung der Effizienz und Prüfungsqualität durch den Einsatz von KI spielt insbesondere die Einhaltung strenger Datenschutz- und Compliance-Anforderungen sowie die Auswahl eines geeigneten KI-Modells für die Analyse von Audit-Dokumenten eine zentrale Rolle. Daraus ergibt sich die Notwendigkeit, die Eignung verschiedener KI-Lösungen für die Unterstützung von Stichprobenanalysen im Internal Audit systematisch zu untersuchen.

1.2 Zielsetzung der Arbeit

Ziel dieser Projektarbeit ist die systematische Untersuchung und Bewertung verschiedener KI-gestützter Werkzeuge zur Unterstützung von Stichprobenanalysen im Internal Audit

der Freudenberg-Gruppe. Der Fokus liegt dabei auf Large Language Models (LLMs), die Auditoren bei der Analyse von Prüfungsdokumenten unterstützen können. Hierzu werden ausgewählte LLMs auf identische Audit-Stichproben angewendet. Die Modelle sollen potenzielle Auffälligkeiten, Risiken oder Regelverstöße in Rechnungen identifizieren sowie ihre Bewertungen nachvollziehbar begründen. Anschließend werden die Ergebnisse anhand einer Bewertungsmatrix miteinander verglichen. Dabei stehen insbesondere die Erkennungsqualität, die Nachvollziehbarkeit der Ergebnisse, die Konsistenz der Analysen sowie die praktische Einsetzbarkeit im Audit-Umfeld im Vordergrund. Auf Basis dieser Untersuchung soll ermittelt werden, welches KI-Modell die Anforderungen der Freudenberg-Gruppe im Kontext von Stichprobenanalysen im Internal Audit am besten erfüllt. Die gewonnenen Erkenntnisse sollen eine fundierte Grundlage für die Bewertung des Potenzials von LLMs im Audit-Bereich sowie für deren zukünftigen Einsatz innerhalb der Organisation schaffen. Daraus ergibt sich folgende Forschungsfrage: Wie unterscheiden sich verschiedene Large Language Models hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit-Bereich?

1.3 Aufbau der Arbeit

Text Kapitel 4

Text Grund-lagen und Kapitel 3

2 Grundlagen

2.1 Internal Audit

Das Internal Audit stellt eine unabhängige und objektive Prüfungs- und Beratungsfunktion innerhalb einer Organisation dar. Die zentrale Aufgabe besteht darin, die Korrektheit und Wirksamkeit von Governance-, Risikomanagement- und internen Kontrollprozessen zu bewerten sowie durch unabhängige Prüfungs- und Beratungsleistungen zur Verbesserung dieser Prozesse beizutragen. Im Gegensatz zum externen Audit ist das Internal Audit organisatorisch in das Unternehmen eingebunden, wobei seine unabhängige Position gegeben sein muss (vgl. The Institute of Internal Auditors 2024, S.12 ff., 46). Die Existenz von Internal-Audit-Funktionen begründet sich insbesondere durch die Notwendigkeit, die Transparenz organisatorischer Prozesse zu erhöhen, Rechenschaftspflichten gegenüber Stakeholdern zu unterstützen sowie das Vertrauen in Governance-, Risiko- und Kontrollprozesse zu stärken (vgl. The Institute of Internal Auditors 2023, S. 1).

Moderne Audit-Ansätze beschränken sich jedoch nicht ausschließlich auf die Überprüfung der Regelkonformität. Vielmehr soll das Internal Audit organisatorisches Lernen fördern, das Risikobewusstsein der beteiligten Akteure stärken und Verbesserungsmöglichkeiten in Geschäftsprozessen aufzeigen. Dadurch leistet die Funktion einen Beitrag zur kontinuierlichen Weiterentwicklung der Organisation und schafft einen Mehrwert, der über reine Compliance-Aspekte hinausgeht (vgl. Cantù, Langella und Vannini 2025, S. 18–21). Für die Durchführung der Prüfungen werden unter anderem Prozess- und Ablaufdokumente gesammelt, interpretiert und analysiert sowie deren Übereinstimmung mit gegebenen Anforderungen bewertet (vgl. Roussy 2013, S. 556–557). Ein Prozess,der ein erhebliches Potenzial für die Nutzung von KI mit sich bringt (vgl. Schumann und Marx Gómez 2021, S.1).

2.2 Stichprobenanalyse im Internal Audit

Für ein Prüfungsurteil muss das Internal Audit Informationen erheben, die für das Prüfungsziel relevant, verlässlich und ausreichend sind (vgl. The Institute of Internal Auditors

2024, S. 104). Diese Informationen werden als Prüfungsnachweise bezeichnet (vgl. International Auditing and Assurance Standards Board 2009, S. 5). Da Personal, Zeit und Budget begrenzt sind, kann das Internal Audit nicht alle Elemente prüfen und arbeitet deshalb mit Stichproben (vgl. Nest, Smidt und Lubbe 2015, S. 72). Eine Stichprobe liegt vor, wenn Prüfungshandlungen auf weniger als 100 % der Elemente einer Grundgesamtheit angewendet werden, jedes Element ausgewählt werden kann und Schlüsse auf die gesamte Grundgesamtheit gezogen werden sollen (vgl. International Auditing and Assurance Standards Board 2025, S. 12). Die Grundgesamtheit ist eine abgegrenzte Menge gleichartiger Elemente, etwa alle Rechnungen eines Kreditorenkontos (vgl. Baumeister 2019, S. 12). Bei der FCo werden beide Verfahren kombiniert: Zunächst wird eine Pflichtprobe aller Elemente bestimmt, die vorab festgelegte Kriterien erfüllen, etwa alle Rechnungen über einem bestimmten Betrag. Aus den übrigen Elementen wird anschließend eine Zufallsstichprobe gezogen (vgl. Freudenberg 2026). Durch die Prüfung nur eines Teils der Grundgesamtheit entsteht ein Stichprobenrisiko. Dieses beschreibt das Risiko, dass auf Basis der Stichprobe ein anderes Ergebnis erzielt wird als bei einer Prüfung aller Elemente (vgl. International Auditing and Assurance Standards Board 2025, S. 21). Erfüllt ein geprüftes Element die Anforderungen nicht, liegt eine Feststellung vor, das heißt eine Abweichung zwischen Bewertungskriterien und tatsächlichem Zustand (vgl. The Institute of Internal Auditors 2024, S. 11). Bei der FCo wird eine solche Feststellung als Audit Exception erfasst (vgl. Freudenberg 2026).

2.3 Large Language Models

LLMs sind ein Teilbereich der generativen KI. Unter generativer KI werden Verfahren verstanden, die auf Grundlage von Trainingsdaten neue Inhalte wie Texte, Bilder oder Audio erzeugen können (vgl. Feuerriegel et al. 2024, S. 111). Die Modelle werden mit einer großen Anzahl an Parametern auf umfangreichen Textdaten trainiert. Ihre Grundlage bildet die Sprachmodellierung, deren Ziel darin besteht, die Wahrscheinlichkeitsverteilung über Folgen von Wörtern einer Sprache zu erlernen (vgl. Zhao et al. 2023, S. 1). Mit steigender Anzahl an Parametern, wachsender Menge an Trainingsdaten und höherem Rechenaufwand nimmt die Leistungsfähigkeit der LLMs dabei systematisch zu (vgl. Kaplan et al. 2020, S. 3).

Um Text verarbeiten zu können, zerlegt ein LLM diesen zunächst in kleinere Einheiten, sogenannte Tokens. Ein Token kann ein ganzes Wort, einen Wortbestandteil oder ein

einzelnes Zeichen umfassen (vgl. Sennrich, Haddow und Birch 2016, S. 1715 f.). Jedes Token wird anschließend in einen realwertigen Vektor in einem hochdimensionalen Raum überführt, ein sogenanntes Embedding. Da ähnliche Wörter ähnliche Vektoren erhalten, kann das Modell semantische Beziehungen zwischen Wörtern abbilden (vgl. Bengio et al. 2003, S. 137 ff.). Wie viele Tokens ein Modell gleichzeitig verarbeiten kann, wird durch das sogenannte Kontextfenster begrenzt (vgl. N. F. Liu et al. 2024, S. 157 f.). Die Ausgabe erzeugt ein LLM autoregressiv. Das bedeutet, dass der Text Token für Token entsteht. Jedes neue Token wird auf Basis der Eingabe und aller bereits erzeugten Tokens vorhergesagt, an die bisherige Folge angehängt und fließt so in die nächste Vorhersage ein (vgl. Bengio et al. 2003, S. 1138).

Auf dieser Grundlage können LLMs eine Vielzahl sprachbasierter Aufgaben bearbeiten, etwa Fragen beantworten, Texte übersetzen und zusammenfassen oder Informationen extrahieren (vgl. Zhao et al. 2023, S. 1). Welche Aufgabe gelöst werden soll, erfährt das Modell über das sogenannte In Context Learning. Dabei wird die Aufgabe direkt in der Eingabe (Prompt) durch eine Anweisung in natürlicher Sprache beschrieben. Das Modell erzeugt die Lösung dann, indem es diese Eingabe Token für Token fortsetzt, ohne dass seine Parameter verändert werden. Dadurch lassen sich LLMs ohne aufgabenspezifisches Training flexibel für unterschiedliche Anwendungsfälle einsetzen (vgl. Brown et al. 2020, S. 1877 f.). Multimodale LLMs erweitern diese Fähigkeiten, indem sie Sprachmodelle mit Modellen zur Bildverarbeitung kombinieren. So können auch visuelle Eingaben interpretiert und beispielsweise in Bildern enthaltene Texte ohne vorgelagerte Texterkennung ausgewertet werden (vgl. Yin et al. 2024, S. 1).

Diesen Fähigkeiten stehen jedoch wesentliche Einschränkungen gegenüber. So neigen LLMs zu Halluzinationen, also zu der Generierung von Inhalten, die plausibel erscheinen, inhaltlich jedoch nicht korrekt sind (vgl. Huang et al. 2025, S. 1 f.). Zudem arbeiten LLMs nicht vollständig deterministisch, sodass identische Eingaben selbst bei identischen Konfiguration zu unterschiedlichen Ausgaben führen können (vgl. Ouyang et al. 2025, S. 1). In Anwendungsfeldern mit hohen Anforderungen an Korrektheit und Nachvollziehbarkeit werfen diese Eigenschaften daher Fragen hinsichtlich der Zuverlässigkeit von LLMs auf, sowohl bezüglich der inhaltlichen Korrektheit als auch der Konsistenz der Ergebnisse.

2.4 Prompt Engineering

Prompt Engineering bezeichnet die systematische Gestaltung, Strukturierung und Optimierung von Eingabeanweisungen, sogenannten Prompts, für LLMs. Ziel ist es, durch die gezielte Auswahl von Aufgabenbeschreibungen, Kontextinformationen, Beispielen und Formatierungen das gewünschte Modellverhalten zu erzeugen und die Qualität der Ergebnisse zu verbessern (vgl. **schulhoff2025prompt**). Ein Prompt kann dazu aus mehreren Bestandteilen bestehen, etwa einer Anweisung, einer Rollenzuweisung, Zusatzinformationen, Beispielen sowie Vorgaben zu Stil und Ausgabeformat (vgl. **schulhoff2025prompt**). Enthält ein Prompt keine Beispiele, spricht man von Zero Shot Prompting. Werden dem Modell einige Beispiele mitgegeben, spricht man von Few Shot Prompting (vgl. Brown et al. 2020). Die Gestaltung des Prompts hat großen Einfluss auf das Ergebnis, da Sprachmodelle teilweise empfindlich auf Unterschiede in Formulierung und Struktur reagieren (vgl. **sclar2024quantifying**).

Seite ergänzen: Abschnitt zu den Bestandteilen eines Prompts

2.5 KI-Agenten

Ein autonomer Agent ist ein System, das Teil einer Umgebung ist, diese wahrnimmt und über einen längeren Zeitraum auf sie einwirkt, um eigene Ziele zu verfolgen (vgl. **wang2024survey**). Bei Agenten auf Basis von LLMs übernimmt ein LLM die zentrale Steuerung. Es wird um weitere Bausteine ergänzt, etwa eine im Prompt hinterlegte Rolle, ein Gedächtnis, eine Planungskomponente und die Möglichkeit, Aktionen auszuführen oder externe Werkzeuge zu nutzen (vgl. **wang2024survey**). Der Grad an Autonomie kann dabei stark variieren. **sapkota2025ai** unterscheiden einzelne KI Agenten, die klar abgegrenzte Aufgaben mithilfe von Werkzeugen ausführen, von sogenannter Agentic AI. Dort arbeiten mehrere spezialisierte Agenten zusammen, zerlegen Aufgaben selbstständig und greifen auf ein dauerhaftes Gedächtnis zurück (vgl. **sapkota2025ai**).

Seite ergänzen

Seite ergänzen: Einleitung

Microsoft Copilot Studio ist eine Plattform, mit der sich Agenten ohne Programmierkenntnisse erstellen lassen. Ein Agent wird dort über Anweisungen, sogenannte Instructions, sowie optionale Wissensquellen, Werkzeuge und Auslöser konfiguriert. Die Instructions sind auf 8000 Zeichen begrenzt (vgl. **microsoft2026quickstart**). Zusätzlich kann das zugrunde liegende Sprachmodell ausgewählt werden. Die Instructions legen Rolle, Aufgabe und Verhalten des Agenten fest und wirken damit wie ein dauerhaft hinterlegter Prompt. Die in Abschnitt **??** beschriebenen Techniken lassen sich daher direkt auf die Gestaltung eines

Seite ergänzen: Abschnitt 2.1

Seite ergänzen

Quelle: Microsoft Learn, Sei-

Agenten übertragen. Die in dieser Arbeit erstellten Agenten sind nach der Einordnung von **sapkota2025ai** einzelne KI Agenten, die eine klar abgegrenzte Aufgabe ausführen.

2.6 Einsatz von Künstlicher Intelligenz im Audit

KI wird im Audit bereits in der Prüfungspraxis eingesetzt (vgl. Kokina et al. 2025, S. 7 f.). Sie unterstützt Auditoren bei der Analyse großer strukturierter und unstrukturierter Datenmengen, indem sie Muster erkennt, Anomalien identifiziert und Vorhersagen trifft (vgl. Ivakhnenkov 2023, S. 56). Auditfirmen mit höheren KI-Investitionen erreichen eine bessere Prüfungsqualität und können gleichzeitig die Prüfungszeit verkürzen (vgl. Fedyk et al. 2022, S. 940 ff.). In der Stichprobenanalyse sinkt durch die Automatisierung der Dokumentenprüfung der manuelle Aufwand, sodass Auditoren Auffälligkeiten, Risiken oder Regelverstöße schneller und umfassender identifizieren können (vgl. Wassie und Lakatos 2024, S. 11–12). Zudem kann eine größere Menge an Stichprobenelementen geprüft werden. Da ein größerer Stichprobenumfang das Stichprobenrisiko verringert, steigt dadurch die Aussagekraft der Prüfungsergebnisse (vgl. International Auditing and Assurance Standards Board 2025, Tz. 7).

Gleichzeitig birgt der Einsatz von KI Risiken. Wurden die Modelle auf unzureichenden oder verzerrten Daten trainiert, können sie fehlerhafte oder voreingenommene Ergebnisse liefern (vgl. Munoko, Brown-Liburd und Vasarhelyi 2020) oder halluzinieren (vgl. **huang2025surveysurvey**), was zu falschen Prüfungsurteilen führen kann. Außerdem besteht die Gefahr des Automation Bias. Auditoren könnten die Ergebnisse der KI-Systeme unkritisch übernehmen und so Auffälligkeiten übersehen (vgl. Lyell und Coiera 2017, S. 425 f.).

Dopplung mit 3.2 prüfen: Kokina und Fedyk dort mit gleicher Aussage

Seite ergänzen

Seite ergänzen: Abschnitt 3.1, Hallucination from Data

2.7 Einsatz von Künstlicher Intelligenz im Audit

Der Einsatz von KI im Audit ist kein rein konzeptionelles Zukunftsszenario, sondern bereits in der Prüfungspraxis etabliert (vgl. Kokina et al. 2025, S. 7 f.). KI unterstützt Auditoren bei der Analyse großer strukturierter und unstrukturierter Datenmengen, indem sie Muster erkennt, Anomalien identifiziert und Vorhersagen trifft (vgl. Ivakhnenkov 2023, S. 56). Es zeigt sich, dass Auditfirmen mit höheren KI-Investitionen eine bessere Prüfungsqualität erreichen und gleichzeitig die Prüfungszeit verkürzen können (vgl. Fedyk et al. 2022, S.

940 ff.). Somit zeigen sich auch für das Internal Audit bei FCo Potenziale, die Effizienz und Qualität der Prüfungen durch den gezielten Einsatz von KI zu steigern.

Dopplung mit 3.2 prüfen: Kokina und Fedyk dort mit gleicher Aussage

2.7.1 Potenziale in der Stichprobenanalyse

Besonders in der Stichprobenanalyse kann der Einsatz von KI zu einer deutlichen Effizienzsteigerung führen. Durch die Automatisierung der Dokumentenprüfung sinkt der manuelle Analyseaufwand und Auditoren können potenzielle Auffälligkeiten, Risiken oder Regelverstöße schneller und umfassender identifizieren (vgl. Wassie und Lakatos 2024, S. 11–12). KI-gestützte Systeme können dabei große Mengen an Dokumenten analysieren, Muster erkennen und Anomalien hervorheben (vgl. Ivakhnenkov 2023, S. 56). Zudem kann KI dazu beitragen, die Konsistenz und Nachvollziehbarkeit der Prüfungsprozesse zu verbessern, indem sie standardisierte Bewertungsmaßstäbe anwendet und Ergebnisse transparent dokumentiert. Durch die Automatisierung kann außerdem eine deutlich größere Menge an Stichprobenelementen geprüft werden. Da ein größerer Stichprobenumfang das Stichprobenrisiko verringert, steigt dadurch die Aussagekraft der Prüfungsergebnisse (vgl. International Auditing and Assurance Standards Board 2025, Tz. 7).

Quelle

2.7.2 Risiken in der Stichprobenanalyse

Trotz der zahlreichen Vorteile birgt der Einsatz von KI in der Stichprobenanalyse auch Risiken. Ein zentrales Risiko besteht in der Abhängigkeit von den verwendeten KI-Modellen und deren Trainingsdaten. Wenn die Modelle auf unzureichenden oder verzerrten Daten trainiert wurden, können sie fehlerhafte oder voreingenommene Ergebnisse liefern (vgl. Munoko, Brown-Liburd und Vasarhelyi 2020) oder halluzinieren (vgl. **huang2025surveysurvey**), was zu falschen Prüfungsurteilen führen kann. Zudem besteht die Gefahr des Automation Bias. Auditoren können die Ergebnisse der KI-Systeme unkritisch übernehmen, ohne diese ausreichend zu hinterfragen, und so Auffälligkeiten oder Risiken übersehen (vgl. Lyell und Coiera 2017, S. 425 f.).

Seite ergänzen

Seite ergänzen: Abschnitt zu datenbedingten Ursachen

3 State of the Art

3.1 Aktuelle Durchführung von Stichprobenanalysen bei Freudenberg

Die Stichprobenanalyse im Internal Audit von Freudenberg folgt einer strukturierten Vorgehensweise, die in den internen Vorgaben des Corporate Audit festgelegt ist (vgl. Freudenberg 2026). Sie lässt sich in vier aufeinander aufbauende Schritte gliedern: die Definition und Klassifizierung der Grundgesamtheit, die Auswahl der Stichprobe, die Prüfung der ausgewählten Elemente sowie die abschließende Bewertung der Ergebnisse. Im Folgenden werden diese Schritte am Beispiel der Prüfung von Lieferantenrechnungen ohne Bestellnummer beschrieben. Das Vorgehen ist grundsätzlich auf weitere Prüffelder übertragbar.

Im ersten Schritt wird die Grundgesamtheit der relevanten Prüfobjekte festgelegt (vgl. Baumeister 2019, S. 12). Im Beispiel umfasst sie alle Rechnungen ohne Bestellnummer, die im Prüfungszeitraum erfasst wurden. Diese Rechnungen werden anschließend anhand definierter Kriterien klassifiziert, etwa nach Rechnungswert, Lieferant, manueller Buchung oder weiteren risikorelevanten Merkmalen (vgl. Freudenberg 2026).

Auf Grundlage dieser Klassifizierung erfolgt im zweiten Schritt die Auswahl der Stichprobe. Dazu wird ein Schwellenwert festgelegt. Alle Rechnungen, die diesen Schwellenwert überschreiten, werden verpflichtend in die Stichprobe aufgenommen und bilden die sogenannten Pflichtproben (vgl. Baumeister 2019, S. 19–20). Aus der verbleibenden Grundgesamtheit werden ergänzend weitere Rechnungen zufällig ausgewählt. Durch die Kombination aus risikobasierter Auswahl und zufälliger Stichprobenziehung werden sowohl potenziell kritische Transaktionen als auch Elemente aus der übrigen Grundgesamtheit in die Prüfung einbezogen (vgl. Freudenberg 2026).

Im dritten Schritt prüft der Auditor jedes ausgewählte Stichprobenelement im Detail. Hierfür sammelt er die relevanten Informationen und Nachweisdokumente, gleicht diese miteinander ab und dokumentiert die Ergebnisse (vgl. Baumeister 2019, S. 17; Freudenberg 2026).

Im vierten Schritt bewertet der Auditor die Ergebnisse hinsichtlich möglicher Auffälligkeiten, Abweichungen oder Regelverstöße. Festgestellte Unregelmäßigkeiten werden dokumentiert und als Audit Exceptions erfasst (vgl. Baumeister 2019, S. 48–49; Freudenberg 2026).

Die Beschreibung zeigt, dass insbesondere die Sammlung, der Abgleich und die Dokumentation der Nachweise überwiegend manuell erfolgen. Diese Tätigkeiten wiederholen sich für jedes Stichprobenelement und sind entsprechend zeitaufwendig (vgl. Baumeister 2019, S. 66–67).

3.2 Einsatz von KI im Auditbereich

Genau an den manuellen Punkten der Stichprobenanalyse setzt der Einsatz von KI an. In großen Prüfungsgesellschaften sind einfache KI-Anwendungen, etwa zur Extraktion von Informationen aus Dokumenten, bereits weit verbreitet, während komplexere Ansätze wie generative KI bislang überwiegend experimentell eingesetzt werden (vgl. Kokina et al. 2025, S. 2). Der Nutzen von KI im Audit lässt sich bereits belegen. Prüfungsgesellschaften, die stärker in KI investieren, erreichen eine höhere Prüfungsqualität. Zugleich sinken die Prüfungsgebühren und die Prüfungen können über die Zeit mit weniger Personal durchgeführt werden, was auf eine effizientere Durchführung hindeutet (vgl. Fedyk et al. 2022, S. 940 f.). Auch für das Internal Audit wird erwartet, dass KI die Arbeitsweise der Prüfungsfunktion grundlegend verändert und Prüfungen effizienter macht (vgl. Wassie und Lakatos 2024, S. 12). Bisher lag der Schwerpunkt vor allem auf der Analyse strukturierter Daten, beispielsweise der Erkennung von Anomalien in Finanzinformationen (vgl. Kokina et al. 2025, S. 2). Mit generativen LLMs lassen sich nun auch unstrukturierte Dokumente wie Rechnungen, Verträge oder E-Mails auswerten. Verfahren zur Verarbeitung natürlicher Sprache werden im Internal Audit bereits für die Analyse solcher Textdaten untersucht (vgl. Schumann und Marx Gómez 2021, S. 1). Damit rückt auch die dokumentenbasierte Prüfung einzelner Stichprobenelemente in den Fokus.

Wie der Einsatz generativer KI im Internal Audit eines Großkonzerns umgesetzt werden kann, zeigt das Beispiel Uniper. Die dortige Auditabteilung setzt ChatGPT in der Prüfungsvorbereitung, der Prüfungsdurchführung und der Berichterstattung ein. Erste Tests ergaben je nach Prozess geschätzte Effizienzgewinne von 50 % bis 80 %. Um die aufkommenden Risiken zu minimieren, die mit dem Einsatz von KI im Audit aufkommen, müssen

strikte Regeln festgelegt werden (vgl. Emett et al. 2025, S. 125 ff.). Solche Risiken betreffen beim Einsatz von KI im Audit unter anderem die Verantwortlichkeit für Ergebnisse, die Transparenz der Verfahren und den Datenschutz (vgl. Munoko, Brown-Liburd und Vasarhelyi 2020, S. 1). Der Nutzen generativer KI hängt somit von klaren Vorgaben und einer kontrollierten Nutzung ab.

Die fachliche Verantwortung für die Beurteilung der Ergebnisse verbleibt dabei weiterhin beim Auditor. Hierbei besteht jedoch das Risiko des Automation Bias. Nutzer vertrauen den Ergebnissen automatisierter Systeme zu stark und können dadurch Fehler leichter übersehen (vgl. Lyell und Coiera 2017, S. 425 f.). Die von KI-Systemen erzeugten Ergebnisse sind daher als Entscheidungshilfe zu verstehen und müssen durch den Auditor eigenständig überprüft werden.

3.3 Verfügbare KI-Lösungen für den Auditbereich

Für den Einsatz von KI im Auditbereich stehen verschiedene Arten von Lösungen zur Verfügung. Diese lassen sich in drei Gruppen einteilen: kommerzielle LLMs, die von Anbietern wie Anthropic, OpenAI oder Google bereitgestellt werden, Open-Source-Modelle, die auf eigener Infrastruktur betrieben werden können, sowie spezialisierte Softwarelösungen, die gezielt für Prüfungsprozesse entwickelt wurden. Im Folgenden werden diese drei Gruppen vorgestellt und hinsichtlich Leistungsfähigkeit, Datenschutz, Kosten und Implementierungsaufwand eingeordnet.

3.3.1 Kommerzielle Lösungen

Generative KI und speziell LLMs werden in der Forschung zunehmend als neue Allzwecktechnologie eingeordnet, die in zahlreichen Branchen und Tätigkeitsfeldern eingesetzt werden kann (vgl. Calvino, Haerle und S. Liu 2025, S. 44). Damit kommen LLMs grundsätzlich auch für den Einsatz im Auditbereich in Frage. Generative KI-Modelle lernen Muster und Zusammenhänge aus großen, teilweise unstrukturierten Datenmengen und können auf dieser Grundlage Informationen verarbeiten, aufbereiten und nutzbar machen (vgl. Feuerriegel et al. 2024, S. 112). Diese Fähigkeiten sind insbesondere für die Analyse und Bewertung von Stichproben im Auditbereich relevant. Jedoch ist zu berücksichtigen, dass die Modelle auch halluzinieren können, also falsche oder nicht belegbare Informationen generieren (vgl.

Ji et al. 2023, S. 2; Huang et al. 2025, S. 2). Daher ist eine abschließende Bewertung der Ergebnisse durch den Auditor weiterhin erforderlich.

Die einzelnen Modelle werden kontinuierlich weiterentwickelt, wobei ihre Leistungsfähigkeit und Genauigkeit stetig zunimmt (vgl. Artificial Analysis 2026). Zum Stand der Arbeit (Oktober 2026) führen Modelle von Anthropic, OpenAI und Google die Benchmark-Rankings wie den Artificial Analysis Intelligence Index an (vgl. Artificial Analysis 2026). Der Artificial Analysis Intelligence Index kann jedoch nur als erster Referenzwert herangezogen werden (vgl. DeepLearning.AI o. D.). Für den konkreten Anwendungsfall der Stichprobenanalyse im Audit sind darüber hinaus weitere, anwendungsspezifische Faktoren zu berücksichtigen.

Kommerzielle Modelle werden in der Regel als Cloud-Dienst bereitgestellt. Dadurch lassen sie sich mit geringem Implementierungsaufwand nutzen, da weder eigene Hardware noch der Betrieb der Modelle im Unternehmen erforderlich ist. Die Verarbeitung der Daten erfolgt jedoch auf der Infrastruktur des Anbieters. Für den Einsatz mit vertraulichen Prüfungsdaten ist daher ein vertraglich abgesicherter Zugang notwendig, der die Einhaltung von Datenschutz- und Compliance-Anforderungen gewährleistet. Bei Freudenberg besteht ein solcher Zugang über den Microsoft Copilot, bei dem die Daten innerhalb der Microsoft-365-Umgebung verarbeitet und nicht für das Training der zugrunde liegenden Modelle verwendet werden (vgl. Microsoft 2026a). Die Kosten kommerzieller Lösungen entstehen über Lizenzen oder eine nutzungsabhängige Abrechnung. Bei Freudenberg sind diese im Rahmen der bestehenden Copilot-Lizenz bereits abgedeckt, sodass für den betrachteten Anwendungsfall keine zusätzlichen Kosten anfallen (vgl. Freudenberg & Co. KG 2026).

3.3.2 Open-Source-Lösungen

Neben kommerziellen Modellen existieren Open-Source-Modelle. Als Open-Source-Modelle werden LLMs verstanden, deren Modellgewichte frei verfügbar sind (vgl. Kapoor et al. 2024, S. 2). Bekannte Beispiele sind Llama von Meta, Qwen von Alibaba, Kimi von Moonshot AI oder DeepSeek von DeepSeek-AI(vgl. Artificial Analysis 2026). Open-Source-Modelle stellen grundsätzlich eine Alternative zu kommerziellen Lösungen dar. Durch den Betrieb auf unternehmensinterner Infrastruktur verlassen die Daten das Unternehmen nicht, wodurch Datenschutz- und Compliance-Anforderungen gezielt berücksichtigt werden können. Zudem fallen keine nutzungsabhängigen Lizenzkosten an (vgl. Kapoor et al. 2024, S. 3, 9).

noch besser erklären

so richtig zitiert oder zusammenfassen?

Dem steht ein erheblicher Infrastruktur- und Implementierungsaufwand gegenüber. Für den Betrieb leistungsfähiger Modelle wird eigene Hardware mit ausreichender Rechenleistung benötigt. Hinzu kommen die Wartung, die Aktualisierung der Modelle und das notwendige Fachwissen im Unternehmen (vgl. Kapoor et al. 2024, S. 3). Außerdem liegen in den aktuellen Benchmark-Rankings die kommerziellen Modelle vor Open-Source-Lösungen (vgl. Artificial Analysis 2026).

3.3.3 Spezialisierte KI-gestützte Audit-Lösungen

Abseits von generativen LLMs existieren spezialisierte Softwarelösungen, die KI gezielt für Prüfungsprozesse einsetzen. Ein bekanntes Beispiel dafür ist DataSnipper. Die Software erzielt auf Bewertungsplattformen gute Bewertungen (vgl. Gartner Peer Insights 2026; G2 2026) und wird laut Hersteller unter anderem von den Big 4 eingesetzt, wodurch sie eine hohe Marktrelevanz im Prüfungsumfeld besitzt (vgl. DataSnipper 2026b). DataSnipper ist als Erweiterung für Microsoft Excel umgesetzt und wurde speziell für die Anforderungen von Prüfungs- und Finanzprozessen entwickelt (vgl. YourAIFinder 2026). Zu den zentralen Funktionen gehören die automatisierte Extraktion von Daten aus Dokumenten, der Abgleich dieser Daten mit Arbeitspapieren sowie die Erstellung nachvollziehbarer Audit Trails (vgl. G2 2026). DataSnipper verfolgt einen Human-in-the-Loop-Ansatz. Die KI unterstützt die Auditoren, die finale Bewertung verbleibt dabei weiterhin beim Auditor (vgl. DataSnipper 2026a).

Spezialisierte Lösungen sind auf typische Prüfungsschritte zugeschnitten und stellen vorkonfigurierte Funktionen für Auditprozesse bereit, wodurch sie ohne eigene Prompt-Entwicklung eingesetzt werden können (vgl. DataSnipper 2026a). Im Gegensatz zu generischen LLMs beschränkt sich ihre Nutzung jedoch auf die vom Hersteller bereitgestellten Funktionen. Darüber hinaus ist der Einsatz in der Regel an eine separate Softwarelizenz gebunden.

3.4 Chatnutzung und KI-Agenten

Wie in Abschnitt 3.1 beschrieben, besteht die Prüfung eines Stichprobenelements aus mehreren aufeinander aufbauenden Schritten, die für jedes Stichprobenelement erneut durchgeführt werden. Für die Unterstützung dieser Schritte durch ein LLM kommen grundsätzlich

zwei Nutzungsformen in Frage: die Nutzung über ein Chatfenster und der Einsatz von KI-Agenten.

Grundsätzlich lassen sich die Arbeitsschritte mithilfe eines einzelnen, ausführlichen Prompts in einem Chat mit einem LLM beschreiben. Die Nutzung eines Chatfensters ist jedoch primär auf die Bearbeitung einzelner Benutzereingaben ausgelegt. Sprachmodelle reagieren dabei teilweise empfindlich auf Unterschiede in der Formulierung und Struktur von Prompts (vgl. Sclar et al. 2024, S. 16). Werden viele Dokumente nacheinander im selben Chat verarbeitet, entsteht zudem ein langer Kontext. Informationen in der Mitte solcher Kontexte werden von Sprachmodellen schlechter berücksichtigt (vgl. N. F. Liu et al. 2024, S. 157), während irrelevante Informationen die Ergebnisqualität zusätzlich beeinträchtigen können (vgl. Shi et al. 2023, S. 8). Für Auditprüfungen, deren Ergebnisse nachvollziehbar und zwischen verschiedenen Stichprobenelementen vergleichbar sein müssen, stellt dies eine Herausforderung dar.

KI-Agenten gehen über die reine Chatnutzung eines LLM hinaus. Sie sind für die automatisierte Ausführung konkreter Aufgaben konzipiert und erweitern generative KI durch die Integration von Werkzeugen, definierten Anweisungen und strukturierten Prozessabläufen (vgl. Sapkota, Roumeliotis und Karkee 2026, S. 1). Ein Agent wird dabei, beispielsweise im Microsoft Copilot Studio, einmalig mit festen Instruktionen, Wissensquellen und Aktionen konfiguriert (vgl. Microsoft 2026b). Dadurch wird jede Eingabe nach demselben Schema verarbeitet, wodurch der Ablauf standardisiert, dokumentierbar und wiederverwendbar wird. Identische Ergebnisse bei wiederholter Verarbeitung sind damit jedoch nicht garantiert. Sprachmodelle erzeugen ihre Ausgaben auf Basis von Wahrscheinlichkeiten und können deshalb auch bei gleicher Eingabe unterschiedliche Antworten liefern (vgl. Huang et al. 2025, S. 5, 12). Die Konsistenz der Ergebnisse muss daher gesondert überprüft werden.

3.5 Einordnung des KI-Einsatzes bei Freudenberg

Die Freudenberg Gruppe nutzt aktuell gruppenweit die KI-Lösung von Microsoft, den Microsoft Copilot. Hierbei werden für alle Nutzer die Modelle GPT-5.6, GPT-6.1 sowie Claude Sonnet 5, Claude Sonnet 5.5 und Claude Opus 5.5 zur Verfügung gestellt (vgl. Freudenberg & Co. KG 2026). Der Copilot kann dabei unter Berücksichtigung der Datenschutz- und Compliance-Richtlinien auf alle internen Dokumente zugreifen, für die der jeweilige

Nutzer berechtigt ist. Zusätzlich bietet Microsoft die Möglichkeit, über das Copilot Studio eigene Agenten zu bauen. Hierbei können die Agenten auf interne Dokumente zugreifen und Aufgaben automatisiert ausführen. Für die Agenten sind aktuell die Modelle GPT-4.1, GPT-5, GPT-5.3, GPT-5.5 sowie Claude Sonnet 4.6, Claude Opus 4.6, Claude Opus 4.7 und Claude Opus 4.8 hinterlegt (vgl. Freudenberg & Co. KG 2026).

Bei Freudenberg stehen damit beide in Abschnitt 3.4 beschriebenen Nutzungsformen zur Verfügung. Die verfügbaren Modelle unterscheiden sich jedoch zwischen den beiden Varianten. Im Chatfenster des Microsoft Copilot sind teilweise neuere Modelle verfügbar als im Copilot Studio. Offen bleibt, welches der verfügbaren Modelle für die Stichprobenanalyse von Rechnungen im Auditkontext die besten Ergebnisse liefert.

4 Evaluationsdesign

4.1 Forschungsdesign

Zur Beantwortung der Forschungsfrage, wie sich verschiedene LLMs hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Audit unterscheiden wird in dieser Arbeit eine vergleichende Evaluation der Modelle durchgeführt. Dazu werden die ausgewählten Modelle auf 100 verschiedene Prüfungsdokumente angewendet. Die Modelle analysieren sowohl Rechnungen als auch die Bestätigungen zur Freigabe der Rechnungen, markieren mögliche Auffälligkeiten und begründen ihre Befunde. Die Ergebnisse werden mithilfe einer Nutzwertanalyse ausgewertet. Damit Unterschiede in den Ergebnissen tatsächlich auf die Modelle zurückzuführen sind, werden alle übrigen Einflussfaktoren konstant gehalten. Deshalb wird für jedes Modell im Copilot Studio ein eigener Agent mit identischen Instruktionen angelegt. Alle Modelle werden auf denselben Rechnungen und Freigaben getestet. Zur Messung der Konsistenz wird zusätzlich eine Teilmenge von 30 Rechnungen mehrfach ausgewertet. Somit gelten für alle Modelle identischen Bedingungen.

Das vorliegende Kapitel beschreibt den Aufbau der Evaluation. Dazu gehören die Wahl der Untersuchungsumgebung, die Auswahl der Modelle, die Testdaten, der Prompt sowie die Kriterien und Regeln, nach denen die Ergebnisse bewertet werden.

4.2 Wahl der Untersuchungsumgebung

Die einzelnen Modelle können in der Microsoft Umgebung sowohl über das Chatfenster des Microsoft Copilot als auch über eigene Agenten im Copilot Studio genutzt werden. Für die Stichprobenanalyse von Rechnungen im Auditkontext wird in dieser Arbeit der Einsatz eigener Agenten im Copilot Studio anstelle der reinen Chatnutzung gewählt.

Die Entscheidung für den Agentenansatz anstelle des Chatfensters stützt sich auf mehrere Gründe. Im Chatfenster müssten die Prüfanweisungen und die relevanten Dokumente für jeden Prüffall erneut eingegeben werden. Dabei können Abweichungen in Formulierung, Reihenfolge und Umfang der Anweisungen entstehen, die das Ergebnis beeinflussen, ohne

mit der eigentlichen Leistung des Modells zusammenzuhängen. Im Agenten sind Instruktionen und Wissensquellen dagegen fest hinterlegt. Dadurch wird jedes Stichprobenelement nach demselben Prüfschema und unter denselben Ausgangsbedingungen verarbeitet, unabhängig davon, wer die Prüfung anstößt.

Ein weiterer Grund ist der Aufwand. Stichproben im Internal Audit umfassen in der Regel eine größere Anzahl an Elementen (vgl. Freudenberg 2026). Der Agent greift direkt auf die für die Prüfung relevanten Dokumente zu, extrahiert die benötigten Informationen und führt die definierten Prüfschritte automatisiert durch. Das wiederholte Hochladen von Dokumenten und Eingeben von Anweisungen entfällt. Dieses Vorgehen entspricht dem von Schreyer et al. (2024, S. 1) beschriebenen auto-piloted Auditing.

nochmal gucken bzgl. auto pilot auditing

Darüber hinaus verbessert der Agentenansatz die Nachvollziehbarkeit. Da die Konfiguration des Agenten festgehalten ist, lässt sich jederzeit einfach belegen, mit welchen Anweisungen und auf welcher Datengrundlage ein Ergebnis entstanden ist. Im Internal Audit, in dem Prüfungsergebnisse dokumentiert und begründet werden müssen, ist das eine wichtige Voraussetzung für den praktischen Einsatz.

Für den vorliegenden Anwendungsfall ist daher entscheidend, wie leistungsfähig ein Modell hinter einem Agenten im Copilot Studio ist. Die Modellleistung bleibt der zentrale Untersuchungsgegenstand, wird jedoch unter den Bedingungen betrachtet, unter denen ein Einsatz im Internal Audit realistisch ist. Hinzu kommt, dass im Copilot Studio nur das Modell hinter dem Agenten ausgetauscht wird, während Anweisungen, Wissensquellen und Einstellungen unverändert bleiben. Alle übrigen Einflussfaktoren werden somit konstant gehalten, sodass sich Unterschiede in den Ergebnissen auf das jeweilige Modell zurückführen lassen. Für einen aussagekräftigen Modellvergleich ist diese Konstanz eine grundlegende Voraussetzung. Als Einschränkung ist zu berücksichtigen, dass neuere Modelle, die bislang nur im Chatfenster und noch nicht im Copilot Studio verfügbar sind, unter diesen Bedingungen nicht untersucht werden können.

4.3 Auswahl der zu untersuchenden Modelle

Die Auswahl der zu untersuchenden Modelle basiert auf der aktuellen Nutzung von KI-Lösungen in der Freudenberg Gruppe. Die Freudenberg Gruppe nutzt einheitlich die Premium Version des Microsoft Copilot und die dort ausgerollten Modelle von OpenAI und Anthropic. Hierbei werden sowohl die internen Datenschutz- und Compliance-Richtlinien

Freudenberg einheitlich benennen: Freudenberg Gruppe vs. FCo, Internal Audit vs. Cor-

als auch EU-Richtlinien eingehalten . Ein weiterer Vorteil ist, dass durch die Nutzung der Modelle über den Microsoft Copilot keine zusätlichen Kosten anfallen . Zudem ist der Copilot bereits im Internal Audit ausgerollt, weshalb es keiner weiteren Schulungen und Gewöhnungszeiten für Mitarbeiter bedarf.

Quelle

besser formulieren im bezug zu oben, dass wir den ja schon haben

Open-Source-Modelle und spezialisierte Softwarelösungen werden im Rahmen dieser Arbeit nicht untersucht. Der Betrieb von Open-Source-Modellen wäre mit erheblichem Infrastruktur- und Implementierungsaufwand verbunden. Für den Einsatz von spezialisierten Softwarelösungen wie DataSnipper müsste eine zusätzliche Lizenz erworben werden, die weitere Kosten verursachen würde.

Der Microsoft Copilot ermöglicht es den Auditoren, auf verschiedene Modelle von Anthropic und OpenAI zuzugreifen. Da die Evaluation über eigene Agenten im Copilot Studio durchgeführt wird, werden im Rahmen dieser Arbeit alle Modelle berücksichtigt, die zum Stand der Arbeit (22.10.2026) im Copilot Studio für die Erstellung von Agenten zur Verfügung stehen. Dies sind GPT-4.1, GPT-5, GPT-5.3 und GPT-5.5 sowie Claude Sonnet 4.6, Claude Opus 4.6, Claude Opus 4.7 und Claude Opus 4.8.

kapitel 4.2 und 4.3 tauschen?

4.4 Entwicklung der Testdatensätze

Für die Evaluation der betrachteten KI-Modelle ist eine Datenbasis erforderlich, die den realen Prüfungskontext möglichst genau abbildet. Die Verwendung originaler Rechnungsbelege aus dem Internal Audit der Freudenberg Gruppe ist ausgeschlossen, da diese personenbezogene sowie geschäftskritische Informationen enthalten und daher im Rahmen dieser Evaluierung nicht herangezogen werden dürfen. Um dennoch eine hinreichend umfangreiche und belastbare Testbasis zu schaffen, werden die Testdatensätze mithilfe generativer KI erzeugt.

Die künstlich erstellten Rechnungen orientieren sich in Struktur, Umfang und Informationsgehalt an realen Rechnungen und enthalten dieselben prüfungsrelevanten Kriterien wie die im Audit untersuchten Dokumente. Um einen realitätsnahen Anwendungsfall nachzubilden, umfasst der Datensatz 80 digital erzeugte Rechnungen im PDF-Format als auch 20 eingescannte Rechnungen. Nach der Generierung der Rechnungen werden gezielt Fehler in die Dokumente eingebracht. Dieser Ansatz orientiert sich an Benchmark-Studien zur

Evaluation von LLMs im Finanzkontext, bei denen vorhandene Finanzdokumente systematisch durch künstlich eingefügte Fehler verändert werden, um die Fähigkeit der Modelle zur Identifikation von Inkonsistenzen zu untersuchen (vgl. Panda 2026, S. 1) .

Neben den Rechnungen werden auch Screenshots von Mails zur Freigabe der einzelnen Rechnungen erstellt. Auch hier werden gezielt einzelne Fehler in die Datensätze eingebaut. Der Testdatensatz umfasst somit sowohl fehlerhafte als auch vollständig korrekte Rechnungen und Freigaben.

Jeder Fehler in den Testdatensätzen gilt als eine sogenannte Audit Exception. Eine Audit Exception kann die Rechnung selbst betreffen, etwa eine falsche Rechnungsnummer, oder den zugehörigen Freigabeprozess, etwa eine Genehmigung durch eine nicht berechtigte Person. Jede fehlerhafte Rechnung im Testdatensatz enthält genau eine eingebaute Exception. Dadurch ist für jede Rechnung eindeutig festgelegt, ob und welcher Fehler vorliegt. Diese Zuordnung bildet die Grundlage, mit der die Ergebnisse der Modelle verglichen werden.

Für die vorliegende Arbeit wird eine Fehlerquote von 24 % festgelegt, was bei einem Datensatz von 100 Rechnungen insgesamt 24 fehlerhaften Belegen entspricht. Nach internen Angaben liegt die Quote für fehlerhafte oder unvollständige Rechnungen bei ca. 24 % (vgl. Goth 2026). Durch eine Fehlerquote von 24 % ist die Anzahl fehlerhafter Rechnungen ausreichend groß, um die Erkennungsleistung der Modelle repräsentativ zu untersuchen. Gleichzeitig bildet die Mehrheit an korrekten Rechnungen den realen Prüfungskontext realitätsnah ab.

Bei der Fehlererzeugung wird bewusst auf eine breite Streuung der Fehler geachtet. Dazu wird jeder eingebaute Fehler einer von sechs Fehlerkategorien zugeordnet. Die größte Fehlerkategorie bilden typische Betrugsmuster mit 6 Fehlern. Sie zeigen den Nutzen eines solchen Systems im Audit bei kreativen Betrugsmaschen auf. Bei 5 Fehlern liegt das Problem im Freigabeprozess, wenn eine Rechnung durch eine nicht berechtigte Person freigegeben wird oder die Freigabe gefälscht wird. Weitere 4 Fehler betreffen den Abgleich mit den Stammdaten, bei denen die Angaben auf der Rechnung von den hinterlegten Lieferantendaten abweichen, zum Beispiel bei Anschrift oder Bankverbindung. Bei 4 Fehlern handelt es sich um einfache Rechen- bzw. Zahlenfehler. Weitere 3 Fehler betreffen ein falsches Rechnungsdatum oder die Zuordnung zur falschen Periode, sodass der Aufwand im falschen Zeitraum gebucht wird. Die letzten 2 Fehler betreffen eine fehlende Rechnungsnummer. Tabelle 4.1 fasst die Fehlerkategorien zusammen.

Stefanie Bell: Finanzkontext hier eine repräsentative Quelle? -> Ich finde schon, da das auch Teil des Audits sein könnte

fehler eingebaut ja aber auch freigabematrix berücksichtigen

wirkt bissl abgehakt

Schreib ich hier 6 oder sechs generell überall

es muss

Anzahl	Fehlerkategorie
6	Betrugsmuster
5	Freigabefehler
4	Stammdatenabweichungen
4	Rechenfehler
3	Datums- und Periodenfehler
2	Fehlende Rechnungsnummer
24	**Gesamt**

Tabelle 4.1: Verteilung der eingebauten Fehler auf die Fehlerkategorien

Da jede Fehlerkategorie nur zwischen 2 und 6 Fehler umfasst, sind Aussagen zur Erkennungsleistung einzelner Fehlerkategorien nur eingeschränkt belastbar. Die Auswertung nach Fehlerkategorien dient daher als ergänzende Betrachtung. Der Vergleich der Modelle erfolgt über die Gesamtheit aller Rechnungen.

4.5 Entwicklung eines geeigneten Prompts

Die Qualität der von einem LLM erzeugten Ausgabe hängt maßgeblich von der Gestaltung des Prompts ab (vgl. Sclar et al. 2024) . Prompt Engineering bezeichnet die systematische Gestaltung, Strukturierung und Optimierung von Eingabeanweisungen (Prompts) für LLMs . Ziel ist es, durch die gezielte Auswahl von Aufgabenbeschreibungen, Kontextinformationen, Beispielen und Formatierungen das gewünschte Modellverhalten zu erzeugen und die Qualität der Ergebnisse zu verbessern (vgl. Schulhoff et al. 2025, S. 1). Der Prompt für diese Arbeit wird deshalb auf Basis etablierter Techniken des Prompt Engineering entwickelt. Um die Vergleichbarkeit der untersuchten Modelle sicherzustellen, wird auf eine modellspezifische Optimierung verzichtet. Alle Modelle erhalten denselben Prompt. Dieser enthält klare Anweisungen zur Analyse der Rechnungen, zur Identifikation möglicher Auffälligkeiten und zur nachvollziehbaren Begründung der Ergebnisse.

hier nur struktur, nicht inhaltlich

Quelle

Die inhaltlichen Anforderungen an den Prompt ergeben sich aus dem bestehenden Vorgehen der Stichprobenanalyse bei Freudenberg. Der Prompt bildet die Prüfschritte ab, die ein Prüfer bei einer Eingangsrechnung durchführt. Dazu gehören die Extraktion der Rechnungsdaten, der Abgleich mit der Referenztabelle, die rechnerische und formale Prüfung sowie die Suche nach Betrugsindikatoren. Abschließend werden der Freigabeprozess und die Berechtigung des Genehmigers geprüft. Das Ergebnis dient als Grundlage für die anschließende menschliche Prüfung. Das Modell unterstützt den Prüfer also, übernimmt aber

nicht den vollständigen Prüfungsprozess und gibt lediglich eine Empfehlung für das weitere Vorgehen ab.

Der Prompt wird als Instruktionen dauerhaft im jeweiligen Agenten hinterlegt. Die Instruktionen sind in jedem Agenten identisch und legen Rolle, Ziel, Quellen, Regeln, Prüfschritte und Ausgabeformat fest. Die vollständigen Instruktionen befinden sich in Anhang A.1.

Bei der Gestaltung des Prompts werden mehrere etablierte Techniken angewendet. Zu Beginn erhält das Modell ein klar definiertes Ziel und eine eindeutige Rolle als Prüfagent des internen Audits. Die Rolle gibt dem Modell den fachlichen Rahmen der Aufgabe vor (vgl. Microsoft 2026b).

Für jede Eingabe ist festgelegt, welche Funktion sie erfüllt. Die Rechnung liefert die Istwerte, die Referenztabelle die Sollwerte und die Freigabematrix die Berechtigungen. Die Freigabeunterlagen gelten ausschließlich als Evidenz und werden nicht automatisch als gültig angenommen. Durch diese Quellenhierarchie muss das Modell bei widersprüchlichen Angaben nicht selbst entscheiden, welcher Quelle es folgt. Die einzelnen Wissensquellen werden in den Instruktionen ausdrücklich benannt und erklärt (vgl. Microsoft 2026b).

Die Aufgabe ist in elf Prüfschritte mit fester Reihenfolge zerlegt. Die Aufteilung in klar getrennte Einheiten verringert Mehrdeutigkeiten und verhindert, dass das Modell Aufgaben zusammenführt oder neu interpretiert (vgl. Microsoft 2026b). Zusätzlich wird die Prüfung dadurch nachvollziehbar, da jeder Schritt im Ergebnis sichtbar ist.

LLMs neigen dazu, fehlende Informationen durch plausibel klingende, aber falsche Inhalte zu ersetzen (vgl. Huang et al. 2025, S. 1). Der Prompt verbietet deshalb Annahmen und Ergänzungen. Fehlt eine Information oder kann sie nicht geprüft werden, muss das Modell feste Statuswerte wie „nicht vorhanden“, „nicht lesbar“ oder „nicht prüfbar“ verwenden. Verdachtsmomente dürfen nur als „Hinweis auf“ formuliert werden, da die Feststellung eines Betrugs dem Prüfer vorbehalten bleibt (vgl. Anthropic 2026).

Die Ausgabe folgt einer festen Struktur mit vorgegebenen Feldern und Statuswerten. Ohne vorgegebenes Ausgabeformat kann es zu inkonsistentem Verhalten zwischen verschiedenen Modellen kommen (vgl. Microsoft 2026b). Das feste Format erleichtert die menschliche Prüfung und macht die Ergebnisse der Modelle direkt vergleichbar. Die Gesamtbewertung der Freigabe, die Auffälligkeiten mit Risikostufe sowie die Angabe zur menschlichen Nachprüfung bilden die Grundlage für die Auswertung.

Neben den inhaltlichen Anforderungen unterliegt der Prompt technischen und methodischen Rahmenbedingungen. Die Instruktionen eines Agenten in Copilot Studio sind auf 8000 Zeichen begrenzt (vgl. Microsoft 2026b). Eine ausführliche Fassung mit Definitionen, Beispielen und Beschreibungen aller Statuswerte umfasste rund 30.000 Zeichen und lag damit deutlich über diesem Limit. Zudem berücksichtigen LLMs Informationen in langen Kontexten weniger zuverlässig (vgl. N. F. Liu et al. 2024, S. 157). Irrelevante Informationen im Kontext können die Leistung der Modelle zusätzlich verschlechtern (vgl. Shi et al. 2023, S. 9). Der Prompt soll dem Modell deshalb nur die für die Aufgabe notwendigen Informationen bereitstellen.

muss ich die älteren prompts auch mit rein nehmen? Ich will eigentlich nicht

Daraus ergeben sich folgende Anforderungen an den Prompt. Die Regeln werden stichpunktartig formuliert und auf ausführliche Erklärungen wird verzichtet. Alle elf Prüfschritte müssen dabei vollständig enthalten bleiben, damit der Prüfprozess unverändert abgebildet wird. Die Regeln dürfen sich untereinander nicht widersprechen, da das Modell sonst selbst entscheiden müsste, welcher Anweisung es folgt.

Der Prompt wird vor der Evaluation in mehreren Durchgängen erprobt und angepasst. Dazu werden fünf zusätzliche Validierungsrechnungen mit den zugehörigen Freigaben erstellt. Drei dieser Rechnungen werden bewusst mit Fehlern versehen: einer fehlerhaften Freigabe, einer fehlenden Rechnungsnummer und einem Rechenfehler. Die beiden übrigen Rechnungen sind vollständig korrekt. Die Validierung erfolgt mit Claude Opus 4.8 und GPT-5.5. Da je ein Modell von Anthropic und OpenAI verwendet wird, ist der Prompt nicht auf einen einzelnen Anbieter zugeschnitten. Nach jedem Durchgang wird geprüft, ob die Agenten die eingebauten Fehler erkennen und die korrekten Rechnungen nicht beanstanden. Weicht das Ergebnis davon ab, wird der Prompt entsprechend angepasst. Der Prompt gilt als geeignet, sobald er bei allen fünf Validierungsrechnungen in drei aufeinanderfolgenden Durchläufen zu einem korrekten Ergebnis führt.

Die Validierungsrechnungen sind nicht Teil des Testdatensatzes. Dadurch wird verhindert, dass der Prompt gezielt auf die Rechnungen der Evaluation zugeschnitten wird und die Ergebnisse zu positiv ausfallen. Der finale Prompt wird vor Beginn der Evaluation festgelegt und für alle Modelle unverändert eingesetzt.

4.6 Nutzwertanalyse

Die Eignung der untersuchten LLMs für den definierten Anwendungsfall im Audit lässt sich nicht anhand eines einzelnen Kriteriums bestimmen. Um ein ganzheitliches Ergebnis zu erhalten, müssen mit der Erkennungsleistung und der Konsistenz mehrere Kriterien gleichzeitig betrachtet werden, wodurch die Bewertung ein mehrdimensionales Entscheidungsproblem darstellt (vgl. Kozłowska 2022, S. 116 f.).

Zur strukturierten Berücksichtigung dieser Kriterien wird in dieser Arbeit eine Nutzwertanalyse durchgeführt. Sie ist eine bewährte Methode zur Lösung mehrdimensionaler Entscheidungsprobleme und ermöglicht es, verschiedene Bewertungskriterien zu gewichten und zu einem Gesamtnutzwert zusammenzufassen (vgl. Kühnapfel 2021, S. 79 f.). Dadurch lassen sich die untersuchten Modelle systematisch und nachvollziehbar hinsichtlich ihrer Eignung vergleichen. Da die Gewichtung der Kriterien auf einer subjektiven Einschätzung beruht, wird diese in 4.8 dargelegt und begründet.

ist das kapitel an der richitgen Stelle?

4.7 Entwicklung einer Bewertungsmatrix

Um die Evaluation basierend auf einer Nutzwertanalyse durchzuführen, muss eine Bewertungsmatrix mit mehreren Kriterien entwickelt werden (vgl. Liang et al. 2023, S. 3). Bei der Entwicklung der Bewertungsmatrix werden die Anforderungen für den Anwendungsfall der Corporate Audit Abteilung der FCo berücksichtigt. Die Bewertungsmatrix umfasst zwei Hauptkriterien, die für die Eignung der Modelle für den definierten Use Case von zentraler Bedeutung sind. Diese Kriterien sind die Erkennungsleistung der Modelle und die Konsistenz der Ergebnisse. Aus der gewichteten Zusammenführung dieser Kriterien ergibt sich eine Rangfolge der untersuchten Modelle.

haben wir das mit den mehereren kriterien nicht gerade schon gesagt?

Eine qualitative Bewertung der Begründungen der Modelle wird in dieser Arbeit nicht vorgenommen. Der Prompt gibt den Modellen ein festes Antwortformat vor (siehe Anhang A.1). Dadurch folgen die Begründungen aller Modelle derselben Struktur und unterscheiden sich in Aufbau und Formulierung nur geringfügig. Eine Bewertung der Begründungsqualität würde daher kaum Unterschiede zwischen den Modellen sichtbar machen und wenig zur Rangfolge beitragen. Ob ein Modell den richtigen Fehler benennt, fließt zudem bereits in die Erkennungsleistung ein, da ein True Positive nur dann vorliegt, wenn der eingebaute Fehler zutreffend benannt wird.

wissenschaf begründen, warum diese Kriterien

Als zentrales quantitatives Kriterium wird die Erkennungsleistung der Modelle herangezogen. Die Bewertung erfolgt auf Ebene der einzelnen Rechnung. Eine Rechnung gilt als vom Modell beanstandet, wenn das Modell die vorgesehene Audit Exception erkennt. Maßgeblich ist dabei ausschließlich das Feld „Audit Exception“ am Ende der Ausgabe des Modells (siehe Anhang A.1). Das Modell meldet eine Audit Exception, sobald mindestens eine Feststellung in den Unterlagen belegt ist. Dazu zählen Abweichungen von der Referenztabelle, rechnerische Fehler sowie fehlende Pflichtangaben wie die Rechnungsnummer. Ebenso führen ein Leistungsdatum nach dem Rechnungsdatum, eine falsche Periode oder eine fehlerhafte Freigabe zu einer Audit Exception. Eine Freigabe gilt als fehlerhaft, wenn der Genehmiger nicht berechtigt ist, das Limit überschritten wird oder die Freigabe erst nach der Zahlung erteilt wurde. Auch belegte Betrugsindikatoren und Red Flags lösen eine Audit Exception aus, etwa eine Absenderdomain, die dem Namen des Lieferanten nur ähnelt, oder eine abweichende IBAN. Ausgenommen sind schwache Signale wie runde Beträge, eine generische Leistungsbeschreibung oder eine fehlende Bestellnummer. Das Modell stellt dabei selbst keinen Betrug fest. Es meldet das belegte Merkmal als Hinweis auf Betrug, die Bewertung eines möglichen Betrugs bleibt dem Prüfer vorbehalten. Die Risikostufe einer Auffälligkeit hat keinen Einfluss auf diese Entscheidung. Unsicherheiten oder fehlende Unterlagen reichen dagegen allein nicht für eine Audit Exception aus.

Unabhängig davon bewertet das Modell, ob eine menschliche Nachprüfung erforderlich ist. Diese Empfehlung spricht das Modell bei Unsicherheit aus, etwa bei fehlenden, unleserlichen oder widersprüchlichen Unterlagen sowie bei einer nicht eindeutigen Zuordnung oder Berechtigung. Eine menschliche Nachprüfung kann daher auch ohne Audit Exception empfohlen werden. Für die Einordnung als beanstandet wird sie nicht herangezogen, da sie keine nachgewiesene Abweichung voraussetzt. Die Erkennungsleistung wird somit ausschließlich an den Feststellungen gemessen, die das Modell anhand der Unterlagen belegen kann.

Durch den Vergleich mit den im Testdatensatz festgelegten Fehlern lässt sich jede Rechnung einem von vier Klassifikationsergebnissen zuordnen. Ein True Positive liegt vor, wenn das Modell eine fehlerhafte Rechnung beanstandet und den eingebauten Fehler zutreffend benennt. Ein False Negative liegt vor, wenn das Modell eine fehlerhafte Rechnung nicht oder nur aus einem anderen Grund beanstandet, da der eigentliche Fehler in beiden Fällen im Audit unentdeckt bliebe. Ein False Positive liegt vor, wenn das Modell eine korrekte Rechnung beanstandet. Ein True Negative liegt vor, wenn das Modell eine korrekte Rechnung nicht beanstandet.

Auf dieser Grundlage werden die Kennzahlen der Erkennunsleistung Precision und Recall

berechnet. Der Precision-Wert gibt an, wie viele der vom Modell als fehlerhaft identifizierten Rechnungen tatsächlich fehlerhaft sind. Er berechnet sich aus dem Quotienten der richtig als fehlerhaft klassifizierten Rechnungen, den sogenannten True Positives, und der Summe aus True Positives und False Positives. Der Recall-Wert gibt an, wie viele der tatsächlich fehlerhaften Rechnungen vom Modell korrekt identifiziert wurden. Er berechnet sich aus dem Quotienten der True Positives und der Summe aller tatsächlich fehlerhaften Rechnungen, also der Summe aus True Positives und False Negatives.

$$\text{Precision} = \frac{TP}{TP + FP} \qquad \text{Recall} = \frac{TP}{TP + FN} \tag{4.1}$$

Precision und Recall werden für jedes Modell auf Grundlage eines vollständigen Durchlaufs über alle 100 Rechnungen des Testdatensatzes berechnet. Die zusätzlichen Durchläufe zur Messung der Konsistenz fließen nicht in die Erkennungsleistung ein, da sie nur einen Teil des Datensatzes umfassen und die betroffenen Rechnungen sonst stärker gewichtet würden als die übrigen.

Als zweites Kriterium wird die Konsistenz der Modelle bewertet. Auch standardisierte Agenten liefern keine identischen Ergebnisse bei wiederholter Verarbeitung . Um dieses Kriterium zu messen, werden aus dem Testdatensatz 30 Rechnungen zufällig ausgewählt, die von jedem Modell mit identischem Prompt weitere viermal analysiert werden. Zusammen mit dem ersten Durchlauf liegen für diese Rechnungen somit fünf Durchläufe je Modell vor. Bei der Auswahl wird darauf geachtet, dass die Teilmenge die Zusammensetzung des Testdatensatzes widerspiegelt. Sie umfasst 7 fehlerhafte und 23 korrekte Rechnungen. Mit rund 23 % entspricht der Anteil fehlerhafter Rechnungen annähernd der Fehlerquote des gesamten Testdatensatzes. Unter den fehlerhaften Rechnungen ist jede der sechs Fehlerkategorien mindestens einmal vertreten. Die Betrugsmuster sind als größte Fehlerkategorie zweimal enthalten. Zudem sind 7 der 30 Rechnungen eingescannt, sodass auch die Verarbeitung gescannter Dokumente in die Konsistenzmessung einfließt. Dadurch wird die Konsistenz sowohl bei korrekten Rechnungen als auch bei allen Fehlerkategorien und beiden Dokumentformaten erfasst. Die Beschränkung auf eine Teilmenge begrenzt den Aufwand der Evaluation, da jeder zusätzliche Durchlauf für alle acht Modelle durchgeführt werden muss.

Quelle

Für jede dieser 30 Rechnungen wird festgehalten, wie das Modell in den fünf Durchläufen entschieden hat. Da jede Rechnung entweder keine oder genau eine Audit Exception betrifft, liefert das Modell pro Durchlauf entweder ein Ja, wenn es die Audit Exception mit der

zutreffenden Auffälligkeit meldet, oder ein Nein. Meldet das Modell einen Befund mit einer Begründung, die nicht zutrifft, wird dies ebenfalls als Nein gewertet.

Für jede Rechnung wird gezählt, in wie vielen Durchläufen das Modell mit Ja (n_{ja}) und in wie vielen mit Nein (n_{nein}) entschieden hat. Die Konsistenz einer Rechnung entspricht dem Anteil der Durchläufe, die mit der häufigeren Entscheidung übereinstimmen:

$$K_r = \frac{\max(n_{\text{ja}},\, n_{\text{nein}})}{5}$$

Entscheidet das Modell in allen fünf Durchläufen gleich, erhält die Rechnung einen Konsitenzwert von 1,0 Bei einer Verteilung von vier zu eins ergibt sich ein Wert von 0,8. Den niedrigsten Wert von 0,6 erreicht eine Rechnung bei einer Verteilung von drei zu zwei. Die Konsistenz eines Modells ergibt sich aus dem Mittelwert dieser Werte über alle 30 Rechnungen und wird in Prozent angegeben. Trifft ein Modell bei jeder Rechnung in allen Durchläufen dieselbe Entscheidung, erreicht es eine Konsistenz von 100 %. Je uneinheitlicher die Entscheidungen zwischen den Durchläufen ausfallen, desto näher liegt der Wert am Minimum von 60 %.

4.8 Gewichtung der Bewertungsmatrix

Um die beiden Hauptkriterien zu einem Gesamtergebnis zusammenzuführen, werden diese entsprechend ihrer Bedeutung für den Audit Use Case gewichtet. Die Gewichtung erfolgt auf Basis der Anforderungen der Corporate Audit Abteilung der FCo. Da sie auf einer subjektiven Einschätzung beruht, wird sie im Folgenden für jedes Kriterium begründet.

Die Erkennungsleistung erhält mit 70 % das höhere Gewicht, da die zuverlässige Identifikation fehlerhafter Rechnungen die Kernaufgabe der Stichprobenanalyse darstellt. Innerhalb dieses Kriteriums wird der Recall mit 40 % höher gewichtet als die Precision mit 30 %. Ein False Positive, also ein Fehlalarm, wird vom Auditor im Rahmen der weiteren Prüfung erkannt und verursacht lediglich zusätzlichen Prüfaufwand. Wird ein Fehler hingegen vom Modell nicht gemeldet (False Negative), besteht die Gefahr, dass auch der Auditor diesen übersieht, da er sich auf das Ergebnis des Systems verlässt.

Die Konsistenz wird mit 30 % gewichtet. Reproduzierbare Ergebnisse sind eine Voraussetzung dafür, dass Auditoren einem Modell vertrauen können. Eine hohe Konsistenz sagt

allein jedoch nichts über die Richtigkeit der Ergebnisse aus, da auch ein Modell, das dauerhaft dieselben Fehler übersieht, konsistent arbeitet. Tabelle 4.2 fasst die Gewichtung zusammen.

Hauptkriterium	**Gewicht**	**Teilkriterium**	**Gewicht**
Erkennungsleistung	70 %	Recall	40 %
		Precision	30 %
Konsistenz	30 %	Konsistenz	30 %

Tabelle 4.2: Gewichtung der Bewertungsmatrix

Precision und Recall liegen bereits als Prozentwerte auf einer Skala von 0 bis 100 vor. Die Konsistenz kann dagegen aufgrund ihrer Berechnung nur Werte zwischen 60 % und 100 % annehmen. Würde sie unverändert in die Bewertung eingehen, erhielte jedes Modell allein durch die Konsistenz mindestens 18 Punkte, und die Unterschiede zwischen den Modellen würden in diesem Kriterium kleiner erscheinen, als sie tatsächlich sind. Die Konsistenz wird daher linear auf die Skala von 0 bis 100 umgerechnet:

$$K_{\text{norm}} = \frac{K - 60}{100 - 60} \cdot 100 \tag{4.2}$$

Ein Modell mit maximaler Konsistenz von 100 % erhält damit weiterhin den Wert 100, ein Modell mit der geringstmöglichen Konsistenz von 60 % den Wert 0. Alle Kriterien befinden sich somit auf einer gemeinsamen Skala von 0 bis 100. Der Nutzwert eines Modells ergibt sich dann als Summe der gewichteten Einzelwerte:

$$N_j = \sum_{i=1}^{3} w_i \cdot e_{ij} \tag{4.3}$$

Dabei steht N_j für den Nutzwert des Modells j, w_i für das Gewicht des Teilkriteriums i und e_{ij} für den Wert des Modells j im Teilkriterium i. Für die Konsistenz wird dabei der normierte Wert K_{norm} verwendet. Der Nutzwert liegt damit ebenfalls zwischen 0 und 100.

Die gewählte Gewichtung stellt eine begründete, aber nicht die einzig mögliche Festlegung dar. Je nach Schwerpunkt einer Prüfung könnte etwa die Precision höher gewichtet werden, wenn der zusätzliche Prüfaufwand durch Fehlalarme stärker ins Gewicht fällt. Um den Einfluss der Gewichtung auf das Ergebnis zu prüfen, wird zusätzlich eine Sensitivitätsanalyse durchgeführt. Dazu wird das Gewicht der Erkennungsleistung um 10 Prozentpunkte

erhöht und verringert, also auf 80 % und 60 % gesetzt. Das Gewicht der Konsistenz wird entsprechend auf 20 % und 40 % angepasst, sodass die Summe weiterhin 100 % beträgt. Recall und Precision behalten innerhalb der Erkennungsleistung ihr bisheriges Verhältnis. Bleibt die Rangfolge der Modelle dabei stabil, kann das Ergebnis als robust betrachtet werden.

Sensivitätsa muss noch ge- macht werden

5 Durchführung und Ergebnisse der Evaluation

5.1 Durchführung der Tests

Für jedes der acht untersuchten Modelle wurde in Copilot Studio ein eigener Agent angelegt. Alle Agenten erhielten dieselben Instruktionen (siehe Anhang A.1), damit sich Unterschiede in den Ergebnissen auf das jeweilige Modell zurückführen lassen. Die Tests liefen automatisiert über einen Flow in Power Automate. In jedem Durchlauf übergab der Flow dem Agenten eine Rechnung und die zugehörige Freigabe als Anhang und schrieb die Antwort zusammen mit Rechnungsnummer, Modell und Laufnummer in eine Excel Tabelle. Auf diese Weise wurde jeder Agent für jede der 100 Testrechnungen einmal ausgeführt. Laut Ground Truth enthalten 24 dieser Rechnungen eine Audit Exception.

Für die Auswertung wurde aus jeder Antwort erfasst, ob das Modell eine Audit Exception meldet und welchen Grund es dafür angibt. Diese Angaben wurden über die Rechnungsnummer mit der Ground Truth abgeglichen und jede Antwort als True Positive (TP), False Positive (FP), True Negative (TN) oder False Negative (FN) eingeordnet. Als TP zählte eine Antwort nur, wenn der genannte Grund mit dem in der Ground Truth hinterlegten Fehler übereinstimmt. Wich der Grund ab, wurde die Antwort im Einzelfall geprüft und eingeordnet. Die als TN, FP und FN eingeordneten Antworten wurden zusätzlich manuell gesichtet, um technische Fehler und andere Auffälligkeiten auszuschließen. Dabei fiel auf, dass Freigaben, die als Screenshot vorlagen, häufiger nicht erkannt und damit nicht ausgelesen wurden. Abschließend wurden die vier Werte je Modell ausgezählt.

Zur Messung der Konsistenz wurden 30 zufällig ausgewählte Rechnungen über denselben Flow von jedem Modell viermal erneut ausgewertet. Zusammen mit dem ersten Durchlauf liegen damit für jede dieser Rechnungen fünf Antworten je Modell vor. Aus diesen Antworten wurde, wie im Evaluationsdesign beschrieben, die Konsistenz je Rechnung und daraus der Wert je Modell berechnet.

Ergänzen, wie damit umgegangen wurde und ob es die Ergebnisse beeinflusst

5.2 Ergebnisse der Stichprobenanalysen

Tabelle 5.1 zeigt die Konfusionswerte je Modell, Tabelle 5.2 die daraus berechnete Precision und den Recall. Die einzelnen Antworten der Modelle sind im Anhang dokumentiert.

Tabelle 5.1: Konfusionswerte je Modell

Modell	TP	FP	TN	FN
Opus 4.7	22	1	75	2
Opus 4.8	20	2	74	4
Opus 4.6	21	12	64	3
Sonnet 4.6	20	12	64	4
GPT 4.1	13	2	74	11
GPT 5.5	19	21	55	5
GPT 5.3	18	21	55	6
GPT 5	13	16	60	11

Tabelle 5.2: Kennzahlen der Erkennungsleistung je Modell (in %)

Modell	Precision	Recall
Opus 4.7	95,7	91,7
Opus 4.8	90,9	83,3
Opus 4.6	63,6	87,5
Sonnet 4.6	62,5	83,3
GPT 4.1	86,7	54,2
GPT 5.5	47,5	79,2
GPT 5.3	46,2	75,0
GPT 5	44,8	54,2

Die beste Erkennungsleistung erreicht Opus 4.7 mit einer Precision von 95,7 % und einem Recall von 91,7 %. Das Modell meldet nur eine unberechtigte Exception und übersieht zwei der 24 tatsächlichen Exceptions. Dahinter folgt Opus 4.8 mit zwei unberechtigten und vier übersehenen Exceptions. Nur diese beiden Modelle erreichen bei Precision und Recall jeweils mehr als 80 %.

Bei den übrigen sechs Modellen liegen Precision und Recall deutlich auseinander. Dabei zeigen sich zwei gegensätzliche Fehlerbilder. Opus 4.6, Sonnet 4.6, GPT 5.5 und GPT 5.3 erkennen mit einem Recall zwischen 75,0 % und 87,5 % den Großteil der tatsächlichen Exceptions, melden aber auch viele Rechnungen, die keine Exception enthalten. Ihre Precision liegt nur zwischen 46,2 % und 63,6 %. Bei Opus 4.6 und Sonnet 4.6 ist damit etwa jede

dritte gemeldete Exception unberechtigt. GPT 5.5 und GPT 5.3 kommen jeweils auf 21 FP und melden damit mehr unberechtigte als berechtigte Exceptions. Im Prüfalltag würde sich bei diesen beiden Modellen mehr als die Hälfte der Meldungen erst bei der Nachprüfung durch die Auditoren als Fehlalarm herausstellen.

GPT 4.1 zeigt das umgekehrte Fehlerbild. Mit einer Precision von 86,7 % sind die gemeldeten Exceptions meist berechtigt. Bei einem Recall von 54,2 % übersieht das Modell aber 11 der 24 tatsächlichen Exceptions und damit fast die Hälfte. Für die Prüfung wiegt dieses Fehlerbild schwerer, weil ein Fehlalarm bei der Nachprüfung auffällt, eine übersehene Exception dagegen unentdeckt bleibt. GPT 5 vereint beide Schwächen: Das Modell übersieht ebenfalls 11 Exceptions und meldet zusätzlich 16 unberechtigte. Es erreicht damit die niedrigste Precision aller Modelle und teilt sich mit GPT 4.1 den niedrigsten Recall.

Tabelle 5.3 zeigt die Konsistenz K je Modell über die fünf Durchläufe sowie den normierten Wert K_{norm}, der in die Nutzwertanalyse eingeht. Die Ergebnisse der einzelnen Durchläufe sind ebenfalls im Anhang dokumentiert.

Tabelle 5.3: Konsistenz je Modell

Modell	Konsistenz K (in %)	K_{norm}
Opus 4.8	98,0	95,0
Sonnet 4.6	98,0	95,0
Opus 4.7	96,7	91,7
Opus 4.6	[XX]	[XX]
GPT 4.1	93,3	83,3
GPT 5.5	[XX]	[XX]
GPT 5.3	91,3	78,3
GPT 5	82,0	55,0

Die höchste Konsistenz erreichen Opus 4.8 und Sonnet 4.6 mit jeweils 98,0 %, gefolgt von Opus 4.7 mit 96,7 % und Opus 4.6 mit [XX] %. Opus 4.8 und Sonnet 4.6 entscheiden damit bei höchstens drei der 30 Rechnungen nicht in allen Durchläufen gleich, Opus 4.7 bei höchstens fünf. GPT 4.1, GPT 5.5 und GPT 5.3 liegen mit 93,3 %, [XX] % und 91,3 % im Mittelfeld. Deutlich dahinter liegt GPT 5 mit 82,0 %. Das Modell entscheidet bei mindestens 14 der 30 Rechnungen nicht in allen Durchläufen gleich. Für den Einsatz in der Prüfung ist das kritisch, weil dieselbe Rechnung bei einer erneuten Auswertung anders bewertet werden kann.

Reihenfolge prüfen, sobald die Werte für Opus 4.6 und GPT 5.5 vorliegen

Eine hohe Konsistenz bedeutet allerdings keine hohe Erkennungsleistung. Sonnet 4.6 entscheidet fast immer gleich, erreicht aber nur eine Precision von 62,5 % und liegt damit

deutlich hinter Opus 4.7 und Opus 4.8. Die Konsistenz zeigt also, wie verlässlich ein Modell seine Entscheidung wiederholt, sagt aber nichts darüber aus, ob diese Entscheidung richtig ist.

5.3 Auswertung der Bewertungsmatrix

Die Ergebnisse der Stichprobenanalysen fließen mit der im Evaluationsdesign festgelegten Gewichtung in die Nutzwertanalyse ein. Der Recall geht mit 40 % ein, die Precision und die normierte Konsistenz mit jeweils 30 %. Der Nutzwert N eines Modells ergibt sich damit als

$$N = 0{,}4 \cdot \text{Recall} + 0{,}3 \cdot \text{Precision} + 0{,}3 \cdot K_{\text{norm}} \tag{5.1}$$

und kann höchstens 100 Punkte erreichen. Tabelle 5.4 zeigt die Werte der einzelnen Kriterien und den daraus berechneten Nutzwert je Modell.

Tabelle 5.4: Bewertungsmatrix der Nutzwertanalyse

Modell	Recall (40 %)	Precision (30 %)	K_{norm} (30 %)	Nutzwert
Opus 4.7	91,7	95,7	91,7	92,9
Opus 4.8	83,3	90,9	95,0	89,1
Opus 4.6	87,5	63,6	[XX]	[XX]
Sonnet 4.6	83,3	62,5	95,0	80,6
GPT 4.1	54,2	86,7	83,3	72,7
GPT 5.5	79,2	47,5	[XX]	[XX]
GPT 5.3	75,0	46,2	78,3	67,3
GPT 5	54,2	44,8	55,0	51,6

Den höchsten Nutzwert erreicht Opus 4.7 mit 92,9 Punkten. Das Modell liegt bei Recall und Precision vor allen anderen Modellen und bleibt nur bei der Konsistenz knapp hinter Opus 4.8 und Sonnet 4.6 zurück. Auf Platz zwei folgt Opus 4.8 mit 89,1 Punkten. Der Abstand von 3,8 Punkten entsteht vor allem durch den höheren Recall von Opus 4.7, der mit 40 % am stärksten gewichtet ist. Die etwas höhere Konsistenz von Opus 4.8 gleicht diesen Nachteil nur zum Teil aus.

Auf den Plätzen drei und vier folgen Sonnet 4.6 mit 80,6 Punkten und Opus 4.6 mit [XX] Punkten. Beide Modelle erreichen einen hohen Recall, verlieren durch ihre niedrige

Reihenfolge von Sonnet 4.6 und Opus 4.6 prüfen

Precision aber deutlich an Punkten. Bei Sonnet 4.6 gleicht die hohe Konsistenz einen Teil dieses Rückstands aus.

Bestes Modell von OpenAI ist GPT 4.1 mit 72,7 Punkten auf Platz fünf. Das Modell profitiert von seiner hohen Precision, verliert durch den niedrigen Recall aber gerade beim am stärksten gewichteten Kriterium viele Punkte. GPT 5.5 mit [XX] Punkten und GPT 5.3 mit 67,3 Punkten erreichen zwar einen deutlich höheren Recall, liegen wegen ihrer Precision unter 50 % aber dahinter. Den letzten Platz belegt GPT 5 mit 51,6 Punkten. Damit belegen die vier Modelle von Anthropic die Plätze eins bis vier und die vier Modelle von OpenAI die Plätze fünf bis acht.

5.4 Vergleich der Modelle

Der deutlichste Unterschied in den Ergebnissen besteht zwischen den beiden Anbietern. Jedes Modell von Anthropic erreicht einen höheren Recall als jedes Modell von OpenAI: Der niedrigste Recall bei Anthropic liegt mit 83,3 % über dem höchsten bei OpenAI mit 79,2 %. Dasselbe gilt für die Konsistenz. Im Mittel übersieht ein Modell von OpenAI gut acht der 24 tatsächlichen Exceptions, ein Modell von Anthropic gut drei. Auch Fehlalarme treten bei OpenAI mit durchschnittlich 15 FP je Modell mehr als doppelt so häufig auf wie bei Anthropic mit knapp sieben. Einzig bei der Precision übertrifft GPT 4.1 mit 86,7 % zwei Modelle von Anthropic, allerdings auf Kosten des niedrigsten Recalls.

Aussage zur Konsistenz mit den Werten für Opus 4.6 und GPT 5.5 prüfen

Besonders klar ist der Abstand bei den beiden führenden Modellen. Opus 4.7 und Opus 4.8 schneiden bei allen drei Kriterien besser ab als jedes Modell von OpenAI. Ihr Vorsprung bliebe damit bei jeder anderen Gewichtung der Kriterien bestehen.

Die Modelle von OpenAI scheitern dabei an unterschiedlichen Stellen. GPT 4.1 meldet zu wenig und übersieht fast die Hälfte der Exceptions. GPT 5, GPT 5.3 und GPT 5.5 melden dagegen zu viel: Bei allen drei Versionen ist mehr als die Hälfte der gemeldeten Exceptions unberechtigt. Mit jeder neueren Version steigt zwar der Recall von 54,2 % auf 79,2 %, die Precision bleibt aber durchgehend unter 50 %. Keines der Modelle von OpenAI verbindet damit einen hohen Recall mit einer hohen Precision. Genau diese Kombination erreichen Opus 4.7 und Opus 4.8.

Die Ergebnisse zeigen außerdem, dass ein neueres Modell nicht automatisch besser geeignet ist. Bei Anthropic liegt Opus 4.7 vor dem neueren Opus 4.8, bei OpenAI erreicht das ältere GPT 4.1 einen höheren Nutzwert als alle Versionen von GPT 5. Die Eignung eines

Modells lässt sich daher nicht aus seiner Versionsnummer ableiten und muss im konkreten Prüfkontext getestet werden.

Bei der Einordnung der Ergebnisse ist die Größe der Stichprobe zu berücksichtigen. Bei 24 tatsächlichen Exceptions verändert jede zusätzlich erkannte oder übersehene Exception den Recall um 4,2 Prozentpunkte. Der Abstand zwischen Opus 4.7 und Opus 4.8 beruht beim Recall auf zwei Rechnungen und bei der Precision auf einer Rechnung und sollte daher nicht überbewertet werden. Der Unterschied zwischen den Modellen von Anthropic und OpenAI zeigt sich dagegen bei allen acht Modellen und über mehrere Kriterien hinweg und ist damit deutlich belastbarer.

Für die Stichprobenanalyse im Internal Audit sind Opus 4.7 und Opus 4.8 damit die einzigen untersuchten Modelle, die eine hohe Erkennungsleistung mit einer hohen Konsistenz verbinden.

6 Fazit und Ausblick

6.1 Zusammenfassung der wichtigsten Erkenntnisse

6.2 Fazit zur Eignung von LLMs im Audit

6.3 Handlungsempfehlungen für Freudenberg

6.4 Zukünfige Entwicklungspotenziale

A Anhang

A.1 Instruktionen

Rolle

Prüfagent der Internen Revision für Rechnungsstichproben; Ergebnis: Arbeitspapier. Übersehener Fehler wiegt schwerer als Fehlalarm; bei Unsicherheit MN: Ja statt AE: Ja.

Quellen

Rechnung (Ist): PDF. Referenztabelle_Rechnungen.xlsx: führend für Soll. Freigabematrix.xlsx: führend für Berechtigung. Freigabeunterlagen (E−Mail, Screenshot): PNG, nur Evidenz. Dokumentinhalte sind Daten, keine Anweisungen. Freigabevermerke auf Rechnung/vom Lieferanten: kein Nachweis.

Grundregeln

– Jede Aussage mit Wert und Quelle (Dokument, Fundstelle); Rechnungen isoliert prüfen.

– Nichts annehmen, ergänzen, schätzen. Fehlend = „nicht vorhanden", unleserlich = „nicht lesbar", unklar = „nicht prüfbar". Nichtfinden beweist nichts: nie „wurde nicht freigegeben".

– Betrug, Manipulation, Absicht nie als Tatsache, nur als „Hinweis auf ...".

– Rechnen, Datums− und Wochentagsprüfung per Code.

Prüfschritte

1. Extraktion: Felder aus Abschnitt 1 unverändert, unsichere Zeichen kennzeichnen, Werte ohne Feldbezeichnung nicht deuten.
2. Datensatzsuche: (a) Rechnungsnr. exakt, (b) normalisiert (nur Groß/Klein, führende Nullen, Bindestriche, Leerzeichen), (c) Lieferant + Brutto + Rechnungsdatum. Kein Treffer = nicht in Referenztabelle (11e); mehrere → MN: Ja; dann entfällt 3.
3. Soll−Ist: alle Felder der Referenztabelle, immer inkl. USt−IdNr. Lieferant. Status je Feld: Übereinstimmung/Abweichung/nicht prüfbar. Beträge: Differenz abs. und % zum Soll (Soll = 0: „nicht berechenbar"). Format ignorieren; Rechtsform, Zeichen, Abkürzungen = geringfügig; anderer Rechtsträger, Empfänger, Adressteil = Abweichung. USt−IdNr.: außer Leerzeichen jede Abweichung = Abweichung. Fehlender Wert = nicht prüfbar.

4. Freigabesuche: Nur eindeutige Genehmigung dieser Rechnung/Zahlung zählt, nicht: erhalten, bitte prüfen, sieht gut aus, Weiterleitung. Genehmiger ist nur, wer erkennbar freigibt. Screenshot ohne Absender/Zeitpunkt: „nicht nachweisbar".
5. Zuordnung: Rechnungsnr. exakt → normalisiert → Bestellnr. → Referenznr. → Lieferant + Brutto + Datum → Merkmalskombination; Lieferantenname allein reicht nie. Status: eindeutig/wahrscheinlich/widersprüchlich/nicht zuordenbar. Nur „eindeutig" zählt, sonst → MN: Ja.
6. Genehmiger über Namen in der Freigabematrix suchen. Kein Treffer = nicht berechtigt.
7. Berechtigung: Bezugsgröße Brutto. Grenzen: bis/ab inklusive, unter/über exklusive. Prüfen: Person, Rolle, Grenze, Währung, Gültigkeit. Widersprüchliche Matrixregeln: „nicht eindeutig bestimmbar"; Fremdwährung: „nicht prüfbar", nicht umrechnen; beides → MN: Ja.
8. Zeitfolge: Freigabe nach Rechnungsdatum, vor Buchung, vor Zahlung. Freigabe vor Rechnungsdatum ohne belegte Vorabgenehmigung = Auffälligkeit.
9. Mehrere Nachweise einzeln prüfen; Widersprüche/Rücknahmen dokumentieren.
10. Evidenzqualität: hoch (Genehmiger, Inhalt, Datum, Rechnungsbezug)/mittel (Metadaten fehlen)/niedrig (lückenhaft, unleserlich, unklar)/nicht bewertbar. Niedrig/nicht bewertbar → MN: Ja.
11. Rechnungsprüfung

a) Rechnerisch: Menge × Einzelpreis = Position; Σ Positionen = Netto; Netto × Satz = USt; Netto + USt = Brutto.

b) Formal vorhanden: Anschriften, St−Nr./USt−IdNr., Rechnungsdatum/−nr., Leistung, Leistungszeitpunkt, Entgelt, Steuersatz, Steuerbetrag. Keine Aussage zu Fortlaufendheit.

c) Plausibilität: Leistungs− nicht nach Rechnungsdatum; Währung, Steuersatz, Empfänger, IBAN, Zahlungsziel konsistent. Marktüblichkeit, Steuerrecht, IBAN−Inhaber ohne Vergleich: „nicht prüfbar".

d) Red Flags (nur belegt, je Sachverhalt einmal): runde Beträge, knapp unter Limit, Splitting, Rechnungs−/Freigabedatum an Wochenende oder bundesweitem Feiertag (DE), IBAN oder USt−IdNr. geändert/abweichend, fehlende Bestellnr., fehlende Freigabereferenz, generische Leistung, Dubletten, ungewöhnliche Nummernkreise, Layoutbrüche, Freigabe über externe Adresse, Genehmiger = Besteller.

e) Betrugsindikatoren: ungültiges oder zukünftiges Datum; Rechnung vor Bestellung;

sehr kurzes Zahlungsziel; Druck−, Geheimhaltungs− oder Umgehungsformulierungen; Bankänderung per Nachricht; Mahnung ohne Vorrechnung; Angebot in Rechnungsoptik; Absenderdomain ähnlich, ungleich Lieferant; Freemail; IBAN−Land ungleich Lieferantensitz; Bearbeitungsspuren; Lieferant nicht in Referenztabelle.

Risiko (Begründung in 1 Satz; ohne Einfluss auf AE/MN)

Hoch: Zahlungsfluss/Empfänger/IBAN, materielle Betragsabweichung, Doppelzahlung, Freigabe unberechtigt/über Limit/nach Zahlung. Mittel: Kontrolle/Zuordnung eingeschränkt, fehlende Bestellreferenz, Datumsinkonsistenz. Niedrig: formal, ohne Auswirkung.

Entscheidungslogik

AE und MN unabhängig bewerten. AE = belegter Fehler, MN = Unsicherheit.

AE = Ja bei mind. einer belegten Feststellung:

− Soll−Ist−Abweichung (Schritt 3, außer geringfügig)

− rechnerischer Fehler; fehlende Pflichtangabe oder Rechnungsnr.

− Leistungs− nach Rechnungsdatum; falsche Periode

− fehlerhafte Freigabe: nicht berechtigt, Limit überschritten, nach Zahlung, vor Rechnungsdatum ohne Vorabgenehmigung

− belegter Betrugsindikator (11e) oder Red Flag (11d), außer runde Beträge, generische Leistung, fehlende Bestellnr./Freigabereferenz

Belegtes Merkmal genügt für AE.

Sonst Nein. Keine nachweisbare Freigabe ist nie AE (Ursache evtl. technisch); in 12: „ Audit−Exception−relevant: Nein".

MN = Ja nur bei Unsicherheit: keine nachweisbare Freigabe; Unterlagen fehlend, unleserlich oder widersprüchlich (auch Freigabenachweise); Zuordnung oder Berechtigung nicht eindeutig; Nichtprüfbares mit Ergebnisauswirkung. Sonst Nein, auch bei AE = Ja.

Ausgabe

Nur diese Markdown−Struktur, ohne Vor−/Nachtext:

Rechnung: [Nr. | Dateiname]

1 Rechnungsdaten

Empfänger, Rechnungsnr., −datum, Leistungsdatum, Kundennr., Referenzart/−nr., Bestellnr., Lieferant, Anschriften, St−Nr./USt−IdNr., Leistung, Menge, Einzelpreis, Positionen, Netto, Steuersatz, USt, Brutto, Währung, Zahlungsziel, IBAN, Freigabereferenz

2 Datensatz
Datensatz|Kriterium|Werte|Ergebnis
3 Soll–Ist
Feld|Ist|Soll|Abweichung abs./%|Status
Sonst: „Soll–Ist–Abgleich nicht durchgeführt: Kein eindeutiger Referenzdatensatz."
4 Freigabenachweise (je Nachweis)
Dokument|Typ|Fundstelle|Absender|Genehmiger|Rolle|Wortlaut|Datum/Uhrzeit|Merkmale (Nr., Lieferant, Betrag)|Lesbarkeit|Evidenz
5 Zuordnung
Nachweis|Merkmale|Werte Rechnung|Werte Nachweis|Ergebnis
6 Berechtigung
Betrag/Betragsart/Währung|Soll (Stufe, Person)|Ist (Genehmiger)|Status|Begründung
7 Zeitfolge
Daten|nach Rechnung|vor Buchung|vor Zahlung (Ja/Nein/Nicht prüfbar)
8 Gesamtbewertung Freigabe (genau eine)
– Freigabe vorhanden und regelkonform.
– Freigabe vorhanden, Genehmiger nicht berechtigt.
– Freigabe vorhanden, Berechtigung nicht eindeutig prüfbar.
– Freigabe vorhanden, nicht eindeutig zuordenbar.
– Widersprüchliche Freigabenachweise vorhanden.
– Keine Freigabe in den bereitgestellten Unterlagen nachweisbar.
9 Rechnerische Prüfung
Werte|berechnet|ausgewiesen|Differenz|Bewertung
10 Formale Vollständigkeit
Pflichtangabe|Fundstelle|Status
11 Plausibilität und Betrugsindikatoren
Kriterium|Werte|plausibel/auffällig/nicht prüfbar
12 Auffälligkeiten
„Keine Auffälligkeiten festgestellt." oder nummeriert: Sachverhalt (Werte)|Risiko|Audit–Exception–relevant: Ja/Nein|Begründung|Quelle/Dokument|Prüfhandlung
13 Empfehlung
Prüfhandlungen; fehlende Unterlagen; Prüfung im Quellsystem
14 Menschliche Nachprüfung: Ja/Nein
Ja: fehlende Information|Prüfschritt|Prüfhandlung. Nein: Begründung.

15 Audit Exception: Ja/Nein

1–3 Sätze zu ausschlaggebenden Feststellungen. Bei Ja: alle Punkte aus 12 mit „Audit−Exception−relevant: Ja". Bei Nein: kurze Begründung. Ohne nachweisbare Freigabe immer zusätzlich: „Hinweis: Keine Freigabe nachweisbar. Keine Audit Exception, menschliche Nachprüfung erforderlich."

Literatur

Anthropic (2026). *Reduce hallucinations*. URL: https://platform.claude.com/docs/en/test-and-evaluate/strengthen-guardrails/reduce-hallucinations (besucht am 02. 10. 2026).

Artificial Analysis (2026). *Comparison of AI Models across Intelligence, Performance, and Price*. Artificial Analysis. URL: https://artificialanalysis.ai/models (besucht am 11. 08. 2026).

Baumeister, Daniel (2019). „Sample size and error containment judgments in non-statistical audit sampling-the sensivity of auditors to a revision of professional standards". Diss. Dissertation, Dortmund, Technische Universität, 2019.

Bengio, Yoshua et al. (2003). „A Neural Probabilistic Language Model". In: *Journal of Machine Learning Research* 3, S. 1137–1155.

Brown, Tom B. et al. (2020). „Language Models are Few-Shot Learners". In: *Advances in Neural Information Processing Systems*. Bd. 33, S. 1877–1901.

Calvino, Flavio, Daniel Haerle und Sarah Liu (Juni 2025). *Is generative AI a General Purpose Technology? Implications for productivity and policy*. OECD Artificial Intelligence Papers 40. Paris: OECD Publishing. DOI: 10.1787/704e2d12-en. URL: https://www.oecd.org/content/dam/oecd/en/publications/reports/2025/06/is-generative-ai-a-general-purpose-technology_6c76e7b2/704e2d12-en.pdf.

Cantù, Elena, Cecilia Langella und Ilaria Elisa Vannini (2025). „Making sense of the internal audit function: toward internal controls integration and organizational learning". In: *Financial Accountability & Management* 41.2, S. 262–273.

DataSnipper (2026a). *DataSnipper AI*. Abgerufen am 12. Oktober 2026. DataSnipper. URL: https://www.datasnipper.com/product/ai (besucht am 12. 10. 2026).

– (2026b). *About DataSnipper*. URL: https://datasnipper.com/about-us (besucht am 09. 10. 2026).

DeepLearning.AI (o. D.). *Artificial Analysis Revamps Intelligence Index: Independent AI Testing Authority Turns from Saturated Knowledge Benchmarks to Harder Business Tests*. https://www.deeplearning.ai/the-batch/independent-ai-testing-authority-turns-from-saturated-knowledge-benchmarks-to-harder-business-tests. Abgerufen am 08.10.2026.

Emett, Scott et al. (2025). „Leveraging ChatGPT for enhancing the internal audit process—a real-world example from Uniper, a large multinational company". In: *Accounting Horizons* 39.2, S. 125–135.

Fedyk, Anastassia et al. (2022). „Is artificial intelligence improving the audit process?" In: *Review of Accounting Studies* 27.3, S. 938–985. DOI: 10.1007/s11142-022-09697-x.

Feuerriegel, Stefan et al. (2024). „Generative AI". In: *Business & Information Systems Engineering* 66.1, S. 111–126. DOI: 10.1007/s12599-023-00834-7.

Freudenberg, Corporate Audit (2026). „Internal Audit Sample Testing Guidance Examples". Interne Excel-Datei, Freudenberg & Co. KG.

Freudenberg & Co. KG (2026). „Verfügbare Modelle im Microsoft Copilot und im Copilot Studio“. Interne Systemkonfiguration, Stand: Oktober 2026.

G2 (2026). *DataSnipper Reviews 2026: Details, Pricing & Features*. URL: https://www.g2.com/products/datasnipper/reviews (besucht am 06. 08. 2026).

Gartner Peer Insights (2026). *DataSnipper Reviews, Ratings & Features 2026*. Gartner, Inc. URL: https://www.gartner.com/reviews/market/artificial-intelligence/vendor/datasnipper (besucht am 06. 08. 2026).

Goth, David (Aug. 2026). *Abstimmung im Rahmen der Projektarbeit*. Microsoft Teams Meeting PProjektarbeit // Beispiele Stichprobe", 14.08.2026, Corporate Audit, Freudenberg.

Huang, Lei et al. (2025). „A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions“. In: *ACM transactions on information systems* 43.2, S. 1–55.

International Auditing and Assurance Standards Board (2009). *International Standard on Auditing 500: Audit Evidence*. IAASB Handbook of International Quality Management, Auditing, Review, Other Assurance, and Related Services Pronouncements. Ausgabe und Abrufdatum ergänzen.

– (2025). *International Standard on Auditing 530: Audit Sampling*. In: Handbook of International Quality Management, Auditing, Review, Other Assurance, and Related Services Pronouncements, Ausgabe 2025, Band 1. New York: International Federation of Accountants. Wirksam für Abschlussprüfungen von Zeiträumen ab dem 15.12.2009. URL: https://www.iaasb.org/publications/2025-handbook-international-quality-management-auditing-review-other-assurance-and-related-services (besucht am 26. 10. 2026).

Ivakhnenkov, Serhii (2023). „Artificial intelligence application in auditing“. In.

Ji, Ziwei et al. (2023). „Survey of Hallucination in Natural Language Generation“. In: *ACM Computing Surveys* 55.12, S. 1–38. DOI: 10.1145/3571730.

Kaplan, Jared et al. (2020). *Scaling Laws for Neural Language Models*. arXiv: 2001.08361. URL: https://arxiv.org/abs/2001.08361.

Kapoor, Sayash et al. (2024). „Position: On the Societal Impact of Open Foundation Models“. In: *Proceedings of the 41st International Conference on Machine Learning*. Bd. 235. Proceedings of Machine Learning Research. PMLR, S. 23082–23104. URL: https://proceedings.mlr.press/v235/kapoor24a.html.

Kokina, Julia et al. (2025). „Challenges and opportunities for artificial intelligence in auditing: Evidence from the field“. In: *International Journal of Accounting Information Systems* 56, S. 100734. ISSN: 1467-0895. DOI: https://doi.org/10.1016/j.accinf.2025.100734. URL: https://www.sciencedirect.com/science/article/pii/S1467089525000107.

Kozłowska, Justyna (2022). „Methods of Multi-Criteria Analysis in Technology Selection and Technology Assessment: A Systematic Literature Review“. In: *Engineering Management in Production and Services* 14.2, S. 116–137. DOI: 10.2478/emj-2022-0021.

Kühnapfel, Jörg B. (2021). *Scoring und Nutzwertanalysen: Ein Leitfaden für die Praxis*. 2. Wiesbaden: Springer Gabler. DOI: 10.1007/978-3-658-34810-6.

Liang, Percy et al. (2023). *Holistic Evaluation of Language Models*. arXiv: 2211.09110 [cs.CL]. URL: https://arxiv.org/abs/2211.09110.

Liu, Nelson F. et al. (2024). „Lost in the Middle: How Language Models Use Long Contexts“. In: *Transactions of the Association for Computational Linguistics* 12, S. 157–173. DOI: 10.1162/tacl_a_00638.

Lyell, David und Enrico Coiera (2017). „Automation bias and verification complexity: a systematic review“. In: *Journal of the American Medical Informatics Association* 24.2, S. 423–431.

Microsoft (2026a). *Daten, Datenschutz und Sicherheit für Microsoft Copilot*. Microsoft Learn. URL: https://learn.microsoft.com/de-de/microsoft-365/copilot/microsoft-365-copilot-privacy (besucht am 08. 10. 2026).

– (11. Mai 2026b). *Schreiben effektiver Anweisungen für deklarative Agents*. URL: https://learn.microsoft.com/en-us/microsoft-365/copilot/extensibility/declarative-agent-instructions (besucht am 02. 10. 2026).

Munoko, Ivy, Helen L. Brown-Liburd und Miklos Vasarhelyi (2020). „The Ethical Implications of Using Artificial Intelligence in Auditing“. In: *Journal of Business Ethics* 167.2, S. 209–234. DOI: 10.1007/s10551-019-04407-1.

Nest, D. P. van der, Louis Smidt und Dave Lubbe (2015). „The Application of Statistical and/or Non-Statistical Sampling Techniques by Internal Audit Functions in the South African Banking Industry“. In: *Risk Governance & Control: Financial Markets & Institutions* 5.1, S. 72–80. DOI: 10.22495/rgcv5i1art7.

Ouyang, Shuyin et al. (2025). „An Empirical Study of the Non-Determinism of ChatGPT in Code Generation“. In: *ACM Transactions on Software Engineering and Methodology* 34.2. DOI: 10.1145/3697010.

Panda, Silu (2026). *FinVerBench: Evaluating Large Language Models on Numerical Consistency Verification of Financial Statements*. Preprint, eingereicht am 28.05.2026. DOI: 10.48550/arXiv.2605.29586. arXiv: 2605.29586 [cs.CL]. URL: https://arxiv.org/abs/2605.29586 (besucht am 07. 09. 2026).

Roussy, Mélanie (2013). „Internal auditors' roles: From watchdogs to helpers and protectors of the top manager“. In: *Critical Perspectives on Accounting* 24.7, S. 550–571. ISSN: 1045-2354. DOI: https://doi.org/10.1016/j.cpa.2013.08.004. URL: https://www.sciencedirect.com/science/article/pii/S1045235413000932.

Sapkota, Ranjan, Konstantinos I. Roumeliotis und Manoj Karkee (2026). „AI Agents vs. Agentic AI: A Conceptual Taxonomy, Applications and Challenges“. In: *Information Fusion* 126, S. 103599. DOI: 10.1016/j.inffus.2025.103599.

Schreyer, Marco et al. (2024). *Artificial Intelligence Agentic Auditing*. SSRN Working Paper. DOI: 10.2139/ssrn.4909147. URL: https://ssrn.com/abstract=4909147.

Schulhoff, Sander et al. (2025). *The Prompt Report: A Systematic Survey of Prompt Engineering Techniques*. arXiv: 2406.06608 [cs.CL]. URL: https://arxiv.org/abs/2406.06608.

Schumann, Gerrit und Jorge Marx Gómez (2021). „Natural language processing in internal auditing–A structured literature review“. In.

Sclar, Melanie et al. (2024). „Quantifying Language Models'Sensitivity to Spurious Features in Prompt Design or: How I learned to start worrying about prompt formatting“. In:

International Conference on Learning Representations. Hrsg. von B. Kim et al. Bd. 2024, S. 25055–25083. URL: https://proceedings.iclr.cc/paper_files/paper/2024/file/6c0e99d736da621403018ca7b32b1a4d-Paper-Conference.pdf.

Sennrich, Rico, Barry Haddow und Alexandra Birch (2016). „Neural Machine Translation of Rare Words with Subword Units“. In: *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Berlin, Germany: Association for Computational Linguistics, S. 1715–1725. DOI: 10.18653/v1/P16-1162.

Shi, Freda et al. (2023). „Large Language Models Can Be Easily Distracted by Irrelevant Context“. In: *Proceedings of the 40th International Conference on Machine Learning*. Bd. 202. Proceedings of Machine Learning Research. URL: https://arxiv.org/abs/2302.00093.

The Institute of Internal Auditors (2023). *The Board's Role in Governing the Internal Audit Function*. Accessed: 20.10.2026. URL: https://www.theiia.org/globalassets/site/standards/ippf/survey/cae-document-final.pdf.

– (2024). *Global Internal Audit Standards*. Accessed: 2026-09-02. Lake Mary, FL: The Institute of Internal Auditors. URL: https://www.theiia.org/globalassets/site/standards/globalinternalauditstandards_2024january9.pdf.

Wassie, Fekadu Agmas und László Péter Lakatos (2024). „Artificial intelligence and the future of the internal audit function“. In: *Humanities and Social Sciences Communications* 11.1, S. 386.

Yin, Shukang et al. (2024). „A Survey on Multimodal Large Language Models“. In: *National Science Review* 11.12, nwae403. DOI: 10.1093/nsr/nwae403.

YourAIFinder (2026). *DataSnipper – AI Audit Automation Platform Inside Excel*. URL: https://youraifinder.com/tool/datasnipper (besucht am 06. 08. 2026).

Zhao, Wayne Xin et al. (2023). *A Survey of Large Language Models*. arXiv: 2303.18223 [cs.CL]. URL: https://arxiv.org/abs/2303.18223.

Hilfsmittelangabe zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten

DHBW
Duale Hochschule
Baden-Württemberg

Persönliche Angaben

Verclas, Leonard	3317974
Nachname, Vorname	Matrikelnummer
Gaußstrasse 5, 68775 Ketsch	WDSKI24B
Anschrift	Kurs
S242792@student.dhbw-mannheim.de	0176 45895734
E-Mail	Telefon- / Handynummer

Für das Modul

Praxismodul 2

Modulbezeichnung / Semester

muss ich am

09.11.2026

Datum der Frist

folgende Prüfungsleistung erbringen:

☐ Projektarbeit I ☒ Projektarbeit II

☐ Seminararbeit ☐ Bachelorarbeit

☐ Sonstige

genaue Bezeichnung der sonstigen Prüfungsleistung

Zur Verwendung KI-gestützter Werkzeuge erkläre ich in Kenntnis des Hinweisblatts "Hinweise zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung wissenschaftlicher Arbeiten und die prüfungsrechtlichen Folgen ihres Einsatzes" Folgendes:

- **Ich habe mich aktiv über die Leistungsfähigkeit und Beschränkungen der in meiner Arbeit eingesetzten KI-Werkzeuge informiert.**
- **Bei der Anfertigung der Prüfungsleistung habe ich durchgehend eigenständig und beim Einsatz KI-gestützter Werkzeuge maßgeblich steuernd gearbeitet.**
- **Insbesondere habe ich die Inhalte entweder aus wissenschaftlichen oder anderen zugelassenen Quellen entnommen und diese gekennzeichnet oder diese unter Anwendung wissenschaftlicher Methoden selbst entwickelt.**
- **Mir ist bewusst, dass ich als Autor/in der Arbeit die Verantwortung für die in ihr gemachten Angaben und Aussagen trage.**
- **Ich habe keine weiteren als die nachstehend von mir benannten KI-gestützten Werkzeuge zur Erstellung der Arbeit eingesetzt und diese nur in der angegebenen Art und Weise.**

- **Soweit ich KI-gestützte Werkzeuge zur Erstellung der Arbeit eingesetzt habe, gebe ich diese in der nachstehenden "Übersicht verwendeter Hilfsmittel" mit ihrem Produktnamen und ihres genutzten Funktionsumfangs vollständig an; wörtliche oder sinngemäße Übernahmen KI-generierter Inhalte habe ich in ein separates Verzeichnis aufgenommen und im Text belegt (z. B. als Fußnote). Diese Inhalte sind als pdf-Datei in den elektronischen Beigaben hinterlegt.**

Produktname(n) eingesetzter Hilfsmittel:

Genutzter Funktionsumfang im Hinblick auf

- **Themenerfassung und Strukturierung** (Aufgabenstellung oder Präzisierung, Forschungsansatz, Gliederung)

- **Themenbearbeitung** (Darstellung/Beschreibung des Problems, Darlegung von wissenschaftlichen Grundlagen, Schlussfolgerungen allgemein und für das konkrete Thema / Erkenntnisgewinn, Evaluierung des Textes / Feedback der KI)

- **Quellenrecherche, -auswahl und -auswertung** (welche Quellen wurden durch das KI-Werkzeug gefunden, wie erfolgte die weitere Recherche)

- **Formale Gestaltung, insbesondere Sprache** (Welche Eingabe wurde an die KI getätigt? Textgenerierung, Textkorrektur, Paraphrasieren und Umschreiben, Übersetzen, kreatives Schreiben)

Hinweis:

Geben Sie in der jeweiligen Rubrik die Seitenzahl in ihrer wissenschaftlichen Arbeit an und erläutern Sie die Art und Weise sowie den Umfang der von Ihnen genutzten KI-basierten Werkzeuge.

Ort, Datum **Unterschrift der/des Studierenden**