FREUDENBERG
INNOVATING TOGETHER

DHBW
Duale Hochschule
Baden-Württemberg
Mannheim

Duale Hochschule Baden-Württemberg Mannheim

Projektarbeit 2

Einsatz von LLMs zur Unterstützung von Stichprobenanalysen im Audit-Bereich. Ein Vergleich verschiedener KI-Modelle hinsichtlich ihrer Eignung für interne Prüfungsprozesse bei der Freudenberg Group

Studiengang Wirtschaftsinformatik

Studienrichtung Data Science und Künstliche Intelligenz

Verfasser(in):	Leonard Verclas
Matrikelnummer:	3317974
Firma:	Freudenberg & Co. Kommanditgesellschaft
Kurs:	WDSKI24B
Studiengangsleiter:	Prof. Dr. Bernhard Drabant
Wissenschaftliche(r) Betreuer(in):	Stefanie Bell
Firmenbetreuer(in):	Andreas Hass
Bearbeitungszeitraum:	03.08.2026 - 09.11.2026

Inhaltsverzeichnis

Tabellenverzeichnis **ii**

Abkürzungsverzeichnis **iii**

Kurzfassung **iv**

4 Evaluationsdesign **1**
4.6 Entwicklung einer Bewertungsmatrix 1
4.7 Gewichtung der Bewertungsmatrix 3

Literatur **6**

Tabellenverzeichnis

4.1 Gewichtung der Bewertungsmatrix 4

Abkürzungsverzeichnis

DHBW	Duale Hochschule Baden-Württemberg
FCo	Freudenberg & Co.
FN	False Negative
FP	False Positive
KI	Künstliche Intelligenz
LLM	Large Language Model
TN	True Negative
TP	True Positive

Kurzfassung

Die Stichprobenanalyse im Internal Audit erfordert die manuelle Prüfung zahlreicher Rechnungen und Freigaben und ist entsprechend zeitaufwendig. Large Language Models (LLMs) können diese dokumentenbasierte Prüfung unterstützen. Ihre Neigung zu Halluzinationen und nicht deterministischen Ausgaben wirft im Audit jedoch Fragen nach Zuverlässigkeit und Reproduzierbarkeit auf. Die vorliegende Arbeit untersucht daher, wie sich verschiedene LLMs hinsichtlich ihrer Eignung zur Unterstützung von Stichprobenanalysen im Auditbereich der Freudenberg Group (im Folgenden Freudenberg) unterscheiden.

Hierzu wurden die acht in Microsoft Copilot Studio verfügbaren Modelle von OpenAI (GPT-4.1, GPT-5, GPT-5.3, GPT-5.5) und Anthropic (Claude Sonnet 4.6, Opus 4.6, Opus 4.7, Opus 4.8) jeweils als Agent mit identischen, an den Prüfschritten des Corporate Audit ausgerichteten Instruktionen konfiguriert. Als Testdatensatz dienen 100 synthetisch erzeugte Rechnungen mit zugehörigen Freigabenachweisen. In diese wurden 24 Audit Exceptions aus sechs Fehlerkategorien eingebaut. Bewertet wurden die Modelle über eine Nutzwertanalyse mit den Kriterien Recall (40 %), Precision (30 %) und Konsistenz (30 %). Die Konsistenz wurde anhand von fünf Durchläufen über 30 Rechnungen gemessen und die Robustheit der Gewichtung über eine Sensitivitätsanalyse geprüft.

Den höchsten Nutzwert erreicht Claude Opus 4.7 mit 92,9 von 100 Punkten (Recall 91,7 %, Precision 95,7 %), gefolgt von Opus 4.8 mit 89,6 Punkten. Nur diese beiden Modelle erzielen bei Recall, Precision und Konsistenz durchgehend Werte über 80 %. Die Modelle von Anthropic belegen die Plätze eins bis vier und liegen bei Recall und Konsistenz vor allen Modellen von OpenAI, die ein unausgewogenes Fehlerbild zeigen. GPT-4.1 übersieht fast die Hälfte der Exceptions, während bei GPT-5, GPT-5.3 und GPT-5.5 mehr als die Hälfte der Meldungen unberechtigt ist. Die Rangfolge bleibt in allen Szenarien der Sensitivitätsanalyse stabil. Neuere Modellversionen schneiden dabei nicht automatisch besser ab als ältere.

Für Freudenberg wird der Einsatz von Opus 4.7 oder Opus 4.8 als Agent zur Vorprüfung empfohlen. Da auch das beste Modell nicht alle Exceptions erkennt, dienen die Ergebnisse als Entscheidungshilfe, und die abschließende Bewertung verbleibt beim Auditor.

4 Evaluationsdesign

4.6 Entwicklung einer Bewertungsmatrix

Um die Evaluation basierend auf einer Nutzwertanalyse durchzuführen, muss eine Bewertungsmatrix mit mehreren Kriterien entwickelt werden (vgl. Liang et al. 2023, S. 3). Die Bewertungsmatrix berücksichtigt die Anforderungen der Corporate Audit Abteilung der Freudenberg & Co. (FCo) und umfasst zwei Hauptkriterien: die Erkennungsleistung der Modelle und die Konsistenz der Ergebnisse. Aus der gewichteten Zusammenführung dieser Kriterien ergibt sich eine Rangfolge der untersuchten Modelle.

Eine qualitative Bewertung der Begründungen der Modelle wird nicht vorgenommen. Da der Prompt ein festes Antwortformat vorgibt, unterscheiden sich die Begründungen der Modelle in Aufbau und Formulierung nur geringfügig. Ob ein Modell den richtigen Fehler benennt, fließt zudem bereits in die Erkennungsleistung ein.

Als zentrales quantitatives Kriterium wird die Erkennungsleistung der Modelle herangezogen. Die Bewertung erfolgt auf Ebene der einzelnen Rechnung. Maßgeblich ist dabei ausschließlich das Feld „Audit Exception“ am Ende der Ausgabe des Modells. Wann das Modell eine Audit Exception meldet, ist in der Entscheidungslogik der Instruktionen festgelegt (siehe Anhang **??**). Die Empfehlung zur menschlichen Nachprüfung wird für die Bewertung nicht herangezogen, da sie keine nachgewiesene Abweichung voraussetzt. Die Erkennungsleistung wird somit ausschließlich an den Feststellungen gemessen, die das Modell anhand der Unterlagen belegen kann.

Durch den Vergleich mit den im Testdatensatz festgelegten Fehlern lässt sich jede Rechnung einem von vier Klassifikationsergebnissen zuordnen. Ein True Positive liegt vor, wenn das Modell eine fehlerhafte Rechnung beanstandet und den eingebauten Fehler zutreffend benennt. Ein False Negative liegt vor, wenn das Modell eine fehlerhafte Rechnung nicht oder nur aus einem anderen Grund beanstandet, da der eigentliche Fehler in beiden Fällen im Audit unentdeckt bliebe. Ein False Positive liegt vor, wenn das Modell eine korrekte Rechnung beanstandet. Ein True Negative liegt vor, wenn das Modell eine korrekte Rechnung nicht beanstandet.

Auf dieser Grundlage werden die Kennzahlen Precision und Recall berechnet. Die Precision gibt an, welcher Anteil der vom Modell beanstandeten Rechnungen tatsächlich fehlerhaft ist. Der Recall gibt an, welcher Anteil der tatsächlich fehlerhaften Rechnungen vom Modell korrekt erkannt wird.

$$\text{Precision} = \frac{TP}{TP + FP} \qquad \text{Recall} = \frac{TP}{TP + FN} \tag{4.1}$$

Precision und Recall werden für jedes Modell auf Grundlage eines vollständigen Durchlaufs über alle 100 Rechnungen des Testdatensatzes berechnet. Die zusätzlichen Durchläufe zur Messung der Konsistenz fließen nicht in die Erkennungsleistung ein, da sie nur einen Teil des Datensatzes umfassen und die betroffenen Rechnungen sonst stärker gewichtet würden als die übrigen.

Auf die Kennzahlen Accuracy und F1 Score wird bewusst verzichtet. Die Accuracy gibt den Anteil aller richtig eingeordneten Rechnungen an. Da der Testdatensatz mit 76 korrekten und 24 fehlerhaften Rechnungen unausgewogen ist, wird sie stark von den korrekten Rechnungen bestimmt. Ein Modell, das keine einzige Audit Exception meldet, würde bereits eine Accuracy von 76 % erreichen, obwohl es alle Fehler übersieht. Bei unausgewogenen Datensätzen ist die Accuracy daher wenig aussagekräftig (vgl. He und Garcia 2009, S. 1276 f.). Der F1 Score fasst Precision und Recall als harmonisches Mittel zu einem Wert zusammen und gewichtet beide gleich. Der Recall soll in dieser Arbeit jedoch stärker gewichtet werden als die Precision. Zudem gehen Precision und Recall bereits einzeln in die Bewertungsmatrix ein, sodass der F1 Score keine zusätzliche Information liefern würde.

Als zweites Kriterium wird die Konsistenz der Modelle bewertet. Auch standardisierte Agenten liefern bei wiederholter Verarbeitung keine identischen Ergebnisse (vgl. Atıl et al. 2025, S. 142). Zur Messung dieses Kriteriums werden 30 Rechnungen aus dem Testdatensatz ausgewählt und von jedem Modell mit identischem Prompt viermal erneut analysiert. Zusammen mit dem ersten Durchlauf liegen für diese Rechnungen somit fünf Durchläufe je Modell vor. Die Auswahl erfolgt zufällig, jedoch unter der Bedingung, dass die Teilmenge die Zusammensetzung des Testdatensatzes hinsichtlich Fehlerkategorien und Anteil gescannter Rechnungen annähernd widerspiegelt. Sie umfasst 7 fehlerhafte und 23 korrekte Rechnungen, was mit rund 23 % annähernd der Fehlerquote des gesamten Testdatensatzes entspricht. Jede der sechs Fehlerkategorien ist mindestens einmal vertreten, die Betrugsmuster als größte Kategorie zweimal. Zudem sind 7 der 30 Rechnungen eingescannt, sodass auch die Verarbeitung gescannter Dokumente in die Messung einfließt. Die Beschränkung

auf eine Teilmenge begrenzt den Aufwand der Evaluation, da jeder zusätzliche Durchlauf für alle acht Modelle durchgeführt werden muss.

Für jede dieser 30 Rechnungen wird festgehalten, wie das Modell in den fünf Durchläufen entschieden hat. Da jede Rechnung entweder keine oder genau eine Audit Exception betrifft, liefert das Modell pro Durchlauf entweder ein Ja, wenn es die Audit Exception mit der zutreffenden Auffälligkeit meldet, oder ein Nein. Meldet das Modell einen Befund mit einer Begründung, die nicht zutrifft, wird dies ebenfalls als Nein gewertet.

Für jede Rechnung wird gezählt, in wie vielen Durchläufen das Modell mit Ja (n_{ja}) und in wie vielen mit Nein (n_{nein}) entschieden hat. Die Konsistenz einer Rechnung entspricht dem Anteil der Durchläufe, die mit der häufigeren Entscheidung übereinstimmen:

$$K_r = \frac{\max(n_{\text{ja}},\, n_{\text{nein}})}{5}$$

Entscheidet das Modell in allen fünf Durchläufen gleich, erhält die Rechnung einen Konsistenzwert von 1,0. Bei einer Verteilung von vier zu eins ergibt sich ein Wert von 0,8, bei drei zu zwei der niedrigste Wert von 0,6. Die Konsistenz eines Modells ergibt sich aus dem Mittelwert dieser Werte über alle 30 Rechnungen und wird in Prozent angegeben.

4.7 Gewichtung der Bewertungsmatrix

Um die beiden Hauptkriterien zu einem Gesamtergebnis zusammenzuführen, werden diese entsprechend ihrer Bedeutung für den Audit Use Case gewichtet. Die Gewichtung erfolgt auf Basis der Anforderungen der Corporate Audit Abteilung der FCo (vgl. Goth 2026). Da sie auf einer subjektiven Einschätzung beruht, wird sie im Folgenden für jedes Kriterium begründet.

Die Erkennungsleistung erhält mit 70 % das höhere Gewicht, da die zuverlässige Identifikation fehlerhafter Rechnungen die Kernaufgabe der Stichprobenanalyse darstellt. Innerhalb dieses Kriteriums wird der Recall mit 40 % höher gewichtet als die Precision mit 30 %. Ein False Positive, also ein Fehlalarm, wird vom Auditor im Rahmen der weiteren Prüfung erkannt und verursacht lediglich zusätzlichen Prüfaufwand. Wird ein Fehler hingegen vom Modell nicht gemeldet (False Negative), besteht die Gefahr, dass auch der Auditor diesen übersieht, da er sich auf das Ergebnis des Systems verlässt.

Die Konsistenz wird mit 30 % gewichtet. Reproduzierbare Ergebnisse sind eine Voraussetzung dafür, dass Auditoren einem Modell vertrauen können. Eine hohe Konsistenz sagt allein jedoch nichts über die Richtigkeit der Ergebnisse aus, da auch ein Modell, das dauerhaft dieselben Fehler übersieht, konsistent arbeitet. Tabelle 4.1 fasst die Gewichtung zusammen.

Hauptkriterium	**Gewicht**	**Teilkriterium**	**Gewicht**
Erkennungsleistung	70 %	Recall	40 %
		Precision	30 %
Konsistenz	30 %	Konsistenz	30 %

Tabelle 4.1: Gewichtung der Bewertungsmatrix

Precision und Recall liegen bereits als Prozentwerte auf einer Skala von 0 bis 100 vor. Die Konsistenz kann dagegen aufgrund ihrer Berechnung nur Werte zwischen 60 % und 100 % annehmen. Würde sie unverändert in die Bewertung eingehen, erhielte jedes Modell allein durch die Konsistenz mindestens 18 Punkte, und die Unterschiede zwischen den Modellen würden in diesem Kriterium kleiner erscheinen, als sie tatsächlich sind. Die Konsistenz wird daher linear auf die Skala von 0 bis 100 umgerechnet:

$$K_{\text{norm}} = \frac{K - 60}{100 - 60} \cdot 100 \tag{4.2}$$

Ein Modell mit maximaler Konsistenz von 100 % erhält damit weiterhin den Wert 100, ein Modell mit der geringstmöglichen Konsistenz von 60 % den Wert 0. Alle Kriterien befinden sich somit auf einer gemeinsamen Skala von 0 bis 100. Der Nutzwert eines Modells ergibt sich dann als Summe der gewichteten Einzelwerte:

$$N_j = \sum_{i=1}^{3} w_i \cdot e_{ij} \tag{4.3}$$

Dabei steht N_j für den Nutzwert des Modells j, w_i für das Gewicht des Teilkriteriums i und e_{ij} für den Wert des Modells j im Teilkriterium i. Für die Konsistenz wird dabei der normierte Wert K_{norm} verwendet. Der Nutzwert liegt damit ebenfalls zwischen 0 und 100.

Die gewählte Gewichtung stellt eine begründete, aber nicht die einzig mögliche Festlegung dar. Um den Einfluss der Gewichtung auf das Ergebnis zu prüfen, wird zusätzlich eine

Sensitivitätsanalyse durchgeführt. Dabei wird in jedem Szenario nur eine Gewichtung verändert, während die übrigen Verhältnisse bestehen bleiben. Zunächst wird das Gewicht der Erkennungsleistung um 10 Prozentpunkte erhöht und verringert, also auf 80 % und 60 % gesetzt. Das Gewicht der Konsistenz wird entsprechend auf 20 % und 40 % angepasst. Recall und Precision behalten dabei ihr Verhältnis von 4 zu 3. Anschließend wird die Gewichtung innerhalb der Erkennungsleistung verändert, da auch die höhere Gewichtung des Recalls auf einer Einschätzung beruht. Je nach Schwerpunkt einer Prüfung könnte etwa die Precision höher gewichtet werden, wenn der zusätzliche Prüfaufwand durch Fehlalarme stärker ins Gewicht fällt. Dazu werden Recall und Precision zunächst gleich mit je 35 % gewichtet und anschließend umgekehrt mit 30 % und 40 %. Die Konsistenz bleibt in beiden Fällen bei 30 %. Bleibt die Rangfolge der Modelle in allen Szenarien gleich, gilt sie als robust gegenüber moderaten Änderungen der Gewichtung. Verändert sie sich, zeigt dies, an welcher Stelle das Ergebnis von der gewählten Gewichtung abhängt.

Literatur

Atıl, Berk et al. (2025). „Non-Determinism of "Deterministic" LLM System Settings in Hosted Environments“. In: *Proceedings of the 5th Workshop on Evaluation and Comparison of NLP Systems (Eval4NLP)*, S. 135–148. URL: https://aclanthology.org/2025.eval4nlp-1.12.

Goth, David (Aug. 2026). *Abstimmung im Rahmen der Projektarbeit*. Microsoft Teams Meeting „Projektarbeit // Beispiele Stichprobe“, 14.08.2026, Corporate Audit, Freudenberg.

He, Haibo und Edwardo A. Garcia (2009). „Learning from Imbalanced Data“. In: *IEEE Transactions on Knowledge and Data Engineering* 21.9, S. 1263–1284. DOI: 10.1109/TKDE.2008.239.

Liang, Percy et al. (2023). *Holistic Evaluation of Language Models*. arXiv: 2211.09110. URL: https://arxiv.org/abs/2211.09110.